VERI BILIMCI MUFREDATI - MODUL 9

Olasilik
Ayrintili Konu Anlatimi

Belirsizligi sayisal olarak dusunmek: kosullu olasilik, Bayes, rassal degiskenler, beklenen deger, dagilimlar, LLN/CLT ve veri bilimi uygulamalari.

Hedef: Olasilik dilini istatistik, A/B testing ve machine learning icin kullanabilir hale gelmek.
Duzey: Temel -> Orta
Odak: Kavram + sezgi + Python + gercek vaka

MOTIVASYON

1. Olasilik neden veri bilimcinin temel dilidir?

Veri bilimi, tamamen kesin olmayan sistemlerle calisir. Bir kullanicinin satin alip almayacagi, bir modelin tahmininin dogru olup olmayacagi, bir A/B testindeki farkin tesadufen ortaya cikmis olup olmadigi veya bir fraud alarmindan sonra islemin gercekten fraud olma ihtimali gibi sorularin hepsi olasilik diline dayanir.

Olasilik bize ne verir?

- Belirsizligi 0 ile 1 arasinda ifade etme
- Yeni kanit geldikce inanci guncelleme
- Beklenen getiri ve riski birlikte dusunme
- Orneklemden anakitle hakkinda cikarim yapma

Data Science baglantisi

- Classification modeli: P(y=1|x)
- A/B test: fark tesaduf mu?
- Forecast: gelecegin olasilik dagilimi
- Bayes: kanit sonrasi posterior

Ana fikir: Veri biliminde tek bir tahminden cok, tahminin ne kadar belirsiz oldugunu anlamak onemlidir.

2. Deney, ornek uzay ve olay

Rassal deney, sonucu onceden kesin bilinmeyen fakat olasi sonuclari tanimlanabilen surectir. Bir zar atmak, bir kullanicinin reklama tiklayip tiklamamasi veya bir islemin fraud olup olmamasi buna ornektir.

Kavram	Tanim	Ornek
Ornek uzay (S)	Butun olasi sonuclar	Zar: {1,2,3,4,5,6}
Olay (A)	Ornek uzayin bir alt kumesi	Cift gelmesi: {2,4,6}
Tumleyen (A^c)	A'nin olmadigi sonuclar	Tek gelmesi
Kesisim (A ∩ B)	A ve B birlikte	Cift ve 4'ten buyuk
Birlesim (A ∪ B)	A veya B	Cift veya 4'ten buyuk

```
0 <= P(A) <= 1 | P(S) = 1 | P(A^c) = 1 - P(A)
```

Toplama kurali

```
P(A ∪ B) = P(A) + P(B) - P(A ∩ B)
```

Iki olay birbirini disliyorsa kesisim sifirdir ve toplam dogrudan P(A)+P(B) olur.

3. Kosullu olasilik

Kosullu olasilik, **bir bilgiye sahip olduktan sonra** olay olasiligini yeniden hesaplamaktir. Veri biliminde en onemli dusunme bicimlerinden biridir.

```
P(A | B) = P(A ∩ B) / P(B), P(B) > 0
```

Mini ornek

100 kullanicinin 40'i mobilden geliyor, 12 mobil kullanici satin alim yapiyor. Mobil oldugu bilinen bir kullanicinin satin alma olasiligi:

```
P(Purchase | Mobile) = 12 / 40 = 0.30 = %30
```

> **Is yorumu:** P(Purchase) ile P(Purchase|Mobile) ayni sey degildir. Segment bilgisi geldikce referans grubun degisir.

Carpim kurali

```
P(A ∩ B) = P(A | B) * P(B)
```

4. Bagimsizlik ve bagimli olaylar

A olayi hakkinda bilgi sahibi olmak B'nin olasiligini degistirmiyorsa olaylar bagimsizdir.

```
Bagimsizlik: P(A | B) = P(A) ve P(A ∩ B) = P(A)P(B)
```

Durum	Yorum
Iki farkli adil para atisi	Ilk atis ikinci atisin sonucunu degistirmez.
Sepete ekleme ve satin alma	Genellikle bagimlidir; sepete ekleyenlerde satin alma ihtimali daha yuksektir.
Replacement olmadan kart cekme	Ilk cekis destenin kompozisyonunu degistirdigi icin bagimlidir.

> **Sik hata:** “Korelasyon yok” demek “bagimsiz” demek degildir. Bagimsizlik daha guclu bir kosuldur.

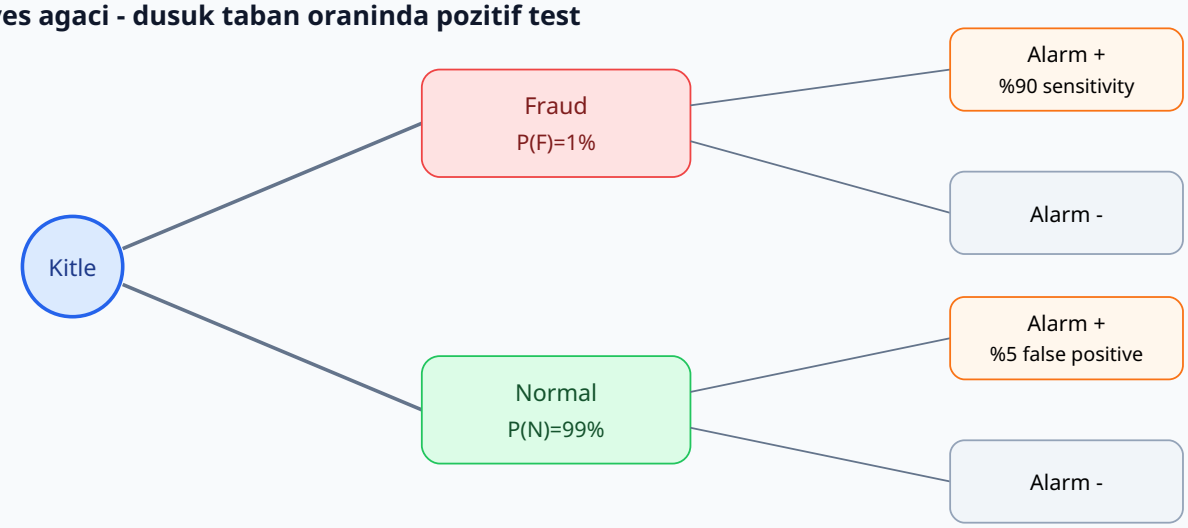
5. Bayes Teoremi

Bayes teoremi, gozlenen kanitin bir hipotez hakkindaki inancimizi nasil guncellemesi gerektigini soyler.

```
P(A | B) = [P(B | A) * P(A)] / P(B)
```

Terim	Anlam
P(A)	Prior - kanit oncesi inanc
P(B|A)	Likelihood - A dogruysa kanitin olasiligi
P(B)	Evidence - kanitin toplam olasiligi
P(A|B)	Posterior - kanit sonrasi guncellenmis inanc

Bayes agaci - dusuk taban oraninda pozitif test



Fraud ornegi

Fraud orani %1, fraud islemlerinin %90'i alarm veriyor, normal islemlerin %5'i yanlis alarm veriyor.

```
P(Fraud | Alarm+) = (0.90*0.01) / [(0.90*0.01)+(0.05*0.99)] ≈ 0.154
```

Alarm pozitif olsa bile gercek fraud ihtimali yaklasik **%15.4**'tur. Bunun nedeni fraud'un taban oraninin cok dusuk olmasidir.

> **Base-rate fallacy:** Sensitivity yuksek diye posterior olasiligin da otomatik olarak yuksek olacagini varsayma.

6. Sayma teknikleri: permutasyon ve kombinasyon

Olasilik problemlerinde kac farkli sonuc oldugunu saymak gerekir. Siralama onemliyse permutasyon, sadece secim onemliyse kombinasyon kullanilir.

Permutasyon

```
P(n,r) = n! / (n-r)!
```

10 adaydan baskan ve baskan yardimcisi secmek: siralar farklidir.

Kombinasyon

```
C(n,r) = n! / [r!(n-r)!]
```

10 adaydan 2 kisilik ekip secmek: sira onemsizdir.

Binomial dagiliminin formulu kombinasyon mantigi uzerine kurulur.

7. Rassal degiskenler

Rassal degisken, rassal deney sonucunu sayisal bir degere esleyen fonksiyondur. Buyuk harf (X) degiskeni, kucuk harf (x) gerceklesen degeri ifade eder.

Tur	Aciklama	Ornek
Discrete	Sayilabilir degerler	Bir gundeki siparis sayisi
Continuous	Aralikta sonsuz deger	Teslimat suresi, gelir

PMF, PDF ve CDF

- **PMF**: discrete degiskenin belirli deger alma olasiligi.
- **PDF**: continuous degiskenin yogunluk fonksiyonu. Tek bir noktadaki olasilik degil, alan olasilik verir.
- **CDF**: P(X <= x). Hem discrete hem continuous icin kullanilabilir.

```
F(x) = P(X <= x)
```

8. Beklenen deger, varyans ve standart sapma

Beklenen deger, rassal bir degiskeni cok uzun sure tekrar gozlemledigimizde ortalama olarak nereye yaklasacagimizi ifade eder.

```
E[X] = Σ x * P(X=x) (discrete)
```

Varyans, degerlerin ortalama etrafindaki yayilimini; standart sapma ise bunun degiskenin orijinal birimindeki karsiligini olcer.

```
Var(X) = E[(X - E[X])^2] = E[X^2] - (E[X])^2
```

```
SD(X) = sqrt(Var(X))
```

Beklenen is degeri

Bir kampanya %8 olasilikla 500 TL ek kar, %92 olasilikla 20 TL maliyet olusturuyorsa:

```
EV = 0.08*500 + 0.92*(-20) = 21.6 TL
```

Tekil sonuc belirsizdir fakat uzun donemli kararlar icin beklenen deger kullanislidir.

9. Kovaryans ve korelasyon

Kovaryans iki rassal degiskenin birlikte nasil hareket ettigini olcer. Korelasyon ise kovaryansi olcekten bagimsiz hale getirir.

```
Cov(X,Y) = E[(X-E[X])(Y-E[Y])]
```

```
Corr(X,Y) = Cov(X,Y) / (SD(X)*SD(Y))
```

Deger	Yorum
Corr ≈ +1	Guclu pozitif dogrusal iliski
Corr ≈ 0	Dogrusal iliski zayif/yok; baska tur iliski olabilir
Corr ≈ -1	Guclu negatif dogrusal iliski

> **Hatirla:** Korelasyon nedensellik degildir. Ortak neden (confounder), selection bias veya zaman trendi iliski uretebilir.

10. Bernoulli ve Binomial dagilimi

Bernoulli

Tek deneme, iki sonuc: 0/1.

```
X ~ Bernoulli(p)
```

E[X]=p, Var(X)=p(1-p)

Binomial

n bagimsiz Bernoulli denemesinde basari sayisi.

```
X ~ Binomial(n,p)
```

E[X]=np, Var(X)=np(1-p)

Data Science ornegi

Conversion orani %4 olan bir landing page'e 100 kullanici geliyorsa beklenen satin alim sayisi 4'tur. Ancak her gun tam 4 satin alim olmak zorunda degildir; binomial dagilim bu oynakligi modeller.

```
from scipy.stats import binom

# 100 kullanicidan en az 7 conversion olasiligi
p = 1 - binom.cdf(6, n=100, p=0.04)
print(p)
```

11. Geometrik ve Poisson dagilimi

Dagilim	Ne modeller?	Tipik kullanim
Geometrik	Ilk basariya kadar gereken deneme sayisi	Ilk purchase'a kadar ziyaret
Poisson	Belirli araliktaki olay sayisi	Dakikadaki ticket, saatteki siparis

```
Poisson: P(X=k) = e^(-λ) * λ^k / k!
```

Poisson icin temel sezgi: olaylar belirli bir ortalama hizla ve yaklasik bagimsiz gerceklesiyorsa, sabit zaman penceresindeki sayiyi modellemek icin kullanisli olabilir.

> **Kontrol:** Gercek veride overdispersion (varyans >> ortalama), gun/saat etkileri veya bagimlilik varsa saf Poisson yetersiz kalabilir.

12. Uniform ve Exponential dagilim

Uniform

Bir araliktaki degerlerin esit yogunluga sahip oldugu model.

```
X ~ Uniform(a,b)
```

E[X]=(a+b)/2

Exponential

Poisson tipi olaylar arasindaki bekleme suresini modellemek icin klasik dagilim.

```
f(x)=λe^(-λx), x>=0
```

E[X]=1/λ

Exponential dagilim **memoryless** ozelligine sahiptir: ne kadar bekledigimiz, kalan bekleme suresinin dagilimini degistirmez. Gercek sistemlerde bu varsayim her zaman uygun degildir.

13. Normal dagilim

Normal dagilim, istatistikte merkezi bir role sahiptir. Bunun sebebi her verinin normal olmasi degil; cok sayida bagimsiz kucuk etkinin toplami ve orneklem ortalamalarinin davranisi ile yakindan iliskili olmasidir.

```
X ~ N(mu, sigma^2)
```



Aralik	Yaklasik kitle
mu ± 1 sigma	%68
mu ± 2 sigma	%95
mu ± 3 sigma	%99.7

Z-score

```
z = (x - mu) / sigma
```

Z-score, bir degerin ortalamadan kac standart sapma uzakta oldugunu ifade eder.

14. Buyuk Sayilar Kanunu (LLN)

Buyuk Sayilar Kanunu, bagimsiz ve benzer kosullardaki gozlemlerin orneklem ortalamasinin, orneklem buyudukce beklenen degere yaklasacagini soyler.

```
X_bar_n -> E[X] (n buyudukce)
```

Sezgi

Adil bir parayi 10 kez attiginda tura orani %70 olabilir. 100.000 kez attiginda oranin %50'ye cok daha yakin olmasini beklersin.

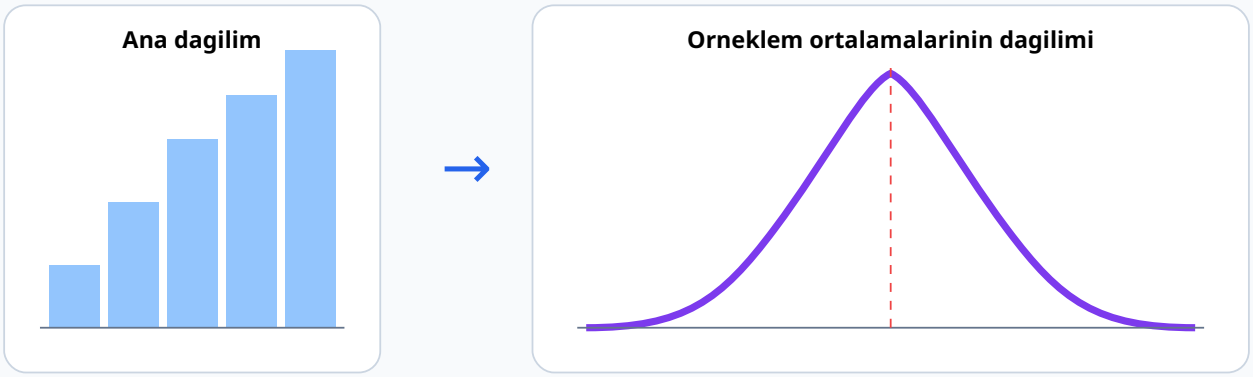
> **Is baglantisi:** Kucuk segmentlerde KPI'lar cok oynak olabilir. Buyuk orneklem daha kararlidir ama bias'i otomatik olarak cozmez.

15. Merkezi Limit Teoremi (CLT)

Belirli kosullarda, anakitle dagilimi normal olmasa bile yeterince buyuk orneklemlerin ortalamalarinin dagilimi yaklasik normal olur.

```
X_bar ≈ Normal(mu, sigma^2 / n)
```

Merkezi Limit Teoremi: orneklem ortalamalari normallesecek sekilde toplanir



Standart hata:

```
SE(X_bar) = sigma / sqrt(n)
```

CLT; confidence interval, hypothesis test ve A/B testing gibi istatistiksel yontemlerin temel sezgisidir.

16. Birlesik, marjinal ve kosullu dagilimlar

Birden fazla degiskeni birlikte modelledigimizde joint distribution kavrami ortaya cikar.

```
Joint: P(X=x, Y=y)
```

Joint dagilimdan diger degiskeni toplayarak/integral alarak **marjinal** dagilima, belirli bir degere kosullayarak **kosullu** dagilima ulasiriz.

Data Science sorusu	Olasilik ifadesi
Genel churn orani	P(Churn)
Premium kullanicilarin churn orani	P(Churn | Premium)
Premium ve churn birlikte	P(Churn ∩ Premium)

17. Law of Total Probability ve Bayes zinciri

Bir olayin olasiligini, birbirini dislayan ve tum uzayi kapsayan segmentler uzerinden hesaplayabiliriz.

```
P(B) = Σ_i P(B | A_i)P(A_i)
```

Ornek

Trafik %60 mobile, %40 desktop. Mobile conversion %3, desktop %6 ise:

```
P(Purchase) = 0.60*0.03 + 0.40*0.06 = 0.042 = %4.2
```

Bu kural Bayes'in paydasini hesaplamak icin de kullanilir.

18. Monte Carlo simulasyonu

Analitik cozum zor oldugunda, olasilik sistemini bilgisayarda cok kez taklit ederek tahmin yapabiliriz. Buna Monte Carlo simulasyonu denir.

```
import numpy as np

rng = np.random.default_rng(42)

# Conversion p=0.04, her deneyde 1000 kullanici
runs = rng.binomial(n=1000, p=0.04, size=50_000)

print(runs.mean())
print(np.quantile(runs, [0.025, 0.975]))
```

Kullanim alanlari: Risk analizi, fiyatlama, capacity planning, expected value, Bayesian computation, forecast uncertainty.

19. Olasilik ve Machine Learning

ML kavrami	Olasilik baglantisi
Logistic Regression	P(y=1|x) tahmini
Naive Bayes	Bayes teoremi + kosullu bagimsizlik varsayimi
Cross-entropy / Log-loss	Tahmin edilen olasiliklara kayip atar
Calibration	%80 tahmin edilen olaylar gercekte yaklasik %80 mi?
Likelihood	Parametreler verildiginde gozlenen verinin olasiligi/yogunlugu
Bayesian ML	Parametreler icin prior -> posterior guncellemesi

Modeli sinif etiketi veren makine olarak degil, belirsizligi puanlayan sistem olarak dusun. Threshold daha sonra is maliyetine gore secilebilir.

20. Gercek vaka: Fraud alarm sistemi

Problem

Bir odeme sistemi islemleri “fraud olabilir” diye isaretliyor. Ekip alarm precision'inin dusuk oldugunu goruyor.

Verilenler

- Fraud prevalence: %0.8
- Sensitivity: %92
- False positive rate: %3
- Gunluk 500.000 islem

Adim 1 - Beklenen sayilar

```
Fraud = 500,000*0.008 = 4,000 True Positive = 4,000*0.92 = 3,680 Normal =
496,000 False Positive = 496,000*0.03 = 14,880
```

Adim 2 - Alarm sonrasi fraud olasiligi

```
Precision = 3,680 / (3,680+14,880) ≈ 19.8%
```

Adim 3 - Is karari

Alarm veren her islemi bloklamak ciddi musteri kaybina yol acabilir. Cozum; risk skoruna gore threshold, ek dogrulama, segment bazli modeller veya maliyet-duyarli karar olabilir.

> **Data Scientist bakisi:** “Model %92 sensitivity” tek basina yeterli bilgi degildir. Base rate, false positive maliyeti ve posterior probability birlikte degerlendirilmelidir.

21. Python ile olasilik: NumPy + SciPy kaliplari

```
import numpy as np
from scipy import stats

rng = np.random.default_rng(42)

# Bernoulli / Binomial
x = rng.binomial(n=1, p=0.3, size=10_000)
print(x.mean())

# Normal dagilimdan ornek
samples = rng.normal(loc=100, scale=15, size=50_000)

# P(X <= 120)
p = stats.norm.cdf(120, loc=100, scale=15)

# Binomial: tam 5 basari
p5 = stats.binom.pmf(5, n=20, p=0.2)

# Poisson: saatte ortalama 4 olay, en az 7 olay
p7plus = 1 - stats.poisson.cdf(6, mu=4)

# Quantile
q95 = np.quantile(samples, 0.95)
```

Not: Kodda rastgelelik icin modern NumPy Generator API'sini ve reproducibility icin sabit seed kullanmak iyi pratiktir.

22. Sik yapilan hatalar

Hata	Neden sorun?	Duzeltme
P(A|B) ile P(B|A)'yi karistirmak	Base-rate yanilgisi yaratir	Bayes agaci veya contingency table kur
Bagimsizlik varsayimini kontrol etmemek	Carpim kurali yanlis uygulanir	Sureci/domain'u incele
PDF degerini olasilik sanmak	Continuous degiskende nokta olasiligi sifirdir	Alan/integral dusun
Beklenen degeri garanti sonuc sanmak	Tek deneme oynak olabilir	Varyans ve quantile da raporla
Normal dagilimi her seye zorlamak	Heavy tail / skew gozden kacar	Dagilimi ve domain'i kontrol et
Korelasyonu nedensellik sanmak	Yanlis aksiyonlara yol acar	Deney / causal design

23. Mulakat sorulari

1) P(A|B) ile P(B|A) arasindaki fark nedir?

Referans gruplari farklidir. Bayes teoremi ikisini prior ve evidence ile birbirine baglar.

2) Iki olay ne zaman bagimsizdir?

$P(A \cap B)=P(A)P(B)$ ise; esdeger olarak B bilgisi A olasiligini degistirmiyorsa.

3) LLN ile CLT farki?

LLN orneklem ortalamasinin beklenen degere yaklasmasini, CLT ise orneklem ortalamasinin dagiliminin normallesecegini anlatir.

4) Normal dagilim neden onemli?

Bir cok toplamsal surecte dogal olarak gorunur ve CLT sayesinde orneklem ortalamalarinda merkezi rol oynar.

5) Accuracy yuksek ama fraud modeli kotu olabilir mi?

Evet. Fraud cok nadirse tum islemleri “normal” demek bile yuksek accuracy verebilir. Posterior, precision/recall ve maliyetler incelenmelidir.

6) Expected value ne zaman yeterli degildir?

Risk/asimetri buyukse varyans, quantile, tail risk ve utility de gerekir.

24. Alistirmalar

1. Bir e-ticaret sitesinde mobil trafik %70, desktop %30; conversion sirasiyla %2.5 ve %5.0. Genel conversion'i hesapla.
2. Bir fraud modelinde prevalence %0.5, sensitivity %95, false positive %2. Alarm pozitif oldugunda fraud olasiligini Bayes ile bul.
3. 20 bagimsiz kullanicinin her biri %10 ihtimalle purchase yapiyor. Tam 3 purchase olasiligini hesapla.
4. Saatte ortalama 6 ticket gelen sistemde bir saatte 10 veya daha fazla ticket gelme olasiligini SciPy ile hesapla.
5. Bir dagilimin ortalamasi 80, std 12. x=104 icin z-score hesapla.
6. 10, 100, 1000 ve 10000 Bernoulli denemesi simule edip sample mean'in p'ye yaklasmasini goster.
7. Exponential dagilimdan 100.000 bekleme suresi simule et; ortalamanin 1/lambda'ya yaklasmasini kontrol et.
8. Bir regression probleminde target heavy-tailed ise normal varsayiminin nerede risk yaratabilecegini acikla.

25. Final cheat sheet ve sonraki adim

Kavram	Hatirlanacak ifade
Tumleyen	P(A^c)=1-P(A)
Toplama	P(A∪B)=P(A)+P(B)-P(A∩B)
Kosullu	P(A|B)=P(A∩B)/P(B)
Bagimsizlik	P(A∩B)=P(A)P(B)
Bayes	P(A|B)=P(B|A)P(A)/P(B)
Beklenen deger	E[X]=ΣxP(X=x)
Varyans	Var(X)=E[X^2]-(E[X])^2
Standart hata	SE=σ/sqrt(n)

Bil

Kosullu olasilik, Bayes, expectation, variance, dagilimlar.

Uygula

NumPy/SciPy ile PMF, CDF, quantile ve simulasyon.

Bagla

Istatistik, A/B testing ve ML probability output.

Hazirsan sonraki temel halka: Modül 10 - Istatistik. Olasilik “modeli/dili” verir; istatistik gozlenen veriden bilinmeyen parametreler hakkinda cikarim yapar.