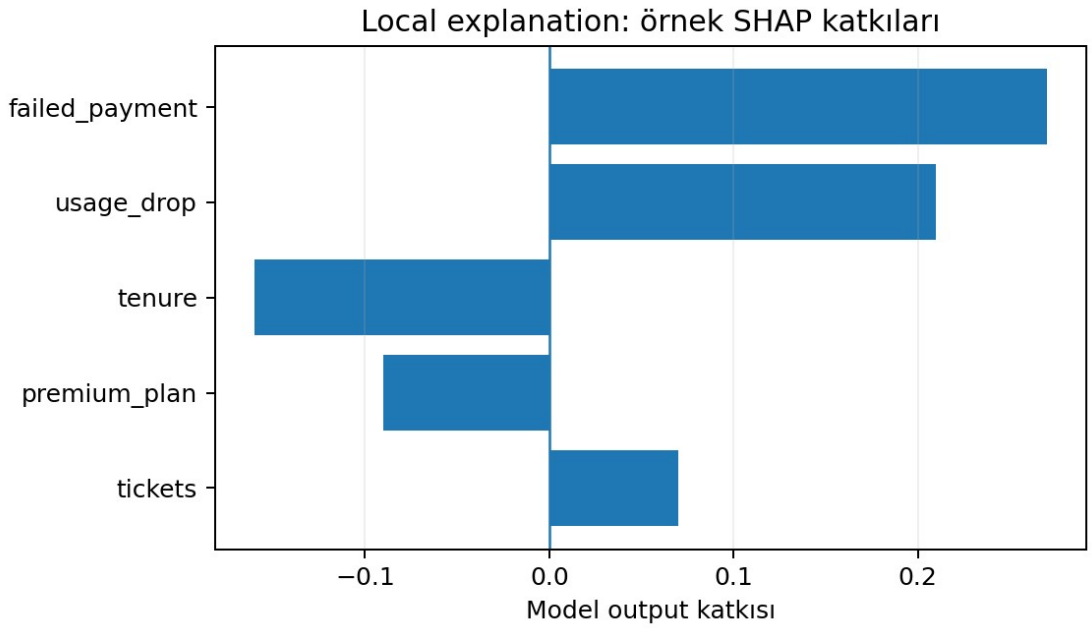
# 24. EXPLAINABLE AI

## Feature Importance • Permutation Importance • SHAP • PDP • ICE




**Bu modülün amacı**
Bir modelin neden belirli tahmini yaptığını farklı seviyelerde açıklamak; global ve local açıklamaları ayırmak; açıklama yöntemlerinin sınırlarını bilmek ve açıklamayı nedensellikle karıştırmamak.

| Kazanım | Modül sonunda |
|---|---|
| Global açıklama | Model genelinde hangi feature ailelerinin önemli olduğunu analiz edebilirsin. |
| Local açıklama | Tek bir tahminde hangi feature katkılarının skoru artırıp azalttığını okuyabilirsin. |
| Yöntem seçimi | Feature importance, permutation importance, SHAP, PDP ve ICE arasındaki farkları bilirsin. |
| Risk farkındalığı | Correlation, leakage, extrapolation ve causal yorum hatalarını tanırsın. |
| İletişim | Teknik açıklamayı iş paydaşına karar odaklı sunabilirsin. |

# 1. Explainable AI nedir?

Explainable AI (XAI), model davranışını insanlar için anlaşılır hale getiren yöntemler bütünüdür. Amaç yalnızca güzel grafik üretmek değil; modelin neye dayandığını sorgulamak, hata kaynaklarını bulmak, güven ve denetim sağlamaktır.

| Soru | XAI cevabı |
|---|---|
| Model genel olarak neye bakıyor? | Global explanation |
| Bu müşteri neden riskli çıktı? | Local explanation |
| Feature artınca tahmin nasıl değişiyor? | PDP / ICE |
| Feature çıkarılırsa performans ne kadar düşüyor? | Permutation importance |
| Bu tahmine hangi feature ne kadar katkı yaptı? | SHAP benzeri attribution |

**Açıklama != doğruluk**
Bir model çok iyi açıklanabilir ama kötü tahmin yapabilir; çok iyi tahmin yapan model de yanlış explanation ile yanlış anlaşılabilir.

# 2. Global vs local explanations

| Tür | Odak | Örnek |
|---|---|---|
| Global | Tüm model davranışı | Feature importance, PDP |
| Local | Tek tahmin | SHAP waterfall, local surrogate |
| Cohort | Belirli segment | Segment SHAP/PDP |
| Counterfactual | Ne değişirse karar değişir? | Gelir +X olsaydı onay |

**İş kullanımı**
Risk ekibi global açıklamayla policy öğrenmek isterken müşteri temsilcisi tek bir kararın local açıklamasına ihtiyaç duyabilir.

## 3. Intrinsic vs post-hoc explainability

| Yaklaşım | Örnek | Artı / eksi |
|---|---|---|
| Intrinsic | Linear/logistic regression, küçük tree | Model yapısı doğrudan okunabilir; esneklik sınırlı olabilir. |
| Post-hoc | SHAP, permutation importance, PDP | Karmaşık modelleri açıklar; açıklama yaklaşık/model-dependent olabilir. |

**Basit model her zaman yeterli değil**
Regülasyon veya karar maliyeti yüksek olduğunda performans-açıklanabilirlik dengesi açıkça değerlendirilmelidir.

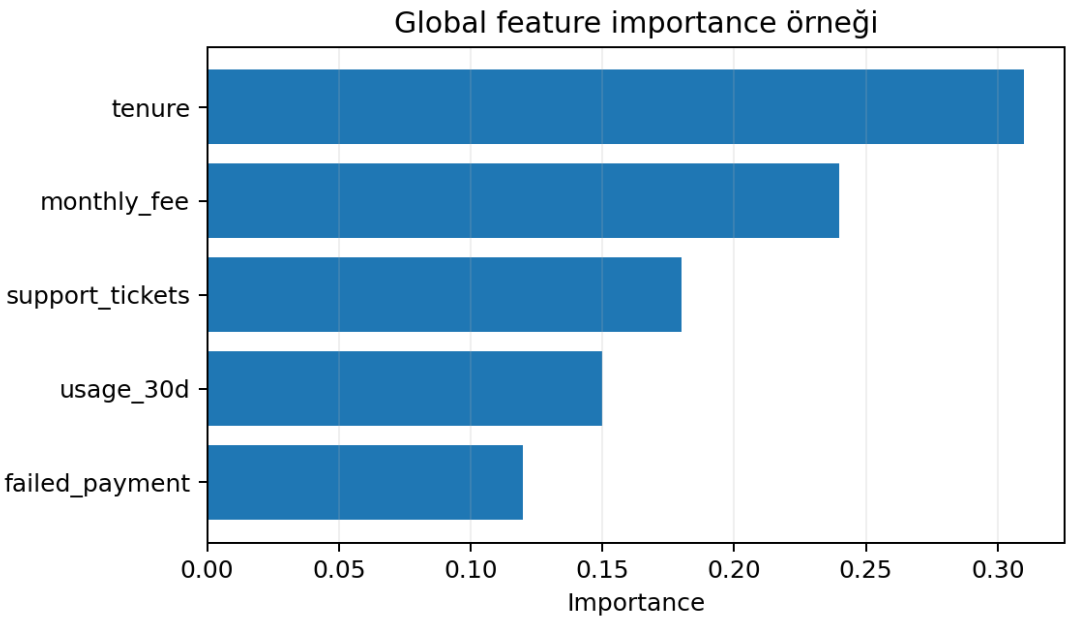
## 4. Linear model coefficient açıklaması

Linear ve logistic modellerde katsayılar doğal açıklama kaynağıdır. Ancak feature scale, interaction, multicollinearity ve encoding nedeniyle dikkatli yorum gerekir.

- Standardized coefficient büyüklükleri daha karşılaştırılabilir olabilir.
- Logistic regression coefficient log-odds üzerindedir.
- Correlated feature varsa coefficient kararsızlaşabilir.

**Katsayı nedensellik değildir**
Coefficient koşullu ilişkiyi temsil eder; confounding giderilmediyse causal etki değildir.

## 5. Tree feature importance




Decision tree ve ensemble modeller impurity reduction tabanlı feature importance sağlayabilir.

| Avantaj | Risk |
|---|---|
| Hızlı ve model içinde hazır | High-cardinality feature kayırabilir |
| Global özet verir | Correlated feature importance paylaşabilir |

## 6. Permutation Importance

Bir feature değerlerini karıştırıp model performansının ne kadar bozulduğunu ölçer. Feature gerçekten model için yararlıysa permutation sonrası skor düşer.

```
from sklearn.inspection import permutation_importance

r = permutation_importance(
    model, X_valid, y_valid,
    scoring="roc_auc",
    n_repeats=20,
    random_state=42
)
```

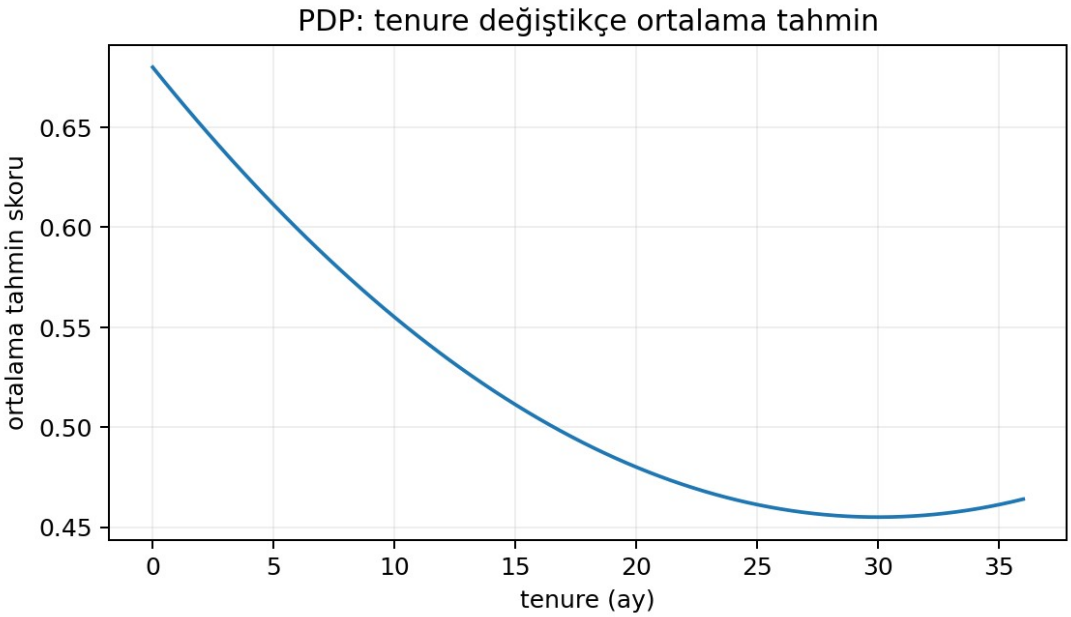
**Validation üzerinde hesapla**
Training permutation importance overfit sinyalini önemli gösterebilir. Açıklamayı unseen validation/test veride yapmak daha anlamlıdır.

## 7. Correlated feature problemi

İki feature aynı bilgiyi taşıyorsa birini permute ettiğinde diğeri sinyali koruyabilir; importance düşük görünebilir.

**Çözüm fikirleri**
Correlation kümeleri, feature-family ablation, grouped permutation veya domain tabanlı birlikte yorumlama kullan.

# 8. PDP - Partial Dependence Plot




PDP bir feature değerini sistematik değiştirip diğer gözlemler üzerinden model tahmininin ortalama nasıl değiştiğini gösterir.

**Risk**
Feature diğer featurelarla güçlü korelasyonluysa PDP veri manifoldunun dışında gerçek dışı kombinasyonlar yaratabilir.

## 9. ICE - Individual Conditional Expectation

ICE, PDP ortalamasının arkasındaki bireysel eğrileri gösterir. Farklı müşteri segmentlerinin aynı feature değişimine farklı tepki verdiğini ortaya çıkarabilir.

**Interaction keşfi**
ICE eğrileri paralel değilse feature etkisi başka featurelara bağlı olabilir.

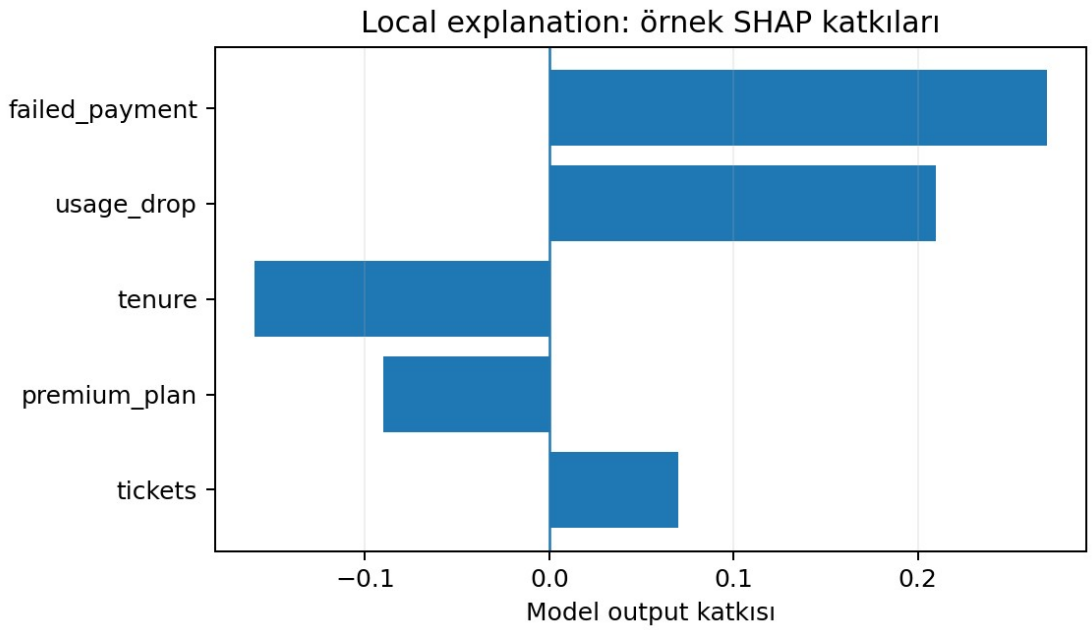
## 10. ALE - Accumulated Local Effects

ALE, correlated feature problemlerinde PDP'ye alternatif olabilir. Yerel veri bölgelerindeki değişimi biriktirerek daha gerçekçi etki tahmini amaçlar.

**Ne zaman?**
Strongly correlated tabular feature'larda PDP şüpheli görünüyorsa ALE düşünülebilir.

## 11. SHAP nedir?

SHAP, cooperative game theory'deki Shapley value fikrini model attribution için kullanır. Bir tahmini baseline'dan model çıktısına taşıyan feature katkılarını paylaştırır.




**Local açıklama**
Pozitif SHAP değeri model output'unu artırır, negatif değer azaltır. İşaret target/class tanımına bağlıdır.

## 12. SHAP additive decomposition

Temel fikir: model output ≈ base value + feature katkılarının toplamı.

```
# Kavramsal:
model_output = base_value + shap_1 + shap_2 + ... + shap_p
```

**Output scale**
TreeExplainer/logistic model ayarına göre SHAP değerleri probability, margin veya log-odds scale'de olabilir. Grafiği yorumlamadan önce output türünü bil.

## 13. SHAP global summary

- Mean absolute SHAP: global importance.
- Beeswarm: importance + direction + distribution.
- Dependence plot: feature değeri vs SHAP contribution.
- Cohort comparison: segmentler arası explanation farkı.

**Global SHAP**
Global önem, local attributionların toplulaştırılmasıdır; yine causal etki değildir.

## 14. TreeSHAP ve model-specific explainers

| Model | Yaklaşım |
|---|---|
| Tree models | TreeSHAP hızlı/uygun |
| Linear models | Linear explainer |
| Arbitrary black-box | Kernel/model-agnostic yöntemler |
| Deep networks | Deep-specific approximations / gradient methods |

**Maliyet**
Model-agnostic SHAP büyük veri ve çok feature'da pahalı olabilir; sampling gerekebilir.

## 15. LIME

LIME, tek bir tahminin çevresinde sentetik komşular üretip basit local surrogate model fit eder.

| Artı | Eksi |
|---|---|
| Model-agnostic | Sampling choices açıklamayı değiştirebilir |
| Local ve sezgisel | Stability problemi olabilir |
| Text/image/tabular destekler | Yerel approximation global davranışı temsil etmez |

**SHAP vs LIME**
İkisi de local explanation sunabilir; SHAP daha güçlü additive attribution teorisine, LIME local surrogate fikrine dayanır.

# 16. Counterfactual explanations

Counterfactual: "Karar değişmesi için girdide en küçük hangi değişiklik gerekir?"

| Örnek | Counterfactual |
|---|---|
| Kredi reddi | Debt-to-income %45 yerine %32 olsaydı onay |
| Churn | Usage son 30 günde %40 daha yüksek olsaydı risk düşerdi |
| Fraud | Yeni cihaz + yurtdışı yerine tanıdık cihaz/ülke olsaydı skor düşerdi |

**Actionability**
Değiştirilemez feature (yaş gibi) counterfactual öneriye dönüşmemeli.

# 17. Surrogate models

Karmaşık model tahminlerini hedef olarak alıp basit decision tree/linear model fit ederek global approximate explanation üretilebilir.

**Fidelity ölç**
Surrogate modelin black-box tahminlerini ne kadar iyi taklit ettiğini ayrıca ölç. Düşük fidelity ile açıklama yanıltıcıdır.

# 18. Explanation stability

- Yakın iki gözlem çok farklı explanation alıyor mu?
- Farklı random seed açıklamayı değiştiriyor mu?
- Feature correlation attributionı oynatıyor mu?
- Model retrain sonrası explanation drift var mı?

**Production**
Explanation da bir output'tur; modelle birlikte versiyonlanmalı ve izlenmelidir.

# 19. Explainability ve causality farkı

| XAI | Causal inference |
|---|---|
| Model hangi feature'a dayandı? | Feature değiştirildiğinde dünya nasıl değişir? |
| Association/model behavior | Intervention effect |
| SHAP/PDP/importance | RCT, DAG, causal estimators |
| Tahmin açıklaması | Nedensel karar |

**En tehlikeli hata**
"SHAP yüksek -> bu feature sonucu yaratıyor" demek yanlıştır. SHAP model davranışını açıklar, dünyadaki causal mekanizmayı değil.

# 20. Leakage explainability ile yakalanabilir

Aşırı güçlü ve iş açısından şüpheli feature'lar explanation analizinde leakage sinyali verebilir.

- Churn modelinde cancellation_reason top feature.
- Fraud modelinde chargeback_status top feature.
- Loan default modelinde collection_status top feature.

**XAI debugging aracı**
Açıklama sadece paydaş sunumu değil, veri leakage ve pipeline hatası bulmak için de kullanılabilir.

# 21. Fairness ve subgroup explanation

Global importance, belirli gruplardaki farklı karar mekanizmalarını gizleyebilir. Segment/cohort bazında explanation karşılaştır.

**Protected attributes**
Doğrudan protected feature çıkarılsa bile proxy featurelar aynı bilgiyi taşıyabilir. Fairness değerlendirmesi ayrı metrikler gerektirir.

## 22. Explanation ve calibration birlikte

Local explanation, probability'nin güvenilir olduğu anlamına gelmez. Risk skorunu kullanıcıya açıklarken calibration ayrıca doğrulanmalıdır.

## 23. Churn vaka çalışması

Bir churn modelinde retention ekibi yüksek riskli müşteriler için açıklama istiyor.

| Katman | Kullanım |
|---|---|
| Global SHAP | Genel churn driver'ları |
| Local SHAP | Müşteri bazında neden riskli? |
| PDP/ICE | Usage düşüşünün skorla ilişkisi |
| Counterfactual | Hangi davranış iyileşirse risk düşer? |
| Error analysis | False positive müşterilerin açıklamaları |

**İş mesajı**
"Model bu müşteriyi riskli görüyor çünkü son 30 günde kullanım %55 düşmüş, 2 başarısız ödeme var ve destek ticket sayısı yükselmiş."

## 24. Fraud vaka çalışması

Fraud analyst tek işlem alarmının neden oluştuğunu anlamak ister.

- Amount vs user median yüksek.
- Yeni cihaz flag'i.
- Son işlemden coğrafi uzaklık yüksek.
- Velocity feature yüksek.

**Güvenlik**
Fraud explanation'ı saldırganlara karar kurallarını sızdırmayacak seviyede paylaşmak gerekir.

## 25. Credit risk vaka çalışması

Kredi kararlarında explanation daha yüksek yönetişim gerektirir. Local reason codes, model card ve audit trail birlikte düşünülmelidir.

**Reason code**
Teknik SHAP grafiğini doğrudan müşteriye vermek yerine stabil, anlaşılır ve policy ile uyumlu reason code üretmek daha uygundur.

## 26. Python - permutation importance

```
from sklearn.inspection import permutation_importance

r = permutation_importance(
    model, X_valid, y_valid,
    n_repeats=20,
    random_state=42,
    scoring="average_precision"
)

importance = r.importances_mean
```

## 27. Python - PDP

```
from sklearn.inspection import PartialDependenceDisplay

PartialDependenceDisplay.from_estimator(
    model, X_valid,
    features=["tenure", "monthly_fee"]
)
```

## 28. Python - SHAP

```
import shap

explainer = shap.Explainer(model, X_background)
shap_values = explainer(X_sample)

shap.plots.beeswarm(shap_values)
shap.plots.waterfall(shap_values[0])
```

**Pratik not**
Preprocessing + model Pipeline kullanıyorsan SHAP'e hangi transformed feature matrix'in ve feature name'lerin gittiğini net yönet.

## 29. Pipeline + explainability

- Raw feature isimlerini transformed feature isimleriyle map et.
- One-hot kategorileri insan okunur isimlere çevir.
- Feature generation logic'i model versiyonuyla kaydet.
- Explanation dataset'ini training'den bağımsız tut.

## 30. Model card içinde explainability

| Alan | İçerik |
|---|---|
| Model purpose | Ne için kullanılıyor? |
| Primary metrics | Performans ve calibration |
| Global drivers | Importance/SHAP summary |
| Known limitations | Correlation, drift, weak segments |
| Fairness | Group metrics ve review |
| Explanation method | Yöntem + versiyon |
| Monitoring | Explanation drift / feature drift |

## 31. Sık yapılan hatalar

- Feature importance'ı causal etki sanmak.
- Training data üzerinde explanation yapıp overfit sinyalini önem sanmak.
- Correlated feature sorununu görmezden gelmek.
- PDP ile gerçek dışı feature kombinasyonları yaratmak.
- SHAP output scale'ini bilmeden probability diye yorumlamak.
- Tek local explanation'dan global sonuç çıkarmak.
- Counterfactual'da değiştirilemez feature önermek.
- Surrogate fidelity ölçmemek.
- Explanation graph'ını kullanıcıya teknik bağlam olmadan vermek.
- Explainability ile fairness ve calibration problemlerini çözülmüş saymak.

## 32. Explainability checklist

1. Açıklama ihtiyacı global mi local mi?
2. Hangi kullanıcı açıklamayı okuyacak?
3. Model output scale nedir?
4. Açıklama validation/test veride mi?
5. Correlation ve interaction etkileri kontrol edildi mi?
6. Leakage sinyalleri araştırıldı mı?
7. Causal iddia yapılmıyor mu?
8. Explanation stable mı?
9. Regülasyon/gizlilik gereksinimleri var mı?
10. Explanation model versiyonuyla kaydediliyor mu?

# 33. Mülakat soruları

| Soru | Kısa cevap |
|---|---|
| Global vs local explanation? | Global tüm model davranışı, local tek tahmin. |
| Permutation importance nedir? | Feature permute edilince performans düşüşünü ölçer. |
| Permutation importance correlation'da neden düşebilir? | Benzer feature sinyali taşımaya devam eder. |
| PDP ne gösterir? | Feature değiştikçe ortalama model prediction etkisi. |
| PDP riski? | Correlated featurelarda gerçek dışı kombinasyonlar. |
| ICE ne sağlar? | Bireysel conditional effect eğrileri. |
| SHAP neyi açıklar? | Prediction'ı baseline'dan output'a taşıyan additive feature katkıları. |
| SHAP causal mı? | Hayır. |
| LIME nedir? | Local surrogate model yaklaşımı. |
| Counterfactual nedir? | Kararı değiştiren minimal input değişikliği. |
| Surrogate fidelity nedir? | Basit modelin black-box davranışını taklit başarısı. |
| Tree importance sorunu? | Cardinality bias ve correlation. |
| Explanation stability neden önemli? | Benzer inputlarda açıklamanın aşırı oynamaması gerekir. |
| XAI leakage bulabilir mi? | Evet, şüpheli güçlü feature'ları görünür kılabilir. |
| Model card'da XAI neden? | Audit, kullanım sınırı ve paydaş iletişimi için. |

# 34. Uygulama alıştırmaları

1. Random Forest için impurity importance ve permutation importance karşılaştır.
2. Correlated iki feature üret ve permutation importance davranışını incele.
3. PDP ve ICE grafikleri oluştur; heterojen etki var mı bak.
4. Bir XGBoost/LightGBM modelinde SHAP beeswarm üret.
5. Tek bir false positive için waterfall explanation çıkar.
6. Feature-family ablation ile SHAP global ranking'i karşılaştır.
7. Bir counterfactual senaryo tasarla ve actionability kontrol et.
8. Leakage feature ekleyip XAI ile yakala.
9. Segment bazında mean absolute SHAP karşılaştır.
10. Model retrain öncesi/sonrası explanation drift raporu üret.

# 35. Mini portföy projesi

Proje: Explainable Churn Risk System

| Çıktı | İçerik |
|---|---|
| 01_model.ipynb | Churn model + calibration |
| 02_global_xai.ipynb | Permutation + SHAP summary |
| 03_local_xai.ipynb | Waterfall / reason codes |
| 04_pdp_ice.ipynb | Feature effect analizi |
| 05_error_xai.ipynb | False positive/negative explanation |
| model_card.md | Limitations, fairness, XAI method |
| report.md | Business narrative ve aksiyon önerileri |

**CV cümlesi**
Built an explainable churn-risk system using permutation importance, SHAP, PDP/ICE and local reason codes, with leakage checks, segment-level error explanations and a production-oriented model card.

## 36. Final cheat sheet

| Kavram | Hatırlanacak fikir |
|---|---|
| Global explanation | Model genel davranışı |
| Local explanation | Tek prediction |
| Tree importance | Hızlı ama biaslı olabilir |
| Permutation | Performans düşüşü |
| PDP | Ortalama feature effect |
| ICE | Bireysel effect |
| ALE | Correlation-aware alternatif |
| SHAP | Additive attribution |
| LIME | Local surrogate |
| Counterfactual | Kararı değiştiren input |
| Surrogate | Black-box approx |
| Fidelity | Açıklamanın black-box'a uyumu |
| Causality | XAI değildir |
| Stability | Explanation güvenilirliği |
| Model card | Yönetişim + iletişim |

**Bu modülden sonra**
Clustering bölümüne geçerken unsupervised modellerde açıklamanın neden farklılaştığını ve segmentlerin hangi feature'larla ayrıştığını daha sistematik yorumlayabileceksin.