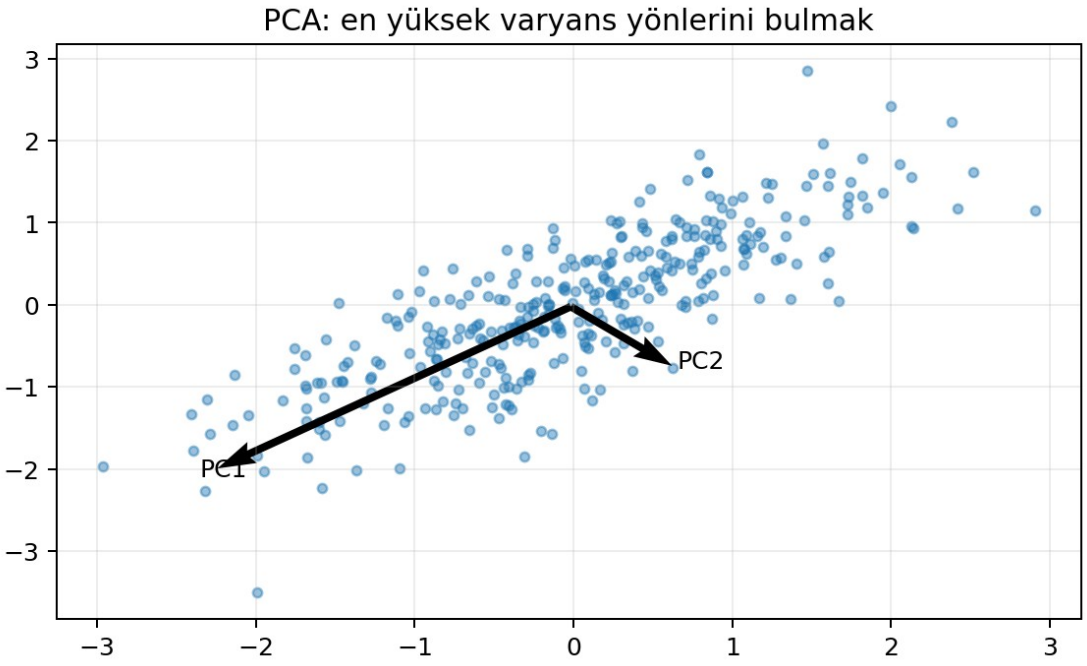
26. DIMENSIONALITY REDUCTION

PCA • SVD • t-SNE • UMAP • Visualization • Compression



Bu modülün amacı
Yüksek boyutlu veriyi bilgi kaybını kontrol ederek daha küçük bir temsile dönüştürmek; PCA gibi lineer yöntemlerle t-SNE/UMAP gibi görselleştirme yöntemlerini doğru amaçlarla kullanmayı öğrenmek.

Kazanım	Modül sonunda
Boyut problemi	Curse of dimensionality, sparsity ve redundancy etkilerini açıklayabilirsin.
PCA	Centering, covariance, eigenvector/SVD ve projection mantığını kurabilirsin.
Component seçimi	Explained variance ve reconstruction trade-off ile k seçebilirsin.
t-SNE / UMAP	2D/3D görselleştirmeyi model input reduction ile karıştırmazsın.
Pipeline	Scaling + dimensionality reduction + model akışını leakage-safe kurabilirsin.
Yorumlama	Components/loadings ve embedding çıktılarının sınırlarını doğru anlatabilirsin.

1. Dimensionality reduction nedir?

Çok sayıda feature içeren veriyi, önemli yapıyı mümkün olduğunca koruyarak daha az boyutta temsil etme sürecidir. Amaç yalnızca dosya boyutunu küçültmek değil; noise azaltmak, redundancy çözmek, görselleştirmek ve bazı modelleri daha kararlı hale getirmektir.

Amaç	Örnek
Compression	500 feature -> 40 component
Visualization	100D embedding -> 2D harita
Denoising	Zayıf varyans/noise yönlerini atmak
Multicollinearity azaltma	Correlated feature gruplarını component ile temsil
Compute	Daha az feature ile daha hızlı model

Önemli ayrım
Dimensionality reduction, feature selection değildir. Selection mevcut sütunları seçer; PCA gibi yöntemler mevcut feature'ların kombinasyonlarından yeni eksenler üretir.

2. Curse of dimensionality

- Boyut arttıkça veri uzayda seyrekleşir.
- Distance ölçüleri birbirine yaklaşabilir; nearest-neighbor mantığı zayıflayabilir.
- Daha fazla parametre/feature, overfitting riskini büyütebilir.
- Görselleştirme ve insan yorumu zorlaşır.

Ama her yüksek boyut kötü değil
Tree boosting veya regularized linear modeller çok sayıda feature ile iyi çalışabilir. Reduction bir amaç değil, problem çözme aracıdır.

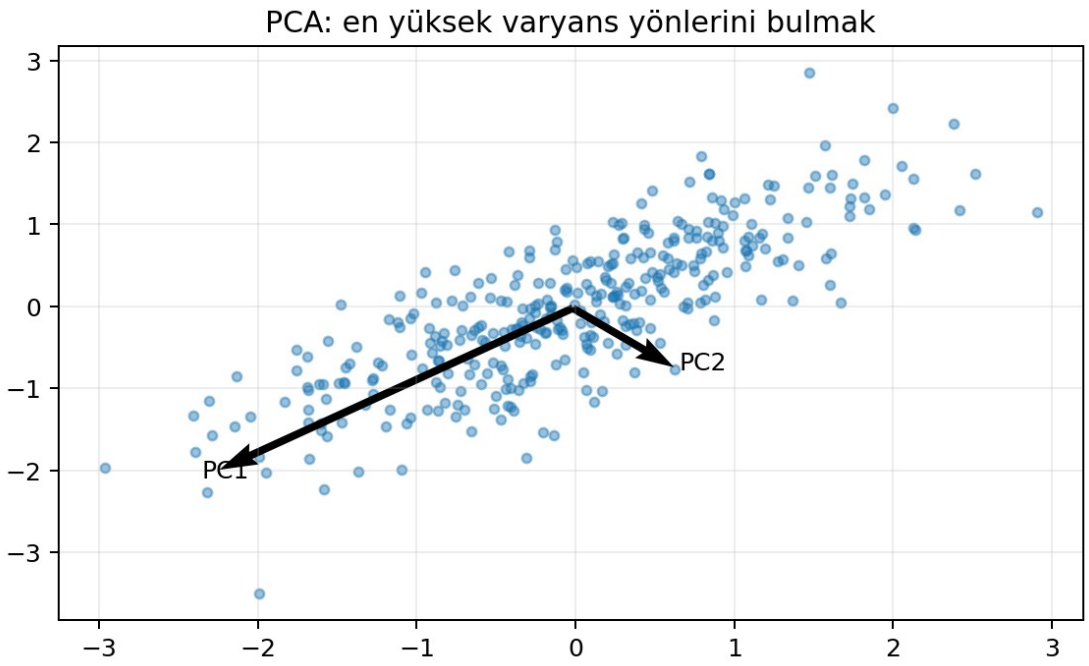
3. Intrinsic dimension

Veri 100 sütun taşısa bile gerçek bilgi birkaç latent faktör etrafında oluşabilir. Örneğin 20 davranış metriği "müşteri aktivitesi", "harcama gücü" ve "indirim hassasiyeti" gibi daha az sayıda gizli faktör tarafından yönlendirilebilir.

4. Lineer vs nonlinear reduction

Tür	Yöntem	Ana kullanım
Lineer	PCA / TruncatedSVD	Compression, decorrelation, model preprocessing
Nonlinear	t-SNE	Yerel komşuluk görselleştirmesi
Nonlinear	UMAP	Visualization, manifold yapısı; bazen downstream representation
Neural	Autoencoder	Learned nonlinear compression

5. PCA - Principal Component Analysis



PCA, merkezlenmiş veride varyansın en yüksek olduğu orthogonal yönleri bulur. İlk principal component en fazla varyansı, ikinci component ilkine dik olacak şekilde kalan en fazla varyansı açıklar.

Geometrik sezgi
PCA yeni bir koordinat sistemi döndürür. Veri noktaları değişmez; onları ifade ettiğimiz eksenler değişir ve sonra yalnız ilk k eksene projection yapılır.

6. PCA adımları

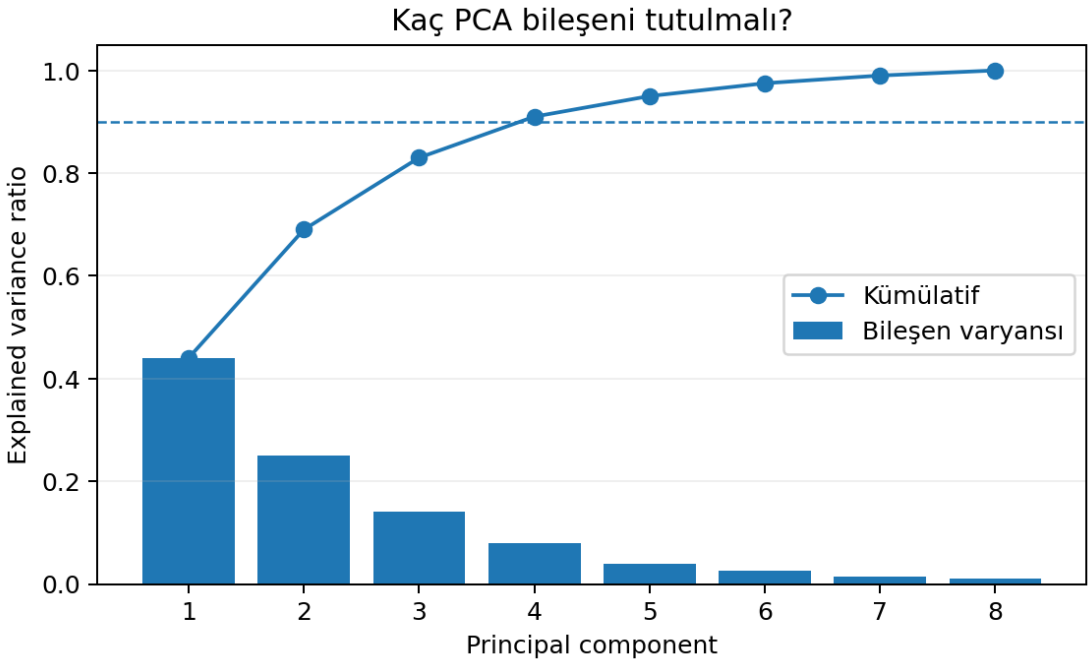
1. Numerik feature'ları hazırla ve gerekirse scale et.
2. Her feature'dan training mean çıkararak center et.
3. Covariance matrix veya doğrudan SVD üzerinden ana yönleri bul.
4. Eigenvalue/singular value büyüklüğüne göre component'leri sırala.
5. İlk k component'i seç.
6. X verisini yeni basis'e project et.

7. Scaling neden kritik olabilir?

Durum	Sonuç
Feature ölçekleri benzer	Centering çoğu zaman yeterli olabilir.
Gelir 0-1,000,000; yaş 18-80	Gelir varyansı PCA yönünü domine edebilir.
StandardScaler + PCA	Her feature standardized varyans üzerinden katkı verir.

Kural değil, karar
Scale etmek domain'e bağlıdır. Fiziksel birimlerin gerçek varyansını korumak istediğin bazı bilimsel problemlerde scaling istenmeyebilir.

8. Explained variance



Her component'in eigenvalue/singular value gücü, ne kadar varyans açıkladığını belirler. Explained variance ratio bileşen bazında payı; cumulative ratio ilk k bileşenin toplam koruduğu varyansı gösterir.

```
from sklearn.decomposition import PCA

pca = PCA()
Z = pca.fit_transform(X_train_scaled)

print(pca.explained_variance_ratio_)
print(pca.explained_variance_ratio_.cumsum())
```

9. Kaç component seçilmeli?

Yaklaşım	Ne zaman?
%90 / %95 cumulative variance	Compression hedefi için hızlı heuristic
Scree / elbow	Ek component kazancı ne zaman azalıyor?
Cross-validation	Downstream model performance hedefi
Reconstruction error	Compression kalitesini ölçmek için
Business/latency constraint	Model boyutu ve compute limiti varsa

En iyi k = en yüksek explained variance değildir
Tahmin problemi için target-aware CV sonucu daha önemlidir. PCA target'ı görmez; variance ile predictive signal aynı şey değildir.

10. Loadings ve component yorumu

Loadings, original feature'ların component yönüne katkısını gösterir. Büyük mutlak loading ilgili component'in yorumunda daha etkili feature anlamına gelir.

Component	Yüksek loadings	Olası yorum
PC1	orders_90d, spend_90d, sessions_30d	Genel müşteri aktivitesi/değeri
PC2	discount_share (+), avg_price (-)	Fiyat/indirim hassasiyeti
PC3	support_tickets, refund_rate	Sorun/servis davranışı

Dikkat
Component isimleri model çıktısı değildir; loadings ve domain bilgisine dayalı insan yorumudur.

11. PCA ve SVD bağlantısı

Pratik implementasyonlar covariance matrix'i açıkça kurmak yerine centered X üzerinde SVD kullanabilir. $X = U \Sigma V^T$ ayrışımında V yönleri principal axes ile yakından ilişkilidir.

```
U, s, Vt = np.linalg.svd(X_centered, full_matrices=False)

# İlk k doğrultu
V_k = Vt[:k]
Z = X_centered @ V_k.T
```

Neden SVD?
Dikdörtgen matrislere doğrudan uygulanır ve sayısal olarak güçlüdür. Sparse data için TruncatedSVD özellikle kullanışlıdır.

12. Reconstruction error

PCA ile k boyuta indikten sonra yaklaşık original space'e dönülebilir. Kaybolan bilgi reconstruction error ile ölçülebilir.

```
pca = PCA(n_components=10)
Z = pca.fit_transform(X_train_scaled)
X_hat = pca.inverse_transform(Z)

reconstruction_mse = ((X_train_scaled - X_hat)**2).mean()
```

13. PCA ne zaman iyi çalışır?

- Feature'lar arasında lineer correlation/redundancy varsa.
- Çok sayıda numeric feature daha az latent faktöre dayanıyorsa.
- Noise azaltma/compression gerekiyorsa.
- Linear model/KNN gibi yöntem öncesi multicollinearity azaltmak istiyorsan.

14. PCA ne zaman zayıf olabilir?

- Signal nonlinear manifold üzerinde ise.
- Low-variance feature target için çok önemliyse.
- Component interpretability kritikse.
- Sparse one-hot feature'larda centering pahalıysa; TruncatedSVD daha uygun olabilir.

15. TruncatedSVD

Sparse matrix'i center etmeden low-rank representation üretebilir. NLP TF-IDF ve recommendation matrix gibi sparse problemlerde yaygındır.

```
from sklearn.decomposition import TruncatedSVD

svd = TruncatedSVD(n_components=100, random_state=42)
Z = svd.fit_transform(tfidf_matrix)
```

LSA bağlantısı
TF-IDF + TruncatedSVD kombinasyonu Latent Semantic Analysis yaklaşımının temelidir.

16. PCA + supervised model pipeline

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.linear_model import LogisticRegression

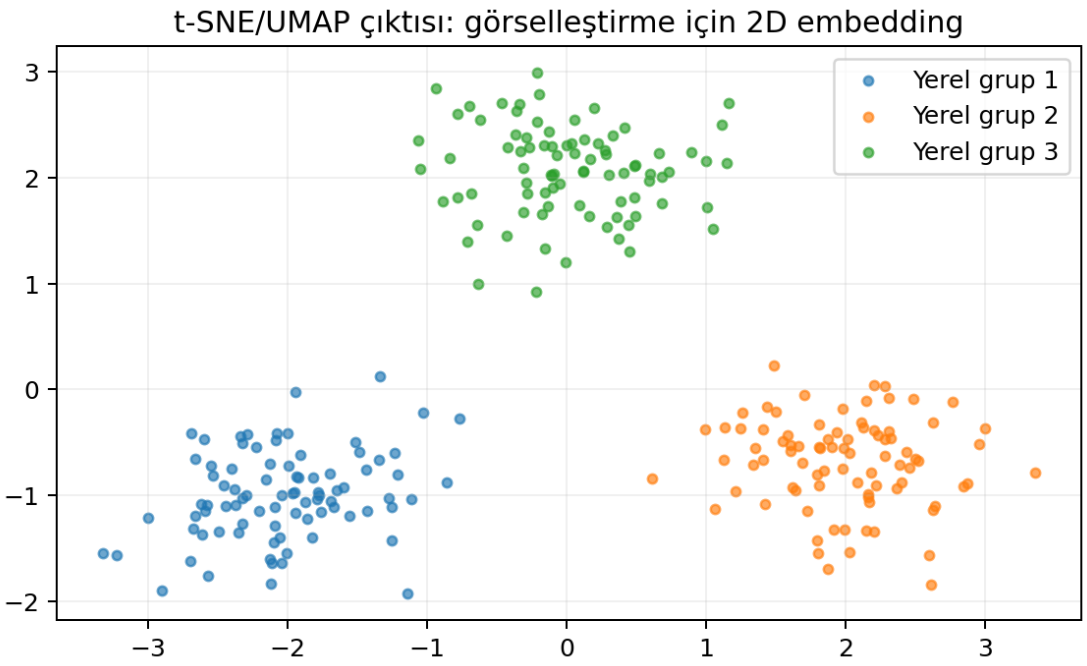
pipe = Pipeline([
    ("scale", StandardScaler()),
    ("pca", PCA(n_components=0.95)),
    ("model", LogisticRegression(max_iter=2000))
])
```

Leakage-safe
Scaler ve PCA yalnız CV training fold üzerinde fit edilir. Split öncesi tüm veride PCA fit etmek validation leakage'dır.

17. PCA her modele fayda sağlar mı?

Model	PCA etkisi
Linear/Logistic	Correlation azaltabilir, compute düşürebilir.
KNN/SVM	Boyut ve distance davranışını iyileştirebilir.
Tree/Boosting	Çoğu zaman gerekli değil; original nonlinear splits kaybolabilir.
Neural network	Bazen input compression; ama learned representations tercih edilebilir.

18. t-SNE nedir?



t-SNE, yüksek boyutlu komşuluk ilişkilerini düşük boyutta korumaya çalışan nonlinear bir görselleştirme yöntemidir. Özellikle 2D/3D keşif için kullanılır.

En önemli uyarı
t-SNE koordinatlarının global uzaklıklarını, cluster büyüklüklerini veya eksenlerini doğrudan business anlamı olarak yorumlama.

19. Perplexity

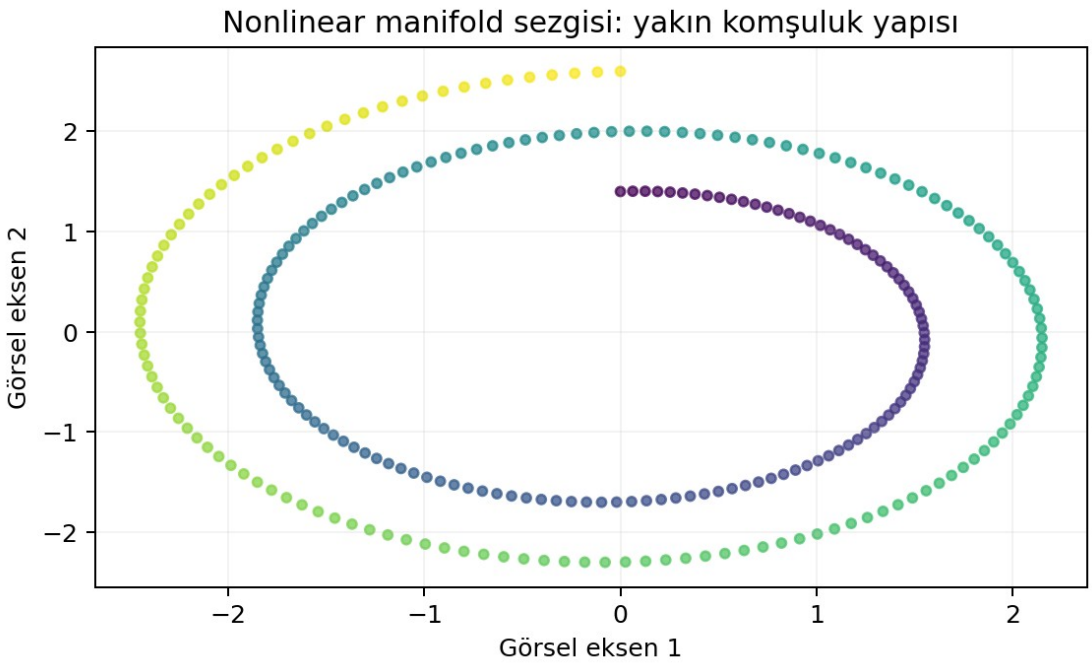
Perplexity kabaca her noktanın kaç komşuluk ölçeğini dikkate aldığını kontrol eder. Tek doğru değer yoktur; farklı değerlerde yapının stabil olup olmadığına bakılır.

Düşük perplexity	Yüksek perplexity
Çok lokal yapı	Daha geniş komşuluk
Fragmentation artabilir	Local detay kaybolabilir
Noise'a duyarlı olabilir	Global yapı nispeten smooth olabilir

20. t-SNE anti-patternleri

- Tek random seed sonucu üzerinden cluster hikâyesi anlatmak.
- 2D'de uzak görünen grupları original space'te kesin uzak kabul etmek.
- t-SNE çıktılarını doğrudan production model feature'ı yapmak.
- Ölçekleme/preprocessing etkisini görmezden gelmek.
- Farklı dataset t-SNE haritalarını eksen koordinatlarıyla karşılaştırmak.

21. UMAP nedir?



UMAP, komşuluk grafiği ve manifold varsayımlarıyla düşük boyutlu embedding üretir. t-SNE gibi local structure'a odaklanır; pratikte daha hızlı olabilir ve daha fazla global yapı koruyabilir.

Parametre	Sezgi
n_neighbors	Local vs daha geniş neighborhood ölçeği
min_dist	Embedding'de noktaların ne kadar sıkışabileceği
n_components	2D görsel veya daha yüksek latent representation
metric	Original space distance ölçüsü

Yine dikkat
UMAP de görselleştirme şeklidir; 2D kümelerin gerçek ve ayrı segment olduğunu otomatik kanıtlamaz.

22. t-SNE vs UMAP vs PCA

Yöntem	Lineer?	Yeni veri transform?	Ana amaç
PCA	Evet	Evet	Compression + preprocessing + visualization
t-SNE	Hayır	Klasik kullanımda sınırlı	Keşif/görselleştirme
UMAP	Hayır	Implementasyona göre transform mümkün	Visualization / manifold embedding

23. Visualization önce PCA?

Çok yüksek boyutta önce PCA ile 30-100 boyuta inip sonra t-SNE/UMAP uygulamak hesap yükünü azaltabilir ve noise'u filtreleyebilir.

```
X50 = PCA(n_components=50).fit_transform(X_scaled)
```

```
# ardından t-SNE veya UMAP görselleştirmesi
```

24. Clustering öncesi dimensionality reduction

Yüksek boyutlu ve correlated veride PCA clustering'i stabil hale getirebilir. Ama reduction cluster yapısını değiştirebildiği için original ve reduced-space sonuçları karşılaştırılmalıdır.

7. Scale et.
8. PCA k seçimini CV/variance/stability ile belirle.
9. Clustering uygula.
10. Cluster profiling'i original feature'larda yap.
11. Farklı seeds/samples ile stability kontrol et.

25. Cluster görselleştirme hatası

2D güzel görünmek yeterli değil
t-SNE/UMAP üzerinde ayrık görünen kümeler original space'te aynı şekilde ayrılmayabilir. Cluster quality'yi yalnız 2D haritadan değerlendirme.

26. Anomaly detection ve PCA

Normal verinin düşük-rank alt uzayda iyi reconstruct edilip anomalilerin yüksek reconstruction error üretmesi fikri anomaly detection için kullanılabilir.

```
err = ((X_scaled - pca.inverse_transform(pca.transform(X_scaled)))**2).mean(axis=1)
flag = err > np.quantile(err, 0.99)
```

27. Supervised prediction için reduction

CV ile test et
PCA unsupervised olduğu için yüksek variance direction her zaman target signal değildir. Model CV skoru reduction olmadan daha iyi olabilir.

28. Feature selection vs PCA

Feature Selection	PCA
Original feature isimleri korunur	Yeni component isimleri oluşur
Yorumlanabilirlik yüksek	Yorum component loadings üzerinden
Redundant feature seçimi mümkün	Correlation'ı latent yönlerde birleştirir
Supervised selection olabilir	Klasik PCA unsupervised

29. Sparse ve categorical data

- One-hot sparse matrix için centered PCA memory açısından kötü olabilir.
- TruncatedSVD sparse input için daha uygundur.
- Pure categorical data için MCA gibi alternatif yöntemler vardır.
- Mixed numeric/categorical için Factor Analysis of Mixed Data gibi yöntemler düşünülebilir.

30. Autoencoders - ileri köprü

Autoencoder, input'u bottleneck latent space'e encode edip yeniden reconstruct etmeyi öğrenen neural network yapısıdır. PCA'nın nonlinear ve öğrenilebilir genellemesi gibi düşünülebilir; ancak eğitim, regularization ve interpretability daha karmaşıktır.

Ne zaman?
Görüntü, sensör, çok büyük nonlinear representation ve deep-learning ekosisteminde faydalı olabilir; klasik tabular problemde PCA daha güçlü baseline'dır.

31. Leakage ve preprocessing

Yanlış	Doğru
Tüm dataset StandardScaler + PCA sonra split	Split/CV training fold içinde fit
Test explained variance ile k seçmek	Validation/CV üzerinde k seçmek
t-SNE haritasına bakıp label-aware parametre ayarlamak	Keşif ile final evaluation'ı ayırmak

32. Gerçek vaka: müşteri davranışı PCA

E-ticaret şirketinde müşteri başına 45 davranış feature'ı var: recency, 7d/30d/90d spend, order counts, category shares, returns, sessions, discounts ve support interactions.

Aşama	Karar
Preprocess	Missing + StandardScaler
Reduction	PCA; %90 variance veya clustering stability ile k
Profiling	Loadings + original feature ortalamaları
Downstream	KMeans / segmentation
Visualization	PCA 2D + UMAP yalnız anlatım için
Risk	Segments 2D görünüşe göre isimlendirilmez

Portföy yorumu
PC1 genel aktivite/değer; PC2 indirim hassasiyeti gibi yorumlar yalnız loadings ve original feature profilleri destekliyorsa yapılır.

33. Gerçek vaka: image embeddings

768 boyutlu image embedding'leri görselleştirmek için önce PCA ile 50D, ardından UMAP/t-SNE ile 2D uygulanabilir. Yakın örneklerin sınıf/etiket davranışı incelenir.

34. Gerçek vaka: text TF-IDF

100,000+ sparse TF-IDF feature TruncatedSVD ile 200 latent dimension'a indirilebilir ve linear classifier/clustering uygulanabilir.

```
svd = TruncatedSVD(n_components=200, random_state=42)
X_train_svd = svd.fit_transform(X_train_tfidf)
X_valid_svd = svd.transform(X_valid_tfidf)
```

35. İyi dimensionality reduction workflow

12. İş amacını belirle: visualization mı, compression mı, model performance mı?
13. Data type ve sparsity'yi kontrol et.
14. Split'i önce yap.
15. Preprocessing + reduction adımını training fold içinde fit et.
16. k / parametreleri validation/CV ile seç.
17. Original-space baseline ile kıyasla.
18. Interpretation gerekiyorsa loadings ve reconstruction analizi yap.
19. Visualization yöntemlerinde seed/parameter stability kontrol et.
20. Production transform maliyetini ve model artifact'larını versiyonla.

36. Sık yapılan hatalar

- PCA öncesi scale ihtiyacını düşünmemek.
- Explained variance yüksek diye predictive signal korunduğunu varsaymak.
- t-SNE/UMAP cluster görünümünü gerçek cluster kanıtı saymak.
- Split öncesi PCA fit etmek.
- t-SNE eksenlerine anlam yüklemek.
- Component loadings'i causal effect gibi yorumlamak.
- Tree modeline PCA'yı otomatik faydalı sanmak.
- Sparse matrix'i centered PCA ile gereksiz densify etmek.
- Bir random seed visualization'a aşırı güvenmek.

37. Mülakat soruları

Soru	Kısa cevap
PCA neyi optimize eder?	Projeksiyon altında korunacak varyansı maksimize eder / reconstruction error ile eşdeğer ilişki taşır.
PCA supervised mı?	Hayır; target'ı görmez.
Scaling neden?	Büyük ölçekli feature'ların variance ile domine etmesini engelleyebilir.
Explained variance nedir?	Component'in toplam varyanstan açıkladığı pay.
PCA ve feature selection farkı?	PCA yeni linear combinations üretir; selection original features seçer.
SVD bağlantısı?	Centered X'in right singular vectors principal directions ile ilişkilidir.
t-SNE ne için?	Yüksek boyutlu local neighborhood yapısını 2D/3D keşif için görselleştirmek.
t-SNE cluster kanıtı mı?	Hayır.

UMAP avantajı?	Hızlı olabilir, local ve bazı global yapıları koruyabilir; transform desteği bulunabilir.
Sparse TF-IDF için?	TruncatedSVD.
PCA leakage nasıl olur?	Tüm data üzerinde fit edip sonra CV/split yapmak.
k nasıl seçilir?	Explained variance + downstream CV + reconstruction/business constraints.

38. Uygulama alıştırmaları

21. StandardScaler öncesi/sonrası PCA explained variance karşılaştır.
22. PCA k=2,5,10,0.90 için reconstruction error ölç.
23. PCA + Logistic Regression ile raw Logistic Regression CV skorunu kıyasla.
24. PCA loadings tablosundan ilk 3 component'i yorumla.
25. TF-IDF + TruncatedSVD pipeline kur.
26. Aynı dataset için t-SNE farklı perplexity ve seed sonuçlarını karşılaştır.
27. UMAP n_neighbors/min_dist parametrelerinin haritayı nasıl değiştirdiğini incele.
28. Clustering'i raw ve PCA-space'te çalıştırıp silhouette/stability karşılaştır.
29. Anomaly detection için reconstruction error percentile threshold dene.
30. Split öncesi PCA leakage örneği üret ve skor farkını ölç.

39. Mini portföy projesi

Proje: High-Dimensional Customer Behavior - PCA, UMAP and Segmentation

Çıktı	İçerik
01_eda.ipynb	Correlation, scale, missing, dimensionality
02_pca.ipynb	Explained variance, loadings, reconstruction
03_embedding.ipynb	PCA 2D vs t-SNE vs UMAP
04_clustering.ipynb	Raw vs PCA clustering stability
05_model.ipynb	Raw vs PCA supervised benchmark
src/pipeline.py	Scaler + PCA + model
report.md	Interpretation, limitations, business use

CV cümlesi
Built a high-dimensional customer representation pipeline using PCA and UMAP, with explained-variance analysis, component interpretation, clustering stability tests and leakage-safe supervised benchmarking.

40. Final cheat sheet

Kavram	Hatırlanacak fikir
Curse of dimensionality	Boyut arttıkça sparsity/distance problemi
PCA	En yüksek variance orthogonal directions
Scaling	PCA geometry'sini değiştirir
Explained variance	Korunan variance oranı
Loadings	Original feature -> component katkısı
SVD	PCA'nın güçlü hesaplama temeli
Reconstruction	Compression bilgi kaybı
TruncatedSVD	Sparse matrices
t-SNE	Local-neighborhood visualization

UMAP	Manifold embedding / visualization
Feature selection	Original features korunur
Autoencoder	Learned nonlinear compression
Leakage	Reduction fit sadece train fold
Cluster profiling	Original feature space'te yorumla

Bu modülden sonra
Time Series bölümüne geçmeden önce yüksek boyutlu feature setlerinde ne zaman PCA/SVD kullanacağını, ne zaman yalnız görselleştirme için t-SNE/UMAP kullanacağını ayırabilecek seviyede olmalısın.