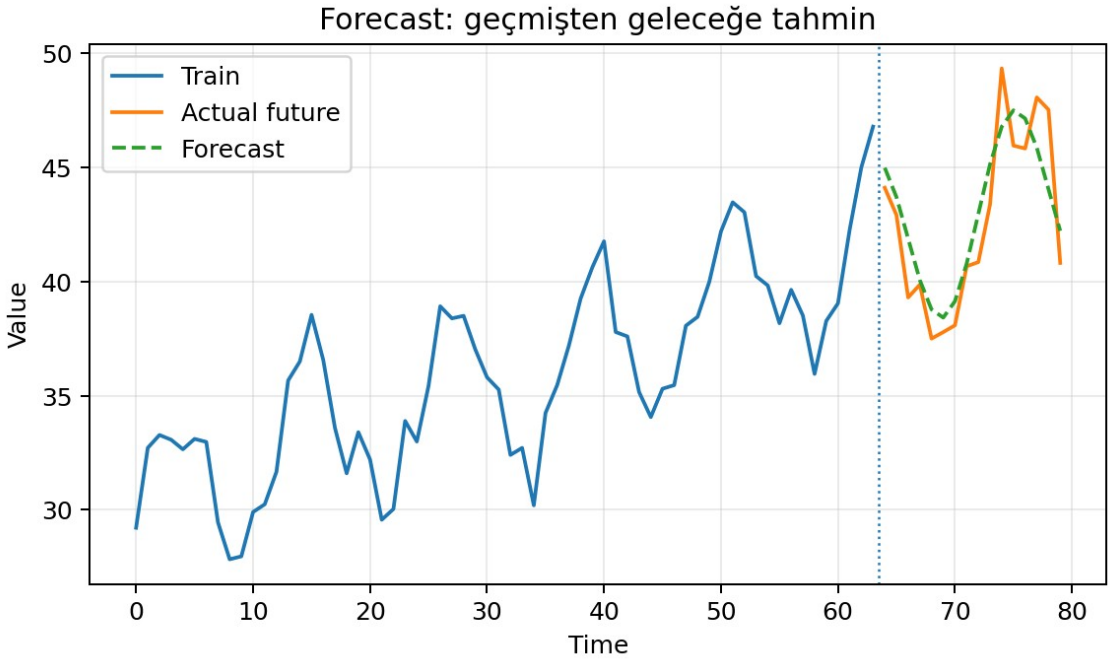
27. TIME SERIES

Trend • Seasonality • ARIMA • Prophet • ML Forecasting



Bu modülün amacı
Time series problemlerini sadece model seçimi olarak değil; zaman bağımlılığı, leakage, doğru backtesting, baseline ve business horizon ile birlikte uçtan uca kurabilmek.

Kazanım	Modül sonunda
Problem framing	Forecast horizon, frequency, grain ve availability kavramlarını doğru tanımlayabilirsin.
Time structure	Trend, seasonality, cycle, noise ve autocorrelation kavramlarını okuyabilirsin.
Baselines	Naive, seasonal naive ve moving-average baseline kurabilirsin.
Classical models	AR, MA, ARIMA/SARIMA yaklaşımını kavrarsın.
ML forecasting	Lag/rolling/calendar feature ile tree/boosting modelleri kurabilirsin.
Validation	Walk-forward / TimeSeriesSplit ile leakage-safe evaluation tasarlayabilirsin.

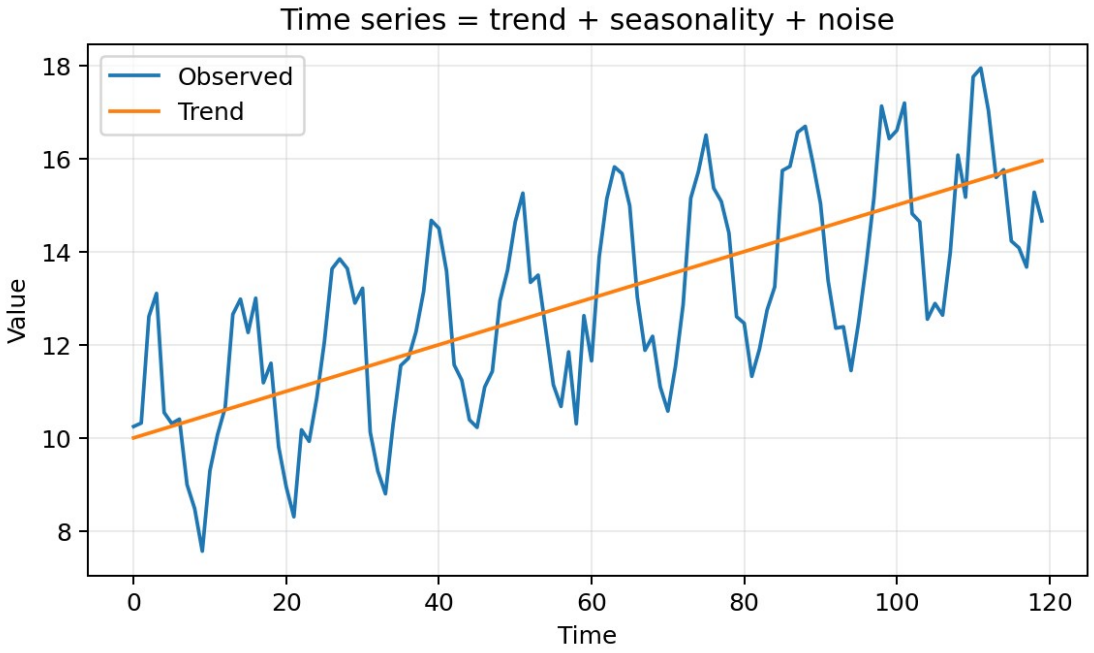
1. Time series problemi nedir?

Zaman sıralı gözlemlerde hedef yalnız feature değerlerine değil, geçmişe ve zaman yapısına da bağlı olabilir. Amaç çoğu zaman gelecekteki bir veya daha fazla adımı tahmin etmektir.

Örnek problem	Target	Horizon
Perakende talep	Günlük satış adedi	7 / 30 gün
Enerji	Saatlik tüketim	24 saat
Finans	Getiri/volatilite	1-5 gün
Çağrı merkezi	Saatlik çağrı sayısı	1 gün
SaaS	Aylık abonelik geliri	3-12 ay

İlk dört soru
1) Prediction time nedir? 2) Horizon kaç adım? 3) Frequency nedir? 4) Target hangi grain seviyesinde?

2. Time series bileşenleri



Bileşen	Anlam
Trend	Uzun dönem yön.
Seasonality	Sabit periyotlu tekrar.
Cycle	Periyodu sabit olmayan daha geniş dalgalanma.
Noise	Açıklanmayan kısa dönem rastgele değişim.
Level	Serinin genel seviyesi.

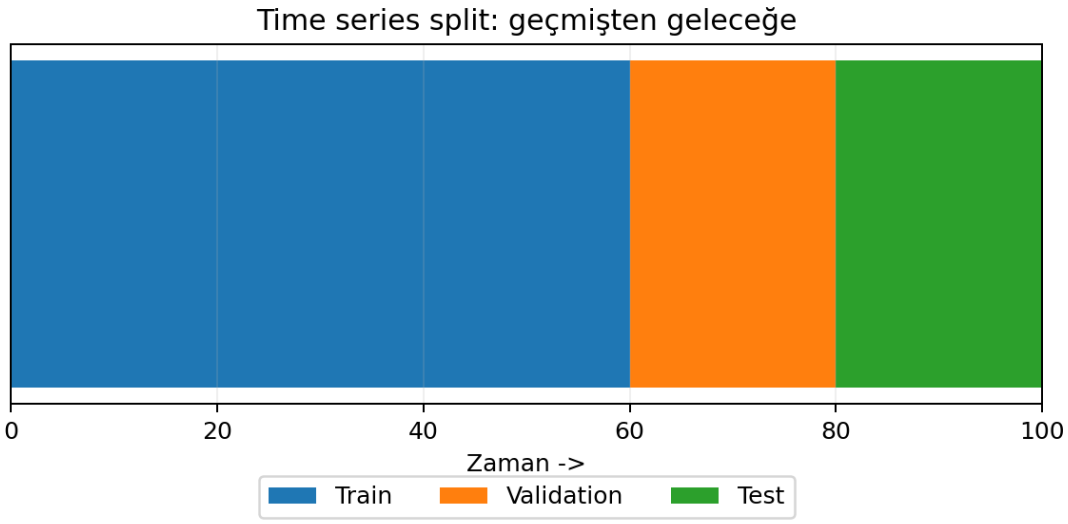
Additive vs multiplicative
Seasonal amplitude seviye arttıkça büyüyorsa multiplicative yapı düşün. Log dönüşümü bazen bu yapıyı additive hale yaklaştırır.

3. Frequency, horizon ve grain

Kavram	Örnek
Frequency	Günlük / saatlik / haftalık
Horizon	t+1 veya t+30
Grain	store-product-day
Cutoff	Tahmin üretilen son bilinen zaman
Availability	Feature hangi gecikmeyle hazır?

Production gerçeği
Feature teorik olarak geçmişte olsa bile production sisteminde 2 gün gecikmeyle geliyorsa t anında kullanılamaz.

4. Zaman sırasını neden bozamazsın?



Random split gelecekteki gözlemleri training set içine taşıyabilir. Bu nedenle forecasting evaluation çoğunlukla kronolojik yapılır.

Leakage örneği
2026 satışlarını train edip 2025 aylarını validation yapmak production senaryosunu taklit etmez.

5. Naive baseline

En basit forecast son değeri geleceğe taşımaktır: y_hat(t+h)=y(t). Güçlü trend/seasonality yoksa şaşırtıcı derecede rekabetçi olabilir.

```
# one-step naive forecast
y_pred = y.shift(1)
```

Baseline zorunlu
Karmaşık model seasonal-naive baseline'ı geçemiyorsa modelin gerçek değeri sorgulanmalıdır.

6. Seasonal naive baseline

Seride haftalık seasonality varsa geçen haftanın aynı gününü tahmin olarak kullanmak güçlü baseline olabilir.

```
# günlük seri ve haftalık seasonality
y_pred = y.shift(7)
```

Baseline	Ne zaman?
Naive	Random-walk / yüksek persistence
Seasonal naive	Güçlü sabit periyotlu seasonality
Mean/median	Durağan, düşük autocorrelation
Moving average	Noise smoothing

7. Autocorrelation ve ACF

Autocorrelation, serinin gecikmeli kopyalarıyla korelasyonunu ölçer. ACF farklı laglerde ilişkiyi gösterir; PACF ara lag etkilerini kontrol ederek doğrudan ilişkiyi ölçmeye çalışır.

- Lag-1 yüksek: kısa dönem persistence olabilir.
- Lag-7/12/24 tepe: seasonality işareti olabilir.
- ACF yavaş sönüyor: trend/non-stationarity işareti olabilir.

Korelasyon nedensellik değildir
ACF yapısal ilişki gösterir; business mechanism için domain analizi gerekir.

8. Stationarity

Kabaca mean, variance ve autocorrelation yapısı zaman içinde çok değişmiyorsa seri stationarity varsayımına daha yakındır. ARIMA ailesinde önemli kavramdır.

Sorun	Dönüşüm
Trend	Differencing
Multiplicative scale	Log / Box-Cox
Seasonality	Seasonal differencing
Changing variance	Variance-stabilizing transform

9. Differencing

```
df["diff_1"] = df["y"].diff(1)
df["diff_7"] = df["y"].diff(7)
```

Birinci fark y_t-y_(t-1) trendi azaltabilir. Seasonal difference y_t-y_(t-s) seasonality'yi azaltabilir.

Aşırı differencing
Gereksiz differencing noise'u büyütebilir. D parametresini otomatik artırmak yerine seri yapısını incele.

10. AR modeli

Autoregressive model, bugünkü değeri geçmiş değerlerin lineer kombinasyonu ile açıklar: y_t = c + phi1*y_(t-1)+...+error.

Parametre	Anlam
p	Kaç autoregressive lag kullanılacağı
phi	Lag katsayıları
error	Yeni shock/noise

11. MA modeli

Moving Average modelinde target geçmiş forecast error/shock'ların kombinasyonuyla açıklanır. Buradaki MA, rolling mean ile aynı şey değildir.

AR vs MA
AR geçmiş y değerlerini, MA geçmiş error terimlerini kullanır.

12. ARIMA

ARIMA(p,d,q): autoregression + differencing + moving-average bileşenlerini birleştirir.

Parametre	Anlam
p	AR order
d	Differencing order
q	MA order

```
from statsmodels.tsa.arima.model import ARIMA

model = ARIMA(train, order=(2, 1, 1))
fit = model.fit()
forecast = fit.forecast(steps=14)
```

13. SARIMA / seasonal ARIMA

Seasonal ARIMA, ARIMA'ya seasonal P,D,Q ve period s bileşenlerini ekler. Günlük veride haftalık seasonality için s=7 örnektir.

```
from statsmodels.tsa.statespace.sarimax import SARIMAX

model = SARIMAX(
   train,
   order=(1,1,1),
   seasonal_order=(1,1,1,7)
)
```

Model selection
AIC/BIC yardımcı olabilir ama final seçim temporal validation/backtest performansına dayanmalıdır.

14. Exogenous variables - ARIMAX/SARIMAX

Fiyat, kampanya, tatil, hava durumu gibi dış feature'lar eklenebilir. Ancak gelecekteki exogenous feature değerlerinin forecast horizon için gerçekten biliniyor olması gerekir.

Future-known vs future-unknown
Holiday calendar bilinir; gelecek haftanın gerçek talep kampanya tepkisi bilinmez. Exogenous availability kritik.

15. Exponential Smoothing / Holt-Winters

Level, trend ve seasonality'yi recursive smoothing ile tahmin eder. Güçlü seasonal business serileri için sağlam classical baseline olabilir.

Yöntem	Bileşen
Simple Exponential Smoothing	Level
Holt	Level + trend
Holt-Winters	Level + trend + seasonality

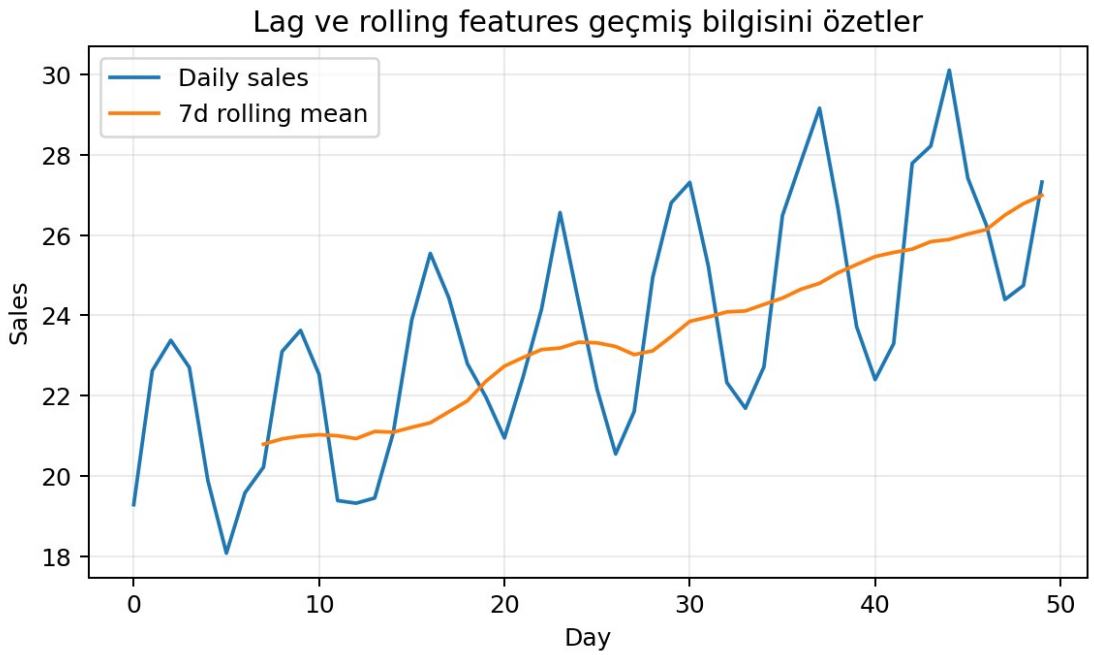
16. Prophet yaklaşımı

Prophet tarzı yaklaşım trend, multiple seasonality ve holiday/event etkilerini additive model mantığında ayrıştırır. Hızlı business forecasting baseline'ı olarak kullanışlıdır.

- Trend değişim noktaları.
- Weekly/yearly seasonality.
- Holiday/event regressors.
- Uncertainty interval.

Sihirli model değil
Düzgün backtest olmadan Prophet, ARIMA veya boosting modelinden hangisinin daha iyi olduğunu söyleyemezsin.

17. Lag features




```
df["lag_1"] = df["sales"].shift(1)
df["lag_7"] = df["sales"].shift(7)
df["lag_28"] = df["sales"].shift(28)
```

Horizon uyumu
30 gün ileri recursive forecast yapıyorsan lag feature'ların gelecekte nasıl üretileceğini düşün. Training sırasında kolay olan feature inference'ta imkansız olabilir.

18. Rolling features

```
df["ma_7"] = (
    df["sales"].shift(1).rolling(7).mean()
)
df["std_28"] = (
    df["sales"].shift(1).rolling(28).std()
)
```

Neden shift(1)?
Bugünkü target değerinin bugünkü feature'a sızmasını engellemek için.

19. Calendar ve cyclical features

Feature	Örnek
Calendar	day_of_week, month, quarter
Flag	is_weekend, is_month_end
Holiday	is_holiday, days_to_holiday

Cyclical	sin/cos(hour), sin/cos(day_of_week)

```
df["dow_sin"] = np.sin(2*np.pi*df["dow"]/7)
df["dow_cos"] = np.cos(2*np.pi*df["dow"]/7)
```

20. ML tabanlı forecasting

Lag, rolling, calendar ve exogenous feature'lar oluşturulduktan sonra problem tabular supervised learning'e çevrilebilir.

Model	Avantaj
Linear/Ridge	Basit ve hızlı baseline
Random Forest	Nonlinear ilişkiler
XGBoost/LightGBM/CatBoost	Tabular güçlü performans
Neural Networks	Büyük/çok serili problemlerde potansiyel

```
features = ["lag_1","lag_7","ma_7","dow","price","promo"]
model.fit(train[features], train["sales"])
```

21. Direct vs recursive multi-step forecasting

Strateji	Mantık	Risk
Recursive	t+1 tahminini sonraki adım feature'ı olarak kullan	Error accumulation
Direct	Her horizon için ayrı model	Daha fazla model
Multi-output	Bir model tüm horizon vektörünü üretir	Model karmaşıklığı

Horizon önemlidir
1 gün ileri iyi modelin 30 gün ileri performansı otomatik iyi değildir. Metric horizon bazında raporlanmalı.

22. Walk-forward validation

1. İlk training window ile modeli kur.
2. Bir sonraki zaman penceresini tahmin et.
3. Training window'u ileri taşı/genişlet.
4. Her fold sonucunu kaydet.
5. Horizon ve segment bazında hata dağılımını raporla.

Gerçeğe en yakın test
Forecast sistemi production'da zaman ilerledikçe yeniden eğitilecekse expanding/rolling backtest bunu taklit eder.

23. TimeSeriesSplit

```
from sklearn.model_selection import TimeSeriesSplit

tscv = TimeSeriesSplit(n_splits=5)

for train_idx, valid_idx in tscv.split(X):
    X_train, X_valid = X.iloc[train_idx], X.iloc[valid_idx]
```

Gap
Label veya rolling window overlap leakage yaratıyorsa train-valid arasında gap/embargo gerekebilir.

24. Forecasting metrikleri

Metric	Güçlü yön	Risk
MAE	Kolay yorum	Scale bağımlı
RMSE	Büyük hataları cezalandırır	Outlier duyarlı
MAPE	Yüzdesel yorum	Zero/near-zero target sorunu
sMAPE	Daha dengeli yüzdesel yapı	Özel durumlar
WAPE	Toplam hacim odaklı	Segment bias gizleyebilir
MASE	Naive baseline'a ölçekli	Daha az bilinir

Metric business ile uyumlu olmalı
Stok-out maliyeti overforecast maliyetinden farklıysa asymmetric custom loss daha doğru olabilir.

25. Prediction interval

Point forecast tek sayı verir; prediction interval gelecekteki belirsizliği ifade eder. Planlama ve risk yönetiminde çoğu zaman daha değerlidir.

- Classical models: analytic intervals.
- Quantile regression: P10/P50/P90 gibi quantiles.
- Conformal prediction: distribution-light uncertainty yaklaşımı.

26. Hierarchical forecasting

Store -> region -> country veya SKU -> category -> total gibi hiyerarşilerde alt seviye forecast toplamları üst seviye forecast ile tutarlı olmalıdır.

Yaklaşım	Mantık
Bottom-up	Alt serileri tahmin edip topla
Top-down	Üst toplamı tahmin edip dağıt
Reconciliation	Farklı seviyeleri tutarlı hale getir

27. Intermittent demand

Yedek parça gibi birçok sıfır ve arada talep içeren seriler klasik yöntemleri zorlar.

- Zero-inflated yapı.
- Demand occurrence ve size ayrı modellenebilir.
- Croston ailesi gibi specialized yöntemler düşünülebilir.

MAPE dikkat
Target sıklıkla 0 ise MAPE uygun değildir.

28. Multiple time series / global models

Binlerce SKU/store serisini tek tek modellemek yerine ortak bir global model series ID ve ortak feature'larla birden çok seriden birlikte öğrenebilir.

Avantaj
Az gözlemli seriler güçlü serilerden ortak pattern öğrenebilir; ancak heterogeneity yönetilmelidir.

29. Missing dates ve irregular time

- Beklenen timestamp grid'ini oluştur.
- Eksik tarih gerçekten 0 mı yoksa missing mi belirle.
- Resampling/aggregation kararını business grain'e göre ver.
- Timezone ve DST değişimlerini kontrol et.

30. Outliers ve events

Kampanya, stok-out, sistem kesintisi veya tek seferlik event outlier gibi görünebilir ama business olarak gerçek mekanizma olabilir.

Silme yerine açıklama
Event flag, stock availability veya promotion feature ile nedeni temsil etmek çoğu zaman daha doğrudur.

31. Leakage örnekleri

Leakage	Neden yanlış
Centered rolling mean	Geleceği pencereye alır
shift(-1)	Future target
Random split	Gelecek train'e girebilir
Future promo actual	Tahmin anında bilinmiyorsa leak
Full-series scaling	Future distribution sızabilir

As-of düşün
Her feature için: bu değeri cutoff tarihinde gerçekten biliyor muydum?

32. Forecasting pipeline

6. Business horizon ve grain tanımla.
7. Regular timeline ve data quality kontrolü yap.
8. Naive + seasonal-naive baseline kur.
9. Trend/seasonality/ACF incele.
10. Temporal backtest tasarla.
11. Classical + ML modeller karşılaştır.
12. Horizon/segment metrics raporla.
13. Prediction interval üret.
14. Production retraining ve monitoring planı yap.

33. Gerçek vaka: perakende talep tahmini

Adım	Karar
Grain	store-SKU-day
Horizon	14 gün
Features	lag 1/7/14/28, rolling 7/28, price, promo, holiday
Validation	4 walk-forward fold
Baselines	seasonal naive lag-7
Models	LightGBM + SARIMA baseline
Metrics	WAPE + MAE + stock-out weighted cost
Output	P50 + P90 demand

Business etki
Amaç yalnız WAPE düşürmek değil; stock-out ve excess inventory maliyetini birlikte azaltmak.

34. Gerçek vaka: çağrı merkezi

Saatlik çağrı hacmi forecast edilerek agent planlaması yapılır.

- Hour-of-day ve day-of-week seasonality.
- Holiday/event etkileri.
- Lag 24/168 ve rolling windows.
- Underforecast overtime/queue maliyeti, overforecast idle capacity maliyeti.

35. Model karşılaştırma matrisi

Model	Güçlü	Zayıf
Seasonal Naive	Çok basit, sağlam	Trend değişimini kaçırır
Holt-Winters	Trend+seasonality	Exogenous sınırlı
ARIMA/SARIMA	İstatistiksel yapı, interval	Parametre/linearity
Prophet yaklaşımı	Takvim/event kolay	Her veri setinde üstün değil
Boosting + lags	Güçlü tabular nonlinear	Feature engineering gerekir
Deep global model	Çok seri ve büyük veri	Daha karmaşık

36. Monitoring

- Forecast error zaman içinde.
- Bias: sürekli under/over forecast.
- Horizon-specific error.
- Feature/data drift.
- Prediction interval coverage.
- Retraining cadence.

Bias metriği
Ortalama signed error sıfırdan sapıyorsa model sistematik over/under forecast yapıyor olabilir.

37. Python - feature engineering şablonu

```
df = df.sort_values(["store_id", "date"])

g = df.groupby("store_id")["sales"]

df["lag_1"] = g.shift(1)
df["lag_7"] = g.shift(7)

df["ma_7"] = (
   g.shift(1)
    .rolling(7)
    .mean()
    .reset_index(level=0, drop=True)
)
```

38. Python - backtest iskeleti

```
cutoffs = ["2026-06-01", "2026-07-01", "2026-08-01"]

for cutoff in cutoffs:
   train = df[df.date < cutoff]
   valid = df[(df.date >= cutoff) &
           (df.date < cutoff + pd.Timedelta(days=14))]

   model.fit(train[features], train[target])
   pred = model.predict(valid[features])
```

39. Mülakat soruları

Soru	Kısa cevap
Time series random split neden sorun?	Future observations training içine girerek leakage yaratabilir.
Trend ve seasonality farkı?	Trend uzun dönem yön, seasonality sabit periyodik tekrar.
Naive baseline nedir?	Son gözlem gibi basit geçmiş değerini forecast olarak kullanmak.
ARIMA p,d,q?	AR order, differencing order, MA order.

SARIMA ne ekler?	Seasonal P,D,Q ve season period s.
Lag feature nedir?	Geçmiş değerleri supervised feature olarak kullanmak.
Rolling feature'da niye shift?	Current/future target leakage'ini önlemek.
MAPE sorunu?	Zero ve near-zero targetlarda patlar.
Walk-forward validation?	Zaman ilerledikçe train window ile sonraki dönemi tekrar tekrar tahmin etmek.
Direct vs recursive?	Her horizon için ayrı model vs tahminleri ardışık beslemek.
Exogenous feature riski?	Forecast horizon için değer gerçekten bilinmiyorsa leakage/availability sorunu.
Prediction interval neden?	Planlama için forecast belirsizliğini gösterir.
Global model nedir?	Birçok seriyi ortak modelde birlikte öğrenmek.
Seasonal naive ne zaman güçlü?	Stabil, güçlü seasonality olduğunda.

40. Uygulama alıştırmaları

15. Bir günlük satış serisinde naive ve seasonal-naive baseline karşılaştır.
16. ACF/PACF grafikleri üret ve olası lag yapılarını yorumla.
17. ARIMA ve Holt-Winters modellerini walk-forward backtest ile kıyasla.
18. Lag 1/7/28 ve rolling 7/28 feature ile LightGBM/XGBoost modeli kur.
19. Random split ile temporal split skor farkını gözlemle.
20. 14 günlük horizon için horizon bazında MAE eğrisi çıkar.
21. MAPE ve WAPE sonuçlarını sıfırlı target üzerinde karşılaştır.
22. Promotion feature'ın future availability durumunu iki senaryo ile test et.
23. Quantile regression ile P50/P90 forecast üret.
24. Store-SKU segmentlerinde forecast bias dashboard'u oluştur.

41. Mini portföy projesi

Proje: Retail Demand Forecasting - Backtesting + Classical + ML

Çıktı	İçerik
01_problem.md	Grain, horizon, cost ve feature availability
02_eda.ipynb	Trend/seasonality/ACF ve data gaps
03_baselines.ipynb	Naive, seasonal naive, moving average
04_classical.ipynb	Holt-Winters, SARIMA
05_ml.ipynb	Lag/rolling/calendar + boosting
06_backtest.ipynb	Walk-forward CV ve horizon metrics
07_uncertainty.ipynb	P50/P90 veya interval
report.md	Model selection + inventory recommendation

CV cümlesi
Built a retail-demand forecasting system with leakage-safe lag/rolling features, walk-forward backtesting, seasonal baselines, classical time-series models and gradient boosting, including horizon-level error and uncertainty analysis.

42. Final cheat sheet

Kavram	Hatırlanacak fikir
Trend	Uzun dönem yön
Seasonality	Sabit periyotlu tekrar
Lag	Geçmiş gözlem
Rolling	Geçmiş pencere özeti
Naive	Son değeri taşı
Seasonal naive	Geçen periyodu taşı
ARIMA	AR + differencing + MA
SARIMA	Seasonal ARIMA
Prophet yaklaşımı	Trend + seasonality + holiday
Backtest	Geçmişten geleceğe tekrar değerlendirme
MAE/RMSE	Scale bazlı hata
WAPE	Toplam hacme göre hata
MAPE	Zero target riskli
Prediction interval	Belirsizlik
Direct/recursive	Multi-step strateji
Leakage	Future information yasak

Bu modülden sonra
NLP bölümüne geçerken sequential data kavramının time series ve language modelleme arasında nasıl farklılaştığını daha net görebileceksin.