44

DATA ETHICS & GOVERNANCE

Bias • Fairness • Privacy • Governance • Explainability • Security

Amaç: Bir veri bilimcinin yalnızca doğru model kurmasını değil, modelin kimleri etkilediğini, hangi verileri kullandığını, hangi riskleri doğurduğunu ve üretimde nasıl denetlenmesi gerektiğini sistematik olarak değerlendirebilmesini sağlamak.

Bu modülün sonunda; etik riskleri teknik kontrollerle ilişkilendirecek, adalet metriklerini yorumlayacak, veri gizliliği ve yönetişim ilkelerini uygulayacak, model kartı/datasheet hazırlayacak ve bir ML sistemine risk temelli governance katmanı tasarlayabileceksin.

Bölüm	Odak
1-4	Etik düşünme, risk ve sorumluluk
5-8	Bias, fairness, privacy, security
9-12	Explainability, governance, yaşam döngüsü kontrolleri
13-16	2026 çerçeveleri, vaka, mülakat, kontrol listesi

Temel fikir: Etik, modelden sonra eklenen bir “compliance kutusu” değildir. Veri toplama anından deployment ve monitoring’e kadar tüm ML yaşam döngüsünün tasarım kriteridir.

1. Data Ethics Nedir?

Data ethics; verinin nasıl toplandığı, işlendiği, paylaşıldığı ve karar sistemlerinde nasıl kullanıldığıyla ilgili hak, zarar, adalet, özerklik, hesap verebilirlik ve toplumsal etki sorularını inceler.

1.1 Teknik doğruluk neden yetmez?

Teknik soru	Etik / yönetişim sorusu
Modelin AUC değeri yüksek mi?	Hata maliyeti gruplar arasında dengesiz mi?
Tahmin doğru mu?	Tahmin insanların hak veya fırsatlarını etkiliyor mu?
Veri çok mu?	Bu veriyi toplamak gerekli ve meşru mu?
Feature güçlü mü?	Feature hassas bir özelliğin proxy'si mi?
Sistem otomatik mi?	İnsan itirazı, düzeltme veya override mekanizması var mı?

1.2 Altı temel etik ilke

- Zarar vermeme: Modelin hata ve yan etkilerini sistematik biçimde azalt.
- Fayda: Sistemin gerçek ve ölçülebilir bir iş/kullanıcı faydası üretmesini hedefle.
- Adalet: Benzer durumda olan kişilere keyfi biçimde farklı davranılmasını önle.
- Özerklik: Kullanıcıların önemli otomatik kararlarda bilgi, seçim ve itiraz imkanını koru.
- Şeffaflık: Sistemin amacı, sınırları ve önemli karar mantığı anlaşılabilir olmalı.
- Hesap verebilirlik: "Model yaptı" bir sorumluluk mekanizması değildir; sahiplik ve karar yetkisi tanımlanmalıdır.

Mülakat cümlesi: "Ethical ML, yalnızca fairness metriği hesaplamak değildir; problem framing, veri, model, deployment ve insan süreçleri birlikte değerlendirilmelidir."

2. Risk Temelli Düşünme

Her model aynı governance seviyesine ihtiyaç duymaz. Film öneri sistemi ile kredi onayı, işe alım veya sağlık triyaj modeli aynı risk sınıfında değildir. Bu yüzden önce modelin risk bağlamı tanımlanmalıdır.

2.1 Risk = olasılık × etki

Basit risk modeli

```
Risk ≈ P(olumsuz olay) × Etki

Beklenen zarar = Σ P(hata_i) × maliyet(hata_i)
```

Risk boyutu	Sorular
Kişisel etki	Karar kişinin gelirini, sağlığını, eğitimini, işini veya haklarını etkiliyor mu?
Ölçek	Bir hata kaç kişiyi etkileyebilir?
Geri döndürülebilirlik	Hatalı karar kolayca düzeltilebilir mi?
Otomasyon	İnsan incelemesi var mı, yoksa model kararı otomatik mi uyguluyor?
Veri hassasiyeti	Sağlık, biyometri, finans, konum gibi hassas veri kullanılıyor mu?
Belirsizlik	Modelin çalışacağı ortam eğitim verisinden hızlıca sapabilir mi?

2.2 Risk tier yaklaşımı

Seviye	Örnek	Kontrol yoğunluğu
Düşük	İçerik sıralama / basit talep tahmini	Temel kalite, güvenlik, logging
Orta	Churn / fiyat önerisi / müşteri segmentasyonu	Fairness review, model card, monitoring
Yüksek	Kredi, işe alım, sağlık, eğitim erişimi	Bağımsız review, güçlü dokümantasyon, human oversight, audit trail

Pratik kural: Risk yükseldikçe yalnızca model testleri değil; onay mekanizması, dokümantasyon, izleme sıklığı ve insan denetimi de güçlenmelidir.

3. Bias: Önyargı Nereden Gelir?

Bias, modelin “kötü niyetli” olması değildir. Çoğu zaman veri üretim sürecindeki sistematik bozulmaların, ölçüm hatalarının veya geçmiş kararların modele taşınmasıdır.

Bias türü	Açıklama	Örnek
Historical bias	Geçmiş dünyadaki eşitsizlik veriye yansır.	Geçmiş işe alımlar belirli bir grubu sistematik az seçmiş olabilir.
Sampling bias	Örneklem hedef popülasyonu temsil etmez.	Mobil uygulama kullanıcıları tüm müşteri kitlesi sanılır.
Measurement bias	Ölçülen değişken gerçek kavramı farklı kalitede temsil eder.	Sağlık ihtiyacı yerine sağlık harcaması proxy olarak kullanılır.
Label bias	Etiket taraflı veya eksik süreçten gelir.	Dolandırıcılık etiketi yalnızca incelenen işlemlerden oluşur.
Aggregation bias	Farklı alt gruplar tek model altında ezilir.	Farklı hasta gruplarında aynı model kullanılır.
Deployment bias	Model amaçlanandan farklı süreçte kullanılır.	Risk skoru doğrudan otomatik ret kararına dönüşür.

3.1 Proxy değişkenler

Model protected attribute kullanmasa bile posta kodu, okul, harcama örüntüsü veya cihaz türü gibi feature’lar hassas özelliklerle güçlü korelasyon taşıyabilir. “Sensitive column’ı sildim” fairness garantisi değildir.

Leakage ile bias farklıdır: Leakage tahmin performansını yapay olarak şişirir; bias ise temsil, ölçüm veya karar süreçlerinde sistematik dezavantaj üretebilir. İkisi aynı projede birlikte de bulunabilir.

4. Fairness: Tek Bir Tanımı Yoktur

Fairness bağlama bağlıdır ve farklı matematiksel tanımlar birbiriyle çelişebilir. Bu nedenle “hangi fairness metriği?” sorusundan önce “hangi zararı önlemeye çalışıyoruz?” sorusu sorulmalıdır.

4.1 Temel grup fairness metrikleri

Metrik	Fikir	Form
Demographic parity	Pozitif karar oranı gruplar arasında benzer olsun.	$P(\hat{y}=1 \mid A=a) \approx P(\hat{y}=1 \mid A=b)$
Equal opportunity	Gerçek pozitifler için TPR gruplar arasında benzer olsun.	$TPR_a \approx TPR_b$
Equalized odds	TPR ve FPR birlikte benzer olsun.	$TPR_a \approx TPR_b$ ve $FPR_a \approx FPR_b$
Predictive parity	Pozitif tahminin doğruluğu gruplarda benzer olsun.	$PPV_a \approx PPV_b$
Calibration	Aynı risk skoru farklı gruplarda benzer gerçek risk anlamına gelsin.	$P(Y=1 \mid score=s, A=a) \approx s$

4.2 Fairness trade-off

Base rate’lerin farklı olduğu durumlarda bazı fairness kriterlerini aynı anda tam olarak sağlamak matematiksel olarak mümkün olmayabilir. Bu nedenle metrik seçimi normatif bir karardır ve domain paydaşlarıyla belirlenmelidir.

Örnek hesaplama

```
selection_rate = positive_predictions / group_size
disparate_impact = selection_rate_group_A / selection_rate_group_B

# Oran tek başına hukuki veya etik karar değildir; bağlam gerekir.
```

Dikkat: Fairness metriği “checklist puanı” değildir. Metrik, hatanın kimde ne sonuç yarattığıyla birlikte yorumlanmalıdır.

5. Fairness Analizi Nasıl Yapılır?

5.1 Sistematik akış

1. Etkilenen grupları ve kararın zarar türlerini tanımla.
2. Protected/sensitive attribute kullanımının meşru ve güvenli biçimde analiz edilip edilemeyeceğini belirle.
3. Genel performans + grup bazlı confusion matrix çıkar.
4. TPR, FPR, precision, calibration, selection rate gibi bağlama uygun metrikleri karşılaştır.
5. Küçük örneklemlerde güven aralıklarını ve istatistiksel belirsizliği kontrol et.
6. Bias kaynağını teşhis et: veri, label, feature, threshold, süreç.
7. Mitigation uygula ve performans/fairness trade-off'unu yeniden ölç.
8. Deployment sonrası aynı metrikleri izlemeye devam et.

5.2 Mitigation katmanları

Aşama	Yöntemler
Pre-processing	Daha dengeli veri toplama, reweighting, label audit, veri kalite iyileştirme
In-processing	Class weights, fairness-aware objective/constraints, regularization
Post-processing	Threshold ayarı, human review bölgesi, belirsiz vakaları escalation
Process	Appeal mekanizması, ikinci inceleme, kararın açıklanması, audit logging

En iyi çözüm çoğu zaman model değildir: Bias label üretiminden geliyorsa yeni algoritma yerine label sürecini düzeltmek daha etkili olabilir.

6. Privacy ve Veri Minimizasyonu

Privacy, veriyi yalnızca “kimse görmesin” diye saklamak değildir. Hangi verinin neden toplandığını, ne kadar tutulduğunu, kimlerin eriştiğini ve hangi amaçla işlendiğini sınırlar.

6.1 Privacy by design ilkeleri

- Purpose limitation: Veri belirli ve meşru amaç için toplanmalıdır.
- Data minimization: İhtiyaç olmayan alanı toplama.
- Storage limitation: Veriyi sonsuza kadar tutma; retention politikası tanımla.
- Access control: Least privilege uygula.
- Security: Şifreleme, secret yönetimi, audit log kullan.
- Transparency: Kullanıcıya verisinin nasıl kullanıldığı açıkça anlatılmalı.

6.2 Anonimleştirme kavramları

Kavram	Açıklama
Pseudonymization	Kimlik doğrudan görünmez ancak ek bilgiyle yeniden eşleştirilebilir.
Anonymization	Kişiyi makul yöntemlerle yeniden tanımlamak pratikte mümkün olmamalıdır.
k-anonymity	Her kayıt, quasi-identifier kombinasyonunda en az k kayıtla ayırt edilemez olur.
Differential privacy	Tek bir bireyin veri setine eklenip çıkarılmasının çıktıyı sınırlı etkilemesini matematiksel olarak kontrol eder.

Differential privacy sezgisi

```
P[M(D) ∈ S] ≤ exp(ε) × P[M(D') ∈ S] + δ

ε küçüldükçe daha güçlü privacy, genellikle daha fazla utility kaybı.
```

GDPR ilkesi örneği: GDPR Article 5; lawfulness/fairness/transparency, purpose limitation ve data minimisation gibi temel işleme ilkelerini tanımlar. Bu modül hukuki danışmanlık değil, teknik farkındalık sağlar.

7. ML Security ve Abuse Riskleri

AI/ML güvenliği klasik uygulama güvenliğinin üzerine yeni saldırı yüzeyleri ekler. Model endpoint'i, training data, feature pipeline, model artefact ve GenAI prompt/output zinciri ayrı ayrı korunmalıdır.

Risk	Örnek	Kontrol
Data poisoning	Training verisine manipülatif kayıt ekleme	Kaynak doğrulama, lineage, anomaly checks
Model extraction	API sorgularıyla model davranışını kopyalama	Rate limit, auth, output minimization
Membership inference	Bir kaydın train setinde olup olmadığını çıkarma	Privacy değerlendirmesi, regularization, DP
Adversarial input	Küçük input değişimiyle modeli yanıltma	Robustness test, input validation
Prompt injection	LLM'e talimat zincirini manipüle ettirme	Tool permissions, sanitization, isolation, evals
Sensitive output	Modelin gizli/kişisel veri sızdırması	DLP, redaction, output filters, access control

7.1 Threat modeling soruları

- Korumaya çalıştığımız asset nedir? Veri mi, model mi, karar mı, kullanıcı hesabı mı?
- Saldırgan kim olabilir ve hangi yetkiye sahip?
- En kritik attack surface hangisi? API, upload, model registry, data pipeline?
- Başarılı saldırının finansal, hukuki veya güvenlik etkisi nedir?
- Tespit ve recovery mekanizmamız var mı?

8. Explainability ve Interpretability

Explainability, modelin her detayını “insan gibi açıklaması” değildir. İhtiyaç; geliştirici, denetçi, etkilenen kullanıcı ve yönetici için farklıdır. Açıklamanın hedefi baştan belirlenmelidir.

Yöntem	Tür	Güçlü yanı	Sınır
Linear coefficients	Global	Doğrudan yorum	Ölçek ve korelasyona duyarlı
Tree rules	Global/local	Sezgisel olabilir	Büyük ağaçlarda karmaşık
Permutation importance	Global	Model-agnostic	Korelasyonlu feature’larda yanıltabilir
PDP	Global	Ortalama ilişkiyi gösterir	Gerçekçi olmayan feature kombinasyonları
SHAP	Local + global	Zengin katkı açıklaması	Hesap maliyeti ve yanlış nedensellik yorumu riski

8.1 Açıklama ≠ nedensellik

Kritik hata: “SHAP değeri yüksek, demek ki bu özellik sonucu oluşturdu” demek yanlıştır. SHAP model davranışını açıklar; dünyadaki nedensel mekanizmayı kanıtlamaz.

8.2 Açıklanabilir karar tasarımı

- Kararın hangi veri kaynaklarına dayandığını göster.
- Kullanıcıya etkili faktörleri anlaşılır dilde aktar.
- Model uncertainty yüksekse bunu saklama.
- Düzeltilebilir feature ile değiştirilemez feature’ı ayır.
- Appeal / human review yolunu açıkça sun.

9. Data Governance

Data governance; verinin sahipliğini, kalitesini, erişimini, tanımlarını, yaşam döngüsünü ve uyumluluğunu kurumsal olarak yönetir. İyi governance olmadan ML sistemleri tekrarlanabilir ve denetlenebilir değildir.

Bileşen	Ne sağlar?
Data ownership	Hangi datasetin sorumlusu kim?
Data catalog	Dataset, kolon, tanım ve kullanım alanlarını bulabilme
Data lineage	Veri nereden geldi, hangi dönüşümlerden geçti?
Data quality	Completeness, validity, freshness, consistency kontrolleri
Access governance	Kim hangi veriyi neden görebiliyor?
Retention	Ne kadar süre tutuluyor ve ne zaman siliniyor?
Classification	Public / internal / confidential / restricted gibi sınıflandırma

9.1 Data contract örneği

Basitleştirilmiş data contract

```
dataset: transactions_v3
owner: payments-data
primary_key: transaction_id
required_columns:
  - amount: float >= 0
  - event_time: timestamp
  - country: ISO-3166
freshness_sla: < 15 minutes
pii: [customer_id]
retention: 365 days
```

ML bağlantısı: Feature pipeline'ın kaynağı değiştiğinde model bozuluyorsa bu yalnızca "model problemi" değildir; lineage, schema ve data contract eksikliği olabilir.

10. Model Governance

Model governance; bir modelin kim tarafından geliştirildiğini, nasıl onaylandığını, hangi veri ve kodla üretildiğini, hangi sınırlar içinde kullanılacağını ve ne zaman emekli edileceğini kontrol eder.

10.1 Minimum governance artefact'ları

Artefact	İçerik
Model card	Amaç, kullanıcı, performans, alt grup metrikleri, sınırlar, etik riskler
Dataset / datasheet	Kaynak, toplama yöntemi, popülasyon, label, eksikler, hassas alanlar
Experiment record	Kod, data version, parametre, metric, random seed
Approval record	Kim review etti, hangi riskler kabul edildi?
Deployment record	Hangi model sürümü nerede çalışıyor?
Monitoring plan	Hangi metric, threshold ve escalation akışı kullanılacak?
Retirement plan	Model ne zaman ve hangi koşulda kapatılacak?

10.2 Model registry metadata

Örnek metadata

```
model_version: fraud-v18
data_version: tx-2026-09-15
git_commit: 7ac3f91
auc: 0.941
recall_at_fpr_1pct: 0.73
fairness_review: approved_with_monitoring
risk_tier: high
owner: fraud-ml
expiry_review: 2026-12-15
```

11. ML Yaşam Döngüsünde Governance Kontrolleri

Aşama	Kontrol soruları
Problem framing	Model gerekli mi? Karar otomasyonu uygun mu? Başarı ve zarar nasıl ölçülecek?
Data collection	Amaç, consent/legal basis, minimization, temsil yeterli mi?
Labeling	Label nasıl üretildi? Annotator bias veya selective labels var mı?
Training	Reproducibility, leakage, subgroup test, security tamam mı?
Validation	Business + technical + fairness + robustness review yapıldı mı?
Deployment	Human oversight, rollback, auth, logging var mı?
Monitoring	Drift, fairness, incident, complaint sinyalleri izleniyor mu?
Retirement	Artefact, endpoint, data ve erişimler güvenli şekilde kapatıldı mı?

11.1 Three lines of defense yaklaşımı

- 1. hat: Modeli geliştiren ürün/veri ekibi - riskin günlük sahibi.
- 2. hat: Risk, privacy, security, compliance - politika ve bağımsız challenge.
- 3. hat: Internal audit - governance sisteminin gerçekten çalışıp çalışmadığını denetler.

Anti-pattern: Aynı kişi modeli geliştirip, riskini değerlendirip, production onayını tek başına veriyorsa yüksek riskli sistemlerde bağımsız challenge mekanizması zayıftır.

12. Monitoring: Etik Riskler Production'da Değişir

Fairness ve güvenilirlik yalnızca offline validation anında ölçülmez. Kullanıcı davranışı, ürün akışı ve veri dağılımı değiştikçe modelin etkisi de değişebilir.

Sinyal	Örnek metrik
Data drift	PSI, feature distribution distance, missing rate
Performance drift	AUC, recall, precision, calibration error
Fairness drift	TPR/FPR gap, selection rate gap, calibration gap
Operational risk	Latency, error rate, fallback rate
Human signals	Override rate, appeal rate, complaint rate
Security	Abnormal request patterns, auth failures, injection attempts

12.1 Escalation tasarımı

Örnek incident akışı

```
if critical_metric_breach:
    disable_automation()
    route_to_human_review()
    page_on_call()
    freeze_model_version()
    open_incident_ticket()

# Monitoring yalnızca dashboard değildir; bir aksiyon akışına bağlanmalıdır.
```

Shadow mode: Yüksek riskli yeni modeller doğrudan karar vermek yerine bir süre mevcut sistemin yanında gölge modda çalıştırılabilir. Böylece davranış ve alt grup etkileri production verisiyle gözlenir.

13. 2026 Governance Çerçeveleri - Ne Bilmelisin?

Bir veri bilimcinin hukukçu olması gerekmez; ancak hangi çerçevelerin organizasyonun risk ve dokümantasyon beklentilerini şekillendirdiğini bilmesi gerekir. Aşağıdaki bölüm teknik farkındalık içindir, hukuki danışmanlık değildir.

Çerçeve	2026 açısından önemli nokta
GDPR	Kişisel veri işlemede lawfulness/fairness/transparency, purpose limitation ve data minimisation gibi ilkeler temel referanstır.
EU AI Act	Risk temelli düzenleme. Avrupa Komisyonu kaynaklarına göre 2 Ağustos 2026'dan itibaren önemli uygulama ve enforcement aşamaları başladı; bazı yüksek riskli sistem kuralları daha ileri tarihlerde uygulanmaktadır.
NIST AI RMF	Gönüllü risk yönetim çerçevesi; Govern, Map, Measure, Manage fonksiyonlarıyla AI risklerini yaşam döngüsünde ele alır. NIST 2026'da AI RMF 1.0'ın revize edilmekte olduğunu belirtiyor.
ISO/IEC 42001:2023	AI Management System (AIMS) kurmak, uygulamak, sürdürmek ve sürekli iyileştirmek için yönetim sistemi standardıdır.

13.1 NIST AI RMF zihinsel modeli

Function	Soru
GOVERN	Politika, rol, sorumluluk ve risk kültürü var mı?
MAP	Kullanım bağlamı, paydaşlar ve zarar senaryoları anlaşıldı mı?
MEASURE	Riskleri hangi teknik ve sosyo-teknik testlerle ölçüyoruz?
MANAGE	Ölçülen risklere göre neyi azaltıyor, kabul ediyor, izliyor veya durduruyoruz?

2026 notu: Regülasyon takvimleri değişebilir. Gerçek bir proje veya şirket politikası için her zaman güncel resmi metin ve hukuk/compliance ekibiyle doğrulama yapılmalıdır.

14. Gerçek Vaka: Kredi Risk Modeli

Senaryo: Banka, kredi başvurularını hızlandırmak için default risk modeli geliştiriyor. Model başvuru sahibine 0-1 arasında risk skoru üretiyor; yüksek skor ret kararına yol açabiliyor.

14.1 Risk analizi

Katman	Analiz
Problem	Yanlış ret müşterinin finansal fırsatını ciddi etkileyebilir.
Data	Gelir, borç, ödeme geçmişi yanında postcode gibi proxy riskleri incelenmeli.
Label	Geçmişte kredi verilmeyen kişiler için “geri öder miydi?” etiketi bilinmiyor: selective labels.
Fairness	Grup bazlı TPR/FPR, approval rate, calibration ve hata maliyeti incelenmeli.
Explainability	Ret nedenleri anlaşılır ve aksiyon alınabilir biçimde sunulmalı.
Human oversight	Borderline veya düşük güvenli vakalar manuel incelemeye yönlendirilebilir.
Monitoring	Default rate, approval rate ve grup farkları zaman içinde izlenmeli.
Appeal	Müşteri yanlış/veri hatalı karar için itiraz ve düzeltme kanalı bulabilmeli.

14.2 Teknik tasarım

Karar akışı

```
Input -> validation -> feature service -> model
      -> risk score + confidence
      -> policy engine
          if low_confidence: human_review
          elif score > threshold: adverse_action_review
          else: approve
      -> explanation + audit log
      -> monitoring
```

Asıl ders: Model skoru ile nihai iş kararı arasına policy, insan denetimi ve audit katmanı koymak çoğu yüksek etkili kullanımda kritik bir tasarım tercihidir.

15. Mülakat Soruları ve Cevap Çerçeveleri

Soru	Güçlü cevap omurgası
Model protected attribute kullanmıyorsa adil midir?	Hayır. Proxy değişkenler, temsil hataları ve label bias nedeniyle ayrımcı etkiler devam edebilir. Grup bazlı outcome/hata analizi gerekir.
Demographic parity her zaman hedef olmalı mı?	Hayır. Kullanım bağlamına göre equal opportunity, calibration veya zarar odaklı başka kriterler daha anlamlı olabilir.
Fairness ile accuracy çatışırsa ne yaparsın?	Tek metric optimize etmem. Hata maliyetlerini, paydaşları, hukuki/etik sınırları ve risk toleransını tanımlar; Pareto trade-off'u karar sahiplerine sunarım.
PII kolonunu silmek privacy için yeterli mi?	Hayır. Quasi-identifiers, re-identification, access, retention ve purpose limitation gibi konular da vardır.
Explainable model mi, açıklama yöntemi mi?	Yüksek riskte mümkünse intrinsically interpretable seçenekleri değerlendiririm; karmaşık model gerekiyorsa post-hoc açıklamaların sınırlarını açıkça dokümante ederim.
Model governance neden Data Scientist'in işi?	Tamamı DS'in işi değildir; fakat model card, data lineage, test, risk ve monitoring artefact'larını üretmek DS'in teknik sorumluluklarının parçasıdır.
Production fairness nasıl izlenir?	Delayed labels varsa proxy/leading indicators kullanır, labels geldikçe grup bazlı gerçek performansı yeniden hesaplar ve threshold breach'lerini escalation'a bağlar.
Ethical issue fark edersen?	Etkiyi ve kanıtı dokümante eder, owner/risk kanallarına escalate eder, gerekiyorsa deployment'ı durdurma/geri alma seçeneğini savunurum.

16. Uygulama Projesi: Responsible ML Audit

Bir churn, kredi, fraud veya işe alım dataset seç. Amaç yalnızca model kurmak değil; modelin governance paketini üretmek.

Teslimatlar

- Problem & harm map: Kim etkileniyor, yanlış pozitif/negatif ne zarar verir?
- Dataset datasheet: kaynak, örnekleme, label üretimi, eksikler, sensitive/proxy alanlar.
- Baseline model + genel performans.
- Subgroup performance ve fairness analizi.
- Privacy & security threat checklist.
- Explainability analizi ve yanlış nedensellik yorumlarına karşı notlar.
- Model card: intended use, out-of-scope use, limitations, metrics.
- Monitoring & incident plan.
- Executive risk memo: deploy / limited pilot / block gibi karar alternatifleri ve koşulları.

Önerilen repo

Portföy yapısı

```
responsible-ml-audit/
├── README.md
├── data/README.md
├── notebooks/
│   ├── 01_data_audit.ipynb
│   ├── 02_model.ipynb
│   └── 03_fairness_explainability.ipynb
├── src/
│   ├── metrics.py
│   └── monitoring.py
├── governance/
│   ├── model_card.md
│   ├── datasheet.md
│   ├── risk_register.csv
│   └── monitoring_plan.md
└── tests/
```

Portföy avantajı: Bu proje yalnızca “model accuracy” göstermediğin için seni ürün, risk ve production düşüncesine yakınlaştırır. Seniorlaşma yolunda güçlü bir sinyaldir.

17. Final Kontrol Listesi

Alan	Kontrol
Problem	Model gerçekten gerekli mi? Kararın etkilediği hak/fırsatlar tanımlandı mı?
Data	Kaynak, consent/legal basis, quality, lineage, minimization incelendi mi?
Bias	Sampling, measurement, label, proxy ve deployment bias kontrol edildi mi?
Fairness	Uygun metrik seçildi ve alt grup belirsizliği değerlendirildi mi?
Privacy	Access, retention, re-identification ve leakage riskleri ele alındı mı?
Security	Threat model, auth, logging, abuse kontrolleri var mı?
Explainability	Hedef kullanıcıya uygun açıklama ve sınırlamalar var mı?
Governance	Owner, approver, model card, registry ve audit trail mevcut mu?
Deployment	Human oversight, rollback ve safe fallback tanımlı mı?
Monitoring	Performance + fairness + drift + complaint sinyalleri izleniyor mu?
Incident	Breach olursa kim, ne zaman, hangi aksiyonu alacak?
Retirement	Modeli kapatma ve erişimleri temizleme planı var mı?

Özet zihinsel model

Tek sayfalık akış

```
RESPONSIBLE ML

Problem → Harm map → Data governance → Bias/Fairness
       → Privacy/Security → Model/Explainability
       → Independent review → Controlled deployment
       → Monitoring/Incident → Reassessment/Retirement
```

Son cümle: İyi bir Data Scientist yalnızca “model ne kadar doğru?” sorusunu değil, “bu model kim için, hangi şartlarda, hangi riskle ve hangi denetim altında çalışmalı?” sorusunu da cevaplar.

18. Kaynaklar ve Güncel Referanslar

Bu PDF eğitim amaçlıdır. Özellikle regülasyon ve compliance gerektiren projelerde güncel resmi kaynaklar esas alınmalıdır.

European Commission - AI Act regulatory framework
https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai

European Commission - Enforcement framework of the AI Act
https://digital-strategy.ec.europa.eu/en/policies/enforcement-ai-act

European Commission - Article 50 transparency obligations
https://digital-strategy.ec.europa.eu/en/faqs/transparency-obligations-under-article-50-ai-act

EUR-Lex - Regulation (EU) 2016/679 (GDPR), Article 5 principles
https://eur-lex.europa.eu/eli/reg/2016/679

NIST - AI Risk Management Framework
https://www.nist.gov/itl/ai-risk-management-framework

NIST - AI RMF Playbook
https://www.nist.gov/itl/ai-risk-management-framework/nist-ai-rmf-playbook

ISO - ISO/IEC 42001:2023 AI management systems
https://www.iso.org/standard/81230.html

Çalışma önerisi: Bu modülü bitirdikten sonra gerçek bir dataset üzerinde Responsible ML Audit projesini GitHub portföyüne ekle. Ardından 45-48. modüllerle birleştirerek iş sonucu + governance + deployment + system design anlatabilen uçtan uca bir vaka oluştur.