Veri Bilimci Müfredatı 2026 | Modül 47

DATA SCIENCE INTERVIEW

Ayrıntılı Konu Anlatımı

Modül 47 - Veri Bilimci Müfredatı 2026

Bu modülü bitirdiğinde

Data Science mülakatını yalnızca soru ezberleyerek değil; problemi netleştirme, varsayım kurma, doğru metriği seçme, kodlama, istatistiksel düşünme, modelleme ve iş etkisini açıklama adımlarıyla sistematik biçimde yönetebileceksin.

Kapsam: mülakat süreci, CV/proje anlatımı, Python, Pandas/NumPy, SQL, olasılık-istatistik, A/B testing, machine learning teorisi, model evaluation, feature engineering, case study, product sense, take-home assignment, behavioral interview, canlı kodlama, mini ML system design, soru bankası ve çalışma planı.

İçindekiler

- 1. Data Science Mülakatının Yapısı
- 2. Mülakata Hazırlık Sistemi
- 3. CV ve Proje Deep-Dive
- 4. Python Mülakatı
- 5. NumPy ve Pandas Mülakatı
- 6. SQL Mülakatı
- 7. Olasılık ve İstatistik
- 8. A/B Testing ve Experiment Design
- 9. Machine Learning Temelleri
- 10. Algoritmalar ve Model Seçimi
- 11. Model Evaluation
- 12. Feature Engineering ve Preprocessing
- 13. Leakage, Imbalance, Calibration ve Threshold
- 14. Unsupervised Learning, Time Series ve NLP
- 15. Data Science Case Study
- 16. Product ve Business Sense
- 17. Take-Home Assignment
- 18. Behavioral Interview
- 19. Live Coding Stratejisi
- 20. ML System Design - Mülakat Seviyesi
- 21. Örnek Mülakat Vakaları
- 22. Soru Bankası ve Kısa Cevaplar
- 23. 4 Haftalık Hazırlık Planı
- 24. Son Gün ve Mülakat Kontrol Listesi

Çalışma ilkesi

Her soruda önce düşünce yapını görünür kıl: problemi yeniden ifade et, varsayımları belirt, çözüm seçeneklerini karşılaştır, sonra uygulamaya geç. Mülakatçı çoğu zaman yalnızca son cevabı değil, karar sürecini değerlendirir.

1. Data Science Mülakatının Yapısı

Şirketler aynı unvanı kullansa bile mülakat içeriği ürün, sektör ve rolün ağırlığına göre değişir. Bir Product Data Scientist ile Applied Scientist veya ML ağırlıklı Data Scientist aynı derinlikte SQL, deney tasarımı ya da model deployment soruları görmeyebilir. Bu yüzden hazırlık, rol tanımını teknik başlıklara çevirmekle başlar.

1.1 Yaygın aşamalar

Aşama	Ne ölçülür?	Hazırlık odağı
Recruiter / HR	Rol uyumu, motivasyon, iletişim	CV hikayesi, neden bu rol, beklenti
Technical screen	SQL/Python/istatistik temeli	Kısa problemleri hızlı ve temiz çözme
Case / Product	Problem framing ve business sense	KPI, metrik, hipotez, trade-off
ML interview	Modelleme bilgisi	Algoritmalar, validation, leakage, metrics
Live coding	Kodlama ve iletişim	Edge case, complexity, test etme
Take-home	Uçtan uca çalışma	EDA, model, raporlama, reproducibility
Behavioral	Takım çalışması ve sahiplenme	STAR hikayeleri
System design	Production düşüncesi	Data/feature/model serving/monitoring

1.2 Rol tanımını mülakat haritasına çevirme

- "Experimentation", "product analytics", "growth" -> SQL + istatistik + A/B testing + KPI soruları ağır basar.
- "Forecasting", "pricing", "risk" -> istatistik + time series + model evaluation + domain case soruları artar.
- "ML platform", "production ML", "real-time" -> Python + ML + deployment + system design ağırlığı artar.
- "NLP", "recommendation", "computer vision" -> ilgili model ailesinde daha derin teknik sorgulama beklenir.

Yanlış yaklaşım
Her şirkete aynı 200 soruyu ezberlemek verimsizdir. İlanı parçala, her gereksinimi bir mülakat başlığına eşleştir ve çalışma süresini rolün ağırlığına göre dağıt.

2. Mülakata Hazırlık Sistemi

2.1 Dört katmanlı hazırlık

Katman	Amaç	Örnek çıktı
Bilgi	Kavramı bilmek	Precision ile recall farkını açıklamak
Uygulama	Kavramı kullanmak	Threshold değişince metrikleri hesaplamak
İletişim	Kararı anlatmak	Neden recall odaklı seçtiğini savunmak
Trade-off	Alternatifleri karşılaştırmak	False positive maliyetiyle threshold seçmek

2.2 90 saniyelik cevap şablonu

1. Soruyu kendi cümlelerinle yeniden ifade et.
2. Eksik bilgiyi veya varsayımı netleştir.
3. Temel yaklaşımı söyle.
4. Neden bu yaklaşımı seçtiğini açıkla.
5. Edge case / risk / trade-off belirt.
6. Gerekirse ölçüm veya doğrulama planını ekle.

Mülakat sinyali
"Bilmiyorum" demek tek başına sorun değildir. Bildiğin sınırı net söyleyip nasıl doğrulayacağını açıklamak, uydurma bir kesinlikten daha güçlü bir mühendislik sinyalidir.

3. CV ve Proje Deep-Dive

CV'de yazdığın her teknoloji, metrik ve sonuç sorgulanabilir. Bir proje anlatımı; problem, veri, yöntem, değerlendirme, etki ve sonraki adım zincirini kurmalıdır.

3.1 Proje anlatım iskeleti

Bölüm	Sorulacak soru	Güçlü cevapta bulunmalı
Problem	Ne çözüyordun?	Kullanıcı/iş hedefi ve karar
Data	Veri nereden geldi?	Kaynak, boyut, kalite, leakage riski
Baseline	İlk referans neydi?	Basit model veya mevcut süreç
Model	Neden bu model?	Alternatifler ve trade-off
Validation	Nasıl test ettin?	Split mantığı, metric, CV
Result	Ne kadar iyileşti?	Teknik ve iş metriği
Production	Nasıl kullanılırdı?	Serving, monitoring, retraining
Learning	Ne değiştirirdin?	Hata analizi ve sonraki deney

3.2 CV satırını savunma

```
CV: "Churn modelini F1 skorunda %18 iyileştirdim."

Mülakatçı: Baseline neydi?
Sen: Önce majority-class ve logistic regression baseline kurdum.
Mülakatçı: Neden F1?
Sen: Pozitif sınıf azınlıktı ve hem kaçırılan churn hem gereksiz retention maliyeti vardı.
Mülakatçı: Test setine kaç kez baktın?
Sen: Model seçimini train/CV üzerinde yaptım; test setini yalnızca final değerlendirmede
kullandım.
```

Hazırlık görevi

CV'deki her madde için en az beş "neden?" sorusu yaz. "Neden bu model?", "Neden bu metric?", "Neden bu split?", "Ne başarısız oldu?", "Production olsaydı ne değişirdi?"

4. Python Mülakatı

4.1 Temel konular

- List, tuple, set, dict farkları
- Mutable vs immutable
- Shallow copy vs deep copy
- Comprehension, generator, iterator
- Function scope, *args/**kwargs
- Exception handling
- OOP temelleri
- Time/space complexity
- Sorting/searching
- Hash map, stack, queue
- String ve array problemleri

4.2 Sık sorulan kavramlar

Konu	Beklenen kısa açıklama
list vs tuple	List mutable; tuple immutable. Tuple hashable elemanlarla dict key olabilir.
set	Unique değer ve ortalama O(1) membership kontrolü için uygundur.
dict	Hash table tabanlı key-value yapı; ortalama lookup O(1).
generator	Tüm veriyi belleğe almadan lazy üretim yapar.
deep copy	Nested nesneleri de bağımsız kopyalar; shallow copy iç referansları paylaşabilir.
GIL	CPython'da aynı anda Python bytecode çalıştıran thread sayısını sınırlar; I/O ve multiprocessing bağlama göre farklı etkilenir.

4.3 Kodlama örneği - en sık geçen eleman

```
from collections import Counter

def most_frequent(values):
    if not values:
        return None
    counts = Counter(values)
    return max(counts, key=counts.get)

# O(n) time, O(k) space
```

Mülakatta yalnızca kodu yazmak yetmez. Empty input, tie durumu ve input boyutu gibi varsayımları belirt. Ardından karmaşıklığı söyle.

4.4 Kodlama örneği - duplicate tespiti

```
def has_duplicate(values):
    seen = set()
    for value in values:
        if value in seen:
            return True
        seen.add(value)
    return False

# Time: O(n) average
# Space: O(n)
```

4.5 Python soruları

- Bir listede en sık geçen üç elemanı nasıl bulursun?
- İki çok büyük dosyadaki ortak ID'leri RAM sınırlıyken nasıl bulursun?
- Generator ne zaman listeden daha iyi seçimdir?
- Bir fonksiyonun neden yavaş olduğunu nasıl profilersin?
- Threading ve multiprocessing arasında nasıl seçim yaparsın?

5. NumPy ve Pandas Mülakatı

5.1 NumPy

- Vectorization neden Python loopundan hızlı olabilir?
- Broadcasting kuralları
- Shape, axis ve reshape mantığı
- Boolean indexing
- NaN davranışı
- View vs copy
- Memory layout fikri

```
import numpy as np

x = np.array([1, 2, 3, 4])
# Vectorized transformation
y = np.log1p(x)

# Boolean filtering
z = x[x > 2]
```

5.2 Pandas

- loc vs iloc
- merge/join türleri
- groupby + agg
- pivot_table
- missing values
- duplicated/drop_duplicates
- datetime işlemleri
- rolling/window
- apply yerine vectorized çözüm
- SettingWithCopy ve copy/view farkı

5.3 Gerçek mülakat görevi

Elinde user_id, order_date, revenue kolonları olan orders tablosu var. Her kullanıcının ilk sipariş tarihini, toplam gelirini ve son 30 gündeki gelirini üret.

```
orders['order_date'] = pd.to_datetime(orders['order_date'])
cutoff = orders['order_date'].max() - pd.Timedelta(days=30)

summary = (
    orders.groupby('user_id')
    .agg(first_order=('order_date', 'min'),
         total_revenue=('revenue', 'sum'))
)

rev30 = (orders.loc[orders['order_date'] >= cutoff]
               .groupby('user_id')['revenue'].sum()
               .rename('revenue_30d'))

summary = summary.join(rev30).fillna({'revenue_30d': 0})
```

İyi sinyal
Pandas çözümünden sonra aynı işi SQL ile nasıl yapacağını söyleyebilmek, veri manipülasyon mantığını araca bağımlı olmadan bildiğini gösterir.

6. SQL Mülakatı

6.1 Mutlaka bilmen gerekenler

- SELECT / WHERE / ORDER BY
- GROUP BY / HAVING
- INNER / LEFT / FULL JOIN
- CASE WHEN
- CTE ve subquery
- Window functions
- ROW_NUMBER / RANK / DENSE_RANK
- LAG / LEAD
- Rolling metrics
- Date functions
- NULL semantiği
- COUNT(*) vs COUNT(col)
- Duplicate kaynakları
- Query execution mantığı ve basic optimization

6.2 SQL düşünme sırası

7. Output grain'i belirle: sonuçta bir satır neyi temsil edecek?
8. Gerekli tabloları ve join key'leri belirle.
9. Filtreleri doğru aşamada uygula.
10. Aggregation gerekiyorsa group grain'i kontrol et.
11. Window function gerekiyorsa partition/order tanımla.
12. Duplicate ve NULL davranışını test et.

6.3 Örnek - kategori bazında en yüksek gelirli müşteri

```
WITH customer_revenue AS (
    SELECT
        category,
        customer_id,
        SUM(revenue) AS revenue
    FROM orders
    GROUP BY category, customer_id
), ranked AS (
    SELECT
        *,
        ROW_NUMBER() OVER (
            PARTITION BY category
            ORDER BY revenue DESC
        ) AS rn
    FROM customer_revenue
)
SELECT category, customer_id, revenue
FROM ranked
WHERE rn = 1;
```

6.4 Örnek - 7 günlük rolling revenue

```
SELECT
    order_date,
    daily_revenue,
    SUM(daily_revenue) OVER (
        ORDER BY order_date
        ROWS BETWEEN 6 PRECEDING AND CURRENT ROW
    ) AS revenue_7d
FROM daily_sales;
```

6.5 SQL tuzakları

Tuzak	Neden olur?	Kontrol
Join sonrası satır patlaması	Many-to-many join	Join öncesi key uniqueness kontrolü
LEFT JOIN -> INNER gibi davranır	Sağ tablo filtresi WHERE'de	Filtreyi ON koşuluna taşı
COUNT yanlış	NULL değerler sayılmaz	COUNT(*) ve COUNT(col) farkını bil
RANK beklenmeyen sonuç	Tie davranışı	ROW_NUMBER/RANK/DENSE_RANK seçimini netleştir
Window order eksik	Deterministik olmayan sıra	ORDER BY ve tie-breaker ekle

7. Olasılık ve İstatistik

7.1 Temel kavramlar

- Population vs sample
- Random variable
- Expected value ve variance
- Conditional probability
- Bayes theorem
- Bernoulli/Binomial/Normal dağılımlar
- Law of Large Numbers
- Central Limit Theorem
- Sampling bias
- Confidence interval
- Hypothesis testing
- Type I / Type II error

- Power
- Correlation vs causation

7.2 Beklenen değer

Beklenen değer, uzun vadeli ortalama sonucu temsil eder. Bir kararın yalnızca olasılığını değil, sonuç büyüklüğünü de hesaba katmak için kullanılır.

```
E[X] = Σ x * P(X=x)

Örnek:
%1 olasılıkla 1000 TL kayıp, %99 olasılıkla 0 TL
Beklenen kayıp = 0.01 * 1000 = 10 TL
```

7.3 Bayes teoremi - fraud örneği

Bir alarm sisteminin doğruluğunu değerlendirirken yalnızca sensitivity yetmez. Fraud'un base rate'i düşükse, pozitif alarmın gerçekten fraud olma olasılığı beklenenden düşük olabilir. Bu, base-rate fallacy'nin klasik örneğidir.

```
P(Fraud | Alarm) = P(Alarm | Fraud) * P(Fraud) / P(Alarm)
```

7.4 Confidence interval

Confidence interval, tahminin belirsizliğini ifade eder. %95 güven aralığını "parametrenin bu aralıkta olma olasılığı %95" diye yorumlamak klasik frequentist çerçevede doğru değildir. Tekrarlanan örneklemelerde aynı prosedürle kurulan aralıkların %95'i gerçek parametreyi kapsar.

7.5 p-value

p-value ne değildir?
p-value, H0'ın doğru olma olasılığı değildir. H0 doğru kabul edildiğinde gözlenen veya daha uç bir sonucun ortaya çıkma olasılığıyla ilgilidir.

7.6 İstatistik soruları

- Bir coin 100 atışta 60 kez yazı geldi. Adil olmadığını söyler misin?
- Median ne zaman mean'den daha iyi özet olur?
- Correlation yüksekse causation diyebilir miyiz?
- Sample size artınca confidence interval neden daralır?
- Selection bias bir modeli production'da nasıl bozar?

8. A/B Testing ve Experiment Design

8.1 Deney tasarımının iskeleti

13. Decision / business question
14. Primary metric ve guardrail metrics
15. Unit of randomization
16. H0/H1
17. Minimum detectable effect
18. Sample size / power
19. Experiment duration
20. Analysis plan
21. Decision rule

8.2 Primary ve guardrail metric

Örneğin checkout akışını kısaltan bir deneyde primary metric conversion olabilir. Ancak refund rate, support contact rate veya latency gibi guardrail metrics kötüleşiyorsa yalnızca conversion artışına bakmak yanlış karar üretebilir.

8.3 Sık deney hataları

Hata	Sonuç
Peeking	False positive oranını fiilen artırabilir
Çok fazla metric test etmek	Multiple testing problemi
Randomization unit yanlış	Interference / contamination
Eksik sample size	Düşük power
Novelty effect	Kısa dönem etkiyi kalıcı sanmak
SRM - sample ratio mismatch	Randomization veya logging problemi sinyali
Sadece p-value	Etki büyüklüğü ve iş anlamı kaybolur

8.4 Örnek cevap

```
Soru: Yeni öneri algoritması CTR'ı %3 artırdı, p=0.03. Ship eder misin?

Cevap akışı:
1) Deney önceden tanımlanan primary metric mi?
2) Sample size/power yeterli mi?
3) Relative mi absolute lift mi? CI nedir?
4) Guardrail metrics nasıl?
5) SRM/logging sorunu var mı?
6) Segmentlerde tutarlılık var mı?
7) İş etkisi ve maliyet ne?
8) Gerekirse staged rollout + monitoring.
```

9. Machine Learning Temelleri

9.1 Supervised vs unsupervised

Tür	Amaç	Örnek
Supervised	Label üzerinden tahmin	Churn, fraud, price prediction
Unsupervised	Yapı keşfetme	Clustering, anomaly exploration
Semi-supervised	Az label + çok unlabeled data	Label maliyetli senaryolar
Self-supervised	Veriden supervision üretme	Representation learning

9.2 Bias - variance

Yüksek bias modelin ilişkileri yeterince yakalayamaması; yüksek variance ise training verisinin gürültüsüne aşırı uyum sağlamasıdır. Model complexity, regularization, feature seti ve veri miktarı bu dengeyi etkiler.

9.3 Overfitting nasıl anlaşılır?

- Train performansı çok iyi, validation belirgin kötü
- Cross-validation foldları arasında yüksek varyans
- Yeni zaman döneminde performans çökmesi
- Model karmaşıklığı arttıkça validation iyileşmek yerine kötüleşmesi

9.4 Data split

Problem	Uygun split
IID tabular	Random train/validation/test
Classification + imbalance	Stratified split

Time series	Time-based split / TimeSeriesSplit
Aynı kullanıcıdan çok satır	Group-based split
Geographic generalization	Region-based holdout düşünülebilir

Temel kural

Split stratejisi deployment koşulunu taklit etmelidir. Geleceği tahmin edeceksen random split çoğu zaman gerçek kullanım koşulunu temsil etmez.

10. Algoritmalar ve Model Seçimi

10.1 Linear regression

- Amaç: continuous target
- OLS varsayımları
- Residual analizi
- Multicollinearity
- Ridge/Lasso regularization
- Interpretability avantajı

10.2 Logistic regression

Logistic regression log-odds'u lineer kombinasyonla modeller. Baseline olarak güçlüdür, hızlıdır ve katsayı yorumlanabilirliği sağlar. Doğrusal karar sınırı yetersiz kalabilir.

10.3 Decision tree

- Non-linearity yakalar
- Scaling gerekmez
- Kolay overfit olabilir
- Split criterion: Gini/entropy
- Depth/min_samples gibi parametrelerle kontrol edilir

10.4 Random Forest vs Gradient Boosting

Özellik	Random Forest	Gradient Boosting
Ana fikir	Paralel birçok ağaç + bagging	Ardışık ağaçlarla hatayı düzeltme
Variance	Bagging ile azaltır	Boosting bias/variance dengesi kurar
Tuning	Görece kolay	Learning rate/depth/estimators hassas
Tabular performans	Güçlü baseline	Çoğu problemde çok güçlü
Parallelization	Daha kolay	Ardışık yapı nedeniyle daha sınırlı

10.5 KNN, Naive Bayes, SVM

- KNN: instance-based; scaling önemli; inference pahalı olabilir.
- Naive Bayes: conditional independence varsayımı; text classification'da baseline olabilir.
- SVM: margin maximization; kernel ile non-linearity; büyük datasetlerde maliyetli olabilir.

10.6 Model seçme cevabı

Güçlü cevap

"En iyi algoritma X" demek yerine; veri boyutu, latency, interpretability, class imbalance, non-linearity, maintenance ve business cost üzerinden adayları daralt. Baseline -> validation -> error analysis -> complexity artışı sırasını anlat.

11. Model Evaluation

11.1 Classification metrics

Metric	Ne ölçer?	Ne zaman önemli?
Accuracy	Toplam doğru oranı	Sınıflar dengeli ve maliyetler benzer
Precision	Pozitif tahminlerin doğruluğu	False positive pahalı
Recall	Gerçek pozitiflerin yakalanması	False negative pahalı
F1	Precision-recall harmonik ortalama	İkisini dengelemek
ROC-AUC	Ranking ayrımı	Genel ayrıştırma; imbalance'da tek başına yetmeyebilir
PR-AUC	Precision-recall trade-off	Pozitif sınıf nadir olduğunda kullanışlı
Log Loss	Probability quality	Probabilistic prediction
Calibration	Tahmin olasılığı güvenilir mi?	Risk skoru/karar sistemleri

11.2 Regression metrics

Metric	Özellik
MAE	Outlierlara RMSE'den daha dayanıklı; aynı birimde
MSE/RMSE	Büyük hataları daha fazla cezalandırır
R^2	Variance açıklama oranı; tek başına iş metriği değildir
MAPE	Yüzdesel yorum kolay; sıfır/küçük gerçek değerlerde sorunlu
WAPE/SMAPE	Forecasting'de alternatifler

11.3 Threshold seçimi

Modelin ürettiği probability ile business decision threshold aynı şey değildir. Threshold; false positive ve false negative maliyetleri, operasyon kapasitesi ve risk toleransı ile seçilir.

```
Expected Cost(t) =
    FP(t) * Cost_FP + FN(t) * Cost_FN

Seçim: minimum expected cost veya kapasite constraint altında maksimum değer.
```

11.4 Cross-validation

- K-Fold
- Stratified K-Fold
- Group K-Fold
- TimeSeriesSplit
- Nested CV (model selection bias azaltmak için)

12. Feature Engineering ve Preprocessing

12.1 Missing values

Missingness mekanizmasını anlamadan yalnızca median ile doldurmak eksik bir yaklaşımdır. Eksik değer bazen doğrudan sinyal olabilir.

- Numerical: median/mean/model-based imputation
- Categorical: explicit "Unknown" category
- Missing indicator
- Train üzerinde fit, validation/test üzerinde transform
- Production'da aynı preprocessing artifact kullanımı

12.2 Scaling

Model	Scaling ihtiyacı
Linear/Logistic Regression	Genellikle faydalı; regularization ile önemli
KNN/SVM	Çok önemli
Neural Networks	Genellikle önemli
Decision Tree/Random Forest/GBM	Genellikle gerekli değil

12.3 Encoding

- One-hot encoding
- Ordinal encoding
- Target encoding - leakage riski
- Frequency encoding
- High-cardinality kategoriler

12.4 Feature seçimi

Feature selection yalnızca performans için değil; latency, maliyet, explainability, stability ve data availability için de yapılır.

13. Leakage, Imbalance, Calibration ve Threshold

13.1 Data leakage

- Target leakage: target sonrası oluşan bilgi feature'a girer.
- Train-test contamination: preprocessing tüm veri üzerinde fit edilir.
- Time leakage: gelecekteki bilgi geçmiş tahmine sızar.
- Entity leakage: aynı kullanıcı/cihaz train ve testte yanlış biçimde paylaşılır.

13.2 Imbalanced classification

- Class weights
- Undersampling / oversampling
- SMOTE - yalnızca training fold içinde
- Threshold tuning
- PR-AUC ve recall@precision gibi metrikler
- Cost-sensitive evaluation

13.3 Calibration

Bir modelin AUC'si yüksek olup calibration'ı kötü olabilir. Örneğin model %80 risk dediği örneklerin yalnızca %30'u pozitifse probability doğrudan karar maliyetlerinde kullanılamaz. Platt scaling veya isotonic regression gibi yöntemler değerlendirilebilir.

Mülakat seviyesi

"AUC iyi ama business result kötü" sorusuna; threshold, calibration, segment drift, label delay, objective mismatch ve operational constraint başlıklarıyla yaklaş.

14. Unsupervised Learning, Time Series ve NLP

14.1 Clustering

- K-Means: distance-based, scaling önemli, k seçimi gerekir.
- Hierarchical clustering: dendrogram ve nested structure.
- DBSCAN: density-based, arbitrary shape, noise handling.

- Cluster validation: silhouette + iş anlamı; yalnızca metrik yeterli değil.

14.2 Time series

- Trend, seasonality, autocorrelation
- Lag ve rolling features
- Time-based split
- Forecast horizon
- Backtesting
- Leakage riskleri
- MAE/RMSE/MAPE/WAPE seçimi
- Baseline: naive / seasonal naive

14.3 NLP

- Tokenization
- Bag-of-words / TF-IDF
- Embeddings
- Transformer temel fikri
- Class imbalance
- Sequence length
- Evaluation ve hallucination ayrımı (LLM uygulamalarında)

15. Data Science Case Study

Case interview'de amaç çoğu zaman tek doğru modele ulaşmak değil; belirsiz iş problemini ölçülebilir bir analitik plana çevirmektir.

15.1 CASE çerçevesi

Adım	Soru
C - Clarify	Hangi kullanıcı, hangi karar, hangi zaman ufku?
A - Align metric	Başarıyı hangi KPI ile ölçeceğiz? Guardrail ne?
S - Structure	Data, analysis, model, experiment, rollout nasıl ayrılacak?
E - Evaluate	Offline/online metric, risk, maliyet ve next step nedir?

15.2 Churn case

Soru: Abonelik ürününde churn arttı. Ne yaparsın?

22. Churn tanımını netleştir: voluntary/involuntary, dönem, cohort.
23. Artışın logging/definition değişikliğinden gelmediğini kontrol et.
24. Segmentlere ayır: acquisition channel, plan, tenure, geography, device.
25. Funnel ve lifecycle noktalarını incele.
26. Driver analizi / predictive model gerekiyorsa leakage-safe feature set kur.
27. Retention aksiyonlarının maliyetini ve hedeflenebilirliği değerlendir.
28. Aksiyon varsa A/B test ile incremental impact ölç.

15.3 Case'de sorulacak veri soruları

- Label nasıl üretiliyor?
- Feature'lar decision time'da mevcut mu?
- Sample population production population ile aynı mı?
- Eksik/yanlı logging var mı?
- Data freshness ne?
- Feedback loop oluşur mu?

16. Product ve Business Sense

16.1 Metric tree

Üst seviye KPI'ı alt bileşenlere ayırmak root-cause analysis'i kolaylaştırır.

```
Revenue = Active Users * Orders per User * Average Order Value

Orders per User = Sessions/User * Conversion Rate * Orders/Converted Session
```

16.2 North Star vs guardrail

- North Star: ürünün temel kullanıcı değerini temsil eden ana yön metriği.
- Input metrics: North Star'ı sürükleyen davranış metrikleri.
- Guardrail: büyümeyi kötü yan etkiler pahasına optimize etmeyi önler.

16.3 Metric düşüşü sorusu

29. Metric tanımı veya instrumentation değişti mi?
30. Düşüş ne zaman başladı? Change point var mı?
31. Tüm segmentlerde mi, belirli segmentte mi?
32. Funnel'ın hangi adımında bozulma var?
33. Seasonality / external event etkisi olabilir mi?
34. Recent release / experiment / pricing değişikliği var mı?
35. Causal doğrulama için hangi deney veya quasi-experiment yapılabilir?

17. Take-Home Assignment

17.1 Değerlendirilen şeyler

- Problem framing
- Data quality kontrolü
- EDA'nın amaca hizmet etmesi
- Baseline kurulması
- Doğru split ve metric
- Reproducible pipeline
- Error analysis
- Business interpretation
- Kod kalitesi
- README ve presentation

17.2 Önerilen klasör yapısı

```
project/
├── README.md
├── data/              # raw data commit edilmeyebilir
├── notebooks/
│   └── 01_eda.ipynb
├── src/
│   ├── features.py
│   ├── train.py
│   └── evaluate.py
├── tests/
├── requirements.txt
└── report.pdf
```

17.3 README yapısı

- Problem
- Dataset ve varsayımlar
- Kurulum
- EDA bulguları
- Modeling approach
- Validation strategy
- Results
- Limitations
- Next steps

Take-home kuralı

En karmaşık modeli kurmak yerine, temiz bir baseline + doğru validation + güçlü hata analizi çoğu zaman daha profesyonel görünür.

18. Behavioral Interview

18.1 STAR yöntemi

Adım	İçerik
Situation	Bağlamı kısa kur
Task	Senin sorumluluğunu netleştir
Action	Ne yaptığını detaylandır; "biz" yerine gerektiğinde "ben"
Result	Ölçülebilir sonuç + öğrendiğin ders

18.2 Hazırlanması gereken hikayeler

- Belirsiz problem çözdüğün örnek
- Hata yaptığın ve düzelttiğin örnek
- Paydaşla anlaşmazlık
- Deadline baskısı
- Modelin işe yaramadığı durum
- Data quality problemi
- Teknik olmayan kişiye karmaşık konuyu anlattığın durum
- Bir süreci iyileştirdiğin durum

18.3 Zayıf cevap vs güçlü cevap

Zayıf	Güçlü
"Takımla modeli geliştirdik."	"Feature pipeline'ı ben yeniden tasarladım; leakage'ı kaldırdık ve offline metric X'ten Y'ye çıktı."
"Proje başarılı oldu."	"Pilot segmentte işlem süresi %22 azaldı; ancak ikinci segmentte lift görmedik."
"Stakeholder anlamadı."	"Kararı teknik metric yerine expected cost ile yeniden çerçeveledim."

19. Live Coding Stratejisi

19.1 Kod yazmadan önce

36. Input/output örneklerini netleştir.
37. Edge case sor.
38. Brute-force çözümü bir cümlede söyle.
39. Daha iyi yaklaşımı seç ve complexity tahmini yap.

40. Kodu küçük fonksiyonlarla yaz.
41. Elle test case çalıştır.

19.2 Debug ederken konuş

Sessizce ekrana bakmak yerine gözlemini belirt: "Bu koşul duplicate'i ikinci gördüğüm anda yakalamalıydı; demek ki seen setine ekleme sıramı kontrol ediyorum." Böylece problem çözme sürecin görünür olur.

19.3 Test checklist

- Empty input
- Tek eleman
- Duplicate/tie
- Negative/zero
- Already sorted
- Very large input
- NULL/NaN
- Unexpected category

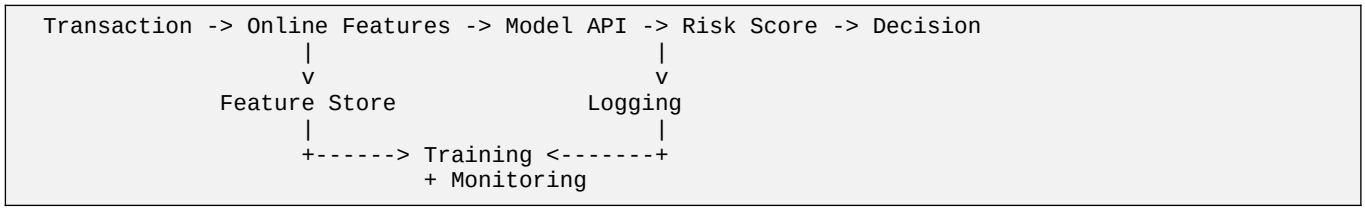
20. ML System Design - Mülakat Seviyesi

Bu konu Modül 48'de ayrıntılıdır. Mülakatta Data Scientist seviyesinde amaç çoğu zaman production sisteminin temel parçalarını ve trade-off'larını kurabilmektir.

20.1 Cevap iskeleti

42. Use case ve SLA: latency, throughput, freshness.
43. Data sources ve labels.
44. Feature pipeline: batch/stream.
45. Training cadence ve validation.
46. Model registry/versioning.
47. Serving: batch vs online.
48. Monitoring: service + data + model + business.
49. Retraining/rollback.

20.2 Fraud örneği



System design bağlantısı

Bu başlık için ayrıntılı mimari, batch/online inference, feature store, deployment ve monitoring konuları Modül 48 - System Design for ML dokümanında işlenir.

21. Örnek Mülakat Vakaları

21.1 Fraud detection

Bir ödeme şirketi fraud kaybını azaltmak istiyor. Nasıl sistem kurarsın?

- Label delay ve chargeback tanımını netleştir.
- Class imbalance için accuracy kullanma.

- PR-AUC + recall at fixed precision veya expected loss değerlendir.
- Time-based validation kullan.
- Velocity features ve identity/device sinyalleri düşün.
- False positive -> müşteri deneyimi maliyetini hesaba kat.
- Threshold + manual review kapasitesini birlikte optimize et.
- Production drift ve adversarial adaptation izle.

21.2 Recommendation

Ana sayfadaki önerileri iyileştir.

- Goal: CTR mi, purchase mi, long-term retention mı?
- Candidate generation + ranking ayrımı
- Cold start
- Popularity bias
- Offline ranking metrics vs online experiment
- Diversity/novelty guardrails
- Latency ve freshness

21.3 Demand forecasting

- Forecast horizon ve granularity
- Seasonality/holiday/promotions
- Stockout -> censored demand
- Time-based backtesting
- Naive baseline
- WAPE/MAE + inventory cost
- Prediction interval

21.4 Marketplace conversion düşüşü

- Instrumentation doğrula
- Buyer/seller segmentleri
- Traffic source
- Search -> detail -> cart -> checkout funnel
- Price/shipping/availability
- Recent product changes
- Experiment plan

22. Soru Bankası ve Kısa Cevaplar

Aşağıdaki soruları önce sesli cevapla. Sonra kısa cevapla karşılaştır. Amaç metni ezberlemek değil, kavramın omurgasını kurmaktır.

Alan	Soru	Kısa cevap
Python	List ile set arasındaki temel fark nedir?	List sıralı ve duplicate kabul eder; set unique eleman tutar ve membership testleri ortalama O(1) sağlar.
Python	Generator neden kullanılır?	Lazy evaluation ile büyük veriyi tamamen belleğe almadan sırayla üretir.
Python	Mutable default argument neden tehlikelidir?	Fonksiyon tanımlandığında bir kez oluşturulur ve çağrılar arasında state paylaşabilir.
Python	Shallow ve deep copy farkı?	Shallow dış container'ı kopyalar, nested referansları paylaşabilir; deep copy nested nesneleri de kopyalar.
Python	Dict lookup complexity nedir?	Ortalama O(1), kötü durumda daha yüksek olabilir; hash table temellidir.
SQL	WHERE ve HAVING farkı?	WHERE aggregation öncesi satırları, HAVING aggregation sonrası grupları filtreler.

SQL	ROW_NUMBER ve RANK farkı?	Tie olduğunda ROW_NUMBER benzersiz sıra verir; RANK aynı rank verir ve sonraki sırada boşluk bırakır.
SQL	LEFT JOIN sonrası WHERE right.col=... neden riskli?	NULL eşleşmeyen satırları atarak join'i fiilen inner join'e çevirebilir.
SQL	COUNT(*) ve COUNT(col) farkı?	COUNT(*) tüm satırları; COUNT(col) NULL olmayan değerleri sayar.
SQL	Many-to-many join nasıl anlaşılır?	Her iki tarafta join key duplicate ise satır sayısı çarpılabilir; key cardinality kontrol edilir.
Statistics	CLT ne söyler?	Uygun koşullarda örneklem ortalamalarının dağılımı sample size büyüdükçe normale yaklaşır.
Statistics	p-value nedir?	H0 doğru kabul edildiğinde gözlenen veya daha uç verinin olasılığıyla ilgilidir; H0'ın doğru olma olasılığı değildir.
Statistics	Type I error?	Doğru H0'ı reddetmek; false positive.
Statistics	Type II error?	Yanlış H0'ı reddedememek; false negative.
Statistics	Power nedir?	Gerçek bir etki varken onu tespit etme olasılığı; 1-beta.
Statistics	Correlation causation mı?	Hayır; confounding, reverse causality veya ortak trend olabilir.
AB Test	Peeking neden sorun?	Tekrarlı plansız kontrol, nominal alpha'dan daha yüksek false positive riski yaratabilir.
AB Test	MDE nedir?	Deneyin tespit etmeyi hedeflediği minimum iş anlamlı etki büyüklüğü.
AB Test	Guardrail metric neden gerekir?	Ana metriği optimize ederken kullanıcı deneyimi veya sistem sağlığının bozulmasını önlemek için.
AB Test	SRM nedir?	Sample ratio mismatch; beklenen trafik dağılımıyla gözlenen dağılımın anlamlı sapması, randomization/logging hatası sinyali olabilir.
ML	Bias vs variance?	Bias yetersiz modelleme; variance training verisine aşırı hassasiyet. Genelleme için denge gerekir.
ML	Overfitting nasıl azaltılır?	Daha fazla veri, regularization, simpler model, early stopping, feature selection, doğru CV.
ML	L1 ve L2 farkı?	L1 sparsity üretebilir; L2 katsayıları küçültür ancak genelde sıfıra indirmez.
ML	Tree model scaling ister mi?	Genellikle hayır; splitler feature ordering'e dayanır.
ML	Logistic regression output nedir?	Sigmoid sonrası sınıf olasılığı olarak yorumlanabilen skor; lineer log-odds modelidir.
ML	Random Forest neden variance azaltır?	Bootstrap örnekleri ve feature randomness ile korelasyonu azaltılmış ağaçların ortalamasını alır.
ML	Gradient boosting nasıl çalışır?	Modeller ardışık eklenir ve önceki ensemble'ın hatasını/gradientini düzeltmeye çalışır.
Evaluation	Accuracy ne zaman yanıltıcı?	Class imbalance yüksekken; majority class model çok yüksek accuracy alabilir.
Evaluation	ROC-AUC ne ölçer?	Rastgele pozitif-negatif çiftinde pozitifin daha yüksek skor alma olasılığıyla ilişkili ranking ayrım gücü.
Evaluation	PR-AUC ne zaman daha anlamlı?	Pozitif sınıf nadirken precision-recall trade-off'una odaklanmak gerektiğinde.
Evaluation	Calibration nedir?	%70 tahmin edilen örneklerin yaklaşık %70'inin pozitif olması gibi probability reliability.
Evaluation	Threshold 0.5 olmak zorunda mı?	Hayır; business cost, prevalence, capacity ve precision/recall hedeflerine göre seçilir.
Data	Data leakage örneği?	Churn prediction'da churn gerçekleştikten sonra oluşan cancellation_reason bilgisini feature yapmak.
Data	Missing value neden sinyal olabilir?	Bir alanın doldurulmaması belirli kullanıcı davranışı veya sistem sürecini yansıtabilir.

Data	Target encoding riski?	Tüm dataset üzerinde hesaplanırsa target leakage yaratır; fold-aware yapılmalıdır.
Case	Metric düştü, ilk ne yaparsın?	Metric tanımı/instrumentation doğrula, zaman ve segment kırılımıyla düşüşün nereden geldiğini lokalize et.
Case	Model metriği iyi, business metric kötü. Neden?	Objective mismatch, threshold, calibration, actionability, latency, selection bias, drift veya intervention etkisi olabilir.
Case	Baseline neden gerekli?	Yeni yaklaşımın gerçekten değer ekleyip eklemediğini karşılaştırmak ve karmaşıklığı gerekçelendirmek için.
System	Batch vs online inference?	Batch önceden toplu skorlar; online request anında skorlar. Freshness/latency/maliyet trade-off'u vardır.
System	Neyi monitor edersin?	Service health, input data quality/drift, model performance/calibration ve business KPI.

22.1 İleri seviye pratik soruları

- Bir fraud modelinin AUC'si yükseldi ama yakalanan fraud tutarı düştü. Nasıl araştırırsın?
- Time series forecast modelinde test performansı iyi, production kötü. Hangi leakage türlerini kontrol edersin?
- Bir feature production'da 500 ms gecikmeyle geliyor. Modelde kalmalı mı?
- Yeni kullanıcılar için recommendation cold-start problemini nasıl çözersin?
- Model fairness'i hangi segmentlerde ve hangi metriklerle incelersin?
- Offline experiment ile online A/B sonucu neden çelişebilir?
- Bir modelin precision'ı aynı kalırken recall neden zamanla düşebilir?
- Bir ürün metriğini optimize ederken Goodhart's Law nasıl ortaya çıkabilir?
- Feature importance yüksek olan bir feature neden causal olmayabilir?
- Bir modeli yeniden eğitme zamanını nasıl belirlersin?

23. 4 Haftalık Hazırlık Planı

Hafta	Odak	Günlük çıktı
1	SQL + Python + Pandas	2 SQL problem + 1 Python problem + 30 dk proje anlatımı
2	İstatistik + A/B testing	10 kavram kartı + 1 experiment case
3	ML + evaluation + case	2 ML topic + 1 case + 1 error-analysis egzersizi
4	Mock interview + weak areas	60-90 dk mock + yanlışların tekrar analizi

23.1 Günlük 3 saatlik şablon

Süre	Çalışma
45 dk	SQL / Python coding
45 dk	Statistics / ML theory
45 dk	Case study veya A/B testing
30 dk	Proje/CV deep-dive sesli anlatım
15 dk	Yanlışlar defteri ve tekrar

23.2 Yanlışlar defteri

- Soruyu yaz
- Yanlış cevabını özetle
- Doğru prensibi yaz
- Benzer soru üret
- 48 saat sonra tekrar çöz

Hedef
Mülakata hazırlanırken "kaç soru çözdüm?" yerine "hangi hata sınıflarını artık tekrarlamıyorum?" metriğini kullan.

24. Son Gün ve Mülakat Kontrol Listesi

24.1 Son gün

- Yeni konu öğrenme; zayıf noktaların kısa tekrarını yap.
- CV'deki her maddeyi tekrar oku.
- 2 proje için 3 dakikalık ve 10 dakikalık anlatım hazırla.
- SQL window functions ve ML metrics cheat sheet gözden geçir.
- Şirket/ürün/rolü tekrar incele.
- Mülakatçıya soracağın 3-5 soru hazırla.

24.2 Teknik soru sırasında

- Soruyu netleştir
- Varsayımları söyle
- Baseline düşün
- Metric seçimini gerekçelendir
- Leakage ve edge case kontrol et
- Trade-off söyle
- Sonucu business etkisine bağla

24.3 Mülakatçıya sorulabilecek sorular

- Bu rolde ilk 90 günde başarı nasıl ölçülüyor?
- Data Scientist'ler ürün ve engineering ekipleriyle nasıl çalışıyor?
- Modellerin production ownership'i hangi ekipte?
- Experimentation süreci nasıl işliyor?
- Takımın şu anki en zor veri problemi nedir?
- Başarılı Data Scientist'leri diğerlerinden ayıran özellikler neler?

Final prensip
İyi Data Science mülakatı; algoritma isimleri sıralamak değil, belirsiz problemi ölçülebilir ve doğrulanabilir kararlara dönüştürebildiğini göstermektir. Problem -> data -> method -> validation -> decision -> monitoring zincirini kur.

Hızlı Tekrar - Mülakat Cheat Sheet

Soru tipi	İlk refleks
SQL	Output grain -> joins -> filters -> aggregation -> windows -> duplicates
Statistics	Population/sample -> assumptions -> uncertainty -> effect size
A/B Test	Metric -> randomization -> power -> guardrails -> decision
ML	Baseline -> split -> metric -> model -> error analysis -> trade-off
Case	Clarify -> metric tree -> segment -> hypothesis -> validate -> action
System	SLA -> data -> features -> train -> serve -> monitor -> retrain
Behavioral	STAR -> kişisel katkı -> ölçülebilir sonuç -> öğrenme

10 kritik cümle

- "Önce hedef metriği ve karar bağlamını netleştireyim."
- "Bu split deployment koşulunu taklit ediyor mu?"
- "Bu feature prediction anında gerçekten mevcut mu?"
- "Baseline ile kıyaslamadan complexity eklemek istemem."
- "Metric seçimini false positive / false negative maliyetine bağlarım."
- "Test setini model seçimi için tekrar tekrar kullanmam."
- "Offline metrik iyi olsa da online impact'i experiment ile doğrularım."
- "Probability kullanacaksam calibration'ı kontrol ederim."
- "Segment bazında performans ve drift kontrolü yaparım."
- "Production'da yalnızca model metriğini değil business KPI'ını da izlerim."

Modül 47 tamamlandı. Sonraki bağlantılı başlık: Modül 48 - System Design for ML.