VERİ ANALİSTİ MÜFREDATI 2026

Modül 3
Veri Temelleri

Veriyi anlamadan analiz yapılmaz.

Bu modülün hedefi
Veri tiplerini tanımak, yapısal ve yapısal olmayan veriyi ayırt etmek, eksik değerleri ve tekrarları yönetmek, aykırı değerleri analiz etmek ve veri kalitesini sistematik biçimde ölçmek. Modül sonunda kirli bir veri setini güvenilir bir analiz veri setine dönüştürebilecek bir yaklaşım kazanmış olacaksın.

Çıktı: Kirli dataset temizleme + veri kalite raporu

1. Veri neden analizin temelidir?

Bir veri analistinin en büyük hatası, verinin ne olduğunu anlamadan doğrudan grafik veya model üretmeye başlamaktır. Analiz çıktısının güvenilirliği; kullanılan verinin tanımı, yapısı, doğruluğu ve iş bağlamıyla uyumu kadar iyidir.

> Bir dashboard teknik olarak kusursuz olabilir; ancak aynı müşterinin iki kez sayıldığı, para birimlerinin karıştığı veya tarih alanlarının yanlış yorumlandığı bir veri setine dayanıyorsa sonuç yine yanlıştır.

Data → Information → Insight → Decision

Aşama	Soru	Örnek
Data	Ne kaydedildi?	order_id=1042, amount=850, city=Istanbul
Information	Ne oldu?	Istanbul satışları bu ay 2,4 milyon TL oldu.
Insight	Neden önemli?	Satış büyümesinin %70'i yeni müşterilerden geliyor.
Decision	Ne yapacağız?	Yeni müşteri kampanyasını ölçeklendir, retention kampanyasını test et.

> Veri temizleme, analizin ön hazırlığı değil; analizin kendisinin bir parçasıdır. Çünkü hangi kaydın geçerli, hangi değerin eksik, hangi noktanın istisna olduğuna karar verirken iş mantığı kullanırsın.

2. Veri tipleri

Veri tipi, bir değerin nasıl saklandığını ve üzerinde hangi işlemlerin anlamlı olduğunu belirler. Aynı görünen iki sütun farklı veri tiplerinde tutulduğunda filtreleme, sıralama, toplama ve birleştirme sonuçları değişebilir.

2.1 Temel veri tipleri

Tip	Örnek	Analitik kullanım	Yaygın hata
Integer	12, 540, -3	adet, sipariş sayısı, gün sayısı	ID alanlarını sayısal metrik sanmak
Float / Decimal	19.95, 0.87	fiyat, oran, marj	yuvarlama ve para hassasiyeti
String / Text	Istanbul, SKU-100	kategori, açıklama, kod	gereksiz boşluk, büyük-küçük harf
Boolean	True / False	aktif mi, iade mi	0/1 ile metin değerlerini karıştırmak
Date	2026-09-28	gün bazlı analiz	metin olarak saklanması
Datetime	2026-09-28 14:25	event ve işlem zamanı	timezone farkını göz ardı etmek
Categorical	Gold/Silver/Bronze	segmentasyon	kategori sayısını kontrol etmemek

2.2 Ölçüm ölçekleri

İstatistiksel olarak veri tipini yalnızca teknik saklama biçimiyle değil, ölçüm ölçeğiyle de düşünmek gerekir.

Ölçek	Tanım	Örnek	Anlamlı işlemler
Nominal	Sırasız kategoriler	şehir, ürün kategorisi	frekans, oran
Ordinal	Doğal sırası olan kategori	memnuniyet: düşük/orta/yüksek	medyan, sıra karşılaştırması
Interval	Eşit aralık, mutlak sıfır yok	°C sıcaklık	fark, ortalama
Ratio	Eşit aralık + gerçek sıfır	gelir, süre, adet	tüm aritmetik işlemler

> Örneğin müşteri_id teknik olarak integer olabilir; ama analitik anlamda sayısal bir ölçüm değildir. Ortalama müşteri_id hesaplamak anlamsızdır.

3. Structured, semi-structured ve unstructured data

3.1 Structured data

Satır ve sütunlardan oluşan, şeması önceden tanımlı veridir. İlişkisel veritabanları ve çoğu Excel/CSV veri seti bu gruptadır.

- Orders tablosu: order_id, customer_id, order_date, amount
- Customers tablosu: customer_id, city, segment
- Products tablosu: product_id, category, cost

3.2 Semi-structured data

Tamamen tablo biçiminde değildir ama anahtar-değer yapısı veya etiketler içerir. JSON, XML ve event logları tipik örneklerdir.

```
{"event":"purchase", "user_id":481, "amount":1299.90, "device":"mobile"}
```

3.3 Unstructured data

Sabit sütun şemasına sahip olmayan metin, görsel, ses veya video gibi verilerdir. Müşteri yorumları, e-postalar, çağrı merkezi kayıtları ve sosyal medya içerikleri bu gruptadır.

Veri	Tip	Analiz yaklaşımı
SQL satış tablosu	Structured	SQL / BI / Pandas
Web event JSON	Semi-structured	parse + flatten + event analytics
Müşteri yorumları	Unstructured	NLP / sentiment / topic extraction
Ürün görselleri	Unstructured	computer vision / metadata

4. Veri şeması ve veri sözlüğü

Bir veri setini temizlemeden önce sütunların iş anlamını bilmek gerekir. Aynı isim farklı sistemlerde farklı şey ifade edebilir. “revenue” brüt sipariş tutarı mı, iadeler sonrası net gelir mi? “customer” kayıtlı kullanıcı mı, ödeme yapan kişi mi?

4.1 Veri sözlüğü örneği

Alan	Tip	Tanım	Kural
order_id	string	benzersiz sipariş kimliği	null olamaz, unique olmalı
customer_id	string	müşteri kimliği	null olabilir: guest checkout
order_date	datetime	sipariş oluşturma zamanı	gelecekte olamaz
quantity	integer	satılan ürün adedi	> 0
unit_price	decimal	birim satış fiyatı	>= 0
discount	decimal	indirim oranı	0 ile 1 arasında
status	category	sipariş durumu	allowed: completed/cancelled/returned

> Gerçek işte veri sözlüğü, analistin en değerli referanslarından biridir. Veri kaynağı değiştiğinde veya yeni ekip üyesi katıldığında yanlış yorumları azaltır.

5. Missing Values - Eksik değerler

Eksik değer, bir alanın beklenen değerinin bulunmamasıdır. Ancak her null hata değildir. Guest checkout yapan müşteride customer_id olmaması iş kuralına uygunsa bu geçerli bir null olabilir.

5.1 Eksikliğin üç temel mekanizması

Mekanizma	Anlam	Örnek
MCAR	Eksiklik diğer değişkenlerden bağımsız	rastgele sensör kesintisi
MAR	Eksiklik gözlenen başka değişkenlerle ilişkili	mobil kullanıcılarda yaş alanının daha sık boş olması
MNAR	Eksikliğin kendisi gerçek değerle ilişkili	yüksek gelirli kişilerin geliri belirtmemesi

5.2 Önce ölç, sonra müdahale et

Her sütun için null sayısı ve null oranı hesaplanır. Ardından eksikliğin segmentlere göre değişip değişmediğine bakılır.

Sütun	Null oranı	İlk yorum
customer_id	3.1%	guest checkout olabilir
city	0.2%	adres entegrasyonu kontrol edilmeli
discount_code	76%	doğal olabilir; çoğu sipariş kuponsuz
unit_cost	12%	profit analizini bozacağı için kritik

5.3 Eksik değer stratejileri

- Silme: Kayıt sayısı küçük ve rastgele eksiklikte düşünülebilir.
- Sabit değerle doldurma: “Unknown”, 0 gibi değerler yalnızca iş anlamı uygunsa.
- İstatistiksel imputasyon: mean/median/mode; dağılımı bozabileceğini unutma.

- Grup bazlı imputasyon: kategori/segment medyanı gibi daha bağlamsal yaklaşım.
- Model bazlı imputasyon: daha ileri senaryolarda.
- Eksiklik göstergesi: was_missing gibi ek kolon oluşturmak bazı analizlerde değerlidir.

0 ile null aynı şey değildir. “discount=0” indirim yapılmadığını, “discount=null” ise bilginin kaydedilmediğini ifade edebilir.

6. Duplicates - Tekrar kayıtlar

Duplicate analizi yalnızca “aynı satırı silmek” değildir. Önce bir kaydın benzersizliğini hangi kolon veya kolon kombinasyonunun tanımladığını bulman gerekir.

6.1 Duplicate türleri

Tür	Örnek	Risk
Tam duplicate	tüm sütunlar birebir aynı	metriklerin iki kez sayılması
Key duplicate	aynı order_id, farklı status	entegrasyon / güncelleme problemi
Business duplicate	aynı müşteri + aynı tutar + aynı dakika	çift ödeme veya retry
Doğal tekrar	aynı müşteri aynı ürünü iki kez almış	silinmemeli

6.2 Duplicate inceleme sırası

1. Primary/business key belirle.
2. Duplicate sayısını ve oranını ölç.
3. Tekrar eden kayıtların hangi alanlarda farklılaştığını incele.
4. Kaynak sistem davranışını doğrula: update mi, append mi?
5. Silme, latest-record tutma veya aggregation kararını iş kuralına göre ver.

order_id benzersiz olmalıysa iki satır görmek otomatik olarak birini silmen gerektiği anlamına gelmez. Biri “pending”, diğeri “completed” ise event history tablosu görüyor olabilirsin.

7. Outliers - Aykırı değerler

Aykırı değer, dağılımın büyük kısmından belirgin şekilde uzak gözlemdir. Fakat aykırı = yanlış değildir. 1 milyon TL’lik sipariş, B2B bir müşteri için tamamen gerçek olabilir.

7.1 Aykırı değer tespit yöntemleri

Yöntem	Mantık	Ne zaman?
Domain rule	iş kuralına aykırı değer	yaş <0, quantity=0
IQR	Q1-1.5×IQR / Q3+1.5×IQR	çarpık dağılımlarda pratik
Z-score	ortalamadan std cinsinden uzaklık	yaklaşık normal dağılım
Percentile	üst/alt yüzdelik eşikleri	iş raporlamasında kolay
Visual	boxplot / histogram / scatter	bağlamı anlamak

7.2 IQR örneği

Q1=100 TL, Q3=500 TL ise IQR=400 TL. Üst eşik = 500 + 1.5×400 = 1.100 TL. Bu kural 1.100 TL üzerindeki değerleri inceleme adayı yapar; otomatik silme kararı değildir.

7.3 Outlier ile ne yapılır?

- Doğrula: veri giriş hatası mı, gerçek gözlem mi?
- Düzelt: kaynak belli ise yanlış değeri düzelt.
- Sil: yalnızca hatalı olduğu kanıtlanmışsa.
- Winsorize / cap: bazı modelleme senaryolarında.
- Log transform: güçlü sağ çarpıklıkta.
- Segment et: VIP/B2B gibi ayrı popülasyon olabilir.
- Olduğu gibi bırak: iş açısından gerçek ve anlamlıysa.

8. Veri kalitesi boyutları

Veri kalitesi “temiz görünüyor” şeklinde subjektif değerlendirilmemelidir. Ölçülebilir boyutlara ayrılmalıdır.

Boyut	Soru	Örnek kontrol
Completeness	Gerekli alanlar dolu mu?	unit_cost null oranı < %1
Uniqueness	Benzersiz olması gereken kayıtlar benzersiz mi?	order_id duplicate = 0
Validity	Değer kurallara uyuyor mu?	discount 0-1 aralığında
Accuracy	Değer gerçeği yansıtıyor mu?	ERP ile ödeme tutarı eşleşiyor mu?
Consistency	Sistemler arasında tutarlı mı?	CRM city ile shipping city uyumlu mu?
Timeliness	Veri zamanında geliyor mu?	D-1 raporu 08:00’e kadar hazır mı?
Integrity	İlişkiler korunuyor mu?	orders.customer_id customers tablosunda var mı?

8.1 Veri kalite skoru

Takımlar bazen her boyut için yüzde üretip tek bir “Data Quality Score” oluşturur. Ancak toplam skor tek başına yeterli değildir; kritik bir alan %70 completeness iken genel skor %95 olabilir. Bu nedenle kritik alan bazlı eşikler de tanımlanmalıdır.

9. Veri temizleme iş akışı

Profesyonel veri temizleme, rastgele fonksiyonlar kullanmak yerine tekrarlanabilir bir pipeline şeklinde yapılır.

6. Kaynağı ve iş bağlamını anla.
7. Schema ve veri sözlüğünü çıkar.
8. Profiling yap: row count, data types, nulls, uniques, dağılımlar.
9. Formatları standardize et: tarih, text, para birimi, kategori.
10. Duplicate kontrollerini uygula.
11. Missing value analizini yap.

12. Outlier ve domain-rule kontrollerini yap.
13. Referential integrity ve cross-field validation uygula.
14. Temizlik kararlarını logla.
15. Temiz veri setini ve kalite raporunu üret.
16. Analizden önce son sanity check yap.

9.1 Asla ham verinin üstüne yazma

> İdeal yapı: raw → staging/clean → analytics. Ham veri immutable tutulursa yanlış bir temizleme adımını geri almak ve audit yapmak kolaylaşır.

10. Text ve kategori standardizasyonu

Kategorik alanlarda küçük yazım farkları aynı grubu farklı değerler haline getirebilir.

Ham değer	Standardize değer	İşlem
istanbul	Istanbul	trim + case normalization
İSTANBUL	Istanbul	case mapping
Istanbul / TR	Istanbul	pattern extraction
Electronics	Electronics	canonical category
electronic	Electronics	mapping table

10.1 Mapping table kullanımı

Hard-code edilen onlarca IF koşulu yerine bir mapping tablosu tutulması daha sürdürülebilirdir: raw_value → canonical_value. Bu yaklaşım Excel, SQL, Power Query ve Python'da aynı prensiple uygulanabilir.

11. Tarih ve zaman verisi

Tarih alanları veri analizinde en çok hata üreten alanlardan biridir. "01/02/2026" ifadesi 1 Şubat mı, 2 Ocak mı? Sistem formatı ve locale bilinmelidir.

11.1 Tarih kontrolleri

- String mi gerçek datetime mı?
- Timezone nedir? UTC mi lokal saat mi?
- Future date veya imkansız tarih var mı?
- Created_at ile completed_at sırası mantıklı mı?
- Gün/hafta/ay başlangıcı tanımları tutarlı mı?
- DST veya timezone dönüşümleri event sayımlarını etkiliyor mu?

> Global ürünlerde timestamp'leri mümkünse UTC saklayıp raporlama katmanında lokal timezone'a çevirmek yaygın bir yaklaşımdır.

12. Cross-field validation ve iş kuralları

Bir sütun tek başına geçerli görünse bile başka bir sütunla birlikte mantıksız olabilir. Bu nedenle çapraz alan kontrolleri kritik önemdedir.

Kural	Geçersiz örnek
completed_at >= created_at	sipariş tamamlanma tarihi oluşturulmadan önce
returned => status=returned	return_amount > 0 fakat status=completed
revenue = quantity × unit_price - discount	hesaplanan ve kayıtlı revenue farklı
profit = revenue - cost	profit ile bileşenler uyuşmuyor
age >= 18 for adult product	yaş kuralı ihlali

13. Veri profiling - ilk 15 dakika

Yeni bir veri seti geldiğinde hemen analiz yapmadan önce sistematik profiling uygulanmalıdır.

Kontrol	Neden?
Row / column count	beklenen hacim mi?
Data types	yanlış tipler var mı?
Head / sample	alanlar neye benziyor?
Null counts	kritik eksiklik var mı?
nunique	ID/kategori davranışı
min/max	imkansız değerler
percentiles	dağılım ve outlier
duplicate keys	benzersizlik
value counts	kategori yazım farkları
date range	veri dönemi doğru mu?

> Profiling çıktısı, çoğu zaman analize başlamadan önce veri kaynağındaki problemi ortaya çıkarır. Bu seni saatlerce yanlış sonuca gitmekten kurtarabilir.

14. Gerçek vaka: Kirli e-ticaret veri seti

Senaryo: Yönetim, son 6 ayın kategori ve şehir bazlı satış performansını görmek istiyor. Sana 250.000 satırlık orders.csv veriliyor. Ancak veri doğrudan raporlanabilir durumda değil.

14.1 Tespit edilen problemler

Problem	Gözlem	Risk
Duplicate order_id	1.842 kayıt	revenue fazla sayılır
unit_cost missing	%8.7	profit yanlış/eksik
city yazım farkları	Istanbul, İstanbul, IST	segment kırılır

Problem	Gözlem	Risk
negative quantity	128 kayıt	iade mi hata mı belirsiz
future dates	37 kayıt	trend bozulur
discount > 1	54 kayıt	oran/yüzde format sorunu
status null	%0.4	funnel ve net sales etkilenir

14.2 Çözüm yaklaşımı

17. order_id davranışını kaynak sistemle doğrula; event history ise son statüyü seç, gerçek duplicate ise deduplicate et.
18. unit_cost için ürün master tablosu ile join yap; halen eksikse rapor kapsamından veya profit metriğinden kontrollü biçimde ayır.
19. city alanını mapping tablosuyla standardize et.
20. negative quantity kayıtlarını return/refund kayıtlarıyla çapraz kontrol et.
21. future date kayıtlarını ingestion bug olarak işaretle ve düzeltme bekleyen quarantine tablosuna al.
22. discount alanında 20 ve 0.20 formatlarının karışıp karışmadığını tespit et.
23. status null kayıtlarında payment ve fulfillment loglarından statü türetmeyi değerlendir.

14.3 Temizlik sonrası kalite raporu

Metrik	Önce	Sonra
Unique order_id	%99.26	%100
unit_cost completeness	%91.3	%99.8
valid city values	%96.5	%100
valid date range	%99.98	%100
valid discount	%99.78	%100
referential integrity	%98.9	%99.99

> Analiste güven kazandıran şey yalnızca “veriyi temizledim” demek değil; neyin değiştiğini, neden değiştiğini ve sonucunda kalite metriklerinin nasıl iyileştiğini gösterebilmektir.

15. Temizlik kararlarının dokümantasyonu

Veri temizleme adımları görünmez kalmamalıdır. Her önemli kural belgelenmelidir.

Alan	Karar	Gerekçe	Etki
city	mapping ile canonical isim	aynı şehrin farklı yazımları	segmentasyon düzeldi
unit_cost	product master’dan doldur	profit için gerekli	%8.5 kayıt kurtarıldı
future order_date	quarantine	sistem hatası	37 kayıt analiz dışı
duplicate order	latest status retained	event update davranışı	double count engellendi

16. Excel, SQL, Python ve Power Query'de aynı prensip

Araç değişse de veri kalite mantığı değişmez.

İş	Excel / Power Query	SQL	Python/Pandas
Null kontrol	COUNTBLANK / profiling	IS NULL	isna()
Duplicate	Remove Duplicates	GROUP BY + HAVING	duplicated()
Type cast	Change Type	CAST	astype()/to_datetime
Text trim	TRIM	TRIM	str.strip()
Outlier	QUARTILE / filters	percentile functions	quantile()/IQR
Join validation	XLOOKUP / Merge	JOIN	merge()

> İyi analist bir araca bağımlı değildir; veri problemi ve kontrol mantığını anlar, sonra uygun araçta uygular.

17. Sık yapılan hatalar

- Null gördüğünde otomatik olarak satırı silmek.
- Duplicate gördüğünde iş anahtarını anlamadan remove duplicates yapmak.
- Outlier'ları "analizi bozuyor" diye silmek.
- ID kolonlarında mean/median hesaplamak.
- String tarihleri gerçek tarih sanmak.
- 0 ile null değerlerini aynı kabul etmek.
- Kategori standardizasyonunu manuel ve tekrarlanamaz yapmak.
- Ham veriyi değiştirip audit trail bırakmamak.
- Veri kalitesini yalnızca görsel kontrolle değerlendirmek.
- Temizleme sonrası row count ve toplam revenue gibi kontrol toplamlarını karşılaştırmamak.

18. Mülakat soruları

Bir veri setinde %30 missing value olan bir kolon gördün. Ne yaparsın?

Önce kolonun iş önemini ve eksikliğin nedenini incelerim. Segmentlere göre missing pattern bakarım. Kritik değilse dışlayabilir, kritikse uygun imputasyon veya başka kaynaktan tamamlama düşünebilirim. Kararı veri mekanizması ve iş etkisine göre veririm.

Duplicate kayıt ile gerçek tekrar arasındaki farkı nasıl belirlersin?

Önce business key belirlerim. Aynı key'e sahip satırların diğer alanlarını, timestamp ve status değişimlerini karşılaştırırım. Kaynak sistem append/update davranışını doğrulamadan kayıt silmem.

Outlier gördüğünde hangi sırayla ilerlersin?

Domain rule → dağılım → IQR/percentile → segment bağlamı → kaynak doğrulama. Gerçek gözlemse korurum; hata ise düzeltir veya kontrollü şekilde hariç tutarım.

Data quality hangi boyutlardan oluşur?

Completeness, uniqueness, validity, accuracy, consistency, timeliness ve integrity temel boyutlardır.

Bir ID alanının integer olması neden onu sayısal metrik yapmaz?
Çünkü veri tipi ile ölçüm anlamı farklıdır. customer_id sayısal biçimde saklanabilir ama yalnızca kimliktir; aritmetik işlem anlamlı değildir.

0 ile NULL arasındaki farkı iş örneğiyle açıkla.
0 bilinen bir değerdir; NULL bilinmeyen veya mevcut olmayan değerdir. discount=0 indirim yok demektir; discount=NULL ise indirim bilgisinin kaydedilmediği anlamına gelebilir.

Referential integrity nedir? Nasıl kontrol edilir?
Tablolar arası ilişkilerin geçerli olmasıdır. Örneğin orders.customer_id değerlerinin customers.customer_id içinde bulunup bulunmadığı anti-join ile kontrol edilebilir.

Bir sütunda "Istanbul, İstanbul, ISTANBUL" değerleri varsa ne yaparsın?
Normalize + mapping table ile canonical "Istanbul" değerine dönüştürürüm; mapping kuralını kodlanmış ve tekrar kullanılabilir tutarım.

Ham veriyi neden değiştirmemeliyiz?
Reproducibility, rollback ve audit için raw katman değişmeden tutulmalıdır. Temizlik staging/clean katmanında uygulanmalıdır.

Bir veri temizleme sürecinin doğru olduğunu nasıl doğrularsın?
Önce/sonra kalite metriklerini, row count ve kontrol toplamlarını kıyaslar; kritik iş metriklerinin beklenmeyen biçimde değişmediğini kontrol eder; kuralları örnek kayıtlarla doğrularım.

19. Uygulama alıştırmaları

24. Bir satış veri setinde her sütun için data type, null count, unique count ve min/max çıkar.
25. order_id duplicate kayıtlarını bul ve hangi kayıtların gerçekten duplicate olduğunu iş mantığıyla sınıflandır.
26. city sütunundaki farklı yazımları canonical değerlere dönüştüren mapping oluştur.
27. unit_price dağılımı için Q1, Q3, IQR ve outlier eşiklerini hesapla.
28. order_date için gelecekteki kayıtları, çok eski tarihleri ve parse edilemeyen değerleri işaretle.
29. revenue = quantity × unit_price × (1-discount) kuralını test eden bir validation alanı üret.
30. customer_id foreign key kontrolü yap ve customers tablosunda bulunmayan kayıtların oranını hesapla.
31. Temizlik öncesi ve sonrası bir Data Quality Scorecard hazırla.

20. Modül projesi - Dirty E-Commerce Dataset Cleaning

Proje hedefi

Gerçekçi biçimde kirletilmiş bir e-ticaret veri setini raw halden analiz-ready hale getir ve veri kalitesi raporuyla birlikte sun.

Teslimatlar

- raw_data: değiştirilmemiş kaynak dosya
- clean_data: temizlenmiş nihai tablo
- data_dictionary: kolon tanımları ve kurallar

- quality_report: completeness, uniqueness, validity, integrity metrikleri
- cleaning_log: yapılan tüm dönüşümler ve gerekçeleri
- README: problem, yöntem, sonuç ve önemli kararlar

Portfolio'da nasıl anlatılır?

> "250K satırlık e-ticaret sipariş verisinde duplicate, missing cost, kategori standardizasyonu, tarih anomalileri ve referential integrity problemlerini tespit edip temizleme pipeline'ı oluşturdum. Kritik veri kalite kontrollerini raporlayarak analiz-ready dataset ürettim."

21. Modül özeti - ezberlemen gereken değil, anlaman gereken

Konu	Ana fikir
Veri tipi	teknik tip ≠ analitik anlam
Structured data	şema analizi kolaylaştırır ama kaliteyi garanti etmez
Missing values	null otomatik hata değildir
Duplicates	business key ve kaynak davranışı anlaşılmadan silinmez
Outliers	inceleme adayıdır, otomatik hata değildir
Data quality	ölçülebilir boyutlarla takip edilir
Cleaning	tekrarlanabilir pipeline olmalıdır
Validation	tek kolon + çapraz alan + ilişkisel kontroller birlikte uygulanır
Documentation	her dönüşüm gerekçesiyle kaydedilir

Bu modülü gerçekten öğrendiğinin göstergesi, kirli bir dosyayı "temiz görünür" hale getirmek değil; hangi kalite problemlerinin bulunduğunu, hangi kararların neden verildiğini ve temizliğin analitik sonucu nasıl etkilediğini açıklayabilmendir.

22. Kendini test et - kontrol listesi

☐ Veri tiplerini teknik ve analitik anlamıyla ayırt edebiliyorum.
☐ Structured / semi-structured / unstructured veriyi ayırt edebiliyorum.
☐ Eksik değerlerin nedenini analiz edip uygun strateji seçebiliyorum.
☐ Duplicate kayıtları business key üzerinden inceleyebiliyorum.
☐ Outlier tespiti için domain rule, IQR ve percentile kullanabiliyorum.
☐ Data quality boyutlarını ölçebiliyorum.
☐ Raw → clean → analytics katman mantığını açıklayabiliyorum.
☐ Veri sözlüğü ve cleaning log hazırlayabiliyorum.
☐ Cross-field ve referential integrity kontrolleri tasarlayabiliyorum.
☐ Temizleme sonrası kaliteyi sayısal olarak doğrulayabiliyorum.