VERI ANALISTI MÜFREDATI - 2026

MODÜL 13

AI Destekli Analiz

SQL üretme/kontrol • Python üretme • EDA hızlandırma • Veri temizleme • Dashboard fikirleri • Analiz doğrulama

Modülün amacı
AI araçlarını analistin yerine karar veren bir otorite gibi değil, analiz sürecini hızlandıran bir copilot gibi kullanmayı öğrenmek. Bu modülün sonunda AI ile daha hızlı çalışırken veri kalitesi, iş mantığı ve doğrulama sorumluluğunu elinde tutabileceksin.

Kazanım	Beklenen çıktı
İyi analitik prompt yazma	Bağlamı, tablo şemasını, business question ve beklenen çıktıyı açıkça tanımlamak
SQL/Python üretme ve kontrol	AI çıktısını çalıştırmadan önce ve sonra sistematik doğrulamak
EDA hızlandırma	Profiling, hipotez üretme ve görsel önerileri hızlandırmak
Veri temizleme desteği	Temizleme kurallarını AI ile tasarlayıp kontrollü uygulamak
Dashboard ve storytelling	KPI, chart ve executive narrative önerileri üretmek
Risk yönetimi	Hallucination, leakage, gizlilik ve yanlış çıkarım risklerini yönetmek

Temel ilke: AI hız kazandırır; doğruluk sorumluluğu analisttedir.

1. AI Destekli Analiz Nedir?

AI destekli analiz; veri analistinin soru formülasyonu, kod yazımı, debugging, veri temizleme, keşifsel analiz, görselleştirme ve iletişim adımlarında üretken yapay zekadan yardım aldığı çalışma biçimidir. Amaç analitik düşünmeyi devretmek değil, mekanik ve tekrar eden işleri hızlandırmaktır.

Klasik yaklaşım	AI destekli yaklaşım
SQL'i tamamen elle yazmak	Taslağı AI ile üretip schema ve sonuçları analist olarak doğrulamak
EDA adımlarını sıfırdan düşünmek	AI'dan profiling checklist'i ve olası hipotezler almak
Hata mesajlarını tek tek aramak	Hata + kod + schema ile debugging önerisi almak
Dashboard tasarımına boş sayfadan başlamak	KPI ve chart önerileri üretip iş önceliklerine göre elemek
Rapor metnini sıfırdan yazmak	Bulguları AI ile executive summary taslağına dönüştürmek

Copilot zihniyeti
AI sana öneri, taslak ve alternatif üretir. Hangi tanımın doğru olduğunu, veri grain'ini, doğru denominator'ı ve hangi sonucun iş açısından anlamlı olduğunu yine sen belirlersin.

1.1 AI'nin güçlü olduğu işler

- Boilerplate SQL/Python kodu üretmek
- Kod açıklamak ve refactor önermek
- Hata mesajlarından olası nedenler çıkarmak
- EDA için kontrol listesi oluşturmak
- Grafik/metric alternatifleri önermek
- Dokümantasyon ve README taslağı hazırlamak
- İçgörüleri farklı paydaş seviyelerine göre yeniden ifade etmek

1.2 AI'ye bırakmaman gereken kararlar

- KPI tanımının son kararı
- Join grain ve cardinality kontrolü
- İstatistiksel test varsayımlarının geçerliliği
- Nedensellik iddiası
- Data leakage riski
- Gizli/veri koruma gereksinimleri
- İş kararının ekonomik anlamı

2. Analitik Prompt Tasarımı

AI çıktısının kalitesi yalnızca modelin gücüne değil, verdiğin bağlamın kalitesine de bağlıdır. Analitik görevlerde iyi prompt; iş sorusunu, veri yapısını, kuralları ve beklenen çıktıyı açıkça tanımlar.

Bileşen	Ne yazmalısın?	Örnek
Rol	AI'nin hangi uzmanlıkla davranacağını belirt	Senior data analyst gibi davran
Amaç	Business question	Son 90 günde repeat purchase neden düştü?
Schema	Tablo ve kolonlar	orders(order_id, customer_id, order_date, revenue, status)
Grain	Bir satırın neyi temsil ettiği	orders tablosunda bir satır = bir sipariş
Kurallar	Filtre/iş tanımı	status = completed; refund hariç
Çıktı	İstenen format	PostgreSQL sorgusu + açıklama + validation queries

Prompt formülü
BAĞLAM + BUSINESS QUESTION + SCHEMA + GRAIN + KURALLAR + İSTENEN ÇIKTI + DOĞRULAMA KRİTERİ

2.1 Zayıf ve güçlü prompt karşılaştırması

Zayıf prompt: "Aylık satış SQL'i yaz."

Güçlü prompt:

> PostgreSQL kullanıyorum.
>
> orders tablosunda bir satır bir siparişi temsil ediyor.
>
> Kolonlar: order_id, customer_id, order_date, status, gross_revenue, refund_amount.
>
> Business question: 2026 yılı için aylık net revenue trendini görmek istiyorum.
>
> Sadece status = completed siparişleri dahil et.
>
> Net revenue = gross_revenue - refund_amount.
>
> Çıktı: month, order_count, net_revenue, avg_order_value.
>
> Önce sorguyu yaz, sonra grain ve double-counting riskini açıkla, ardından 3 validation query öner.

3. AI ile SQL Üretme ve Kontrol

AI SQL yazmayı ciddi biçimde hızlandırabilir; ancak en tehlikeli hata “sorgu çalıştıysa doğrudur” varsayımıdır. Syntactically valid SQL, business-wise wrong olabilir.

3.1 AI’ya SQL yazdırmadan önce

- SQL dialect’i belirt: PostgreSQL, BigQuery, Snowflake, SQL Server vb.
- Tablo grain’lerini yaz
- PK/FK ilişkilerini belirt
- Metric tanımlarını açıkla
- NULL, cancelled, refund gibi edge-case kurallarını ver
- Beklenen satır sayısı veya sonuç şeklini belirt

3.2 Örnek: müşteri segmentasyonu

```
WITH customer_sales AS (
  SELECT
    customer_id,
    COUNT(DISTINCT order_id) AS order_count,
    SUM(net_revenue) AS revenue
  FROM orders
  WHERE status = 'completed'
  GROUP BY customer_id
)
SELECT
  customer_id,
  order_count,
  revenue,
  CASE
    WHEN revenue >= 5000 THEN 'High Value'
    WHEN revenue >= 1500 THEN 'Mid Value'
    ELSE 'Low Value'
  END AS value_segment
FROM customer_sales;
```

3.3 SQL validation checklist

Kontrol	Soru
Grain	Sonuçtaki her satır neyi temsil ediyor?
Join	1:N join revenue’yu çoğaltıyor mu?
Filter	Cancelled/refunded kayıtlar doğru ele alındı mı?
Distinct	COUNT(DISTINCT ...) gerçekten gerekli mi, yoksa hatayı mı gizliyor?
NULL	NULL değerler hesaplamayı etkiliyor mu?
Date	Timezone ve tarih sınırları doğru mu?
Sanity check	Toplam revenue kaynak sistemle makul ölçüde eşleşiyor mu?

Altın kural
AI’dan yalnızca ana sorguyu değil, validation query’lerini de iste. Örneğin join öncesi/sonrası row count, distinct order_id kontrolü ve toplam revenue reconciliation sorguları.

4. AI ile Python Üretme, Debug ve Refactor

Python tarafında AI; Pandas kodu, veri temizleme fonksiyonları, EDA akışları ve hata çözme konusunda çok etkilidir. Fakat otomatik üretilen kodu özellikle büyük veri, dtype ve chained assignment gibi konularda kontrol etmek gerekir.

4.1 İyi Python prompt örneği

> Pandas ile çalışıyorum. df_orders kolonları:
>
> order_id:int, customer_id:int, order_date:str, city:str, revenue:float, status:str.
>
> Amaç:
>
> 1) order_date'i datetime yap,
>
> 2) city alanını trim + title case ile normalize et,
>
> 3) duplicate order_id'leri raporla ama otomatik silme,
>
> 4) revenue < 0 kayıtları ayrı dataframe'e ayır,
>
> 5) temizleme sonrası kalite raporu üret.
>
> Kod fonksiyonlaştırılmış, okunabilir ve her adımda assert içersin.

4.2 AI üretimi kodu nasıl doğrularsın?

- Koddan önce df.shape ve df.dtypes kaydet
- Her transform sonrası row-count değişimini kontrol et
- Unique key için duplicated().sum() kontrol et
- Numeric kolonlarda min/max/quantile kontrolü yap
- Merge sonrası validate= veya row-count kontrolü kullan
- Fonksiyonları küçük test dataframe’lerinde çalıştır
- Beklenmeyen category/NULL artışını takip et

4.3 Hata çözmede bağlam verme

Sadece hata mesajını yapıştırmak yerine: kod parçası + dtypes + örnek 5 satır + beklenen davranış + gerçek davranış ver. Böylece AI semptomu değil nedeni analiz edebilir.

5. AI ile EDA Hızlandırma

EDA'nın amacı otomatik olarak çok grafik üretmek değil, verinin yapısını anlamak ve business question için hangi sinyallerin önemli olabileceğini keşfetmektir. AI bu aşamada bir "hipotez ve kontrol listesi jeneratörü" olarak değerlidir.

EDA adımı	AI'dan isteyebileceğin yardım	Analistin kontrolü
Profiling	Kolon bazlı kontrol listesi	Dtype ve business semantics doğru mu?
Missing	Missing pattern hipotezleri	MCAR/MAR gibi varsayımları doğrudan kabul etme
Outlier	Olası yöntemler: IQR, percentile, domain rules	Outlier iş olayı mı veri hatası mı?
Segment	Hangi segmentler karşılaştırılabilir?	Simpson's paradox / mix effect riski
Trend	Seasonality ve change-point soruları	Takvim etkilerini doğrula
Correlation	İlişki adayları	Correlation != causation

5.1 AI ile hipotez üretimi

Örneğin conversion %3.4'ten %2.8'e düştüyse AI'dan "olası nedenleri" listelemesini isteyebilirsin: kanal mix'i, mobil/desktop farkı, landing page değişimi, trafik kalitesi, fiyat/indirim değişimi, stok problemleri vb. Ancak bunlar sonuç değil, test edilecek hipotezlerdir.

Doğru kullanım
AI: "Nerelere bakmalıyım?" sorusunda güçlüdür. "Kesin neden nedir?" sorusunda veri kanıtı olmadan güvenilmez.

6. AI Destekli Veri Temizleme

Veri temizlemede AI'nın en değerli rolü, dönüşüm kuralı üretmek ve edge-case'leri hatırlatmaktır. Otomatik silme veya imputasyon kararları ise kontrollü uygulanmalıdır.

Problem	AI önerisi örneği	Risk
Kategori varyasyonları	istanbul, İstanbul , ISTANBUL -> İstanbul	Yanlış eşleme
Tarih formatları	dd/mm/yyyy ve yyyy-mm-dd ayrıştırma	Day/month ambiguity
Duplicate	Exact + fuzzy duplicate stratejisi	Gerçek tekrarları silmek
Missing	Imputation seçeneklerini sıralamak	İstatistiksel dağılımı bozmak
Outlier	IQR + domain-rule birlikte kullanmak	Gerçek VIP müşteri/large order'ı silmek

6.1 Temizleme karar günlüğü

Profesyonel workflow'da her temizlik kuralı belgelenir: problem, kural, etkilenen satır sayısı, neden, geri döndürülebilirlik ve doğrulama sonucu. AI bu tabloyu otomatik taslaklayabilir.

Alan	Örnek
Problem	city kolonunda 14 farklı İstanbul yazımı
Kural	trim + lowercase mapping dictionary
Etkilenen satır	18,421
Kontrol	önce/sonra unique category sayısı
Risk	İstanbul dışındaki benzer stringleri yanlış map etmemek

7. AI ile Dashboard ve Görselleştirme Fikirleri

AI'dan "dashboard yap" istemek yerine hedef kullanıcıyı, kararları ve KPI'ları ver. Böylece daha iyi chart ve layout önerileri alırsın.

7.1 Executive dashboard prompt şablonu

Hedef kullanıcı: E-commerce Director.

Kararlar: bütçe dağılımı, kanal optimizasyonu, retention aksiyonları.

KPI'lar: net revenue, orders, AOV, conversion, repeat rate, refund rate.

Boyutlar: month, channel, device, country, category.

Bana 1 sayfalık Power BI dashboard wireframe'i öner.

Her visual için: business question, chart type, x/y/legend, neden uygun olduğu, yanlış yorumlama riski.

7.2 Chart seçiminde AI'yı sorgula

- Trend -> line chart
- Kategori karşılaştırma -> sorted bar
- Dağılım -> histogram/boxplot
- İki numeric ilişki -> scatter
- Funnel -> step conversion veya funnel visual
- Retention -> cohort heatmap
- Executive KPI -> card + comparison delta

Dashboard kalite testi
Her visual bir soruya cevap vermeli. Eğer grafiğin varlığı yalnızca "veri var" gerekçesine dayanıyorsa çıkarılabilir.

8. AI Çıktılarını Doğrulama Sistemi

AI ile çalışmanın profesyonel seviyesi, iyi prompt yazmaktan çok iyi doğrulama yapabilmektir. Her AI çıktısı dört katmanda test edilmelidir.

Katman	Kontrol
1. Syntax	Kod çalışıyor mu?
2. Data logic	Grain, join, filter, null mantığı doğru mu?
3. Statistical logic	Metric/test varsayımları doğru mu?
4. Business logic	Sonuç gerçek iş tanımlarıyla uyumlu mu?

8.1 Reconciliation

Yeni AI sorgusunun sonucu güvenilir bir kaynakla karşılaştırılır. Örneğin aylık revenue toplamı finans dashboard'ı veya mevcut validated query ile karşılaştırılır. Fark varsa oranı ve nedeni açıklanır.

8.2 Assert-first yaklaşımı

```
assert df_orders['order_id'].notna().all()
assert df_orders['order_id'].is_unique
assert (df_orders['net_revenue'] >= -100000).all()
assert df_orders['status'].isin(['completed','cancelled','refunded']).all()
```

8.3 AI'ya karşı AI kullanmak?

Aynı sorguyu başka bir promptla eleştirtmek faydalı olabilir; ancak iki AI cevabının birbirini doğrulaması gerçek doğrulama değildir. Nihai kontrol veriye, schema'ya, iş tanımlarına ve test sonuçlarına dayanmalıdır.

9. Hallucination, Gizlilik ve Güvenlik Riskleri

9.1 Hallucination nedir?

Modelin kendinden emin görünen ancak yanlış tablo, kolon, fonksiyon, iş kuralı veya açıklama üretmesidir. Analitikte en sık görülen biçimi olmayan kolonları varsaymak veya database dialect'ine uymayan fonksiyonlar yazmaktır.

Risk	Örnek	Kontrol
Schema hallucination	orders.customer_segment diye olmayan kolon	Schema'yı prompt'a ver
Yanlış dialect	DATE_TRUNC syntax farkı	Engine'i belirt ve docs ile karşılaştır
Metric uydurma	Gross margin denominator hatası	Metric dictionary kullan
Causality	Correlation'dan neden-sonuç çıkarmak	Deney/identification strategy sorgula
Data leakage	Future data ile model/analiz	Time-aware split / cutoff kontrolü

9.2 Gizlilik

- Müşteri PII, kimlik, e-posta, telefon, ödeme verisini izin olmadan modele göndermeme
- Şirket politikası ve veri sınıflandırmasına uyma
- Mümkünse anonimleştirilmiş/sentetik örnek kullanma
- Prompt'a yalnızca görev için gerekli minimum veriyi koyma
- Üçüncü taraf araçların retention ve training ayarlarını kurumsal politika açısından kontrol etme

Pratik kural
Gerçek müşteri datası yerine schema + 5-10 satırlık anonim örnek + aggregate istatistiklerle çoğu analitik problemi çözebilirsin.

10. Uçtan Uca AI-Assisted Analytics Workflow

Aşağıdaki akış, AI'ı tüm sürece entegre ederken karar kontrolünü analistte tutar.

Adım	Ne yaparsın?
1. Business question	Problemi ve karar vericiyi tanımla.
2. Data contract	Schema, grain, metric definition, tarih aralığını çıkar.
3. Prompt	Görevi ve validation kriterlerini AI'ya ver.
4. Draft	SQL/Python/EDA taslağını al.
5. Static review	Kodun grain, join, filter mantığını oku.
6. Run	Kontrollü ortamda çalıştır.
7. Validate	Row count, totals, unique key, reconciliation.
8. Analyze	Segment/trend/cohort gibi tekniklerle kanıt üret.
9. Challenge	Alternative explanation ve edge-case sor.
10. Communicate	Insight -> evidence -> recommendation formatına çevir.

10.1 İnsan-AI görev paylaşımı

AI'ya uygun	Analistin sahipliği
Kod taslağı	Business logic
Alternatif hipotezler	Hipotez önceliklendirme
Grafik fikirleri	Doğru chart seçiminin son kararı
Metin taslağı	İçgörünün kanıt düzeyi
Debug önerileri	Root cause doğrulaması

11. Gerçekçi Vaka: Conversion Düşüşünü AI ile Analiz Etmek

Senaryo: Bir e-ticaret şirketinde conversion rate son 4 haftada %3,6'dan %2,9'a düştü. Yönetim "neden?" sorusuna hızlı ama güvenilir cevap istiyor.

11.1 Business question parçalama

- Düşüş hangi tarihte başladı?
- Tüm kanallarda mı, belirli acquisition kanallarında mı?
- Mobile/desktop farkı var mı?
- Product/category mix değişti mi?
- Checkout funnel'ın hangi adımında kayıp arttı?
- Stock-out veya price change etkisi var mı?

11.2 AI'ya verilecek veri bağlamı

```
sessions(session_id, user_id, session_date, channel, device, country)
events(session_id, event_time, event_name, product_id)
orders(order_id, session_id, order_time, net_revenue, status)

Conversion = completed_order_sessions / eligible_sessions
Eligible session: bot = false, country in supported_markets
```

11.3 AI'dan istenebilecek çıktı

- Baseline SQL
- Channel-device segmentation SQL
- Funnel step conversion SQL
- Week-over-week contribution decomposition
- Validation queries
- Alternative explanations listesi

11.4 Analistin doğrulaması

AI "mobile paid social conversion düştü" diyebilir. Analist bunun yeterli olmadığını bilir: paid social trafik payı da artmışsa toplam düşüş hem segment performansı hem mix effect kaynaklı olabilir. Bu nedenle weighted decomposition yapılır.

Vaka sonucu örneği
Toplam düşüşün büyük kısmı iki etkiden geliyor olabilir: (1) mobile paid social segmentinde step-2 -> step-3 checkout drop artışı, (2) düşük conversion'lı paid social trafiğinin toplam trafik içindeki payının yükselmesi. Bu sonuç yalnızca segment ve mix etkileri ayrı test edilince güvenilir olur.

12. Analistler İçin Prompt Kütüphanesi

12.1 SQL reviewer

Aşağıdaki SQL'i senior analytics engineer gibi review et.

Kontrol et: grain, join cardinality, duplicate risk, null handling, date filters, metric definitions, performance.

Önce riskleri sırala; sonra düzeltilmiş sorguyu ver; en sonda validation queries yaz.

12.2 EDA planner

Business question ve schema aşağıda. Bana 30 dakikalık EDA planı hazırla.

Her adım için: neden bakıyoruz, hangi metric, hangi segment, hangi chart, hangi validation.

Gereksiz genel öneriler verme.

12.3 Data quality reviewer

Bu dataframe schema'sı için data quality checks üret.

Kontrolleri completeness, uniqueness, validity, consistency, timeliness olarak grupla.

Her kontrol için pandas kodu ve failure threshold öner.

12.4 Executive summary editor

Aşağıdaki bulguları 5 cümlelik executive summary'ye dönüştür.

Format: durum -> ana içgörü -> kanıt -> iş etkisi -> önerilen aksiyon.

Veride olmayan hiçbir neden-sonuç iddiası ekleme.

13. Sık Yapılan Hatalar

Hata	Neden tehlikeli?	Daha iyi yaklaşım
AI kodunu direkt production'da çalıştırmak	Yanlış update/delete veya maliyetli query	Read-only / limit / sandbox ile test
Schema vermemek	Model kolon ve ilişki uydurabilir	Explicit schema + grain
Tek promptta her şeyi istemek	Kontrol edilemez uzun çıktı	Adımlara böl
AI açıklamasını doğruluk kanıtı sanmak	Akıcı metin yanlış olabilir	Data-based validation
PII yapıştırmak	Gizlilik ihlali	Anonim/minimum gerekli veri
AI insight'ını causality gibi sunmak	Yanlış iş kararı	Evidence level belirt

14. Mülakat Soruları

1. AI ile yazdırdığın SQL'in doğru olduğunu nasıl kontrol edersin?
2. AI generated code neden data analyst için risklidir?
3. Bir join sonrası revenue iki katına çıktı. Nasıl debug edersin?
4. AI sana conversion düşüşünün nedenini söyledi. Bunu nasıl test edersin?
5. Prompt'a grain yazmak neden önemlidir?
6. AI ile confidential customer data kullanırken nelere dikkat edersin?
7. AI ile EDA yaparken hangi işleri otomatikleştirirsin, hangilerini etmezsin?
8. AI tarafından üretilmiş dashboard önerisini nasıl değerlendirirsin?
9. Hallucination ile syntax error arasındaki fark nedir?
10. AI kullanmak analistin hangi becerilerini daha önemli hale getirir?

15. Uygulama Alıştırmaları

11. orders tablosu için bir AI promptu yaz: aylık revenue, AOV ve active customer hesaplat. Validation kriterlerini de ekle.
12. AI'ya bir LEFT JOIN sorgusu yazdır. Sonra aynı promptta cardinality ve double-counting riskini incelet.
13. Bir Pandas temizleme scripti üret: duplicate order_id, invalid dates ve negative revenue kayıtlarını raporla.
14. Conversion düşüşü için 8 hipotez üret; her hipotez için test edilecek metric ve segmenti yaz.
15. Bir executive dashboard için 6 visual önerisi al; bunlardan gereksiz olan 2 tanesini nedenleriyle ele.
16. AI'nın oluşturduğu bir insight cümlesini "correlation" ve "causation" açısından eleştir.
17. Sentetik bir dataset schema'sı vererek data quality checklist üret.
18. Bir A/B test sonucu için AI'dan yorum al; p-value, effect size ve confidence interval eksikse promptu iyileştir.
19. AI generated SQL ile validated SQL sonucunu reconciliation tablosunda karşılaştır.
20. Aynı iş sorusunu kötü prompt ve güçlü prompt ile sor; çıktı farklarını analiz et.

16. Modül Sonu Portfolyo Projesi

Proje: "AI-Assisted E-Commerce Analytics Workflow". Amaç, AI kullanarak hızlandırılmış ancak tamamen doğrulanmış bir analiz sürecini GitHub'da göstermek.

Teslimat	İçerik
01_business_question.md	Problem, stakeholder, KPI tanımları
02_schema.md	Tablolar, grain, PK/FK
03_prompts.md	Kullandığın promptlar ve iterasyonlar
04_sql/	AI taslağı + final validated SQL
05_notebooks/	EDA ve data quality kontrolleri
06_validation.md	Reconciliation, asserts, row-count checks
07_dashboard/	Dashboard screenshot/wireframe
README.md	AI nerede kullanıldı, hangi çıktılar reddedildi, ne öğrendin?

Portfolyo açısından güçlü sinyal
"AI kullandım" demek tek başına değerli değildir. "AI ile taslak ürettim, şu riskleri tespit ettim, şu kontrollerle doğruladım ve final kararı kendim verdim" demek değerlidir.

17. AI-Assisted Analytics Cheat Sheet

İş	Prompt'a mutlaka ekle
SQL	Dialect + schema + grain + metric rules + validation
Python	dtypes + sample rows + expected behavior + asserts
EDA	business question + time window + segments + target metric
Cleaning	rules + rows affected + reversible process
Dashboard	audience + decisions + KPI + dimensions
Summary	evidence only + no invented causality + action format

Her AI çıktısından sonra sor

- Bu sonuç hangi varsayıma dayanıyor?
- Hangi edge-case'i kaçırmış olabilir?
- Grain değişti mi?
- Join sonucu satır sayısı arttı mı?
- Metric denominator doğru mu?
- Sonuç başka bir yolla yeniden hesaplanabiliyor mu?
- Bu bulgu gerçekten kanıt mı, yoksa yalnızca hipotez mi?

Modül Tamamlama Kriteri

- AI ile SQL ve Python taslağı üretebiliyorum
- AI çıktısını schema/grain açısından review edebiliyorum
- Validation query ve assert yazabiliyorum
- AI ile EDA hipotezleri oluşturup veriyle test edebiliyorum
- Gizli veri ve hallucination risklerini yönetebiliyorum
- AI desteğini şeffaf şekilde portfolio workflow'una dahil edebiliyorum

Sonraki modül: 14. İletişim - Insight -> Recommendation, Executive Summary, Stakeholder Sunumu ve Data Storytelling