VERI BILIMCI MÜFREDATI

10. İstatistik

Ayrıntılı Konu Anlatımı

Tanımlayıcı istatistiklerden hipotez testlerine,
örneklemeden güven aralıklarına ve veri bilimi kararlarına kadar

Bu modülün hedefi
Bir veri bilimcinin “veride gördüğüm fark gerçek mi, tesadüf mü?” sorusunu matematiksel olarak yanıtlayabilmesi; belirsizliği ölçmesi; doğru testi seçmesi ve sonucu iş diline çevirmesidir.

Seviye: Temel -> Orta -> Uygulamalı

İçindekiler

Bölüm	Konu
1	İstatistik nedir? Tanımlayıcı vs çıkarımsal
2	Popülasyon, örneklem ve örnekleme
3	Merkezi eğilim
4	Yayılım ölçüleri
5	Dağılım, çarpıklık ve kurtosis
6	Standartlaştırma ve z-score
7	Sampling distribution ve CLT
8	Standart hata
9	Güven aralıkları
10	Hipotez testinin mantığı
11	p-value, alpha, Type I/II hata
12	Test seçimi
13	t-testleri ve oran testleri
14	Ki-kare testleri
15	ANOVA
16	Nonparametrik testler
17	Effect size ve practical significance
18	Korelasyon ve nedensellik
19	Multiple testing ve power
20	Bootstrapping
21	E-Commerce vaka çalışması
22	Python uygulama şablonu
23	Mülakat soruları
24	Final checklist ve cheat sheet

Ön koşul
9. Olasılık modülündeki koşullu olasılık, beklenen değer, varyans, temel dağılımlar ve CLT sezgisine aşina olmak bu modülü çok daha kolaylaştırır.

1. İstatistik nedir?

İstatistik, veriden sistematik biçimde bilgi çıkarmak ve belirsizlik altında karar vermek için kullanılan yöntemler bütünüdür. Veri biliminde istatistiğin rolü yalnızca ortalama hesaplamak değildir; model sonuçlarının güvenilirliğini, deney sonuçlarını, segment farklarını ve örneklemden popülasyona yapılacak genellemeleri değerlendirmektir.

Tür	Amaç	Örnek
Tanımlayıcı istatistik	Elindeki veriyi özetler	Ortalama sepet tutarı 620 TL
Çıkarımsal istatistik	Örneklemden popülasyona çıkarım yapar	Yeni checkout tasarımı dönüşümü artırıyor mu?
Tahmine dayalı yaklaşım	Gelecekteki/ölçülmeyen sonucu tahmin eder	Bir müşteri churn edecek mi?

Ana fikir
Tanımlayıcı istatistik “ne oldu?” sorusunu; çıkarımsal istatistik ise “gördüğümüz fark ne kadar güvenilir?” sorusunu yanıtlar.

2. Popülasyon, örneklem ve örnekleme

Popülasyon ilgilendiğimiz tüm birimlerdir. Örneklem ise gözlemleyebildiğimiz veya analiz için seçtiğimiz alt kümedir. Çıkarımsal istatistiğin temel problemi, örneklemdeki bilginin popülasyon hakkında ne kadar şey söylediğini ölçmektir.

Kavram	Tanım	Örnek
Popülasyon	Hedef evren	Tüm aktif müşteriler
Örneklem	Analize alınan alt küme	10.000 müşteri
Parametre	Popülasyonun bilinmeyen özelliği	Gerçek ortalama harcama μ
İstatistik	Örneklemden hesaplanan değer	Örneklem ortalaması x-bar

2.1 Örnekleme yöntemleri

Yöntem	Ne zaman?	Risk
Simple random	Her birim eşit seçilme şansına sahipse	Liste eksikse bias
Stratified	Önemli alt gruplar temsil edilmeli	Yanlış strata tasarımı
Cluster	Coğrafi/organizasyon kümeleri uygunsa	Cluster içi benzerlik
Convenience	Kolay erişim	Yüksek selection bias

Data Scientist refleksi
Bir testin p-value’suna bakmadan önce örneklemin nasıl toplandığını sor. Kötü örnekleme, kusursuz istatistiksel testten daha büyük bir problemdir.

3. Merkezi eğilim ölçüleri

Ölçü	Formül/sezgi	Güçlü yanı	Zayıf yanı
Mean	Toplam / n	Tüm gözlemleri kullanır	Outlierlara duyarlı
Median	Ortadaki değer	Robust	Toplam büyüklüğü yansıtmaz
Mode	En sık değer	Kategorik veride yararlı	Birden fazla olabilir

Gelir, sepet tutarı ve işlem süresi gibi sağa çarpık dağılımlarda mean ile median arasındaki fark önemli bir sinyaldir. Örneğin ortalama sipariş 900 TL, medyan 420 TL ise az sayıdaki çok yüksek sipariş ortalamayı yukarı çekiyor olabilir.

```
import pandas as pd

mean_aov = df["order_value"].mean()
median_aov = df["order_value"].median()
mode_device = df["device"].mode().iloc[0]
```

4. Yayılım ölçüleri

Ölçü	Anlam
Range	max - min; uç değerlere çok duyarlı
Variance	Ortalama kare sapma; birimi karelenmiştir
Std. deviation	Varyansın karekökü; orijinal birimdedir
IQR	Q3 - Q1; robust yayılım ölçüsü
MAD	Medyan çevresindeki mutlak sapma; robust

İki grubun ortalaması aynı olabilir ama risk profilleri çok farklı olabilir. Bu yüzden yalnızca ortalamayı raporlamak çoğu iş probleminde yetersizdir.

Örnek
A mağazası: ortalama günlük satış 100K, std 5K. B mağazası: ortalama 100K, std 40K. Ortalama aynı, operasyonel öngörülebilirlik çok farklıdır.

5. Dağılım, çarpıklık ve kurtosis

Dağılımın şekli hangi özet istatistiği, hangi testi ve hangi dönüşümü kullanacağımızı etkiler. Symmetric dağılımlarda mean ve median yakınken, sağa çarpık dağılımlarda mean genellikle medianın üstündedir.

Durum	Yorum	Tipik aksiyon
Sağa çarpık	Uzun sağ kuyruk	Median/IQR raporla; log dönüşüm düşünülebilir
Sola çarpık	Uzun sol kuyruk	Tavan etkisini araştır
Heavy tail	Uç değer olasılığı yüksek	Robust yöntem/bootstrapping
Bimodal	İki farklı alt popülasyon olabilir	Segmentasyonu araştır

6. Z-score ve standardizasyon

Z-score, bir gözlemin ortalamadan kaç standart sapma uzakta olduğunu söyler: z = (x - mean) / std. Bu kavram hem outlier analizinde hem de farklı ölçeklerdeki değişkenleri karşılaştırmada kullanılır.

```
z = (df["amount"] - df["amount"].mean()) / df["amount"].std()
df["is_extreme"] = z.abs() > 3
```

Dikkat
z > 3 kuralı evrensel bir outlier silme kuralı değildir. Dağılım heavy-tailed ise çok sayıda meşru gözlem bu eşiği aşabilir.

7. Sampling distribution ve Merkezi Limit Teoremi

Aynı popülasyondan tekrar tekrar aynı büyüklükte örneklemler çekip her seferinde bir istatistik hesaplarsak, bu istatistiğin kendi dağılımını elde ederiz. Buna sampling distribution denir. Merkezi Limit Teoremi, belirli koşullarda örneklem ortalamalarının dağılımının n büyüdükçe normale yaklaşmasını sağlar.

> **Neden önemli?**
> Bir örneklem ortalamasının tek başına ne kadar güvenilir olduğunu anlayabilmemizin nedeni sampling distribution fikridir.

8. Standart hata (Standard Error)

Standart sapma gözlemlerin yayılımını, standart hata ise tahmin ettiğimiz istatistiğin belirsizliğini ölçer. Ortalama için yaklaşık standart hata: SE = s / sqrt(n).

n	s	SE
25	20	4.00
100	20	2.00
400	20	1.00

Örneklem büyüdükçe SE azalır. Ancak büyük n bias problemini çözmez. Milyon gözlemli ama yanlış seçilmiş örneklem hâlâ yanıltıcı olabilir.

9. Güven aralıkları

Güven aralığı, tek bir nokta tahmini yerine belirsizliği bir aralıkla ifade eder. Basitleştirilmiş normal yaklaşımda %95 güven aralığı yaklaşık olarak tahmin ± 1.96 x SE şeklindedir.

> **Doğru yorum**
> Sık kullanılan frequentist %95 güven aralığının teknik yorumu: Aynı prosedürü çok kez tekrarlasaydık oluşturulan aralıkların yaklaşık %95'i gerçek parametreyi kapsardı. "Parametrenin bu aralıkta olma olasılığı %95" demek frequentist çerçevede teknik olarak doğru değildir.

```
import numpy as np
from scipy import stats

x = np.array([12, 11, 14, 9, 15, 13, 10, 12])
mean = x.mean()
se = stats.sem(x)
ci = stats.t.interval(0.95, df=len(x)-1, loc=mean, scale=se)
print(mean, ci)
```

10. Hipotez testinin mantığı

Hipotez testi, gözlenen verinin belirli bir başlangıç varsayımı altında ne kadar şaşırtıcı olduğunu ölçer. Başlangıç varsayımına null hypothesis (H0), araştırdığımız alternatif iddiaya H1 denir.

1. Soruyu ve popülasyonu tanımla.
2. H0 ve H1'i yaz.
3. Önceden alpha belirle.
4. Uygun testi ve varsayımları seç.
5. Test istatistiği ve p-value hesapla.
6. Confidence interval ve effect size raporla.
7. İş anlamlılığını değerlendir.

Örnek
H0: Yeni fiyatlandırma conversion rate'i değiştirmiyor. H1: Yeni fiyatlandırma conversion rate'i değiştiriyor.

11. p-value, alpha ve hata türleri

p-value, H0 doğru kabul edildiğinde gözlenen sonuç kadar veya daha uç bir sonucu elde etmenin olasılığıdır. H0'ın doğru olma olasılığı değildir.

Kavram	Anlam
Alpha	Type I hata için kabul edilen üst sınır; sıklıkla 0.05
Type I error	H0 doğruyken reddetmek - false positive
Type II error	H0 yanlışken reddedememek - false negative
Power	Gerçek bir etki varken onu yakalama olasılığı; 1-beta

Kritik yanlış
p = 0.03, "H0'ın doğru olma ihtimali %3" anlamına gelmez.

Çok büyük örneklemlerde iş açısından önemsiz farklar bile çok küçük p-value üretebilir. Bu nedenle p-value tek başına karar kriteri değildir.

12. Hangi testi seçmeliyim?

Soru	Tipik test	Örnek
1 ortalama referanstan farklı mı?	One-sample t-test	Ortalama teslimat 30 dk mı?
2 bağımsız grubun ortalaması farklı mı?	Welch t-test	A/B sepet tutarı
Aynı kişilerin önce/sonra ölçümü	Paired t-test	Eğitim öncesi/sonrası
2 oran farklı mı?	Two-proportion z-test	A/B conversion
2 kategorik değişken ilişkili mi?	Chi-square independence	Device x purchase
3+ grubun ortalaması farklı mı?	ANOVA / Welch ANOVA	3 kampanya geliri
Dağılım varsayımları zayıf mı?	Nonparametrik test	Heavy-tailed süreler

13. t-testleri ve oran testleri

13.1 Bağımsız iki grup: Welch t-test

İki bağımsız grubun ortalamalarını karşılaştırırken klasik Student t-test eşit varyans varsayar. Pratikte çoğu durumda Welch t-test daha güvenli varsayımdır çünkü eşit varyans gerektirmez.

```
from scipy.stats import ttest_ind

stat, p = ttest_ind(group_a, group_b, equal_var=False)
print(stat, p)
```

13.2 Paired t-test

Aynı birimlerin iki zamanda ölçüldüğü durumda gözlemler bağımsız değildir. Örneğin aynı kullanıcıların özellik öncesi ve sonrası harcamaları.

```
from scipy.stats import ttest_rel
stat, p = ttest_rel(before, after)
```

13.3 İki oran testi

Conversion gibi binary sonuçlarda iki oranı karşılaştırmak için two-proportion z-test yaygındır.

```
from statsmodels.stats.proportion import proportions_ztest

success = [420, 470]
nobs = [5000, 5000]
z, p = proportions_ztest(success, nobs)
```

14. Ki-kare testleri

Chi-square independence testi iki kategorik değişkenin bağımsız olup olmadığını değerlendirir. Beklenen hücre frekansları çok düşükse Fisher exact test gibi alternatifler gerekebilir.

```
import pandas as pd
from scipy.stats import chi2_contingency

tab = pd.crosstab(df["device"], df["purchased"])
chi2, p, dof, expected = chi2_contingency(tab)
```

15. ANOVA

Üç veya daha fazla grubun ortalamalarını tek tek t-testleriyle karşılaştırmak Type I hata oranını şişirir. ANOVA önce “en az bir grup farklı mı?” sorusunu test eder. Anlamlıysa post-hoc karşılaştırmalar yapılır.

ANOVA varsayımları
Bağımsız gözlemler, residual düzeyinde yaklaşık normallik ve klasik ANOVA için varyans homojenliği. Homojenlik zayıfsa Welch ANOVA düşünülebilir.

16. Nonparametrik testler

Parametrik	Nonparametrik alternatif	Not
Independent t-test	Mann-Whitney U	Dağılım konumu/rank bazlı fark
Paired t-test	Wilcoxon signed-rank	Eşleşmiş ölçümler
One-way ANOVA	Kruskal-Wallis	3+ bağımsız grup

Dikkat
“Veri normal değilse otomatik Mann-Whitney” doğru bir kural değildir. Sorunun hedef parametresi, örneklem büyüklüğü ve dağılım yapısı birlikte değerlendirilmelidir.

17. Effect size ve practical significance

İstatistiksel anlamlılık, etkinin iş açısından önemli olduğunu garanti etmez. Effect size farkın büyüklüğünü standartlaştırılmış veya doğrudan iş biriminde ifade eder.

Effect size	Kullanım
Mean difference	Doğrudan birim: +18 TL AOV
Absolute proportion difference	+0.7 percentage point conversion
Relative uplift	+8.4% göreli artış
Cohen’s d	Ortalama farkını pooled std ile ölçekler
Odds ratio	Binary sonuçlarda odds karşılaştırması

Raporlama standardı
p-value + confidence interval + effect size + iş etkisi. Bu dört parçadan biri eksikse karar kalitesi düşer.

18. Korelasyon ve nedensellik

Korelasyon iki değişkenin birlikte değişimini ölçer; nedensellik bir değişkenin diğerinde değişime yol açtığı iddiasıdır. Confounder, reverse causality ve selection bias korelasyonu yanıltabilir.

Durum	Örnek
Confounding	Sıcaklık hem dondurma satışını hem boğulma vakalarını artırır
Reverse causality	Düşük satış reklamı artırmış olabilir
Selection bias	Sadece aktif kullanıcıları analiz etmek
Collider bias	Bir sonuç tarafından etkilenen değişkende koşullamak

Nedensellik için randomize deneyler güçlüdür. Deney mümkün değilse quasi-experimental yöntemler ve dikkatli causal inference tasarımı gerekir.

19. Multiple testing ve power

20 bağımsız hipotezi alpha=0.05 ile test ettiğinde, tüm H0’lar doğru olsa bile en az bir false positive görme olasılığı ciddi biçimde artar. Bonferroni, Holm ve FDR gibi düzeltmeler bu riski yönetir.

Yöntem	Fikir	Ne zaman?
Bonferroni	alpha / m	Az test, güçlü family-wise kontrol
Holm	Sıralı Bonferroni	Bonferroni’den daha güçlü
Benjamini-Hochberg	False Discovery Rate	Çok sayıda keşif testi

Power; effect size, sample size, variance ve alpha ile ilişkilidir. Küçük etkileri yakalamak için daha büyük örneklem gerekir.

20. Bootstrapping

Bootstrap, eldeki örneklemden replacement ile tekrar tekrar örneklem çekip ilgilendiğimiz istatistiğin ampirik dağılımını üretir. Karmaşık veya analitik standart hatası zor istatistiklerde çok kullanışlıdır.

```
import numpy as np

rng = np.random.default_rng(42)
boot = []
for _ in range(5000):
    sample = rng.choice(values, size=len(values), replace=True)
    boot.append(np.median(sample))

lo, hi = np.percentile(boot, [2.5, 97.5])
```

Ne işe yarar?
Median, quantile, revenue per user gibi normal yaklaşımın zayıf olduğu metriklerde confidence interval oluşturmak için sık kullanılır.

21. Gerçek Vaka: E-Commerce Teslimat Süresi ve Tekrar Satın Alma

Şirket son çeyrekte retention düşüşü görüyor. Ürün ekibi, geç teslimatın tekrar satın alma davranışını etkilediğini düşünüyor. Amaç yalnızca korelasyon göstermek değil, veriyi sistematik biçimde inceleyip hangi istatistiksel sonuçların güvenilir olduğunu ayırmaktır.

21.1 Sorular

8. Teslimat süresinin dağılımı nasıl? Mean mi median mı daha temsil edici?
9. Geç teslimat alan ve almayan müşterilerin repeat purchase oranları farklı mı?
10. Farkın %95 güven aralığı nedir?
11. Etki istatistiksel olarak anlamlı mı?
12. Etki iş açısından anlamlı mı?
13. Bu gözlemsel analiz nedensellik kanıtlar mı?

21.2 Örnek özet

Grup	n	Repeat rate	Median delivery
Zamanında teslimat	18,200	31.4%	2.1 gün
Geç teslimat	6,800	24.7%	5.8 gün

Absolute fark = -6.7 percentage point. Relative fark yaklaşık -21.3%. Büyük örneklem nedeniyle p-value muhtemelen küçük olacaktır; ancak asıl değer confidence interval ve ticari etki büyüklüğüdür.

21.3 Doğru sonuç dili

Analitik sonuç
Veride geç teslimat alan müşterilerin tekrar satın alma oranı daha düşüktür ve fark istatistiksel olarak güçlü olabilir. Ancak bu gözlemsel karşılaştırma tek başına geç teslimatın düşüşe neden olduğunu kanıtlamaz. Müşteri segmenti, ürün kategorisi, bölge ve stok problemi gibi confounderlar araştırılmalıdır.

21.4 Sonraki adım

- Segment-adjusted model veya matching ile gözlemsel analizi güçlendir.
- Operasyonel iyileştirmenin mümkün olduğu bölgelerde doğal deney / phased rollout fırsatı ara.
- Teslimat SLA müdahalesi yapılabiliyorsa kontrollü deney tasarla.
- Primary metric, guardrail metric ve minimum business effect'i önceden tanımla.

22. Python ile istatistiksel analiz şablonu

```
import numpy as np
import pandas as pd
from scipy import stats
from statsmodels.stats.proportion import proportions_ztest

# 1) Tanımlayıcı istatistik
summary = df["metric"].describe()
median = df["metric"].median()
iqr = df["metric"].quantile(.75) - df["metric"].quantile(.25)

# 2) İki bağımsız grubun ortalaması
a = df.loc[df["group"] == "A", "metric"].dropna()
b = df.loc[df["group"] == "B", "metric"].dropna()
t_stat, p = stats.ttest_ind(a, b, equal_var=False)

# 3) İki oran
success = [df.query('group=="A"')["converted"].sum(),
           df.query('group=="B"')["converted"].sum()]
nobs = [df.query('group=="A"').shape[0],
        df.query('group=="B"').shape[0]]
z, p_prop = proportions_ztest(success, nobs)

# 4) Kategorik ilişki
ct = pd.crosstab(df["device"], df["converted"])
chi2, p_chi, dof, expected = stats.chi2_contingency(ct)

# 5) Bootstrap CI
rng = np.random.default_rng(42)
boots = [rng.choice(a, size=len(a), replace=True).mean() for _ in range(3000)]
ci = np.percentile(boots, [2.5, 97.5])
```

Analiz çıktısında mutlaka
n, metric tanımı, merkez ve yayılım, effect size, confidence interval, p-value, varsayımlar, veri kalite notları ve iş yorumu birlikte bulunmalıdır.

23. Mülakat soruları

Soru	Beklenen cevap özeti
Mean ve median ne zaman ayrışır?	Çarpık/heavy-tailed dağılımlarda; outlier etkisi.
Std ile SE farkı nedir?	Std gözlemlerin, SE tahminin belirsizliğini ölçer.
p=0.03 ne demektir?	H0 altında gözlenen veya daha uç sonucun olasılığı yaklaşık %3.
p<0.05 ise model kesin doğru mu?	Hayır. Etki büyüklüğü, CI, tasarım ve varsayımlar gerekir.
Type I vs Type II?	False positive vs false negative.
Power nasıl artırılır?	n artırma, variance azaltma, daha büyük etki, alpha değişimi.
3 grubu niye 3 t-test ile kıyaslamazsın?	Multiple testing Type I hatayı artırır.
Korelasyon nedensellik midir?	Hayır; confounding, reverse causality vb.
Welch t-test niye tercih edilir?	Eşit varyans varsayımı gerektirmez.
Bootstrap ne zaman yararlı?	Analitik SE/dağılım zor olduğunda, robust CI için.

24. Final Checklist ve Cheat Sheet

24.1 Her istatistiksel analizde kontrol et

- İş sorusu ve hedef popülasyon açık mı?
- Örneklem nasıl seçildi, selection bias var mı?
- Metric doğru tanımlandı mı? Grain doğru mu?
- Dağılımı ve outlierları gördüm mü?
- Mean yanında gerektiğinde median/IQR raporladım mı?
- Testin bağımsızlık ve diğer varsayımlarını kontrol ettim mi?
- Effect size hesapladım mı?
- Confidence interval verdim mi?
- p-value'yu doğru yorumladım mı?
- Multiple testing var mı?
- İstatistiksel anlamlılık ile iş anlamlılığını ayırdım mı?
- Korelasyon sonucunu nedensel dilde abartmadım mı?

24.2 Mini cheat sheet

İhtiyaç	Araç
Veriyi özetle	mean, median, std, IQR, quantiles
Belirsizliği ölç	SE, confidence interval
2 bağımsız ortalama	Welch t-test
Aynı kişiler önce/sonra	Paired t-test
2 oran	Two-proportion z-test
2 kategorik değişken	Chi-square
3+ ortalama	ANOVA / Welch ANOVA
Heavy-tail / robust yaklaşım	Bootstrap / uygun nonparametrik test
Çoklu test	Holm / BH-FDR
İş büyüklüğü	Absolute/relative effect + CI

Modülün özeti
İyi bir veri bilimci yalnızca "fark var mı?" diye sormaz. "Farkın büyüklüğü ne, belirsizliği ne, varsayımlar doğru mu, bu karar iş açısından değerli mi ve nedensel yorum yapabilir miyim?" sorularını birlikte sorar.

Uygulama ödevi

Bir e-ticaret veri seti seç. İki müşteri segmenti için AOV ve conversion farkını analiz et. Önce dağılımları incele; sonra uygun testleri seç; %95 güven aralıkları ve effect size hesapla; sonucu 1 sayfalık executive summary olarak yaz. Son bölümde neden bu analizin nedensellik kanıtlamadığını açıkla.