11

A/B TESTING

Deney Tasarimi | Hipotez Testi | Power | Sample Size | Karar Verme

Amaç: Bir ürün veya iş değişikliğinin gerçekten nedensel etkisi olup olmadığını ölçebilen; doğru randomization, metrik, örneklem ve istatistiksel karar mekanizmasını kurabilen bir veri bilimci olmak.

Bu modül yalnızca p-value hesaplamayı öğretmez. İyi bir deneyin ürün sorusundan başlayıp logging, randomization, sample size, guardrail, analiz, yorum ve rollout kararına kadar nasıl tasarlandığını uçtan uca ele alır.

Bölüm	Odak
1-5	Deney mantığı, nedensellik, H0/H1 ve temel istatistik
6-10	Alpha/beta, power, MDE, sample size ve metrik tasarımı
11-15	Randomization, SRM, peeking, multiple testing, segmentler
16-19	Sürekli metrikler, variance reduction, özel deney tasarımları
20-23	Gerçek vaka, Python, mülakat ve final kontrol listesi

Ana fikir: A/B testinin amacı “istatistiksel olarak anlamlı sonuç bulmak” değil, belirsizlik altında güvenilir bir ürün/iş kararı vermektir.

1. A/B Testing Nedir?

A/B testi, uygun deney birimlerini rastgele iki veya daha fazla gruba atayarak bir müdahalenin nedensel etkisini ölçmeye çalışan randomize kontrollü deneydir. A grubu mevcut deneyimi (control), B grubu yeni deneyimi (treatment/variant) görür.

1.1 Temel yapı

Deney akışı

```
Hedef popülasyon
      |
Randomization
  /        \
A Control   B Variant
  |           |
Metric A    Metric B
  \           /
   Etki tahmini + belirsizlik
```

1.2 Gözlemsel analizden farkı

Gözlemsel karşılaştırma	Randomize deney
Gruplar doğal olarak oluşur.	Gruplar rastgele atanır.
Selection bias güçlü olabilir.	Randomization, gözlenen/gözlenmeyen confounderları ortalamada dengeler.
Korelasyon ağırlıklıdır.	Nedensel etki için daha güçlü tasarımdır.
Kontrol için modelleme gerekir.	Tasarımla confounding azaltılır.
Kampanya müşterileri daha çok harcıyor olabilir.	Kampanyaya rastgele atama incremental etkiyi ölçer.

Nedensel soru: “B varyantını görenler daha çok satın aldı mı?” yerine “Aynı kullanıcı B varyantını görseydi davranışı nasıl değişirdi?” sorusunu hedefleriz. Aynı kişiyi iki dünyada göremediğimiz için randomization kullanırız.

2. Potential Outcomes ve Nedensel Etki

Her deney birimi için teorik olarak iki potansiyel sonuç vardır: Y(1) treatment alınırsa sonuç, Y(0) control alınırsa sonuç. Bireysel treatment effect Y(1)-Y(0) gözlenemez; çünkü kişi yalnızca bir grupta bulunur.

2.1 Average Treatment Effect (ATE)

Nedensel etki

```
ATE = E[Y(1) - Y(0)]

Randomization altında:
ATE ≈ mean(Y | T=1) - mean(Y | T=0)
```

Randomization sayesinde iki grubun kullanıcı kompozisyonu beklenen değerde benzerdir. Bu nedenle sonuç farkını müdahaleye bağlamak daha makul hale gelir.

2.2 SUTVA ve interference

- Bir kullanıcının treatment durumu başka kullanıcının sonucunu etkilememeli (interference yok varsayımı).
- Treatment tanımı herkes için tutarlı olmalı; “B” varyantının birden fazla gizli versiyonu olmamalı.
- Sosyal ağlar, marketplace, fiyat açık artırmaları ve teslimat ağları interference üretebilir.

Örnek: Bir yemek teslimat uygulamasında kurye teşviki test ediyorsan treatment kuryeleri control kuryelerin siparişlerini etkileyebilir. Kullanıcı bazlı klasik A/B testi burada uygun olmayabilir.

3. İş Sorusu -> Deney Hipotezi

İyi deneyler “butonu mavi yapalım mı?” ile değil, açık bir davranış mekanizması ve karar kuralıyla başlar.

3.1 Hipotez şablonu

Ürün hipotezi: “Checkout formundaki alan sayısını azaltmak, kullanıcı friction’ını düşürerek ödeme tamamlanma oranını artıracaktır; başarının ana metriği purchase conversion, guardrail metric’i refund ve support contact oranıdır.”

3.2 İyi hipotezin bileşenleri

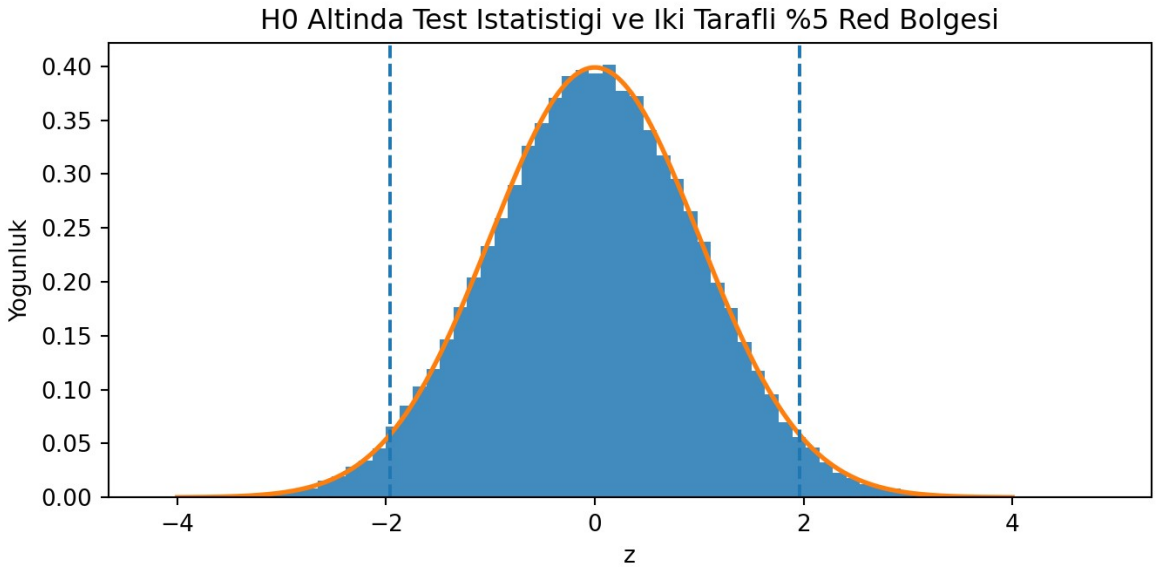
Bileşen	Soru
Problem	Hangi kullanıcı problemi var?
Mekanizma	Değişiklik davranışı neden değiştirsin?
Population	Kimler deneye dahil?
Treatment	Tam olarak ne değişiyor?
Primary metric	Başarı neyle ölçülüyor?
Guardrail	Neyi bozmak istemiyoruz?
Decision rule	Hangi sonuçta launch/no-launch/iterate?

Anti-pattern: Deney çalışırken primary metric değiştirmek, sonuçları gördükten sonra segment seçmek veya “anlamlı” çıkan metriği başarı metriği ilan etmek false positive riskini ciddi biçimde artırır.

4. H0, H1 ve Test İstatistiği

İstatistiksel hipotez testi, gözlenen farkın H0 altında ne kadar şaşırtıcı olduğunu ölçer.

Kavram	Anlam
H0 - Null hypothesis	Gerçek treatment effect yoktur veya belirlenen eşik kadar değildir.
H1 - Alternative	Treatment effect vardır; yönlü veya iki taraflı tanımlanabilir.
Test statistic	Gözlenen farkın standart hata cinsinden büyüklüğü.
p-value	H0 doğru kabul edilirse, gözlenen kadar veya daha uç bir sonuç görme olasılığı.
Confidence interval	Etkinin veriyle uyumlu makul değer aralığı.



Şekil 1 - İki taraflı alpha=0.05 testinde yaklaşık kritik z değerleri ±1.96.

p-value değildir: “H0’ın doğru olma olasılığı” değildir. p-value, H0 altında verinin ne kadar uç olduğunu söyler; hipoteze posterior olasılık vermez.

5. Type I, Type II Hatası ve Karar Matrisi

Gerçek durum / Karar	H0 reddedilmez	H0 reddedilir
Gerçekte etki yok	Doğru negatif	Type I error (false positive) = alpha
Gerçekte etki var	Type II error (false negative) = beta	Doğru pozitif = power = 1-beta

5.1 Alpha

Alpha, test prosedürünün kabul edilen false positive seviyesidir. Sık kullanılan 0.05 bir doğa kanunu değildir; yanlış launch maliyetine göre seçilmelidir.

5.2 Beta ve power

Beta, gerçek bir etki varken onu kaçırma olasılığıdır. Power = 1-beta. Ürün deneylerinde 80% veya 90% power sık tasarım hedefleridir, fakat maliyet ve risk bağlamına göre değişir.

Karar perspektifi: Alpha'yı düşürmek false positive'i azaltır ama aynı örneklemde power'ı düşürebilir. İstatistiksel eşikler ürün riskleriyle birlikte tasarlanmalıdır.

6. Effect Size, MDE ve Pratik Anlamlılık

İstatistiksel anlamlılık ile iş anlamlılığı farklıdır. Çok büyük örneklem, çok küçük ve ekonomik olarak değersiz etkileri bile anlamlı yapabilir.

6.1 Absolute ve relative lift

Etki ifadesi

```
Control conversion = 10.0%
Variant conversion = 10.8%


Absolute lift = 10.8% - 10.0% = +0.8 percentage point
Relative lift = 0.8 / 10.0 = +8%
```

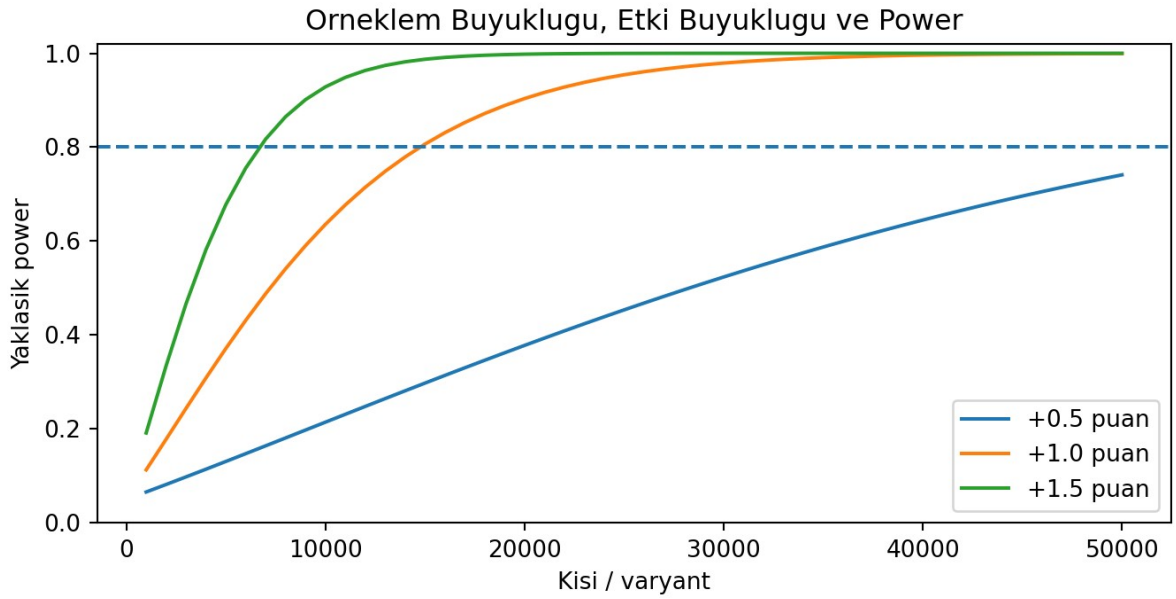
6.2 Minimum Detectable Effect (MDE)

MDE, deney tasarımında güvenilir şekilde yakalamayı hedeflediğin en küçük etkidir. “Ne kadar küçük bir etkiyi önemseriz?” sorusuna iş tarafı cevap vermelidir.

MDE çok küçük	MDE çok büyük
Daha fazla örneklem ve süre gerekir.	Daha hızlı deney biter.
Küçük kazanımları yakalar.	Küçük ama değerli etkileri kaçırabilir.
Maliyet yükselir.	Karar hassasiyeti düşer.

7. Sample Size ve Power

Örneklem büyüklüğü baseline rate, beklenen/MDE etki, alpha, power, varyans ve deney tasarımına bağlıdır. “Her gruba 1000 kullanıcı yeter” gibi sabit bir kural yoktur.



Şekil 2 - Aynı baseline’da daha küçük etkiyi yakalamak için daha fazla kullanıcı gerekir.

Örnek: Baseline conversion %10’dan %11’e çıkışı (1 puan absolute lift) iki taraflı alpha=0.05 ve yaklaşık %80 power ile yakalamak için normal yaklaşım altında varyant başına yaklaşık 14,744 gözlem gerekir.

7.1 Sample size’ı artıran faktörler

- Daha küçük MDE
- Daha yüksek power
- Daha düşük alpha
- Daha yüksek outcome variance
- Cluster randomization / design effect
- Düşük exposure rate veya eligibility oranı

8. Metrik Tasarımı: Primary, Secondary, Guardrail

Deney metriği yalnızca kolay ölçüldüğü için seçilmemelidir. Metrik, ürün mekanizmasını ve uzun vadeli iş değerini mümkün olduğunca temsil etmelidir.

Metrik türü	Rol	Örnek
Primary	Ana başarı kriteri	Checkout completion
Secondary	Mekanizma ve yan etkileri açıklar	Time-to-checkout, add-to-cart
Guardrail	Kazanırken zarar vermeyi engeller	Refund, crash rate, latency
Diagnostic	Deney sağlığını kontrol eder	Exposure, assignment, event coverage

8.1 OEC - Overall Evaluation Criterion

Bazı şirketler çok sayıda metriği tek karar çerçevesinde birleştiren Overall Evaluation Criterion kullanır. Amaç kısa vadeli proxy'lerle uzun vadeli değeri dengelemektir.

Metric gaming: Bir metriği optimize etmek kullanıcı değerini artırmakla aynı şey değildir. Click-through yükselirken kalite, retention veya trust düşebilir.

9. Deney Birimi ve Randomization Unit

Randomization unit, treatment atamasının hangi seviyede yapıldığını belirler: user, session, device, household, store, city veya cluster.

Unit	Ne zaman?	Risk
User	Login tabanlı ürün deneyleri	Cross-device contamination
Session	Kısa süreli UI testleri	Aynı user iki varyant görebilir
Device	Anonim trafik	Multi-device kullanıcılar
Store / city	Operasyon / fiyat / lojistik	Az cluster, yüksek varyans
Seller / driver	Marketplace tarafı	Interference ve spillover

9.1 Sticky assignment

Aynı kullanıcının deney boyunca aynı varyantı görmesi çoğu kullanıcı deneyinde önemlidir. Assignment genellikle hash(user_id, experiment_id) ile deterministik yapılır.

Basitleştirilmiş sticky assignment

```
bucket = hash(user_id + experiment_id) % 10000
variant = 'B' if bucket < 5000 else 'A'
```

Unit of analysis: Randomization user seviyesindeyse satır bazında eventleri bağımsız gözlem gibi test etmek standart hatayı küçültebilir. Analiz birimi tasarımla uyumlu olmalıdır.

10. Exposure, Eligibility ve Intention-to-Treat

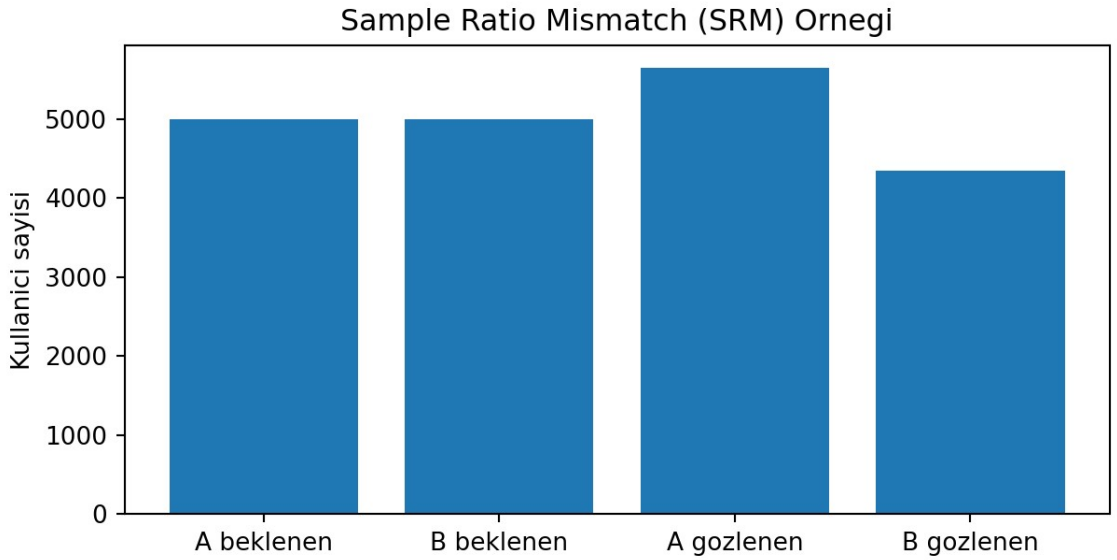
Atanan herkes treatment'ı gerçekten görmeyebilir. Deney analizi assignment, eligibility ve exposure kavramlarını açıkça ayırmalıdır.

Kavram	Tanım
Assignment	Kullanıcının A/B grubuna deterministik/rastgele atanması.
Eligibility	Deneyi görmeye uygun olması.
Exposure	Treatment bileşenini gerçekten görmesi.
ITT	Atandığı gruba göre analiz; randomization avantajını korur.
Triggered analysis	Yalnızca treatment yüzeyine erişen uygun kullanıcıları analiz etmek; önceden tanımlanmalı.

Dikkat: Treatment sonrası oluşan davranışa göre kullanıcıları filtrelemek selection bias yaratabilir. "Deneyden sonra X yapanlar" filtresi randomization dengesini bozabilir.

11. Sample Ratio Mismatch (SRM)

50/50 planlanan deneyde gözlenen trafik anlamlı biçimde 50/50'den sapıyorsa SRM olabilir. Bu, sonuç metriğinden önce deney altyapısının güvenilirliğini sorgulatır.



Şekil 3 - Planlanan 50/50 dağılım ile 5650/4350 gibi büyük sapma alarm üretmelidir.

11.1 SRM nedenleri

- Assignment bug
- Platform/browser bazlı varyant kaybı
- Eligibility filtresinin varyanttan etkilenmesi
- Event logging kaybı
- Bot veya cache davranışı
- Experiment ID / hashing değişikliği
- Treatment'ın kullanıcıyı tracking dışına itmesi

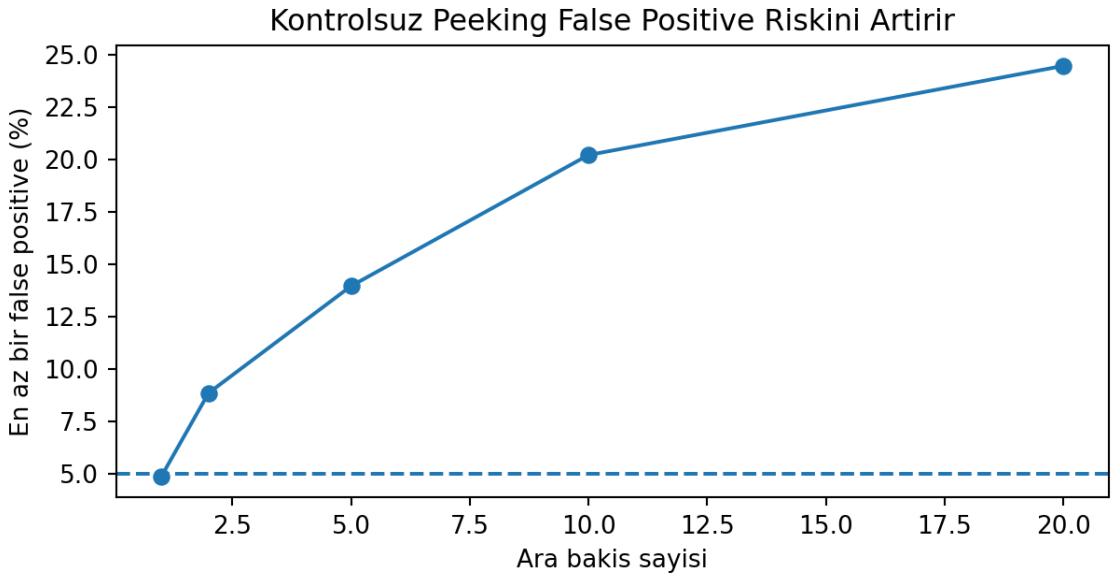
SRM için chi-square fikri

```
from scipy.stats import chisquare
observed = [5650, 4350]
expected = [5000, 5000]
stat, p = chisquare(observed, expected)
```

Kural: SRM çözülmeden primary metric sonucu üzerinden ürün kararı vermek risklidir. Önce deney mekanizmasını doğrula.

12. Peeking, Optional Stopping ve Sequential Testing

Klasik fixed-horizon testte örneklem ve bitiş kuralı önceden belirlenir. Her gün p-value'a bakıp "<0.05 olunca durmak" nominal false positive oranını bozar.



Şekil 4 - Simülasyon: H0 doğruyken kontrolsüz çoklu ara bakışlar en az bir false positive görme olasılığını yükseltir.

12.1 Güvenli yaklaşımlar

- Önceden belirlenmiş fixed horizon
- Group sequential design / alpha spending
- Always-valid p-values / confidence sequences
- Bayesian decision framework (önceden tanımlı karar kuralıyla)

Operasyonel not: Dashboard'a her gün bakmak tek başına sorun değildir; sorun, klasik testin stopping rule'unu sonuçlara bakarak değiştirmektir.

13. Multiple Testing ve False Discovery

20 bağımsız metriği alpha=0.05 ile test edersen, etki yokken bile en az bir “anlamlı” sonuç bulma ihtimali büyür. Aynı risk çok sayıda varyant, segment ve post-hoc analizde de vardır.

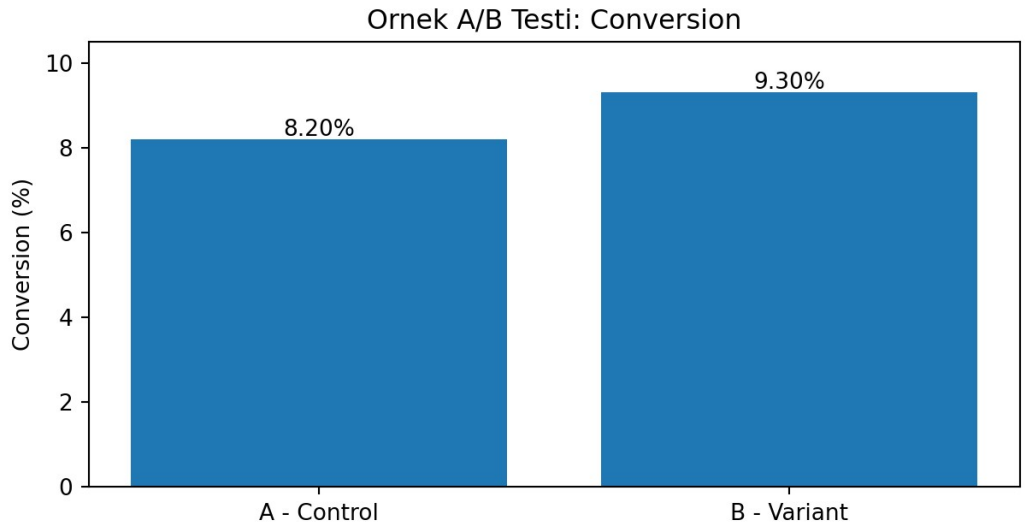
13.1 Çözümler

Yöntem	Amaç / kullanım
Bonferroni	Family-wise error’ı sıkı kontrol; basit ama konservatif.
Holm	Bonferroni’ye göre daha güçlü step-down düzeltme.
Benjamini-Hochberg	False Discovery Rate kontrolü; keşifsel çoklu testlerde yararlı.
Metric hierarchy	Primary metric’i önceden tek/az sayıda tutarak multiplicity’yi tasarımda azalt.
Holdout / confirmatory test	Keşifsel bulguyu bağımsız deneyde doğrula.

Segment avcılığı: “Genelde anlamsız ama iOS, yeni kullanıcı, salı günü gelenlerde anlamlı” gibi post-hoc segmentler çoğu zaman multiple testing problemidir. Bulguyu hipotez olarak yeni testte doğrula.

14. Confidence Interval ile Sonuç Okuma

Tek başına p-value yerine effect estimate + confidence interval + iş eşiği birlikte yorumlanmalıdır.



Şekil 5 - Örnek deneyde A=%8.20, B=%9.30.

Örnek sonuç: A'da 820/10.000, B'de 930/10.000 conversion gözlendi. Absolute lift = +1.10 puan, z = 2.75, iki taraflı p ≈ 0.0059; %95 CI yaklaşık [0.32, 1.88] puan.

14.1 Dört temel sonuç deseni

CI deseni	Yorum
Tamamı 0'ın üstünde ve iş eşiğinin üstünde	Pozitif ve pratik olarak anlamlı olabilir.
0'ı dışlıyor ama çok küçük	İstatistiksel anlamlı, iş değeri zayıf olabilir.
0'ı içeriyor ve dar	Büyük etkiler büyük ölçüde elenmiş; "pratik null" olabilir.
0'ı içeriyor ve geniş	Inconclusive; daha fazla veri veya daha düşük varyans gerekir.

15. Binary Metricler: Conversion Testi

Binary metricler için two-proportion z-test, chi-square veya exact testler kullanılabilir. Büyük örneklemde z yaklaşımı yaygındır.

Python örneği

```
from statsmodels.stats.proportion import proportions_ztest

count = np.array([820, 930])
nobs  = np.array([10000, 10000])
z, p = proportions_ztest(count, nobs)

lift_abs = 930/10000 - 820/10000
lift_rel = lift_abs / (820/10000)
```

15.1 Kullanıcı başına oran mı, event oranı mı?

Örneğin click-through rate event seviyesinde hesaplandığında ağır kullanıcılar daha fazla ağırlık alabilir. Deney sorusu kullanıcı etkisiyse user-level metric gerekebilir.

Denominator hatası: Variant kullanıcıları daha fazla session üretiyorsa “conversion / session” oranı farklı bir estimand ölçer. Numerator ve denominator’ın treatment tarafından nasıl etkilendiğini düşün.

16. Sürekli ve Ağır Kuyruklu Metrikler

Revenue, watch time, order value gibi metrikler sıklıkla zero-inflated ve heavy-tailed olur. Basit mean + t-test bazen çalışır, ama dağılım ve kullanıcı başına agregasyon kontrol edilmelidir.

16.1 Araçlar

Yöntem	Ne zaman?
Welch t-test	Ortalamalar; varyanslar eşit değilse güvenli defaultlardan biri.
Bootstrap CI	Karmaşık metric / heavy-tail için esnek; bağımsız birim seviyesinde resample.
Mann-Whitney	Dağılım/sıralama farkı; “mean farkı testi” değildir.
Winsorization	Önceden tanımlanırsa uç değer varyansını azaltabilir; estimand değişir.
Log transform	Multiplicative yapıda yararlı; yorum dönüşüm gerektirir.

Bootstrap mantığı

```
# User-level bootstrap difference in means
for b in range(B):
    a = rng.choice(metric_A, len(metric_A), replace=True)
    v = rng.choice(metric_B, len(metric_B), replace=True)
    diffs[b] = v.mean() - a.mean()
ci = np.quantile(diffs, [0.025, 0.975])
```

17. Variance Reduction: CUPED ve Pre-period Bilgisi

Aynı kullanıcıların deney öncesi davranışı outcome ile koreleyse, bu bilgiyle variance azaltılarak aynı sample size'da daha yüksek hassasiyet elde edilebilir.

17.1 CUPED sezgisi

CUPED

```
Y_cuped = Y - theta * (X - mean(X))

X = deney öncesi metric
Y = deney dönemi metric
theta = Cov(Y, X) / Var(X)
```

Randomization nedeniyle pre-period X treatment etkisinden önce ölçülmüştür ve gruplar arasında sistematik fark taşımamalıdır. X ile Y korelasyonu güçlendikçe variance reduction potansiyeli artar.

Dikkat: Post-treatment değişkenlerini covariate olarak kullanmak bias yaratabilir. Variance reduction değişkeni treatment'tan önce veya treatment tarafından etkilenmeyen bir kaynak olmalıdır.

18. Cluster, Switchback ve Marketplace Deneyleri

Kullanıcı bazlı randomization her problem için uygun değildir. Interference, operasyon ve network effect olduğunda farklı tasarımlar gerekir.

Tasarım	Örnek	Önemli konu
Cluster randomized	Şube / okul / şehir	Intra-cluster correlation -> design effect
Switchback	Marketplace / dispatch	Zaman bloklarını A/B yap; carryover kontrol et
Geo experiment	Marketing spend	Az birim, pre-period dengeleme önemli
Network experiment	Sosyal ürün	Spillover / graph cluster
Holdout	Uzun vadeli ürün etkisi	Küçük kalıcı control; etik/iş maliyeti

Switchback örneği: Ride-sharing dispatch algoritması kullanıcı bazında ayrıştırılamıyorsa şehir-zaman bloklarını A/B arasında döndürmek daha uygun olabilir. Ancak saat/gün sezonsallığı ve carryover modele dahil edilmelidir.

19. Deney Süresi, Novelty ve Carryover

Sample size'a ulaşmak tek başına yeterli değildir. Deney, önemli davranış döngülerini ve haftalık sezonsallığı kapsamalıdır.

- Hafta içi / hafta sonu farkı
- Payday / ay sonu etkisi
- Kampanya ve tatil dönemi
- Novelty effect: yeni özellik ilk günlerde aşırı ilgi görebilir
- Learning effect: kullanıcılar yeni arayüze zamanla alışabilir
- Carryover: treatment etkisi sonraki döneme sarkabilir
- Long-term metric: retention/churn kısa testte gözlenmeyebilir

Duration ≠ sample size: Trafiğin çok yüksek olması 3 saatte sample size'a ulaştırabilir; yine de haftalık kullanım döngüsünü temsil etmeyebilir. İstatistiksel ve davranışsal süre birlikte düşünülmelidir.

20. Uçtan Uca Gerçek Vaka: Checkout Deneyi

20.1 Problem

E-ticaret şirketinde checkout completion oranı %48. Product ekibi adres formunu 11 alandan 7 alana düşürmek istiyor. Ama yanlış/adres eksikliği nedeniyle teslimat hatasının artmasından çekiniliyor.

20.2 Tasarım

Karar	Seçim
Population	Checkout'a ulaşan uygun kullanıcılar
Unit	user_id, sticky 50/50
Control	11 alanlı form
Treatment	7 alan + otomatik tamamlama
Primary	Checkout completion
Secondary	Time-to-complete, validation error
Guardrail	Delivery failure, cancellation, support contact
MDE	+1.0 puan absolute completion
Duration	Sample size + en az tam haftalık döngüler

20.3 Sonuç senaryosu

Treatment completion +1.3 puan (%95 CI +0.5 ile +2.1), form süresi -18 saniye; delivery failure +0.25 puan (%95 CI +0.05 ile +0.45). Primary metric kazanmış görünse de guardrail kötüleşmiştir.

Karar düşüncesi: "p<0.05 -> launch" otomatik değildir. Incremental checkout geliri ile delivery failure maliyetini, kullanıcı güvenini ve düzeltme seçeneklerini birlikte değerlendir. Belki formu tamamen launch etmek yerine validation iyileştirmesiyle yeni deney gerekir.

21. Python ile Uçtan Uca Analiz Şablonu

Minimal analiz iskeleti

```
import pandas as pd
import numpy as np
from scipy.stats import chisquare, ttest_ind
from statsmodels.stats.proportion import proportions_ztest


# 1) experiment health
users = df.groupby('variant')['user_id'].nunique()


# 2) SRM
obs = users.reindex(['A','B']).values
expected = np.repeat(obs.sum()/2, 2)
srm_stat, srm_p = chisquare(obs, expected)


# 3) user-level metric table
u = (df.groupby(['user_id','variant'])
       .agg(converted=('converted','max'),
            revenue=('revenue','sum'))
       .reset_index())


# 4) conversion test
conv = u.groupby('variant')['converted'].agg(['sum','count'])
z, p = proportions_ztest(conv['sum'], conv['count'])


# 5) continuous metric
a = u.loc[u.variant=='A','revenue']
b = u.loc[u.variant=='B','revenue']
t, p_rev = ttest_ind(a, b, equal_var=False)


# 6) report effect + CI + guardrails + decision
```

Production kalite: Notebook'taki p-value tek başına teslimat değildir. Experiment ID, metric definition, eligibility, analysis window, SRM, effect, CI, guardrail, segment policy ve decision log raporda görünmelidir.

22. A/B Testlerinde En Sık Yapılan Hatalar

Hata	Neden kötü?	Doğrusu
Deney bitmeden p<0.05 görünce durmak	False positive artar	Fixed horizon veya sequential yöntem
20 metric test edip 1 tanesini seçmek	Multiplicity	Primary metric + düzeltme
Post-hoc segmentte karar vermek	Data dredging	Yeni confirmatory test
User randomize edip event-level bağımsızlık varsaymak	SE yanlış	Randomization unit uyumlu analiz
SRM'yi yok saymak	Atama/logging bug olabilir	Önce health check
Sadece p-value raporlamak	Etki büyüklüğü yok	Effect + CI + iş eşiği
Guardrail olmadan launch	Yerel kazanım / global zarar	Primary + guardrail
Treatment sonrası filtre	Selection bias	ITT veya önceden tanımlı trigger

En önemli alışkanlık: Analiz kodundan önce deney tasarım belgesini yaz. Başarılı deney kültürü istatistikten önce iyi soru, temiz telemetry ve disiplinli karar kuralları gerektirir.

23. Mülakat Soruları ve Final Kontrol Listesi

23.1 Mülakat soruları

Soru	Kısa cevap çerçevesi
A/B testinde p=0.03 ne demektir?	H0 doğru kabul edildiğinde gözlenen kadar/uç veri görme olasılığı yaklaşık %3'tür; H0'ın doğru olma olasılığı değildir.
Power nedir?	Belirli bir gerçek etki altında testi anlamlı sonuç üretme olasılığı; 1-beta.
MDE neden business input ister?	İstatistiğin değil, ekonomik olarak değerli en küçük etkinin ürün/iş tarafından belirlenmesi gerekir.
SRM görürsen ne yaparsın?	Primary sonucu yorumlamadan assignment, eligibility, exposure ve logging hattını incelerim.
Neden her gün p-value'a bakıp duramazsın?	Optional stopping fixed-horizon alpha garantisini bozar; sequential yöntem gerekir.
Primary metric yükseldi guardrail kötüleşti; ne yaparsın?	Net iş/kullanıcı etkisini değerlendirir, otomatik launch yapmam; trade-off ve yeni tasarım/iterasyon düşünürüm.
Session randomization ne zaman riskli?	Aynı user farklı varyant görebilir; contamination ve carryover yaratabilir.
Conversion +1% relative mi absolute mi?	Belirsizdir; baseline ve birim mutlaka yazılmalı.
Segment sonucu neden tehlikeli?	Çoklu test ve düşük sample size; önceden tanımlı değilse keşifsel kabul edilip doğrulanmalı.
Revenue için neden bootstrap düşünürsün?	Heavy-tail ve karmaşık metric distribution'larında parametrik varsayımları azaltmak için.

23.2 Deney öncesi kontrol

- İş hipotezi ve mekanizma açık mı?
- Population, eligibility ve randomization unit tanımlı mı?
- Primary/secondary/guardrail metric tanımları version-controlled mı?
- MDE, alpha, power ve sample size hesaplandı mı?
- Duration ve stopping rule önceden yazıldı mı?
- Exposure/assignment eventleri QA edildi mi?
- SRM ve A/A testleri için health check var mı?
- Segment ve multiple-testing politikası önceden belirlendi mi?

23.3 Deney sonrası kontrol

- SRM yok mu?
- Data completeness ve timestamp window doğru mu?
- Effect size + confidence interval raporlandı mı?
- Guardrail ve diagnostic metricler kontrol edildi mi?
- Pratik anlamlılık değerlendirildi mi?
- Novelty/seasonality/carryover riski var mı?
- Decision + rationale kaydedildi mi?
- Gerekirse follow-up experiment tanımlandı mı?

Bu modülü bitirdiğinde: Bir A/B testi için yalnızca istatistiksel test çalıştırabilmek değil; doğru deney tasarımını kurmak, sonucu güvenilir biçimde yorumlamak ve iş kararına dönüştürmek hedeflenir.