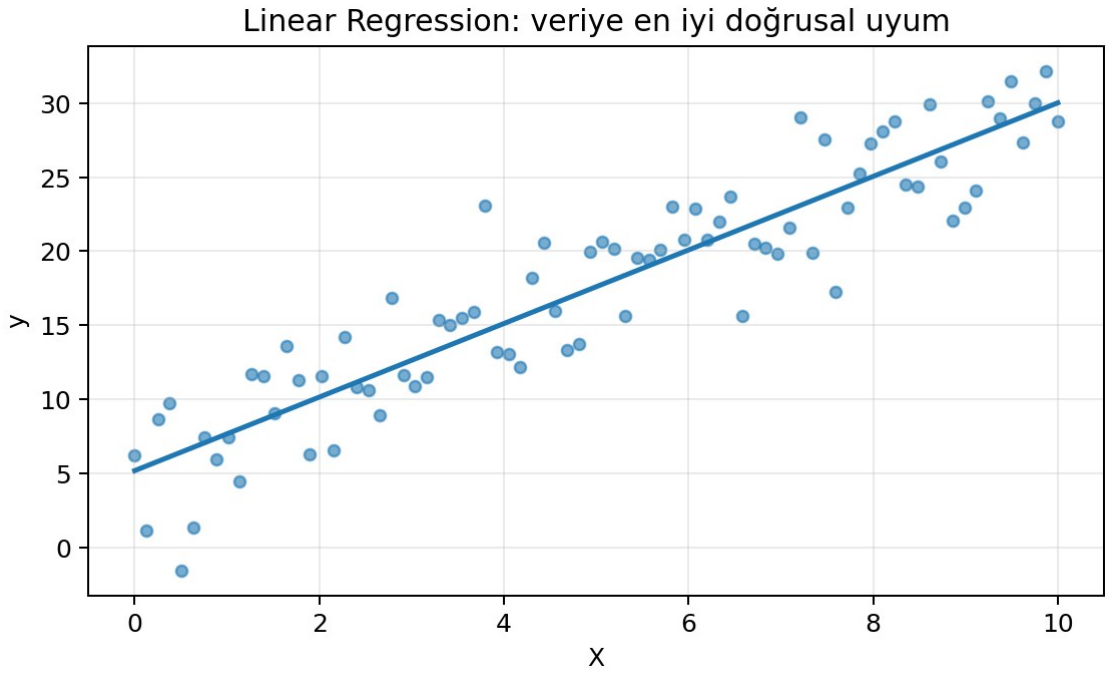
15. REGRESSION

Linear Regression • Ridge • Lasso • ElasticNet • Polynomial Regression



Bu modülün amacı
Regresyonu yalnızca bir sklearn modeli olarak değil; sayısal hedef tahmini, katsayı yorumu, varsayım kontrolü, residual analizi ve regularization ile birlikte uçtan uca anlayabilmek.

Kazanım	Modül sonunda
Problem framing	Hangi iş probleminin regression problemi olduğunu ayırt edebilirsin.
Linear regression	OLS ve katsayıların matematik/iş yorumunu yapabilirsin.
Diagnostics	Residual, heteroscedasticity, multicollinearity ve outlier sorunlarını tanıyabilirsin.
Regularization	Ridge, Lasso ve ElasticNet arasındaki farkı açıklayabilirsin.
Modeling	Polynomial ve interaction feature'ları leakage yaratmadan kullanabilirsin.
Evaluation	MAE, MSE, RMSE ve R^2'yi bağlama göre seçebilirsin.

1. Regression problemi nedir?

Regression, hedef değişkenin sürekli/sayısal olduğu supervised learning problemidir. Amaç x feature'larından y sayısal hedefini tahmin eden fonksiyonu öğrenmektir.

İş problemi	Target	Regression mı?
Ev fiyatı tahmini	Fiyat	Evet
Aylık müşteri harcaması	TL	Evet
Teslimat süresi	Dakika	Evet
Churn olacak mı?	0/1	Hayır - classification
Gelecek hafta satış	Adet	Evet; zaman boyutu varsa forecasting yaklaşımı da gerekir

İlk kontrol
Target'ın sayısal olması tek başına yeterli değildir. Grain, tahmin anı, future leakage ve zaman bağımlılığı da problem tasarımını belirler.

2. Baseline neden zorunlu?

Bir ML modelinin değer üretip üretmediğini görmek için önce basit bir referans gerekir. Regression'da en temel baseline çoğu zaman training target ortalaması veya medyanıdır.

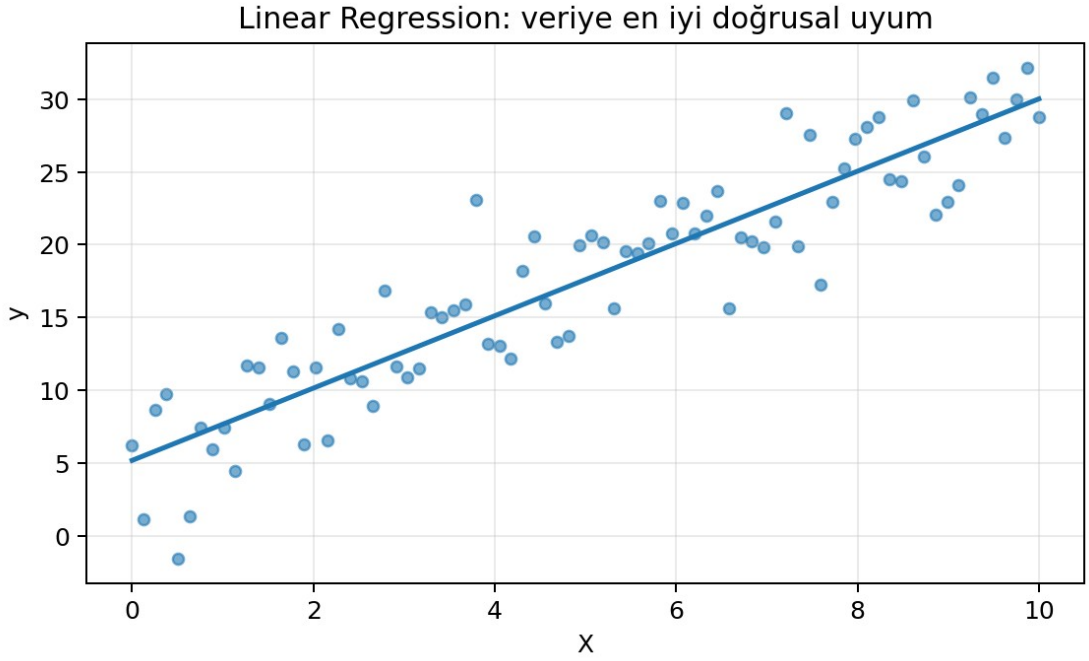
```
from sklearn.dummy import DummyRegressor

baseline = DummyRegressor(strategy="mean")
baseline.fit(X_train, y_train)
pred = baseline.predict(X_valid)
```

Model başarısı
RMSE 120 demek tek başına iyi/kötü değildir. Baseline RMSE 210 ise güçlü olabilir; baseline 100 ise model kötüleşmiştir.

3. Simple Linear Regression

Tek feature için model: y_hat = beta0 + beta1*x. beta0 intercept, beta1 slope/katsayıdır.



Terim	Yorum
beta0	x=0 iken modelin tahmini; her zaman iş açısından anlamlı olmayabilir.
beta1	x bir birim arttığında diğer koşullar sabitken tahminde beklenen değişim.
y_hat	Model tahmini
residual	y - y_hat

4. OLS - Ordinary Least Squares

OLS, residual kareleri toplamını minimize eden katsayıları seçer: sum((y_i - y_hat_i)^2). Kare alma negatif/pozitif hataları aynı yönde cezalandırır ve büyük hataları daha fazla büyütür.

Geometrik bağlantı
Lineer cebir açısından y, X'in sütun uzayına project edilir. Calculus açısından squared-error loss'un gradient'i sıfıra götürülür.

```
from sklearn.linear_model import LinearRegression

model = LinearRegression()
model.fit(X_train, y_train)

print(model.intercept_)
print(model.coef_)
```

5. Multiple Linear Regression

Birden çok feature için: y_hat = beta0 + beta1*x1 + ... + betap*xp. Her katsayı, diğer feature'lar sabit tutulduğunda ilgili feature'ın tahmine marjinal katkısını temsil eder.

Feature	Örnek katsayı	Yorum
house_size_m2	+2,100	Diğer değişkenler sabitken +1 m² yaklaşık +2,100 TL tahmin katkısı
age_years	-4,500	+1 yaş yaklaşık -4,500 TL tahmin katkısı
distance_center_km	-18,000	+1 km merkez uzaklığı yaklaşık -18,000 TL katkı

Katsayı = nedensel etki değildir
Regression coefficient association/conditional prediction anlatır. Nedensellik için confounding, treatment assignment ve tasarım ayrıca ele alınmalıdır.

6. Design matrix ve intercept

X matrisi satırlarda gözlemleri, sütunlarda feature'ları taşır. Intercept kullanılıyorsa model sabit terim öğrenir. Bazı teorik türetimlerde X'e 1'lerden oluşan sütun eklenir.

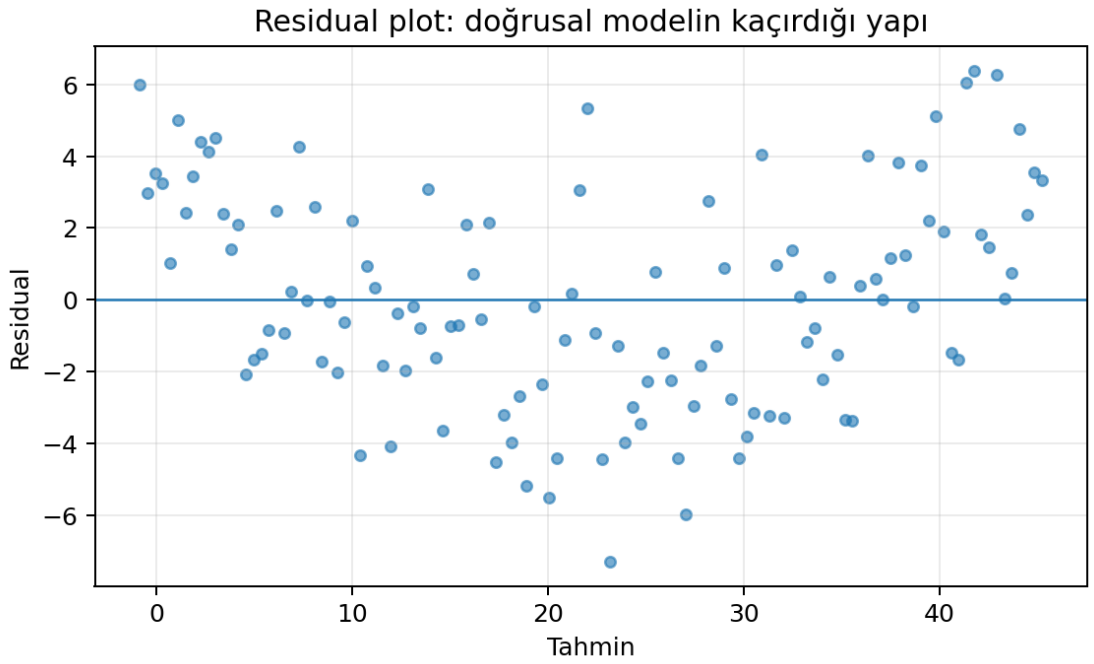
```
# y_hat = X @ beta mantığı
X = np.c_[np.ones(len(X_raw)), X_raw]
```

7. Regression varsayımları

Varsayım	Ne anlama gelir?	Bozulursa
Linearity	E[y|X] yaklaşık doğrusal yapı	Systematic residual pattern
Independent errors	Hatalar bağımsız	SE/p-value yanlış olabilir
Homoscedasticity	Residual variance yaklaşık sabit	Inference güvenilirliği düşer
No perfect multicollinearity	Feature'lar tam lineer bağımlı değil	Katsayı çözümü belirsiz
Errors mean ~ 0	Model sistematik bias taşımıyor	Kalibrasyon/structure sorunu
Normal residuals	Özellikle küçük örneklem inference için yararlı	Prediction için her zaman şart değil

Önemli ayrım
Bu varsayımların bazıları doğru tahmin katsayıları, bazıları standart hata/p-value gibi inference sonuçları için kritiktir. ML tahmini ile klasik istatistiksel inference aynı hedef değildir.

8. Residual analizi



İyi residual plot'ta hata bulutu 0 çevresinde rastgele görünür. Eğri, fan shape veya segment yapısı varsa model yapısal bilgi kaçırıyor olabilir.

Residual pattern	Olası neden
U/curve şekli	Nonlinear ilişki
Fan shape	Heteroscedasticity
Zamana göre kümelenme	Autocorrelation / seasonality
Belirli segmentte bias	Missing interaction / segment feature
Aşırı tekil noktalar	Outlier / leverage point

9. Heteroscedasticity

Residual variance'ın X/tahmin seviyesine göre değişmesine heteroscedasticity denir. Örneğin yüksek fiyatlı evlerde tahmin hatasının doğal olarak daha geniş olması.

- Prediction odağında: model/transformasyon değişikliği düşünebilirsin.
- Inference odağında: robust standard errors gibi yöntemler gerekebilir.
- Target log dönüşümü bazı pozitif/heavy-tail problemlerde faydalı olabilir.

10. Multicollinearity

İki veya daha fazla feature çok benzer bilgiyi taşıdığında katsayıların variance'ı artabilir. Tahmin iyi kalırken katsayılar işaret/büyüklük olarak kararsızlaşabilir.

Belirti	Kontrol
Katsayılar veri split'lerinde çok değişiyor	Cross-validation katsayı stabilitesi
Beklenmedik işaretler	Correlation + domain kontrolü
Büyük standart hatalar	VIF / condition number
X rank sorunu	matrix_rank / redundant dummy

```
# VIF mantığı statsmodels ile
from statsmodels.stats.outliers_influence import variance_inflation_factor

vif = [
    variance_inflation_factor(X_numeric.values, i)
    for i in range(X_numeric.shape[1])
]
```

Ridge bağlantısı
Ridge, correlated feature'lar arasında katsayıların aşırı büyümesini azaltarak daha stabil tahmin üretebilir.

11. Outlier, leverage ve influence

Kavram	Anlam
Outlier	Target/residual açısından sıra dışı gözlem
High leverage	Feature uzayında sıra dışı gözlem
Influential point	Model katsayılarını belirgin değiştiren gözlem

Bir noktayı otomatik silmek doğru değildir. Önce veri hatası mı, gerçek ama nadir vaka mı, yoksa farklı segment mi olduğunu araştır.

Cook's distance
Classical regression diagnostics'te bir gözlemin fit üzerindeki influence'ını özetlemek için kullanılabilir.

12. Target transformation

Pozitif ve güçlü sağ çarpık target'larda log1p dönüşümü stabiliteyi artırabilir ve relative error benzeri davranış yaratabilir.

```
y_train_log = np.log1p(y_train)
model.fit(X_train, y_train_log)

pred_log = model.predict(X_valid)
pred = np.expm1(pred_log)
```

Dikkat
Metric'i original scale'de de hesapla. Log-space'de iyi loss, TL cinsinden iş hatasını otomatik olarak garanti etmez.

13. Regression metrikleri

Metric	Formül sezgisi	Ne zaman?
MAE	|error| ortalaması	Yorumlaması kolay, outlier'a RMSE'den dayanıklı
MSE	error^2 ortalaması	Optimization ve büyük hata cezası
RMSE	sqrt(MSE)	Target biriminde, büyük hatalara duyarlı
R^2	1 - SSE/SST	Baseline ortalamaya göre açıklanan variance oranı
MAPE	|error/y|	Pozitif y; y≈0 olduğunda sorunlu
RMSLE	log-space hata	Relative büyüme ve pozitif hedeflerde

Metric seçimi business kararıdır
Teslimat gecikmesinde 60 dakikalık hata 10 dakikalık hatadan çok daha maliyetliyse RMSE/MSE mantıklı olabilir. Her hatanın maliyeti lineerse MAE daha doğal olabilir.

14. R^2 nasıl yorumlanır?

R^2 validation/test üzerinde baseline mean predictor'a kıyasla performansı ölçer. 1 mükemmel, 0 mean baseline seviyesidir; testte negatif R^2 modelin mean baseline'dan kötü olduğunu gösterir.

Yanlış kullanım
R^2 yüksek diye model mutlaka iş açısından iyi değildir. Target ölçeğinde hata, segment bias ve deployment koşulları ayrıca değerlendirilir.

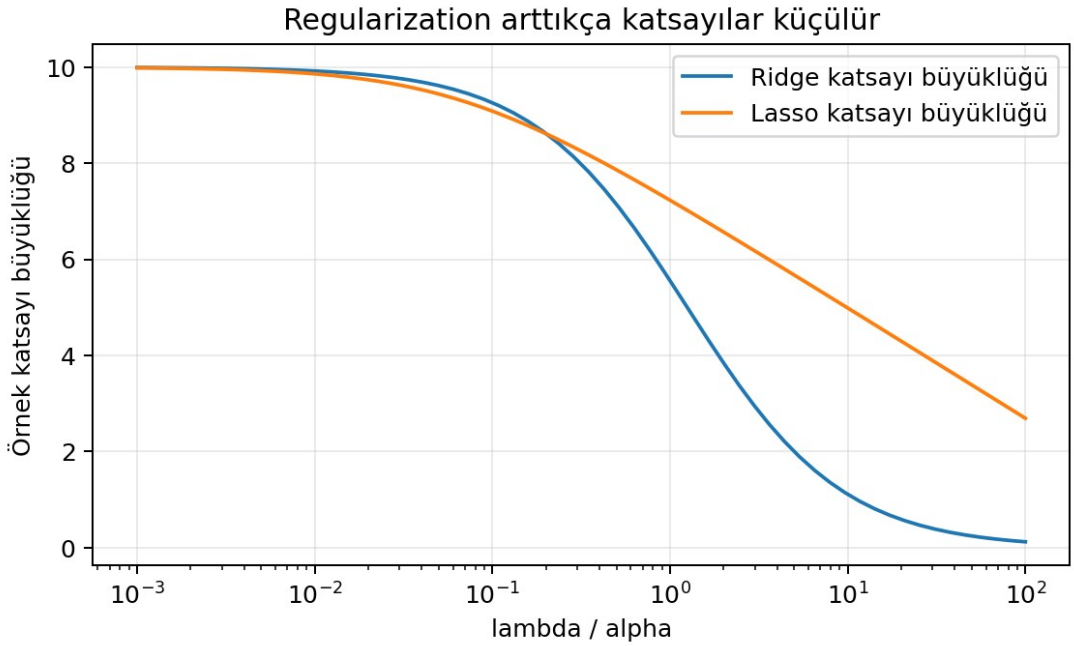
15. Feature scaling regression'da ne zaman gerekli?

Model	Scaling gereksinimi
Plain OLS LinearRegression	Tahmin için zorunlu değil; katsayı karşılaştırması etkilenir
Ridge/Lasso/ElasticNet	Çok önemli; penalty katsayı büyüklüğüne bağlı
Polynomial features	Ölçek farkları numerical stability'yi etkileyebilir

Pipeline kullan
Scaler'ı split öncesi tüm veriye fit etmek leakage'dır. StandardScaler + model'i Pipeline içine koy.

16. Ridge Regression (L2)

Ridge objective: training loss + alpha * sum(beta_j^2). Büyük katsayıları cezalandırır ama genellikle tam sıfıra indirmez.



Alpha	Davranış
0'a yakın	OLS'e yaklaşır
Orta	Variance azalabilir, bias biraz artar
Çok büyük	Katsayılar aşırı küçülür, underfitting

```
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import Ridge

ridge = make_pipeline(
    StandardScaler(),
    Ridge(alpha=1.0)
)
ridge.fit(X_train, y_train)
```

17. Lasso Regression (L1)

Lasso objective'e alpha * sum(|beta_j|) ekler. Geometrik yapısı bazı katsayıları tam 0'a götürebildiği için sparse model/feature selection etkisi yaratabilir.

Ama...
Correlated feature'larda Lasso benzer feature'lardan birini keyfi seçebilir. Katsayı seçimini 'gerçek önemli feature' kanıtı gibi yorumlama.

18. ElasticNet

ElasticNet L1 ve L2 penalty'leri birleştirir. Çok sayıda correlated feature olduğunda Lasso'nun sparsity özelliği ile Ridge'in stabilitesini dengeleyebilir.

```
from sklearn.linear_model import ElasticNet

model = make_pipeline(
    StandardScaler(),
    ElasticNet(alpha=0.05, l1_ratio=0.5)
)
```

19. Bias-variance ve regularization

Model	Bias	Variance
Çok esnek / penalty yok	Düşük	Yüksek olabilir
Uygun regularization	Biraz artar	Azalır
Aşırı regularization	Yüksek	Düşük

Hedef
Training error'u minimum yapmak değil, unseen data expected error'u minimum yapmak. Alpha cross-validation ile seçilir.

20. Alpha tuning

```
from sklearn.linear_model import Ridge
from sklearn.model_selection import GridSearchCV
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler

pipe = Pipeline([
    ("scale", StandardScaler()),
    ("model", Ridge())
])

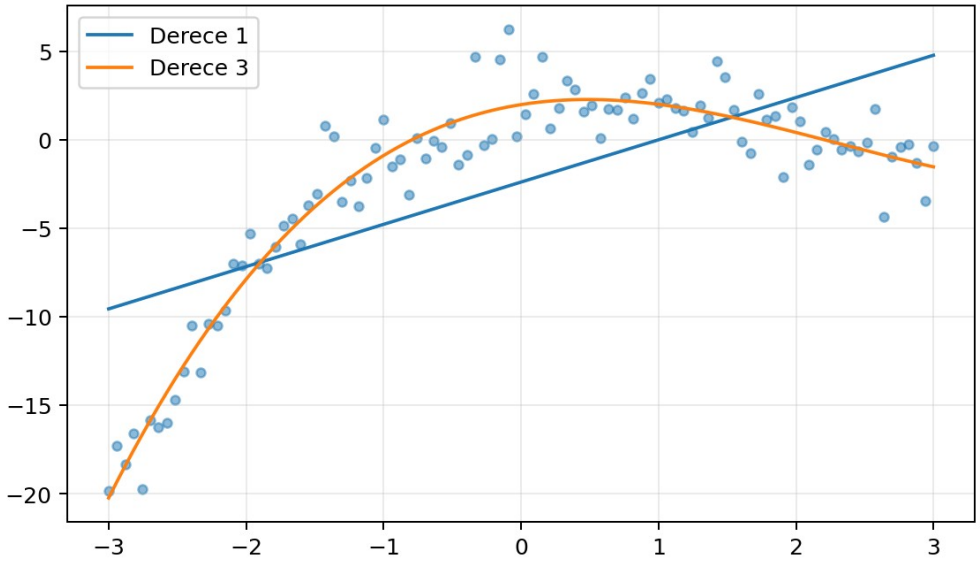
grid = {
    "model__alpha": np.logspace(-4, 4, 25)
}

search = GridSearchCV(
    pipe,
    grid,
    cv=5,
    scoring="neg_root_mean_squared_error"
)
search.fit(X_train, y_train)
```

Test set'e dokunma
Hyperparameter seçimi validation/CV ile yapılır. Test set yalnızca final unbiased evaluation içindir.

21. Polynomial Regression

Polynomial regression: doğrusal olmayan ilişkiyi feature dönüşümüyle yakalamak



Polynomial regression hâlâ katsayılar açısından lineer bir modeldir; nonlinear x ilişkisini x^2, x^3 gibi dönüştürülmüş feature'larla temsil eder.

```
from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import Ridge
from sklearn.pipeline import make_pipeline

poly = make_pipeline(
    PolynomialFeatures(degree=2, include_bias=False),
    StandardScaler(),
    Ridge(alpha=1.0)
)
```

Risk
Degree arttıkça feature sayısı ve overfitting riski hızla büyür. Cross-validation ve regularization önemlidir.

22. Interaction terms

Bir feature'ın etkisi başka bir feature'a bağlıysa interaction gerekir. Örn: marketing_spend etkisi customer_segment'e göre değişebilir.

Model: y = b0 + b1*x1 + b2*x2 + b3*(x1*x2)

Yorum
Interaction varsa b1 tek başına x1'in her koşuldaki etkisi değildir; x2 seviyesine bağlıdır.

23. Categorical variables

Nominal kategoriler çoğunlukla one-hot encoding ile modele girer. Intercept varken tüm dummy sütunlarını tutmak classical full-rank yaklaşımında dummy variable trap yaratabilir.

```
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder, StandardScaler
from sklearn.pipeline import Pipeline
from sklearn.linear_model import Ridge

prep = ColumnTransformer([
    ("num", StandardScaler(), num_cols),
    ("cat", OneHotEncoder(handle_unknown="ignore"), cat_cols)
])

model = Pipeline([
    ("prep", prep),
    ("reg", Ridge(alpha=1.0))
])
```

24. Missing values

scikit-learn LinearRegression/Ridge gibi modeller doğrudan NaN kabul etmez. Imputation pipeline içinde yapılmalıdır.

```
from sklearn.impute import SimpleImputer

# Numerical pipeline örneği:
# SimpleImputer(strategy="median") -> StandardScaler()
```

Leakage
Median/mean imputer training verisine fit edilmelidir; validation/test istatistikleri imputation kararına karışmamalıdır.

25. Statsmodels ile inference

Amaç coefficient standard error, confidence interval ve p-value ise statsmodels klasik istatistiksel regression workflow'u için kullanışlıdır.

```
import statsmodels.api as sm

X_sm = sm.add_constant(X_train)
ols = sm.OLS(y_train, X_sm).fit()

print(ols.summary())
```

Çıktı	Yorum
coef	Tahmin edilen katsayı
std err	Katsayı belirsizliği
t / P>|t|	H0: coefficient=0 test bilgisi
confidence interval	Katsayı için belirsizlik aralığı
R-squared	Fit özeti

Dikkat
p-value düşük olması feature'ın nedensel veya business olarak önemli olduğu anlamına gelmez. Varsayımlar ve multiple testing de önemlidir.

26. Prediction interval vs confidence interval

Aralık	Neyi kapsar?
Confidence interval	Ortalama E[y|x] tahminindeki belirsizlik
Prediction interval	Yeni tek gözlemin y değerindeki belirsizlik; daha geniştir

Business değeri
Sadece point prediction yerine belirsizlik sunmak stok, bütçe veya risk planlamasında çok daha değerlidir.

27. Cross-validation regression'da

IID veride KFold yaygın olabilir. Zaman bağımlı problemde random KFold gelecekten geçmişe bilgi sızdırabilir; TimeSeriesSplit veya temporal holdout gerekir.

Veri yapısı	Split
IID müşteri gözlemleri	KFold / random holdout
Aynı müşteriden tekrar ölçüm	GroupKFold düşünülebilir
Zaman serisi / kronolojik tahmin	TimeSeriesSplit / temporal split

28. Regression pipeline - uçtan uca

```
from sklearn.model_selection import train_test_split
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

model.fit(X_train, y_train)
pred = model.predict(X_test)

mae = mean_absolute_error(y_test, pred)
rmse = mean_squared_error(y_test, pred) ** 0.5
r2 = r2_score(y_test, pred)

print(mae, rmse, r2)
```

1. Business target ve prediction time'ı tanımla.
2. Grain ve leakage kontrolü yap.
3. Baseline oluştur.
4. Split stratejisini veri yapısına göre seç.
5. Preprocessing'i Pipeline içine al.
6. OLS/Ridge/Lasso/ElasticNet karşılaştır.
7. Validation/CV ile hyperparameter seç.
8. Test set'te final metricleri raporla.
9. Residual ve segment error analizi yap.
10. Business recommendation üret.

29. Gerçek vaka: ev fiyatı tahmini

Bir emlak platformu ilan yayınlanırken makul fiyat aralığı önermek istiyor. Target satış/ilan fiyatı; feature'lar m², oda sayısı, bina yaşı, lokasyon, kat, ulaşım uzaklığı ve semt özellikleri.

Aşama	Yapılacak
Problem	Yeni ilan için fiyat tahmini
Baseline	Semt medyan fiyatı / global median
Split	Mümkünse zamansal split; eski ilanlarla geleceği tahmin
Metric	MAE + RMSE + segment bazlı hata
Models	OLS, Ridge, ElasticNet, tree-based model benchmark
Diagnostics	Residual vs price, semt, m²; high-end ev bias
Output	Point prediction + mümkünse prediction interval

Portföy seviyesinde güçlü yorum
Modelin genel MAE'si kadar ucuz/orta/lüks segmentlerde hata dağılımını göster. Ortalama metric bazen business riskini saklar.

30. Gerçek vaka: marketing spend -> revenue

Kanal bazında reklam harcaması ile gelir ilişkisini modellemek klasik regression örneğidir; fakat prediction ile causal ROI'yi karıştırma riski yüksektir.

- Spend yüksekken revenue yüksek olabilir çünkü şirket zaten talebin yüksek olduğu dönemlerde daha çok harcıyor olabilir.
- Seasonality, promotions ve channel mix confounder olabilir.
- OLS prediction modeli causal incrementality sağlamaz.

Nedensellik uyarısı
Marketing Mix Modeling, experiments veya causal inference yöntemleri olmadan coefficient'ı '1 TL reklam +X TL gelir yaratır' diye yorumlamak hatalı olabilir.

31. Model karşılaştırma tablosu

Model	Güçlü yön	Zayıf yön
OLS	Basit, yorumlanabilir, hızlı	Multicollinearity/outlier'a duyarlı
Ridge	Stabil, correlated feature'larda güçlü	Sparse çözüm üretmez
Lasso	Feature selection etkisi	Correlated feature seçiminde kararsız
ElasticNet	L1+L2 dengesi	2 hyperparameter
Polynomial + Ridge	Nonlinear yapı yakalayabilir	Feature explosion
Tree boosting	Güçlü nonlinear tabular performans	Daha az doğrudan yorumlanabilir

32. Sık yapılan hatalar

- Test set'i alpha seçmek için tekrar tekrar kullanmak.
- Scaler/imputer'ı split öncesi tüm veriye fit etmek.
- R^2'yi tek başarı ölçütü olarak kullanmak.
- Katsayıyı nedensel etki gibi yorumlamak.
- Residual analizi yapmadan modeli bitmiş saymak.
- Time-dependent veride random split kullanmak.
- Outlier'ları nedenini incelemeden silmek.
- Lasso'nun sıfırladığı feature'ı kesinlikle önemsiz kabul etmek.
- Polynomial degree'i CV olmadan artırmak.
- Business segmentlerde hata dağılımını kontrol etmemek.

33. Mülakat soruları

Soru	Kısa cevap
Linear regression neyi minimize eder?	OLS sürümünde residual kareleri toplamını / MSE'yi.
MAE ile RMSE farkı?	RMSE büyük hataları daha fazla cezalandırır; MAE daha robust ve doğrudan yorumlanabilir.
R^2 negatif olabilir mi?	Evet, testte model mean baseline'dan kötü ise.
Multicollinearity neyi bozar?	Özellikle katsayı stabilitesi ve inference'ı; tahmin mutlaka kötü olmak zorunda değil.
Ridge ile Lasso farkı?	Ridge L2 ile küçültür; Lasso L1 ile bazı katsayıları tam 0 yapabilir.
ElasticNet neden kullanılır?	L1 sparsity ile L2 stabilitesini birleştirmek için.
Scaling Ridge/Lasso için neden önemli?	Penalty coefficient magnitude'a bağlıdır; scale adil olmalıdır.
Heteroscedasticity nedir?	Residual variance'ın sabit olmaması.
Residual plot'ta U shape ne anlatır?	Model nonlinear yapıyı kaçırıyor olabilir.
Coefficient causal effect midir?	Hayır; prediction association'ı nedensellik değildir.
Polynomial regression lineer mi?	Parametrelerde lineerdir; input feature dönüşümü nonlinear olabilir.
Prediction interval CI'dan neden geniş?	Hem mean tahmin belirsizliğini hem yeni gözlemin irreducible noise'unu içerir.
VIF neyi ölçer?	Bir feature'ın diğer feature'larla açıklanma derecesi üzerinden multicollinearity göstergesi.
Log target ne zaman?	Pozitif, sağ çarpık, multiplicative error yapısında faydalı olabilir.

34. Uygulama alıştırmaları

11. California Housing veya benzer dataset üzerinde DummyRegressor, LinearRegression ve Ridge'i karşılaştır.
12. Validation RMSE ve MAE'yi aynı tabloda raporla; sıralama değişiyor mu kontrol et.
13. Residual vs prediction grafiği çiz ve heteroscedasticity ara.
14. İki feature'ı yüksek korelasyonlu hale getir; OLS ve Ridge katsayı stabilitesini karşılaştır.
15. Lasso alpha arttıkça kaç coefficient sıfır oluyor çiz.
16. PolynomialFeatures degree 1-5 için CV error eğrisi üret.
17. Target'a log1p uygula; original-scale MAE/RMSE ile karşılaştır.
18. Bir categorical feature ekleyip OneHotEncoder + Ridge Pipeline kur.
19. Segment bazında MAE çıkar: düşük/orta/yüksek target segmentleri.
20. Statsmodels OLS ile coefficient CI ve robust SE sonuçlarını incele.

35. Mini portföy projesi

Proje: Used Car Price Prediction - Interpretable Regression Benchmark

Dosya/çıktı	İçerik
01_eda.ipynb	Target distribution, missing, outlier, segment analizleri
02_baseline.ipynb	Median/Dummy baseline
03_regression.ipynb	OLS, Ridge, Lasso, ElasticNet
04_diagnostics.ipynb	Residual, segment error, coefficient stability
src/pipeline.py	Preprocessing + model pipeline
report.md	Metric + business recommendation + limitations

CV cümlesi

Built an interpretable used-car price regression pipeline comparing OLS, Ridge, Lasso and ElasticNet with cross-validation, residual diagnostics and segment-level error analysis.

36. Final cheat sheet

Kavram	Hatırlanacak fikir
OLS	Squared residual toplamını minimize eder
Coefficient	Diğer X'ler sabitken conditional tahmin etkisi
Residual	Gerçek - tahmin
MAE	Absolute error ortalaması
RMSE	Büyük hatalara daha duyarlı
R^2	Mean baseline'a göre açıklanan varyans
Multicollinearity	Coefficient instability
Ridge	L2 shrinkage
Lasso	L1 shrinkage + sparsity
ElasticNet	L1 + L2
Polynomial	Feature dönüşümü ile nonlinear ilişki
Residual diagnostics	Modelin kaçırdığı yapıyı bul
Pipeline	Leakage önleyen preprocessing + model akışı
CV	Model/hyperparameter seçimi
Prediction interval	Tek yeni gözlem için belirsizlik

Bu modülden sonra

Classification'a geçerken Logistic Regression'ın neden aynı lineer predictor Xw üzerine probability link'i eklediğini çok daha rahat anlayacaksın.