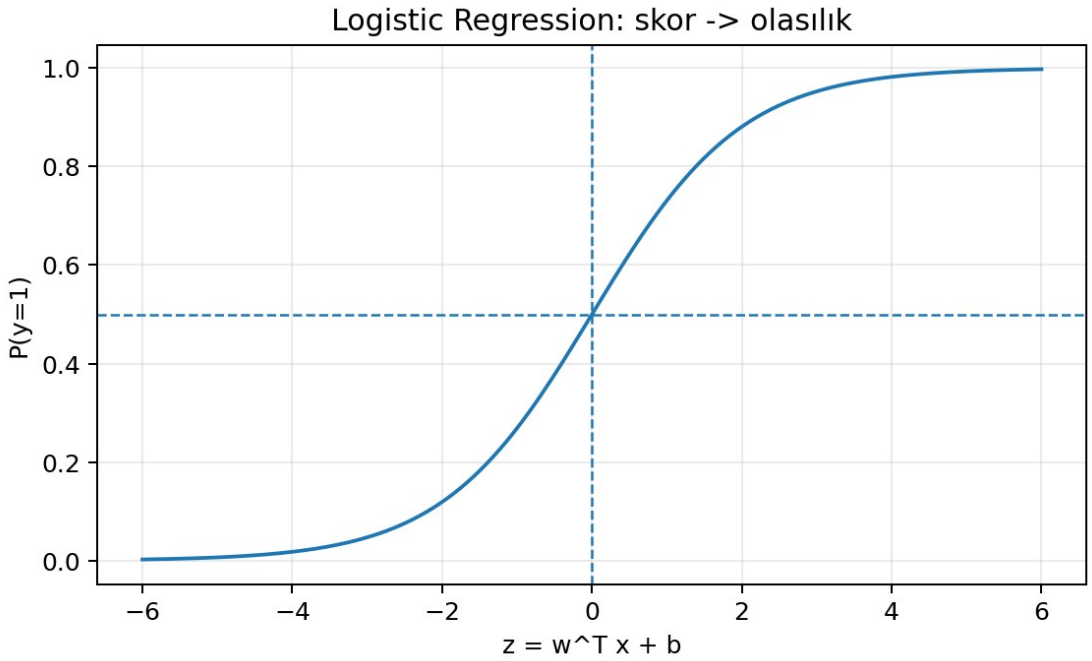
16. CLASSIFICATION

Logistic Regression • KNN • Naive Bayes • Decision Tree



Bu modülün amacı
Classification'ı yalnızca '0/1 tahmini' olarak değil; olasılık üretme, karar eşiği seçme, hata maliyetini yönetme ve farklı algoritmaları doğru bağlamda değerlendirme problemi olarak öğrenmek.

Kazanım	Modül sonunda
Problem framing	Classification problemini doğru target ve prediction time ile kurabilirsin.
Logistic Regression	Probability, log-odds ve coefficient yorumunu anlayabilirsin.
Temel algoritmalar	KNN, Naive Bayes ve Decision Tree mantığını karşılaştırabilirsin.
Evaluation	Confusion matrix, precision, recall, F1, ROC-AUC ve PR-AUC'yi seçebilirsin.
Threshold	Business cost'a göre decision threshold ayarlayabilirsin.
Pipeline	Leakage'siz preprocessing + model + validation akışı kurabilirsin.

1. Classification problemi nedir?

Classification, hedef değişkenin ayrık sınıflardan oluştuğu supervised learning problemidir. Binary classification iki sınıf, multiclass classification üç veya daha fazla sınıf içerir.

Problem	Target	Tür
Müşteri churn olacak mı?	0/1	Binary
İşlem fraud mu?	normal/fraud	Binary
E-posta kategorisi	spam/promotions/social/primary	Multiclass
Ürün kalite sınıfı	A/B/C	Multiclass
Bir müşteri aynı anda birden fazla kategoriye ait mi?	çoklu 0/1 etiket	Multilabel

İlk soru
Model hangi anda tahmin yapacak ve o anda hangi bilgiler gerçekten erişilebilir olacak? Bu soru leakage kontrolünün temelidir.

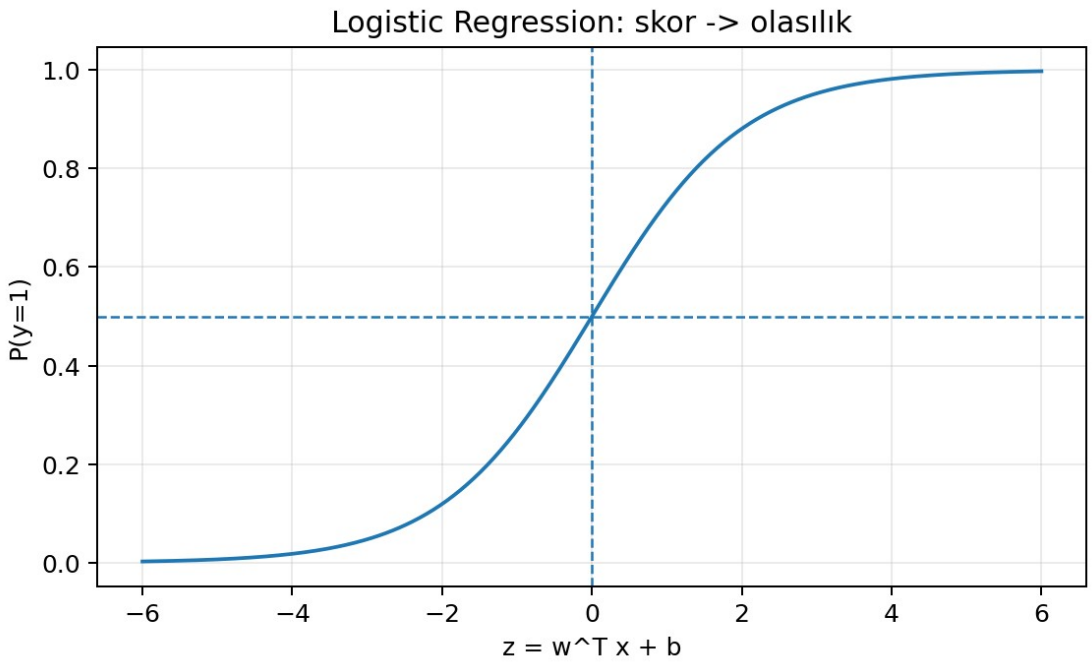
2. Probability vs class prediction

İyi classification workflow'u önce probability/score üretir, sonra bu skor threshold ile sınıfa çevrilir. Threshold modelin doğal sabiti değil, business kararıdır.

```
proba = model.predict_proba(X_valid)[:, 1]
pred = (proba >= 0.50).astype(int)
```

Önemli
0.50 eşiği yalnızca bir default'tur. Fraud, sağlık riski veya churn outreach gibi işlerde optimum eşik farklı olabilir.

3. Logistic Regression



Logistic Regression önce lineer skor z = w^T x + b üretir, sonra sigmoid ile bu skoru 0-1 aralığında olasılığa dönüştürür.

```
p = 1 / (1 + np.exp(-z))
```

Neden linear regression değil?
Linear regression 0'ın altı veya 1'in üstünde tahmin üretebilir. Logistic link probability aralığını doğal biçimde korur.

4. Odds ve log-odds

Odds = p/(1-p). Logistic regression lineer predictor'ı doğrudan log-odds ile ilişkilendirir: log(p/(1-p)) = b0 + b1*x1 + ...

Katsayı	Yorum
beta > 0	Feature arttıkça positive class odds'u artar.
beta < 0	Positive class odds'u azalır.
exp(beta)	Bir birim feature artışındaki odds ratio

Katsayı = nedensellik değil
Logistic coefficient de conditional association ifade eder; causal effect değildir.

5. Binary cross-entropy / log-loss

Logistic regression parametreleri genellikle log-loss minimize edilerek öğrenilir. Doğru sınıfa yüksek probability vermek ödüllenir; yanlış sınıfa aşırı güvenmek güçlü biçimde cezalandırılır.

```
from sklearn.metrics import log_loss
loss = log_loss(y_true, proba)
```

Probability kalitesi
Accuracy sınıf kararını ölçerken log-loss probability confidence'ını da hesaba katar.

6. Logistic Regression - sklearn

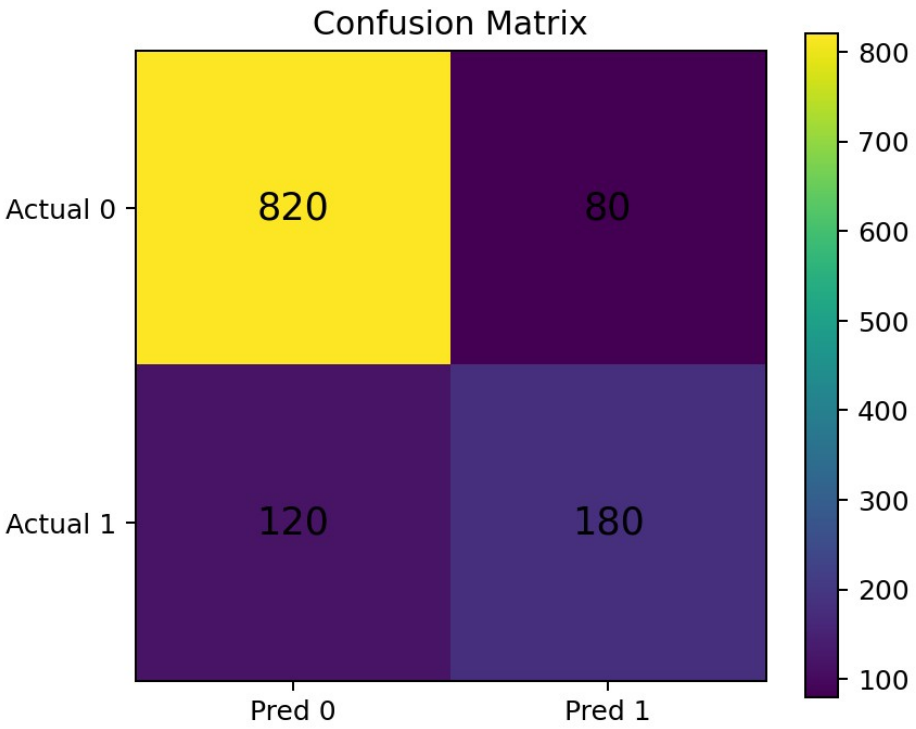
```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression

model = Pipeline([
    ("scale", StandardScaler()),
    ("clf", LogisticRegression(
        penalty="l2",
        max_iter=2000
    ))
])

model.fit(X_train, y_train)
proba = model.predict_proba(X_valid)[:, 1]
```

Scaling
Regularized logistic regression'da scaling önemlidir çünkü penalty coefficient büyüklüklerine uygulanır.

7. Confusion Matrix



Terim	Anlam
TP	Pozitif gerçekte pozitif, model pozitif dedi.
TN	Negatif gerçekte negatif, model negatif dedi.
FP	Gerçekte negatif ama model pozitif dedi.
FN	Gerçekte pozitif ama model negatif dedi.

Business cost
FP ve FN çoğu gerçek problemde aynı maliyete sahip değildir. Metric/threshold seçimini bu maliyet belirlemelidir.

8. Accuracy neden tehlikeli olabilir?

Fraud oranı %1 ise herkese normal diyen model %99 accuracy alabilir ama hiçbir fraud yakalamaz.

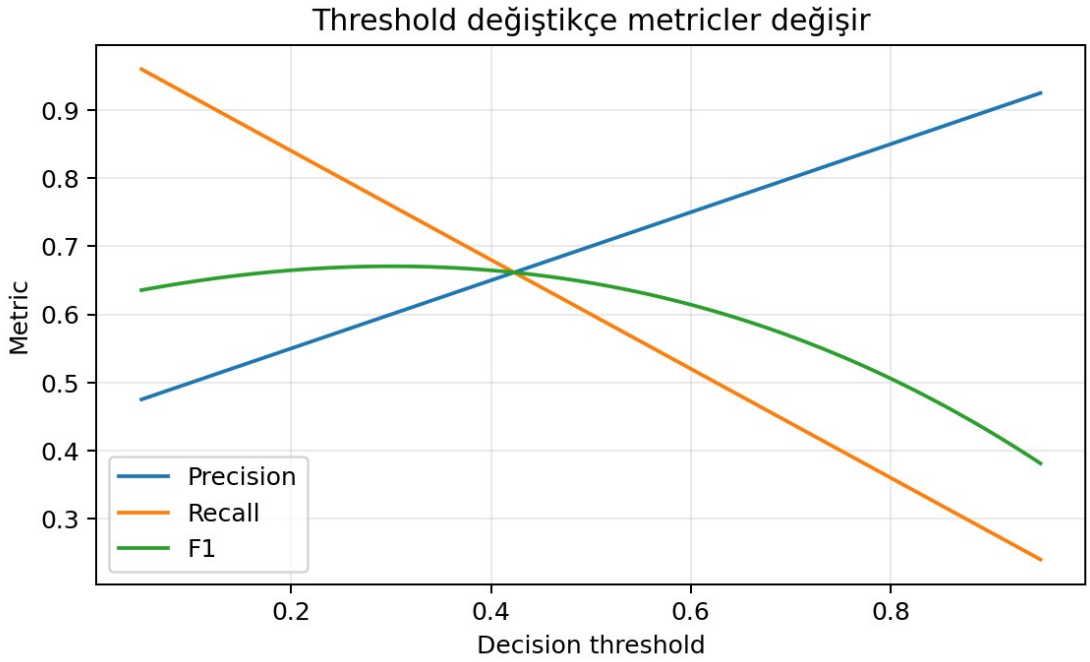
Metric	Formül sezgisi	Ne sorar?
Accuracy	(TP+TN)/all	Genel olarak kaçını doğru bildim?
Precision	TP/(TP+FP)	Pozitif dediklerimin kaçı gerçekten pozitif?
Recall	TP/(TP+FN)	Gerçek pozitiflerin kaçını yakaladım?
Specificity	TN/(TN+FP)	Negatiflerin kaçını doğru dışladım?
F1	Precision-recall harmonic mean	İki metriği dengeler

9. Precision vs Recall

Senaryo	Daha kritik metric
Kanser taraması / fraud screening	Recall genellikle çok kritik
Manuel inceleme kapasitesi sınırlı fraud alert	Precision da çok kritik
Spam filtresi	False positive maliyeti yüksekse precision
Churn kampanyası	Outreach maliyeti ve kaçırma maliyetine göre

Tek metric yok
İş kararında precision-recall trade-off'u açıkça konuşmak çoğu zaman 'en iyi modeli' seçmekten daha değerlidir.

10. Threshold tuning



Threshold düşerse daha fazla kişi pozitif sınıfa girer: recall genellikle artar, precision düşebilir. Threshold yükselirse tam tersi olur.

```
threshold = 0.30
pred = (proba >= threshold).astype(int)
```

Doğru yöntem
Threshold'u test set'te optimize etme. Validation/CV üzerinde seç, test set'i final değerlendirme için sakla.

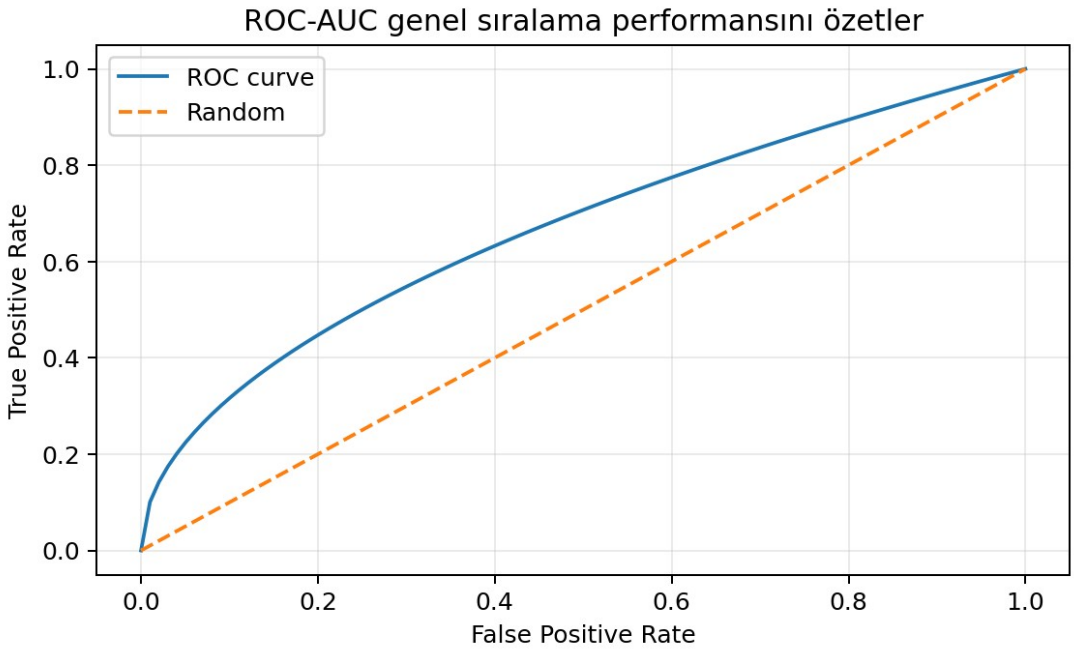
11. Cost-based threshold

Bir FN maliyeti 100 TL, FP maliyeti 5 TL ise eşik seçimini toplam expected cost üzerinden yapabilirsin.

```
cost = 100 * FN + 5 * FP
```

Senior bakış
Metric yerine doğrudan business cost veya expected utility optimize etmek daha doğru olabilir.

12. ROC Curve ve ROC-AUC



ROC curve tüm threshold'lar boyunca TPR (recall) ile FPR arasındaki trade-off'u gösterir. ROC-AUC modelin pozitif örneği negatiften daha yüksek sıralama olasılığı olarak yorumlanabilir.

Sınır
Ağır class imbalance'da ROC-AUC iyimser görünebilir. PR-AUC daha bilgilendirici olabilir.

13. Precision-Recall Curve ve PR-AUC

PR curve precision ile recall ilişkisini gösterir. Positive class nadir olduğunda modelin gerçek pozitifleri ne kadar temiz yakaladığını daha iyi görünür kılar.

Metric	Güçlü olduğu durum
ROC-AUC	Genel ranking, class oranları aşırı uç değil
PR-AUC	Rare positive / class imbalance
Log-loss	Probability quality
F1	Tek operating point'te precision-recall dengesi

14. Calibration

Bir model %0.8 probability verdiği örneklerin yaklaşık %80'i gerçekten pozitif oluyorsa iyi calibrated'dır. Ranking iyi olsa bile probability calibration kötü olabilir.

Kavram	Soru
Discrimination	Pozitifleri negatiflerden ayırabiliyor mu?
Calibration	Verdiği probability sayıları gerçek frekansla uyumlu mu?

Nerede kritik?
Risk skoru, kredi, fraud, churn ROI ve karar teorisi problemlerinde probability'nin sayısal anlamı önemlidir.

```
from sklearn.calibration import CalibratedClassifierCV

calibrated = CalibratedClassifierCV(
    estimator=base_model,
    method="isotonic",
    cv=5
)
```

15. Class imbalance

- Accuracy'ye güvenme.
- Stratified split kullan.
- PR-AUC/recall/precision gibi metricleri incele.
- Class weights, resampling ve threshold tuning'i ayrı araçlar olarak düşün.
- Synthetic oversampling yalnızca training fold içinde yapılmalıdır.

Leakage riski
SMOTE veya oversampling split/CV dışına uygulanırsa validation verisi sentetik training örneklerinin oluşumuna sızabilir.

16. Class weights

Loss içinde minority class hatalarına daha yüksek ağırlık verilebilir.

```
LogisticRegression(
    class_weight="balanced",
    max_iter=2000
)
```

Ne değişir?
Class weight decision boundary ve learned probabilities'i etkiler. Sonrasında threshold ve calibration tekrar değerlendirilmelidir.

17. K-Nearest Neighbors (KNN)

KNN parametrik bir model öğrenmez; yeni gözlemin en yakın k komşusuna bakarak sınıf kararı verir.

Avantaj	Dezavantaj
Basit ve sezgisel	Prediction pahalı olabilir
Nonlinear boundary yakalayabilir	Scaling'e çok duyarlı
Training maliyeti düşük	High-dimensional space'te distance anlamı zayıflar
Local patterns	k seçimine hassas

Scaling zorunlu gibi düşün
Distance tabanlı olduğu için gelir ve yaş gibi farklı ölçekte feature'lar standardize edilmezse büyük ölçekli feature baskın olur.

```
from sklearn.neighbors import KNeighborsClassifier

knn = Pipeline([
    ("scale", StandardScaler()),
    ("clf", KNeighborsClassifier(n_neighbors=15))
])
```

18. K seçimi

k	Davranış
Çok küçük	Low bias, high variance; noise'a duyarlı
Orta	Daha dengeli
Çok büyük	Boundary aşırı smooth, underfitting

Seçim
k validation/CV ile seçilir; test performansına göre ayarlanmaz.

19. Naive Bayes

Naive Bayes, Bayes teoremini kullanır ve class verildiğinde feature'ların koşullu bağımsız olduğunu varsayar. Bu varsayım gerçekte güçlüdür ama model pratikte şaşırtıcı derecede iyi çalışabilir.

Variant	Kullanım
GaussianNB	Sürekli feature'lar; class içinde Gaussian varsayımı
MultinomialNB	Kelime sayımları / text
BernoulliNB	Binary indicator feature'lar

NLP bağlantısı
TF-IDF/word-count tabanlı text classification'da Multinomial Naive Bayes güçlü ve hızlı baseline olabilir.

20. Bayes ile sınıf kararı

$P(y|x) \propto P(x|y)P(y)$. Prior class olasılığı ile likelihood birlikte posterior class probability üretir.

Naive kısmı
$P(x1,...,xp|y)$ yaklaşık olarak feature likelihood'larının çarpımı kabul edilir. Bu computational olarak büyük kolaylık sağlar.

21. Decision Tree

Decision Tree feature uzayını if-else kurallarıyla bölerek daha saf node'lar oluşturmaya çalışır.

Kavram	Yorum
Root	İlk split
Node	Ara karar noktası
Leaf	Final class/probability
Depth	Ağacın karmaşıklığı
Impurity	Node'daki sınıf karışımı

Güçlü yanı
Scaling gerektirmez, nonlinear interaction'ları doğal yakalar ve kuralları açıklamak kolay olabilir.

22. Gini ve Entropy

Tree split'i seçerken node impurity azaltılmaya çalışılır. Gini impurity ve entropy yaygın kriterlerdir.

Criterion	Sezgi
Gini	Yanlış sınıflama/karışım ölçüsü
Entropy	Bilgi belirsizliği; information gain ile bağlantılı

Pratik
İki criterion çoğu tabular problemde benzer sonuç verebilir; overfitting kontrolü genellikle daha önemlidir.

23. Tree overfitting ve pruning

Hyperparameter	Etkisi
max_depth	Ağaç derinliğini sınırlar
min_samples_split	Node split için minimum örnek
min_samples_leaf	Leaf minimum örnek
max_features	Split'te görülen feature sayısı
ccp_alpha	Cost-complexity pruning

Tree sezgisi
Kontrolsüz derin ağaç training verisini ezberleyebilir. Validation/CV ile complexity sınırlandırılır.

24. Logistic vs KNN vs NB vs Tree

Model	Güçlü yön	Zayıf yön
Logistic Regression	Yorumlanabilir, hızlı, calibrated olabilir	Lineer decision boundary
KNN	Local nonlinear pattern	Scaling ve high dimension sorunu
Naive Bayes	Hızlı, text'te güçlü baseline	Bağımsızlık varsayımı güçlü
Decision Tree	Nonlinear, interaction, açıklanabilir kurallar	High variance / overfit

25. Multiclass classification

Multiclass problemlerde model her sınıf için score/probability üretir. Stratejiler One-vs-Rest veya multinomial/softmax yaklaşımı olabilir.

```
proba = model.predict_proba(X_valid)
pred = model.predict(X_valid)
```

Metric	Multiclass kullanım
Accuracy	Genel doğru sınıf oranı
Macro F1	Her sınıfa eşit ağırlık
Weighted F1	Sınıf büyüklüğüne göre ağırlık
Confusion matrix	Hangi sınıflar karışıyor?

26. Macro, micro, weighted averaging

Average	Yorum
Macro	Her sınıf eşit önemli
Weighted	Büyük sınıflar daha fazla ağırlık
Micro	Tüm TP/FP/FN global toplanır

Rare class
Az görülen ama kritik sınıflarda macro metric ve sınıf bazlı recall'i mutlaka ayrıca incele.

27. Feature preprocessing

Feature türü	Yaklaşım
Numeric	Impute + scale (özellikle linear/KNN)
Nominal category	OneHotEncoder
Ordinal	Domain sırasına göre encoding
High-cardinality	Target leakage'siz encoding veya model değişikliği
Text	TF-IDF / embeddings

Pipeline
Preprocessing tüm validation/test bilgisinden izole olmalıdır.

28. Classification pipeline

```
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.impute import SimpleImputer
from sklearn.linear_model import LogisticRegression

preprocess = ColumnTransformer([
    ("num", Pipeline([
        ("impute", SimpleImputer(strategy="median")),
        ("scale", StandardScaler())
    ]), num_cols),
    ("cat", Pipeline([
        ("impute", SimpleImputer(strategy="most_frequent")),
        ("onehot", OneHotEncoder(handle_unknown="ignore"))
    ]), cat_cols)
])

model = Pipeline([
    ("prep", preprocess),
    ("clf", LogisticRegression(max_iter=2000))
])
```

Neden önemli?
Aynı preprocessing hem CV fold'larında hem deployment'ta aynı sırayla uygulanır; leakage ve train-serving skew riski azalır.

29. Split strategy

Veri yapısı	Doğru yaklaşım
IID + imbalance	Stratified split
Aynı kullanıcı birden çok satır	Group split
Zaman içinde oluşan target	Temporal split
Fraud/churn gibi zaman bağımlı	Gelecekten geçmişe bilgi sızdırma!

30. Probability calibration kontrolü

- Reliability/calibration curve çiz.
- Brier score veya log-loss izle.
- Threshold seçmeden önce probability anlamını kontrol et.
- Isotonic/Platt calibration yalnızca validation/CV düzeninde uygulanmalı.

31. Gerçek vaka: churn classification

Bir abonelik şirketi önümüzdeki 30 günde churn edecek müşterileri önceden belirlemek istiyor.

Aşama	Karar
Target	prediction_date sonrası 30 günde churn=1
Features	Prediction anına kadar bilinen kullanım, ödeme, destek davranışları
Split	Zamansal; eski kohortlarla geleceği tahmin
Baseline	Majority + simple rule
Models	Logistic, tree, boosting benchmark
Metric	PR-AUC, recall@capacity, precision
Threshold	Retention ekibinin günlük arama kapasitesine göre
Output	Risk probability + top-N müşteri

İş metric'i
Modeli F1 ile seçmek yerine örneğin 'günde 5,000 müşteriye ulaşabiliyoruz; top 5,000 içindeki churn recall/precision nedir?' sorusu daha doğrudan olabilir.

32. Gerçek vaka: fraud detection

Fraud oranının %0.5 olduğu işlem sisteminde accuracy anlamsızlaşır. Model score üretir, risk seviyesi ve manuel inceleme kapasitesine göre farklı action threshold'ları kullanılabilir.

Score	Aksiyon
< 0.20	Approve
0.20 - 0.70	Ek doğrulama / review
> 0.70	Block veya yüksek öncelikli review

Tek threshold şart değil
Gerçek sistemlerde score'u farklı aksiyon katmanlarına çevirmek binary karar vermekten daha iyi olabilir.

33. Error analysis

Model metric'i tek sayı değildir. Hataları segment bazında incelemek model geliştirmede kritik adımdır.

- False negatives hangi segmentte yoğun?
- False positives hangi ülke/device/source'ta artıyor?
- Yeni müşterilerde calibration farklı mı?
- Probability distribution drift ediyor mu?
- Model belirli protected group'larda farklı hata oranı üretiyor mu?

Feature engineering kaynağı
Error analysis çoğu zaman yeni feature veya veri kalite hipotezlerinin en güçlü kaynağıdır.

34. Data leakage örnekleri

Leakage	Neden hatalı?
Churn sonrası cancellation_reason feature'ı	Target sonrası bilgi
Fraud chargeback sonucu	Karar anında bilinmiyor
Tüm dataset'te target encoding	Validation target bilgisi sızıyor
Split öncesi SMOTE	Synthetic training validation'dan bilgi taşıyabilir
Future transaction aggregate	Geleceği geçmiş feature'a katıyor

35. Model selection checklist

- Business objective ve hata maliyeti tanımlı mı?
- Probability mi ranking mi class label mı gerekiyor?
- Class imbalance seviyesi nedir?
- Split gerçek deployment zamanını taklit ediyor mu?
- Baseline var mı?
- Metric business amacıyla uyumlu mu?
- Threshold validation üzerinde seçildi mi?
- Calibration kontrol edildi mi?
- Segment/error analysis yapıldı mı?
- Test set yalnızca final değerlendirmede kullanıldı mı?

36. Mülakat soruları

Soru	Kısa cevap
Logistic regression neden classification için uygundur?	Linear score'u sigmoid ile probability'ye dönüştürür ve log-loss ile eğitilir.
Accuracy ne zaman yanıltıcı?	Class imbalance yüksek olduğunda.
Precision ile recall farkı?	Precision pozitif tahminlerin temizliğini, recall gerçek pozitifleri yakalama oranını ölçer.
ROC-AUC ne anlatır?	Threshold bağımsız ranking/discrimination performansı.
PR-AUC ne zaman daha yararlı?	Positive class nadir olduğunda.
Threshold neden 0.5 olmak zorunda değil?	FP/FN business maliyetleri ve kapasite farklıdır.
Calibration nedir?	Tahmin probability'lerinin gerçek frekanslarla uyumu.
KNN neden scaling ister?	Distance feature ölçeklerine duyarlıdır.
Naive Bayes'in naive varsayımı ne?	Class verildiğinde feature'ların koşullu bağımsızlığı.
Decision tree neden overfit olur?	Derinlik arttıkça küçük veri detaylarını ezberleyebilir.
Class weight ne yapar?	Loss'ta sınıf hatalarının önemini değiştirir.
SMOTE nerede uygulanmalı?	Yalnızca training fold içinde.
Macro F1 ne zaman?	Her sınıf eşit önemdeyse.
Log-loss accuracy'den ne fark taşır?	Probability confidence'ını da cezalandırır.
False negative maliyeti yüksekse ne yaparsın?	Recall/expected cost odaklı threshold ve metric seçerim.

37. Uygulama alıştırmaları

1. Breast Cancer dataset üzerinde Logistic Regression, KNN ve Decision Tree karşılaştır.
2. Accuracy, precision, recall, F1, ROC-AUC ve PR-AUC'yi aynı tabloda raporla.
3. Threshold'u 0.1-0.9 arasında gezdirip precision-recall trade-off çiz.
4. False negative maliyeti 20x olacak şekilde cost-optimal threshold seç.
5. Class imbalance simüle et ve accuracy'nin nasıl yanıltıcı olduğunu göster.
6. KNN'i scaling öncesi/sonrası karşılaştır.
7. Decision Tree max_depth için CV eğrisi çıkar.
8. Calibration curve çiz ve CalibratedClassifierCV sonrası değişimi incele.
9. Multiclass dataset'te macro vs weighted F1 farkını incele.
10. Segment bazlı confusion matrix üret.

38. Mini portföy projesi

Proje: Subscription Churn Risk Classification

Dosya/çıktı	İçerik
01_problem_definition.md	Target window, prediction time, business cost
02_eda.ipynb	Class balance, leakage ve cohort analizi
03_baselines.ipynb	Majority + Logistic baseline
04_models.ipynb	Logistic, KNN, Naive Bayes, Tree
05_threshold.ipynb	Precision-recall, cost/capacity threshold
06_error_analysis.ipynb	FN/FP segment analizi
src/pipeline.py	Leakage-safe preprocessing/model pipeline
report.md	Business recommendation ve limitations

CV cümlesi
Built a churn classification system comparing interpretable and nonlinear models, with probability calibration,

threshold optimization, PR-AUC evaluation and segment-level error analysis.

39. Final cheat sheet

Kavram	Hatırlanacak fikir
Logistic Regression	Linear score + sigmoid
Log-loss	Probability confidence'ını değerlendirir
Confusion Matrix	TP/TN/FP/FN
Precision	Pozitif tahminlerin temizliği
Recall	Gerçek pozitifleri yakalama
F1	Precision-recall dengesi
ROC-AUC	Ranking / discrimination
PR-AUC	Rare positive için güçlü
Threshold	Business kararı
Calibration	Probability'nin sayısal güvenilirliği
KNN	Distance-based local classifier
Naive Bayes	Bayes + conditional independence
Decision Tree	If-else partition
Class weights	Loss'ta sınıf önemini değiştir
Stratified split	Class oranlarını koru
Error analysis	Model geliştirme kaynağı

Bu modülden sonra
Ensemble Models bölümünde Random Forest ve Gradient Boosting'in Decision Tree'nin yüksek variance sorununu nasıl çözdüğünü çok daha rahat anlayacaksın.