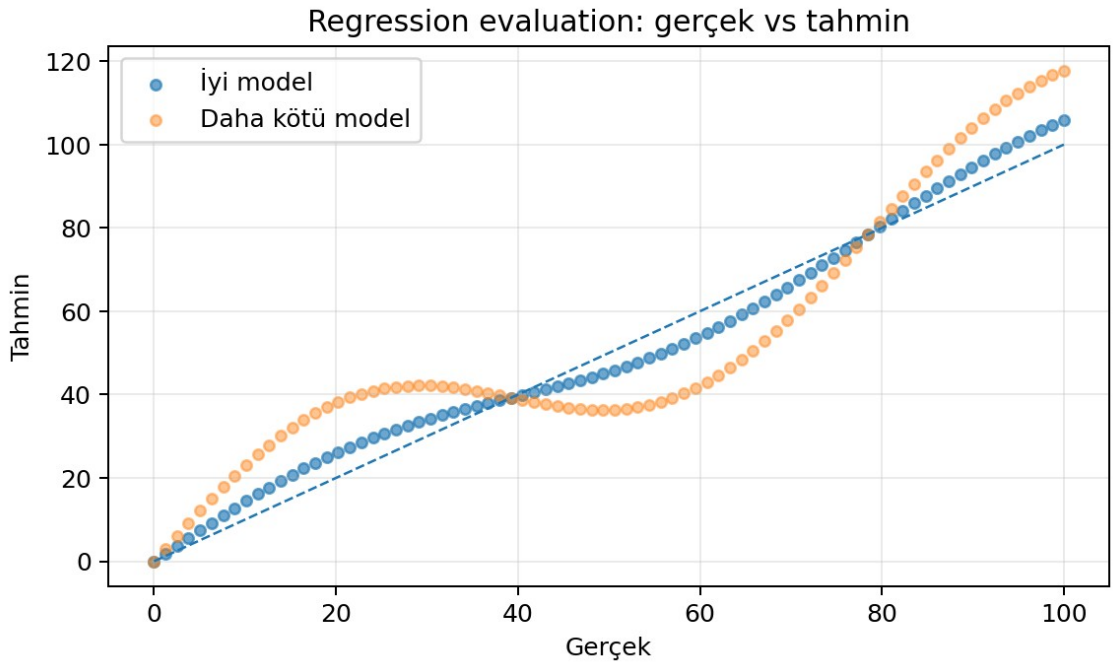
18. MODEL EVALUATION

Regression • Classification • Threshold • Calibration • Cross-Validation



Bu modülün amacı
Model evaluation'ı tek bir accuracy veya RMSE sayısına indirgemeden; doğru metric seçimi, validation tasarımı, threshold, calibration, segment analizi ve business cost ile birlikte değerlendirebilmek.

Kazanım	Modül sonunda
Regression evaluation	MAE, MSE, RMSE, R^2 ve yüzdesel hataları doğru yorumlayabilirsin.
Classification evaluation	Confusion matrix, precision, recall, F1, ROC-AUC ve PR-AUC kullanabilirsin.
Validation	Holdout, cross-validation, group ve time-based split farklarını bilirsin.
Threshold	Business maliyetine göre classification threshold seçebilirsin.
Calibration	Probability skorlarının sayısal güvenilirliğini kontrol edebilirsin.
Error analysis	Segment bazında model hatalarını teşhis edebilirsin.

1. Model evaluation neden model kadar önemlidir?

Aynı model, farklı metric veya split altında tamamen farklı görünebilir. Bu yüzden model evaluation sadece raporlama değil, model geliştirme sürecinin kendisidir.

Yanlış soru	Daha iyi soru
Accuracy kaç?	Hangi hata türü business için pahalı?
RMSE düşük mü?	Baseline'a göre ne kadar iyileşme var?

AUC yüksek mi?	Kullanacağımız threshold'da precision/recall ne?
CV iyi mi?	CV split'i deployment gerçekliğini taklit ediyor mu?
Genel metric iyi mi?	Kritik segmentlerde hata nasıl?

Ana fikir
Evaluation tasarımı problem framing'in devamıdır. Yanlış evaluation, iyi modeli kötü; kötü modeli iyi gösterebilir.

2. Baseline olmadan metric anlamsızdır

Regression'da mean/median predictor, classification'da majority class veya basit rule-based sistem başlangıç baseline'ıdır.

```
from sklearn.dummy import DummyRegressor, DummyClassifier
```

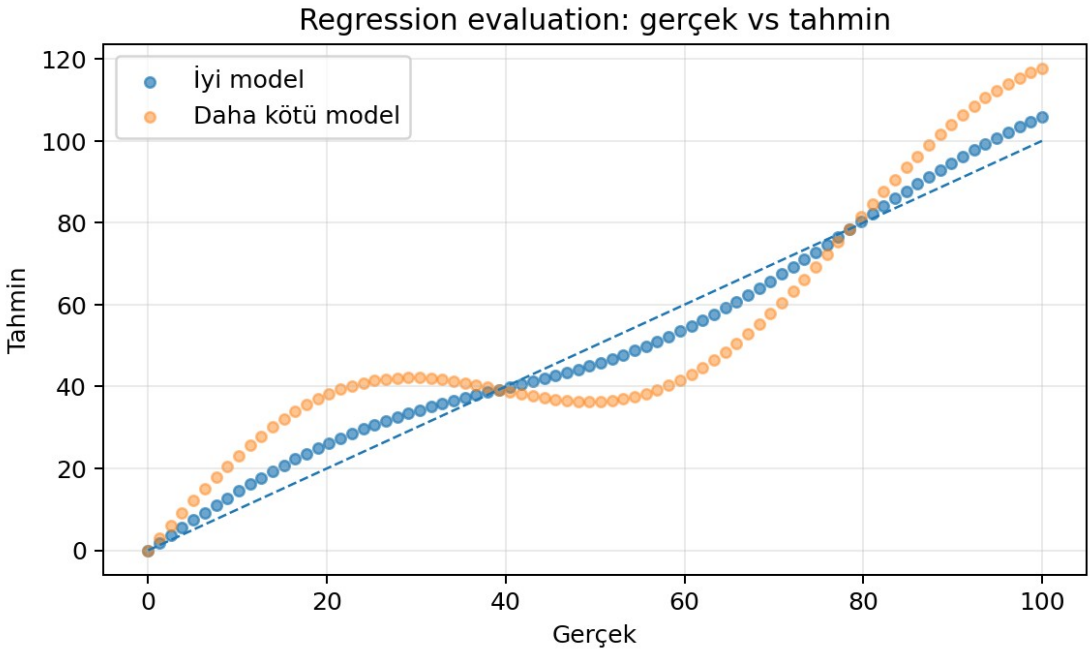
Örnek
Model MAE=120 ise tek başına yorumlayamazsın. Baseline MAE=200 ise anlamlı kazanım; baseline=100 ise model geride.

3. Train / validation / test rolleri

Parça	Rol
Train	Model parametrelerini öğrenir.
Validation	Model/hyperparameter/threshold seçimi için kullanılır.
Test	Final unbiased performans tahmini için saklanır.

Test set disiplini
Test performansına bakıp modele tekrar tekrar müdahale edersen test set de validation set'e dönüşür.

4. Regression metricleri



Metric	Sezgi	Avantaj / risk
MAE	|y-pred| ortalaması	Kolay yorumlanır; outlier'a RMSE'den dayanıklı.
MSE	error² ortalaması	Büyük hataları sert cezalandırır; birimi kareseldir.
RMSE	sqrt(MSE)	Target biriminde; büyük hatalara duyarlı.
R^2	Mean baseline'a göre açıklanan varyans	Negatif olabilir; business hata birimini vermez.
MAPE	Yüzdesel absolute error	y≈0 iken patlar; düşük hedeflerde dengesiz.
RMSLE	Log-space hata	Pozitif/multiplicative hedeflerde yararlı.

5. MAE vs RMSE

RMSE büyük hataları daha fazla cezalandırdığı için birkaç büyük hata önemliyse tercih edilir. MAE her hataya lineer maliyet varsayar.

Business bağlantısı
Teslimat tahmininde 60 dakikalık hata 6 tane 10 dakikalık hatadan daha pahalıysa RMSE mantığı iş maliyetine daha yakın olabilir.

6. R^2 ve Adjusted R^2

R^2 = 1 - SSE/SST. Test set'te negatif olabilir; bu, modelin mean baseline'dan kötü olduğunu gösterir.

Adjusted R^2
Klasik regression inference'ta feature sayısını hesaba katar. Ancak modern model selection'da cross-validation

genellikle daha güçlü yaklaşımdır.

7. Yüzdesel hata metrikleri

Metric	Dikkat
MAPE	Zero ve near-zero targetlarda problem.
sMAPE	Paydada |y|+|pred| kullanır; yine özel durumları vardır.
WAPE	Toplam absolute error / toplam actual; toplu planlamada kullanışlı olabilir.

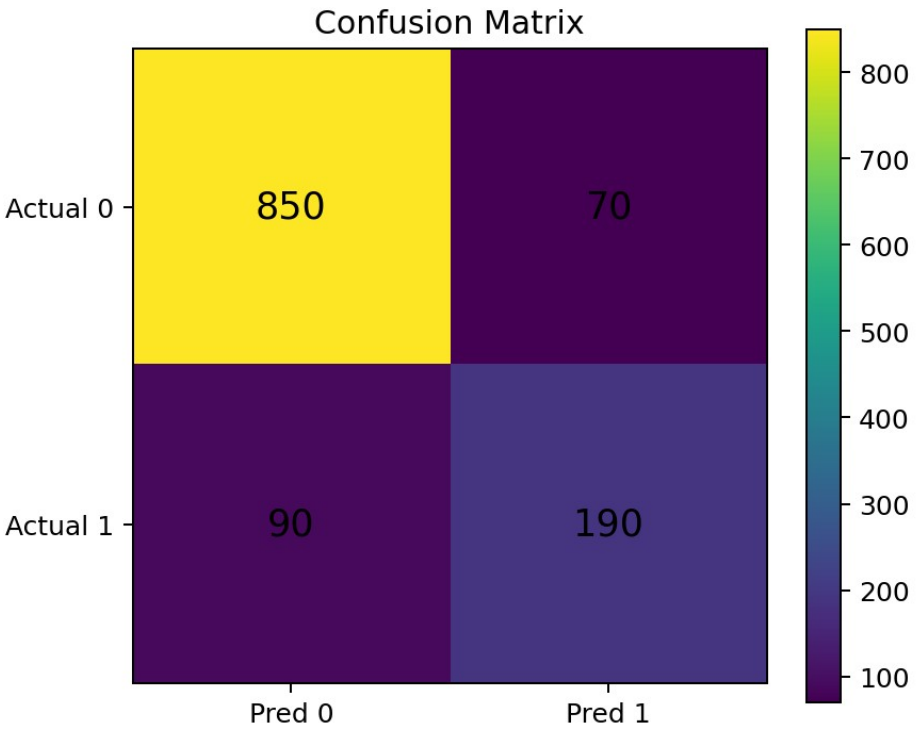
Metric hackleme
Dataset yapısına uygun olmayan metric seçimi model ranking'ini yanlış yönlendirebilir. Özellikle yüzdesel metriclerde küçük denominator problemini kontrol et.

8. Residual analizi evaluation'ın parçasıdır

- Residual vs prediction: nonlinearity / heteroscedasticity.
- Residual vs time: drift / seasonality.
- Residual vs segment: subgroup bias.
- Residual distribution: heavy tail ve outlier.

Tek sayı yetmez
Aynı RMSE'ye sahip iki modelden biri kritik müşteri segmentinde sistematik bias taşıyabilir.

9. Classification confusion matrix



Hata	Anlam
False Positive	Negatifi pozitif işaretlemek.
False Negative	Pozitifi kaçırmak.

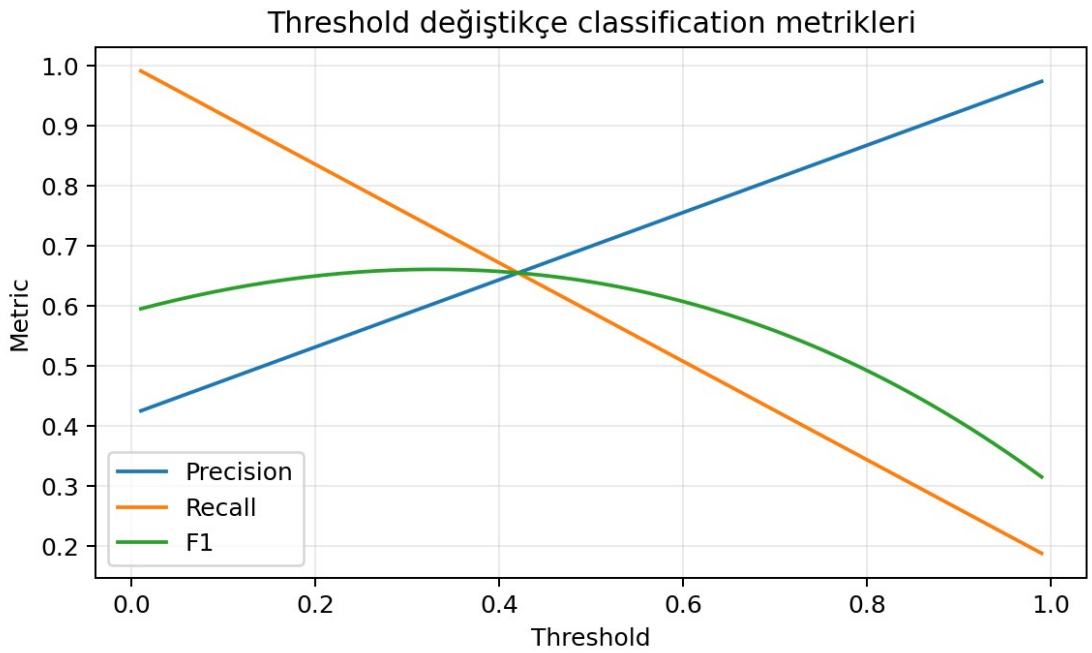
Evaluation'ın merkezinde hata maliyeti var
Fraud, tıp, kredi, churn gibi problemlerde FP ve FN maliyetleri eşit değildir.

10. Accuracy, Precision, Recall, Specificity, F1

Metric	Formül	Soru
Accuracy	(TP+TN)/N	Genel doğruluk?
Precision	TP/(TP+FP)	Pozitif dediklerimin kaçı doğru?
Recall / TPR	TP/(TP+FN)	Gerçek pozitiflerin kaçını yakaladım?
Specificity / TNR	TN/(TN+FP)	Negatiflerin kaçını doğru dışladım?
F1	2PR/(P+R)	Precision-recall dengesi?

Imbalanced data
%1 fraud'da %99 accuracy sıfır değerli olabilir. Accuracy tek başına güvenilmez.

11. Threshold evaluation



Model probability üretir; threshold business aksiyonuna çevirir. Threshold düştükçe recall artma eğiliminde, precision düşme eğilimindedir.

```
threshold = 0.35
pred = (proba >= threshold).astype(int)
```

Threshold'u nerede seçersin?
Validation/CV üzerinde. Test set'te threshold optimize etmek evaluation leakage'dır.

12. Cost-based evaluation

İdeal durumda FP/FN sayısını iş maliyetleriyle çarparak expected cost hesaplarsın.

```
cost = fp_cost * FP + fn_cost * FN
```

Örnek
FN=100 TL, FP=5 TL ise recall lehine daha düşük threshold mantıklı olabilir.

13. ROC Curve ve ROC-AUC

ROC curve threshold boyunca TPR vs FPR'yi gösterir. AUC, modelin rastgele seçilen pozitif örneği negatiften daha yüksek score verme olasılığı şeklinde yorumlanabilir.

Güçlü yön	Sınır
Threshold bağımsız ranking özeti	Heavy imbalance'da fazla iyimser olabilir.

Modelleri genel ayırma gücüyle kıyaslar	Operating point performansını doğrudan söylemez.

14. Precision-Recall Curve ve PR-AUC

Positive class nadir olduğunda PR curve daha açıklayıcıdır. Baseline precision yaklaşık positive prevalence seviyesidir.

Fraud/churn/rare event
PR-AUC ve recall@precision gibi metrikler ROC-AUC'den daha işlevsel olabilir.

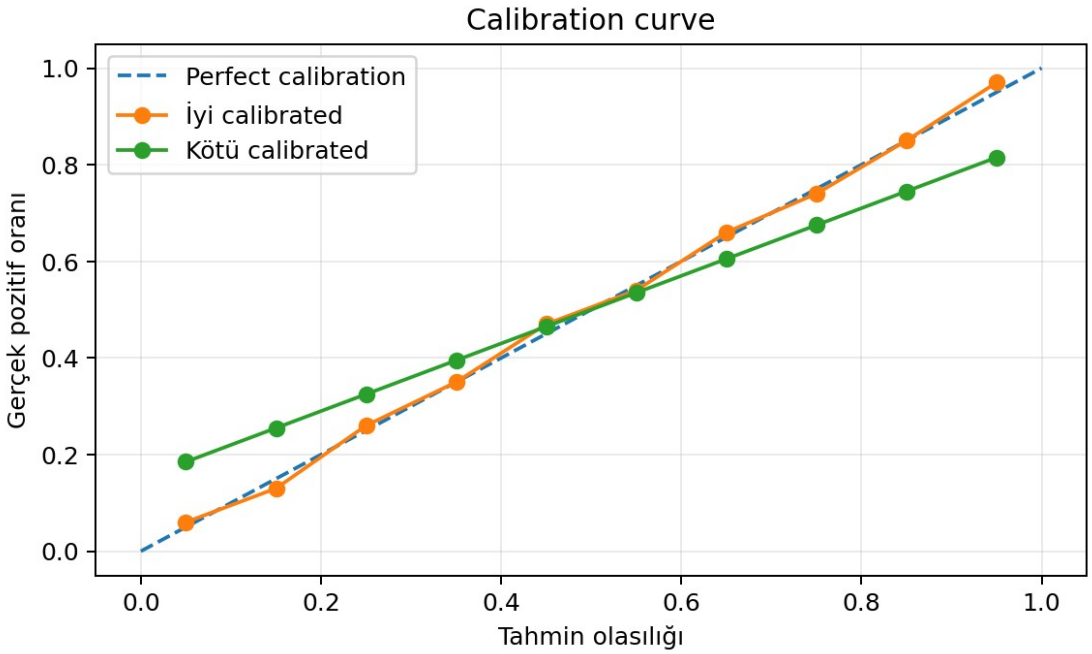
15. Top-k ve capacity-based metrics

Bazı işlerde threshold yerine kapasite vardır. Örneğin retention ekibi günde yalnızca 5,000 müşteri arayabilir.

Metric	Anlam
Precision@k	İlk k riskli kaydın ne kadarı gerçekten pozitif?
Recall@k	Tüm gerçek pozitiflerin ne kadarı ilk k içinde?
Lift@k	İlk k'daki positive rate / genel positive rate

Çok gerçekçi metric
CRM, fraud review, lead scoring ve kampanya seçiminde top-k metrikleri doğrudan operasyon kapasitesine bağlanır.

16. Probability calibration



Probability=0.8 verilen vakaların yaklaşık %80'i pozitifse model calibrated kabul edilir.

Metric / araç	Amaç
Calibration curve	Predicted probability vs observed frequency
Brier score	Probability squared error
Log-loss	Yanlış güveni sert cezalandırır
Platt / sigmoid	Parametric calibration
Isotonic	Daha esnek nonparametric calibration

Discrimination != calibration
AUC çok iyi olup calibration kötü olabilir. Ranking ile probability reliability farklı özelliklerdir.

17. Multi-class evaluation

Metric	Yorum
Accuracy	Genel doğru sınıf oranı
Macro F1	Her sınıfa eşit ağırlık
Weighted F1	Sınıf frekansına göre ağırlık
Per-class recall	Kritik sınıf kaçırılıyor mu?
Confusion matrix	Hangi sınıflar birbirine karışıyor?

18. Macro / Micro / Weighted

Averaging	Ne yapar?
Macro	Her sınıf metricini ayrı hesaplayıp eşit ortalar.
Micro	Global TP/FP/FN üzerinden hesaplar.
Weighted	Sınıf support'u ile ağırlıklandırır.

Rare class
Rare ama kritik sınıf varsa weighted F1 iyi görünürken o sınıfın recall'i çok kötü olabilir.

19. Cross-validation neden kullanılır?

Tek validation split tesadüfi olabilir. K-fold CV model performansını birden fazla split'te ölçerek varyansı görünür hale getirir.

Yöntem	Kullanım
KFold	IID regression / genel kullanım
StratifiedKFold	Classification class oranını korumak
GroupKFold	Aynı grup train ve validation'a bölünmemeli
TimeSeriesSplit	Gelecekten geçmişe leakage engellemek

CV amacı
Sadece ortalama metric değil, fold-to-fold variability de önemlidir.

20. Nested CV

Hyperparameter tuning ve performance estimation aynı CV üzerinde yapılırsa optimistik bias oluşabilir. Nested CV dış döngüyü evaluation, iç döngüyü tuning için kullanır.

Ne zaman?
Küçük/orta dataset ve ciddi model kıyaslamasında daha güvenilir tahmin için yararlıdır.

21. Repeated CV ve confidence

Tek K-fold yerine farklı random splitlerle CV tekrarı, model ranking stabilitesini daha iyi gösterebilir.

Raporlama
Sadece mean CV score değil mean ± std veya fold dağılımını göster.

22. Time-based evaluation

Geleceği tahmin eden sistemde random split gelecek örnekleri training'e taşıyabilir.

Yanlış	Doğru
2025 ve 2026 kayıtlarını karıştırıp random split	Eski dönem train, sonraki dönem validation/test
Future rolling features	Sadece prediction anına kadar olan geçmiş

Deployment simulation
En iyi evaluation, model production'da hangi bilgiyi görecekse onu taklit eder.

23. Group leakage

Aynı müşteri/hasta/cihazın birden fazla kaydı varsa random split modelin aynı entity'yi hem train hem validation'da görmesine yol açabilir.

Çözüm
GroupShuffleSplit, GroupKFold veya entity-temelli holdout.

24. Statistical uncertainty

Metric bir tahmindir. Özellikle küçük test setlerinde metric belirsizliği yüksek olabilir.

- Bootstrap ile MAE/AUC/F1 confidence interval.
- Model farkı için paired bootstrap.
- Segment metrics için sample size kontrolü.

0.002 AUC farkı
Belirsizlik aralığı olmadan küçük metric farklarını 'kazanan model' diye yorumlamak tehlikelidir.

25. Model comparison

Kıyas	Doğru yaklaşım
Aynı test set üzerinde iki model	Paired comparison
Farklı split'lerde skor	Doğrudan karşılaştırma dikkatli
Hyperparameter tune edilmiş model	Test set tuning dışında tutulmalı
Birden fazla metric	Primary metric önceden belirlenmeli

Winner's curse
Çok sayıda model deneyip en iyiyi seçmek validation skorunu optimistik yapabilir.

26. Segment-based evaluation

Global metric alt gruplardaki sistematik hatayı gizleyebilir.

Segment örnekleri	Kontrol
Yeni vs eski müşteri	MAE/recall/calibration farkı
Mobile vs desktop	Performance gap
Ülke/bölge	Data distribution farkı
Düşük vs yüksek target	Regression error scale
Protected groups	Fairness hata oranları

Minimum sample size
Çok küçük segment metricleri aşırı oynak olabilir. Support sayılarını her zaman göster.

27. Error analysis workflow

1. En büyük regression residual'larını veya classification FP/FN'leri çıkar.
2. Feature ve segment ortaklıklarını incele.
3. Data quality problemi var mı kontrol et.
4. Missing feature / interaction hipotezi üret.
5. Yeni feature/model değişikliğini CV ile test et.
6. Aynı hata segmentini tekrar ölç.

28. Metric selection framework

Problem özelliği	Metric yönü
Regression + büyük hata pahalı	RMSE / custom cost
Regression + robust business loss	MAE
Rare positive classification	PR-AUC / recall / precision
Ranking problemi	ROC-AUC / NDCG / top-k
Probability karar sistemi	Log-loss / Brier + calibration
Operasyon kapasitesi var	Precision@k / Recall@k / lift
Multiclass rare critical class	Macro + per-class recall

29. Custom business metric

Standart ML metric business değerini tam temsil etmiyorsa custom scoring function tanımlanabilir.

```
def expected_profit(y_true, proba, threshold):
    pred = proba >= threshold
    # örnek iş değerleri:
    # TP: +80, FP: -10, FN: -120
    return (
        80 * ((pred == 1) & (y_true == 1)).sum()
        -10 * ((pred == 1) & (y_true == 0)).sum()
        -120 * ((pred == 0) & (y_true == 1)).sum()
    )
```

Dikkat
Business metric varsayımlarını paydaşlarla doğrula; sayıları model ekibi tek başına icat etmemeli.

30. Offline vs online evaluation

Offline	Online
Historical holdout	A/B test / shadow deployment
MAE/AUC/F1	Revenue/conversion/latency/complaint
Model ranking	Gerçek kullanıcı davranışı
Ucuz ve hızlı	Daha gerçek ama maliyetli

Production gerçeği
Offline metric iyileşmesi her zaman business KPI artışı yaratmaz. Data drift, latency ve action policy sonucu değiştirebilir.

31. Monitoring için evaluation

- Input distribution drift.
- Prediction score distribution.
- Actual label geldikçe production metric.
- Calibration drift.
- Segment bazlı performance.
- Data quality ve missing rate.

Delayed labels
Fraud chargeback veya churn gibi target geç geliyorsa proxy/leading monitoring metriklerine ihtiyaç olabilir.

32. Gerçek vaka: churn model evaluation

Retention ekibi haftada 20,000 müşteriye ulaşabiliyor. Churn prevalence %8.

Yanlış yaklaşım	Daha doğru yaklaşım
Accuracy optimize et	PR-AUC + precision@20k + recall@20k
0.5 threshold kullan	Kapasiteye göre top-20k
Genel metric raporla	Yeni/legacy plan segmentlerini ayır
Probability'yi risk diye kullan	Calibration kontrol et

Business soru
20,000 arama hakkımızı hangi müşterilere ayırırsak en fazla gerçek churn müşterisini yakalarız?

33. Gerçek vaka: house price model evaluation

Ev fiyat modelinde MAE=150k TL görünse de lüks ev segmenti 1.2M TL sistematik underprediction taşıyabilir.

Kontrol	Neden
MAE + RMSE	Average ve tail error
R^2	Baseline'a göre yapı
Target quantile segmentleri	Low/high-price bias
Residual vs location	Bölgesel bias
Temporal holdout	Market drift

34. Gerçek vaka: fraud model evaluation

Fraud prevalence %0.4; manuel review kapasitesi günde 3,000 işlem.

Metric	İş karşılığı
PR-AUC	Rare-event ranking kalitesi
Precision@3000	Review edilenlerin ne kadarı fraud?
Recall@3000	Tüm fraudların ne kadarı yakalandı?
Expected loss	Kaçırılan fraud + review maliyeti
Calibration	Score risk seviyesi olarak kullanılabiliyor mu?

Operating point
Modeli yalnız AUC ile değil, production kapasitesindeki operating point'te değerlendir.

35. Sık yapılan evaluation hataları

- Metric'i problemden sonra değil, model sonucunu gördükten sonra seçmek.
- Test set'i model/hyperparameter/threshold tuning için kullanmak.
- Imbalanced data'da accuracy'ye güvenmek.
- Time-dependent data'da random CV yapmak.
- Same-user leakage'ı gözden kaçırmak.

- Global metric ile segment hatalarını saklamak.
- Probability calibration kontrol etmemek.
- Küçük metric farklarını uncertainty olmadan yorumlamak.
- Business capacity ve cost'u metric tasarımına katmamak.
- Offline metric'i otomatik business success kabul etmek.

36. sklearn evaluation kod şablonu

```
from sklearn.metrics import (
    mean_absolute_error,
    mean_squared_error,
    r2_score,
    precision_score,
    recall_score,
    f1_score,
    roc_auc_score,
    average_precision_score,
    log_loss
)

# regression
mae = mean_absolute_error(y_true, pred)
rmse = mean_squared_error(y_true, pred) ** 0.5
r2 = r2_score(y_true, pred)

# classification
precision = precision_score(y_true, cls_pred)
recall = recall_score(y_true, cls_pred)
f1 = f1_score(y_true, cls_pred)
roc_auc = roc_auc_score(y_true, proba)
pr_auc = average_precision_score(y_true, proba)
ll = log_loss(y_true, proba)
```

37. Cross-validation kod şablonu

```
from sklearn.model_selection import StratifiedKFold, cross_validate

cv = StratifiedKFold(
    n_splits=5,
    shuffle=True,
    random_state=42
)

scores = cross_validate(
    model,
    X,
    y,
    cv=cv,
    scoring={
        "roc_auc": "roc_auc",
        "pr_auc": "average_precision",
        "f1": "f1"
    }
)
```

CV raporu
Her metric için mean, std ve mümkünse fold değerlerini raporla.

38. Mülakat soruları

Soru	Kısa cevap
MAE ile RMSE farkı nedir?	RMSE büyük hataları daha sert cezalandırır; MAE daha robust ve yorumlanabilirdir.
R^2 negatif olabilir mi?	Evet, testte model mean baseline'dan kötü olabilir.
Accuracy ne zaman yanıltıcıdır?	Class imbalance yüksek olduğunda.
Precision vs recall?	Precision pozitif tahminlerin doğruluğu, recall gerçek pozitifleri yakalama oranıdır.
ROC-AUC ne ölçer?	Genel ranking/discrimination.
PR-AUC ne zaman daha yararlı?	Positive class nadir olduğunda.
Threshold neden 0.5 olmak zorunda değildir?	Hata maliyeti ve operasyon kapasitesi farklıdır.
Calibration nedir?	Predicted probability ile observed frequency uyumu.
K-fold CV neden?	Tek split varyansını azaltıp daha güvenilir model seçimi sağlar.
TimeSeriesSplit neden?	Geleceğin geçmişe sızmasını engeller.
GroupKFold ne zaman?	Aynı entity'nin train/validation'a bölünmemesi gerektiğinde.
Nested CV neden?	Tuning bias'ından bağımsız performance estimation için.
Macro F1 ne zaman?	Her sınıf eşit önemdeyse.
Precision@k ne zaman?	Operasyon kapasitesi sabit top-k aksiyon gerektiriyorsa.
AUC yüksek ama model kötü olabilir mi?	Evet; calibration veya operating threshold performansı kötü olabilir.

39. Uygulama alıştırmaları

7. Aynı regression modelini MAE, RMSE ve R^2 ile değerlendir; model sıralamasının değişip değişmediğini incele.
8. Imbalanced classification dataset oluştur ve accuracy'nin yanıltıcılığını göster.
9. Threshold 0.05-0.95 arasında precision/recall/F1 eğrileri çiz.
10. ROC-AUC ve PR-AUC'yi aynı iki model için karşılaştır.
11. Calibration curve çiz ve calibration sonrası log-loss/Brier değişimini ölç.
12. StratifiedKFold ve random KFold sonuçlarını dengesiz sınıflarda karşılaştır.
13. GroupKFold gerektiren müşteri-tekrarlı veri simüle et.
14. TimeSeriesSplit ile random split farkını zaman trendli veride ölç.
15. Bootstrap ile MAE veya AUC %95 confidence interval üret.
16. Segment bazında metric dashboard'u oluştur.

40. Mini portföy projesi

Proje: Model Evaluation Lab - Churn, Fraud ve Regression Benchmark

Çıktı	İçerik
01_regression_eval.ipynb	MAE/RMSE/R^2 + residual segment analizi
02_classification_eval.ipynb	Confusion, ROC, PR, threshold
03_calibration.ipynb	Reliability curve, Brier, log-loss
04_cv_design.ipynb	KFold, GroupKFold, TimeSeriesSplit
05_business_metric.ipynb	Cost ve top-k operating point

report.md	Model selection kararları ve trade-off'lar

CV cümlesi
Designed a rigorous model-evaluation framework covering cross-validation, threshold optimization, calibration, segment-level error analysis and business-cost metrics across regression and classification tasks.

41. Final cheat sheet

Kavram	Hatırlanacak fikir
Baseline	Model değerini referansla ölç
MAE	Lineer hata maliyeti
RMSE	Büyük hatalara duyarlı
R^2	Mean baseline'a göre varyans
Precision	Pozitif tahmin temizliği
Recall	Pozitif yakalama
F1	Precision-recall dengesi
ROC-AUC	Ranking/discrimination
PR-AUC	Rare positive
Threshold	Business operating point
Calibration	Probability güvenilirliği
KFold	Split belirsizliğini azalt
Group split	Entity leakage engelle
Time split	Future leakage engelle
Top-k	Kapasiteye göre değerlendirme
Error analysis	Hataların yapısını keşfet

Bu modülden sonra
Feature Engineering, Pipelines ve Cross Validation modüllerinde model geliştirme döngüsünü artık sadece 'skor artırmak' değil, doğru evaluation tasarımı üzerinden kurabileceksin.