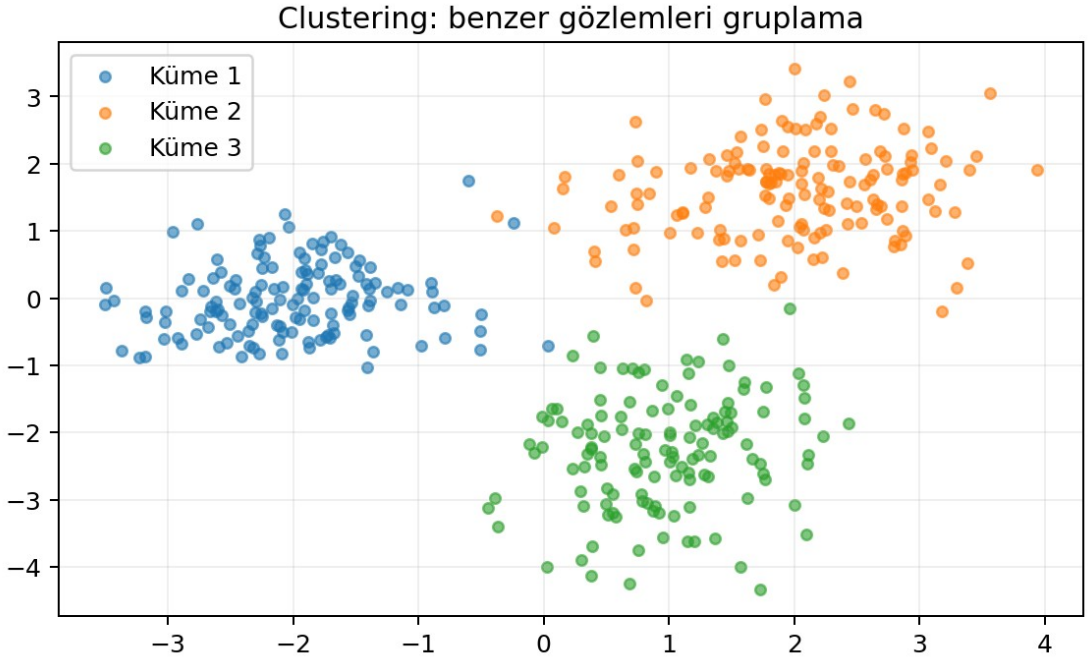
25. CLUSTERING

K-Means • Hierarchical Clustering • DBSCAN • Cluster Profiling



Bu modülün amacı
Clustering'i yalnızca bir algoritma çalıştırma işi olarak değil; doğru temsil, distance seçimi, küme sayısı, kalite ölçümü ve business segmentasyonu ile birlikte öğrenmek.

Kazanım	Modül sonunda
Unsupervised düşünce	Target olmadan benzerlik ve segmentasyon problemlerini kurabilirsin.
K-Means	Centroid tabanlı clustering mantığını ve varsayımlarını açıklayabilirsin.
Hierarchical	Dendrogram ve linkage yaklaşımını yorumlayabilirsin.
DBSCAN	Yoğunluk tabanlı clustering ve noise kavramını kullanabilirsin.
Evaluation	Silhouette, inertia ve stability üzerinden cluster kalitesini değerlendirebilirsin.
Business	Cluster profiling ile aksiyona dönük segmentler oluşturabilirsin.

1. Clustering nedir?

Clustering, etiketlenmiş target olmadan gözlemleri benzerliklerine göre gruplamaya çalışan unsupervised learning yaklaşımıdır. Amaç çoğu zaman doğal yapı keşfi, segmentasyon, veri özeti veya anomaly ön analizidir.

Problem	Clustering kullanımı
Müşteri segmentasyonu	Benzer davranıştaki müşterileri gruplamak
Ürün gruplama	Benzer ürünleri katalog yapısına ayırmak
Belge keşfi	Benzer metinleri topic benzeri gruplara ayırmak
Görüntü	Benzer görsel embeddinglerini gruplamak
Operasyon	Benzer mağaza/şube davranışlarını keşfetmek

Clustering = gerçek sınıf keşfi değildir
Bulunan kümeler veri temsiline ve algoritma varsayımlarına bağlıdır. “Doğal müşteri tipi” olarak otomatik yorumlanmamalıdır.

2. Clustering pipeline

1. Business amacı ve grain’i tanımla.
2. Feature setini seç ve leakage/future bilgi kontrolü yap.
3. Scaling ve gerekirse dönüşüm uygula.
4. Distance metric ve algoritmayı seç.
5. Hyperparameter/küme sayısını değerlendir.
6. Cluster stability ve kalite ölçümlerini kontrol et.
7. Cluster profiling yap.
8. Business aksiyonu ve zaman içi stabiliteyi test et.

En kritik bölüm
Cluster algoritmasından önce feature representation gelir. Yanlış feature ile mükemmel algoritma anlamsız segment üretir.

3. Similarity ve distance

Mesafe	Sezgi	Kullanım
Euclidean	Düz çizgi uzaklığı	K-Means için klasik
Manhattan	Mutlak fark toplamı	Bazı robust/sparse senaryolar
Cosine	Yön benzerliği	Text/embedding
Gower	Mixed numeric/categorical	Karma veri için seçenek

Scaling neden kritik?
Gelir 100,000 ölçeğinde, yaş 50 ölçeğinde ise Euclidean distance gelir feature'ı tarafından domine edilebilir.

4. Scaling

```
from sklearn.preprocessing import StandardScaler

X_scaled = StandardScaler().fit_transform(X)
```

Tree modellerden farklı
Clustering çoğunlukla distance temellidir; scaling genellikle çok önemlidir.

5. K-Means sezgisi

K-Means, k adet centroid seçer; her noktayı en yakın centroid'e atar; centroid'leri cluster ortalamalarıyla günceller ve yakınsayana kadar tekrarlar.

9. Başlangıç centroidlerini seç.
10. Her gözlemi en yakın centroid'e ata.
11. Her cluster için yeni centroid hesapla.
12. Assignment değişimi küçülene kadar tekrar et.

```
from sklearn.cluster import KMeans

model = KMeans(
    n_clusters=4,
    n_init='auto',
    random_state=42
)
labels = model.fit_predict(X_scaled)
```

6. K-Means objective: inertia

K-Means, noktaların kendi centroidlerine squared Euclidean distance toplamını minimize eder. Bu değere inertia veya within-cluster sum of squares denir.

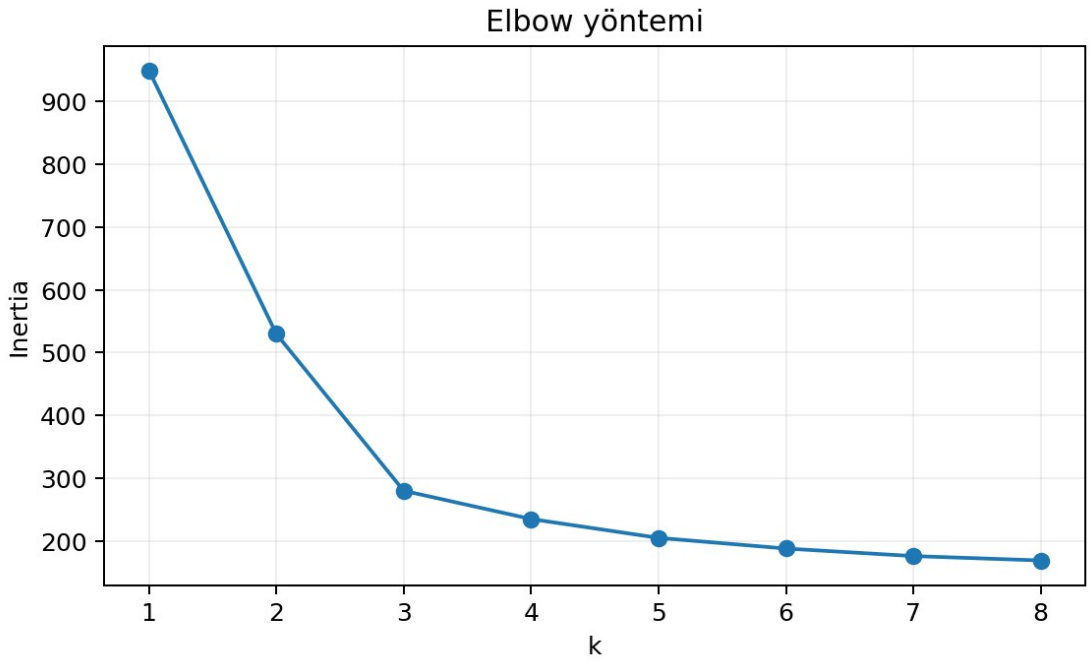
Sonuç
k arttıkça inertia doğal olarak düşer; bu yüzden tek başına minimum inertia ile k seçilmez.

7. K-Means varsayımları ve zayıflıkları

- Yaklaşık küresel/convex kümeleri sever.
- Benzer cluster büyüklüklerinde daha iyi davranır.
- Outlier centroid'i çekebilir.
- k önceden verilmelidir.
- Initialization sonucu etkileyebilir.

k-means++
Akıllı centroid initialization yaklaşımı kötü başlangıç riskini azaltır.

8. Elbow yöntemi



Inertia azalmasının belirgin biçimde yavaşladığı "dirsek" noktası aday k olabilir. Her veri setinde net elbow olmayabilir.

9. Silhouette Score

Silhouette, bir noktanın kendi cluster'ına yakınlığı ile en yakın diğer cluster'a uzaklığını karşılaştırır. Yaklaşık -1 ile 1 arasındadır; yüksek değer daha iyi ayrışma anlamına gelir.

```
from sklearn.metrics import silhouette_score

score = silhouette_score(X_scaled, labels)
print(score)
```

Tek metric değil
Silhouette yüksek olsa bile segmentler business olarak anlamsız olabilir. Profiling ve stability ile birlikte değerlendir.

10. Küme sayısı nasıl seçilir?

Sinyal	Rol
Elbow	Compactness değişimi
Silhouette	Separation + cohesion
Stability	Farklı sample/seed altında tutarlılık
Business usability	Segment sayısı operasyonel olarak kullanılabilir mi?
Domain knowledge	Anlamlı segment yapısı var mı?

Doğru cevap
"Silhouette en yüksek olan k" otomatik cevap değildir. Statistical kalite + business yorumlanabilirlik birlikte gerekir.

11. Cluster profiling

Cluster label üretmek işin yarısıdır. Asıl değer her kümenin hangi davranışlarla ayrıştığını özetlemektir.

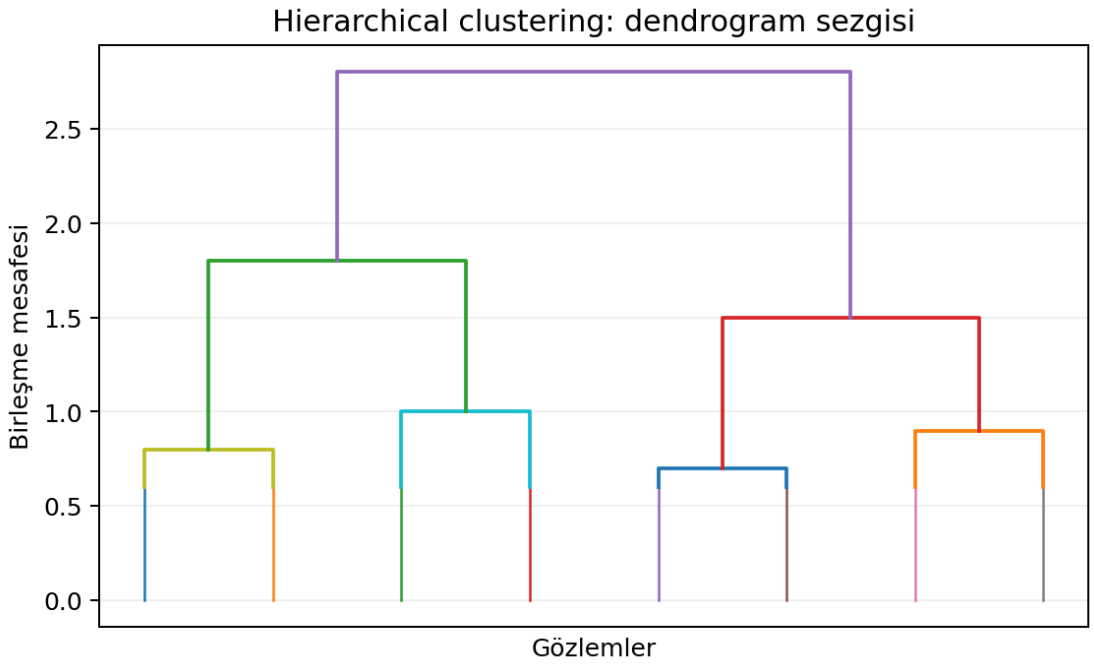
```
profile = (
    df.assign(cluster=labels)
      .groupby('cluster')
      .agg(
          customers=('customer_id','nunique'),
          avg_spend=('spend_90d','mean'),
          avg_orders=('orders_90d','mean'),
          avg_recency=('recency_days','mean')
      )
)
```

12. Segment isimlendirme

Kötü	Daha iyi
Cluster 0 = VIP	Önce profile ölç, sonra isim ver
Cluster 1 = churn riski	Target olmadan churn iddiası yapma
Cluster 2 = düşük değer	Spend + frequency + margin ile destekle

İsim sonradan gelir
Algoritma “VIP” keşfetmez; sen profil sonuçlarına göre business anlamı verirsin.

13. Hierarchical Clustering



Hierarchical clustering gözlemleri aşamalı olarak birleştirir (agglomerative) veya büyük kümeden bölerek ilerler (divisive). Sonuç dendrogram ile incelenebilir.

14. Linkage yöntemleri

Linkage	Mesafe tanımı	Davranış
Single	En yakın iki nokta	Chain effect olabilir
Complete	En uzak iki nokta	Daha compact kümeler
Average	Ortalama pair distance	Dengeli
Ward	Variance artışını minimize eder	Euclidean/compact kümeler

```
from sklearn.cluster import AgglomerativeClustering

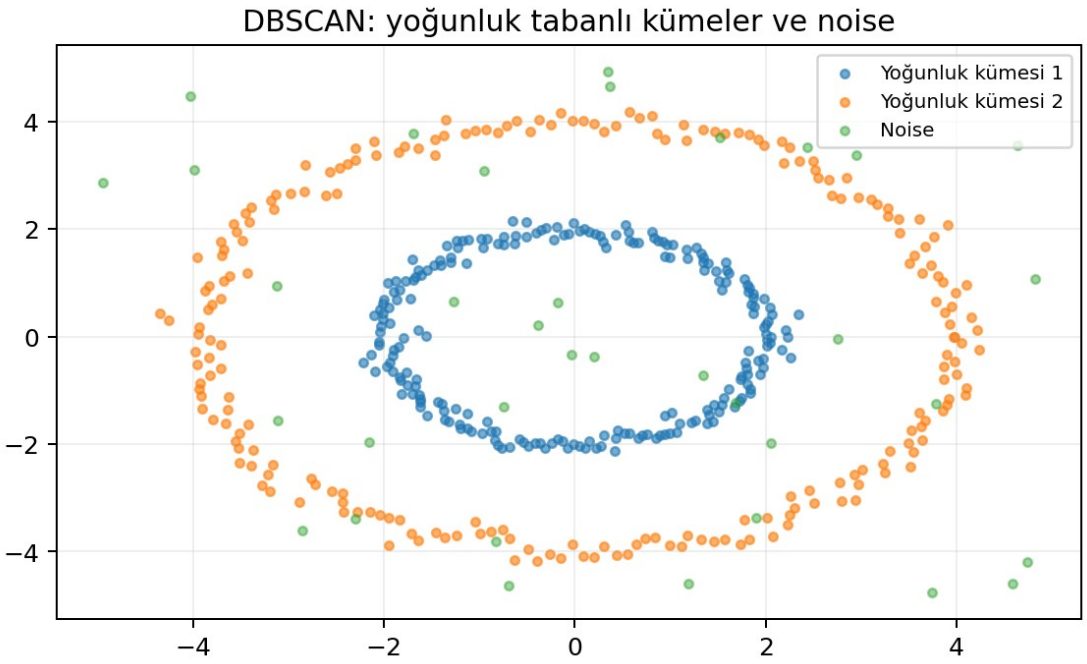
model = AgglomerativeClustering(
    n_clusters=4,
    linkage='ward'
)
labels = model.fit_predict(X_scaled)
```

15. Hierarchical ne zaman?

- Dataset çok büyük değilse.
- Cluster hiyerarşisini görmek istiyorsan.
- Dendrogram business keşfinde yararlıysa.
- Tek bir k yerine farklı seviyelerde segmentasyon düşünüyorsan.

Maliyet
Naive hierarchical yöntemler büyük n için pahalı olabilir.

16. DBSCAN



DBSCAN yoğunluk bölgelerini cluster olarak bulur ve düşük yoğunluklu noktaları noise olarak işaretleyebilir. k vermek gerekmez.

Parametre	Anlam
eps	Komşuluk yarıçapı
min_samples	Yoğun bölge sayılması için minimum komşu
metric	Mesafe ölçüsü

```
from sklearn.cluster import DBSCAN

labels = DBSCAN(
    eps=0.5,
    min_samples=8
).fit_predict(X_scaled)
```

17. DBSCAN güçlü/zayıf yanlar

Güçlü	Zayıf
Arbitrary shape clusters	eps seçimi zor olabilir
Noise/outlier label	Farklı density cluster'larda zorlanır
k gerektirmez	High dimension'da distance zayıflar
Outlier discovery yardımcı	Scaling çok önemli

18. eps seçimi

k-distance grafiği ile her noktanın k'inci komşu mesafesi sıralanır; kırılma bölgesi eps için aday olabilir.

Otomatik reçete değil
eps ve min_samples veri ölçeğine, boyutuna ve beklenen yoğunluğa bağlıdır.

19. High-dimensional clustering

Boyut arttıkça mesafeler birbirine yaklaşabilir ve curse of dimensionality clustering kalitesini bozabilir.

- Ölçekleme yap.
- Noise feature azalt.
- PCA gibi dimension reduction düşün.
- Embeddings için cosine metric değerlendirebilirsin.

PCA bağlantısı
Clustering öncesi PCA hem noise azaltabilir hem görselleştirme kolaylaştırabilir; ama component sayısını kör seçme.

20. PCA + Clustering

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from sklearn.cluster import KMeans

pipe = Pipeline([
    ('scale', StandardScaler()),
    ('pca', PCA(n_components=0.90)),
    ('cluster', KMeans(n_clusters=4, random_state=42))
])
```

Yorum
PCA sonrası cluster profiling'i mümkünse orijinal business feature'larda yap; component uzayındaki cluster tek başına iş anlamı taşımaz.

21. Categorical data clustering

K-Means ham kategorik veriye doğal olarak uygun değildir çünkü mean/Euclidean distance kategoriler için anlamlı değildir.

Veri	Seçenek
Mixed numeric + categorical	Gower distance + uygun clustering
Pure categorical	k-modes
Mixed	k-prototypes
High-cardinality categorical	Embedding veya domain representation

22. Cluster stability

Seed, sample veya küçük veri değişiminde cluster yapısı tamamen değişiyorsa segmentasyon güvenilmez olabilir.

- Farklı random seed ile tekrar çalıştır.
- Bootstrap/subsample üzerinde cluster tekrarlarını kontrol et.
- Adjusted Rand Index gibi label agreement ölçümleri kullan.

Production segment
Stabil olmayan cluster üzerine kampanya stratejisi kurmak risklidir.

23. Adjusted Rand Index (ARI)

İki farklı clustering assignment arasındaki benzerliği chance-adjusted biçimde ölçer. Aynı noktaları farklı cluster numaralarıyla adlandırmak sorun değildir.

```
from sklearn.metrics import adjusted_rand_score

ari = adjusted_rand_score(labels_run1, labels_run2)
```

24. Internal vs external evaluation

Tür	Örnek	Ne zaman?
Internal	Silhouette, Davies-Bouldin	Ground truth yok
External	ARI, NMI	Reference label varsa
Business	Campaign response, margin lift	Gerçek kullanım değeri

Unsupervised gerçekliği
Clustering için çoğu zaman tek “accuracy” yoktur.

25. Davies-Bouldin ve Calinski-Harabasz

Metric	Yorum
Davies-Bouldin	Düşük daha iyi; cluster similarity
Calinski-Harabasz	Yüksek daha iyi; between/within dispersion oranı

Metric agreement
Farklı internal metricler farklı k önerebilir. Business profiling ile birlikte kullan.

26. Outlier ve clustering

- K-Means outlier’a duyarlı olabilir.
- DBSCAN noise etiketi verebilir.
- Robust scaling veya outlier investigation gerekebilir.
- Outlier’ı otomatik silmek yerine nedenini incele.

27. Müşteri segmentasyonu - gerçek vaka

Bir e-ticaret şirketi müşterileri kampanya ve CRM stratejisi için davranışlarına göre segmentlemek istiyor.

Feature ailesi	Örnek
RFM	recency, frequency, monetary
Engagement	sessions_30d, categories_viewed
Discount	discount_share
Returns	return_rate
Margin	gross_margin_90d

13. Prediction/analysis snapshot tarihini belirle.
14. Son 90/180 günlük feature'ları üret.
15. Heavy-tail monetary feature'ları log/scale et.
16. K=2..10 için inertia, silhouette ve stability ölç.
17. Cluster profillerini orijinal ölçeklerde çıkar.
18. Segmentlere business isimleri ver.
19. A/B veya historical response ile segment değerini test et.

Örnek segmentler
"High-value loyal", "deal seekers", "new low-engagement", "at-risk high-value" gibi isimler ancak profiling sonuçlarından sonra verilmelidir.

28. Segmentleri business action'a bağlama

Profil	Aksiyon örneği
High value + low recency	VIP loyalty / cross-sell
High discount share	Promotion-sensitive offers
High returns	Return friction / quality investigation
Recent new customers	Onboarding
Falling engagement	Retention test

Causal uyarı
Bir cluster'a kampanya önerisi vermek kampanyanın etkili olduğunu kanıtlamaz; A/B test ile doğrula.

29. Clustering ve leakage

Clustering target kullanmasa bile future bilgi, post-event bilgi veya tüm dönem aggregate'leri yanlış segmentasyon yaratabilir.

Leakage	Örnek
Future activity	Snapshot sonrası satın alma
Post-churn info	Cancellation sonrası davranış
Full-lifetime aggregate	Historical snapshot için geleceği içerir

As-of mantığı
Segment feature'ları da belirli snapshot tarihinde yalnız geçmiş bilgiden hesaplanmalıdır.

30. Clustering production lifecycle

- Feature pipeline versiyonla.
- Scaler/PCA/clustering modelini serialize et.
- Yeni müşteriye cluster assignment stratejisi tanımla.
- Cluster size ve centroid/profile drift izle.
- Periyodik retraining kriteri belirle.
- Cluster meaning değişirse business isimlerini yeniden gözden geçir.

31. Yeni gözlemi cluster'a atamak

K-Means yeni gözleme predict sağlayabilir. Agglomerative clustering'ın klasik sklearn implementasyonu doğrudan yeni örneğe predict vermez; production tasarımında bu fark önemlidir.

Production seçimi
Offline keşif için hierarchical güçlü olabilir; sürekli yeni müşteri ataması gereken sistemde centroid/prototype tabanlı yöntem daha pratik olabilir.

32. Algorithm selection

Durum	Aday
Compact numeric clusters	K-Means
Hiyerarşi önemli	Agglomerative
Arbitrary shape + noise	DBSCAN
Çok büyük tabular	MiniBatchKMeans
Mixed categorical/numeric	k-prototypes/Gower tabanlı yaklaşım
Embedding clusters	Cosine + uygun clustering

33. MiniBatchKMeans

Büyük veri setlerinde her iterasyonda küçük mini-batch kullanarak K-Means'i daha ölçeklenebilir hale getirir.

```
from sklearn.cluster import MiniBatchKMeans

model = MiniBatchKMeans(
    n_clusters=8,
    batch_size=2048,
    random_state=42
)
labels = model.fit_predict(X_scaled)
```

34. Sık yapılan hatalar

- Scaling yapmadan K-Means çalıştırmak.
- k'yı sadece elbow ile seçmek.
- Cluster label numarasına anlam yüklemek.
- Clustering sonucunu gerçek sınıf gibi yorumlamak.
- Profiling'i standardized scale'de business sunumuna koymak.
- Outlier/noise etkisini incelememek.
- Feature selection/domain bilgisini ihmal etmek.
- Stability kontrol etmemek.
- PCA 2D görselini gerçek cluster doğruluğu sanmak.
- Cluster aksiyonlarını A/B test etmeden etkili kabul etmek.

35. sklearn evaluation şablonu

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans
from sklearn.metrics import (
    silhouette_score,
    davies_bouldin_score,
    calinski_harabasz_score
)

Xs = StandardScaler().fit_transform(X)
labels = KMeans(
    n_clusters=4,
    random_state=42
).fit_predict(Xs)

print('silhouette:', silhouette_score(Xs, labels))
print('db:', davies_bouldin_score(Xs, labels))
print('ch:', calinski_harabasz_score(Xs, labels))
```

36. Mülakat soruları

Soru	Kısa cevap
Clustering nedir?	Target olmadan benzer gözlemleri gruplama yaklaşımı.
K-Means neyi minimize eder?	Within-cluster squared Euclidean distance / inertia.
Scaling neden önemli?	Distance feature ölçeklerine duyarlıdır.
K nasıl seçilir?	Elbow, silhouette, stability ve business usability birlikte.
Silhouette ne ölçer?	Cohesion ile separation dengesini.
K-Means outlier'dan etkilenir mi?	Evet, centroid mean olduğu için.
DBSCAN avantajı?	Arbitrary shape cluster ve noise tespiti.
DBSCAN parametreleri?	eps ve min_samples.
Hierarchical clustering ne üretir?	Dendrogram/hiyerarşik birleşme yapısı.
Ward linkage nedir?	Birleşmede variance artışını minimize eder.
High-dimensional problem?	Distance concentration ve noise.
PCA neden önce kullanılabilir?	Noise/boyut azaltmak için.
Clustering accuracy var mı?	Ground truth yoksa klasik accuracy yok; internal/stability/business metric kullanılır.
Cluster profiling nedir?	Her kümenin feature ve business özetlerini çıkarmak.
Cluster label 0/1/2 anlamlı mı?	Hayır; keyfi ID'lerdir.

37. Uygulama alıştırmaları

20. Mall/customer benzeri dataset üzerinde StandardScaler + KMeans kur.
21. k=2..10 inertia ve silhouette grafikleri çiz.
22. Seed değiştirip cluster stability ölç.
23. PCA 2D projection üzerinde clusterları görselleştir.
24. Agglomerative clustering ile farklı linkage'leri karşılaştır.
25. DBSCAN eps/min_samples grid dene ve noise oranını raporla.
26. Customer RFM feature'larıyla cluster profile tablosu üret.
27. Cluster isimlerini business kriteriyle ver ve gerekçelendir.
28. MiniBatchKMeans ile büyük synthetic veri benchmark yap.
29. Bir cluster aksiyonunu A/B test hipotezine dönüştür.

38. Mini portföy projesi

Proje: E-Commerce Customer Segmentation - RFM + Behavioral Clustering

Çıktı	İçerik
01_problem.md	Segmentation amacı ve snapshot tarihi
02_features.sql	Point-in-time RFM ve davranış feature'ları
03_cluster_selection.ipynb	K, silhouette, stability
04_profiles.ipynb	Business profile ve isimlendirme
05_actions.md	Segment bazlı CRM hipotezleri
src/pipeline.py	Scale/PCA/KMeans pipeline
report.md	Segment sizes, profiles, risks, actions

CV cümlesi
Built an e-commerce customer segmentation system using point-in-time behavioral features, K-Means/DBSCAN benchmarks, silhouette and stability analysis, cluster profiling and CRM action hypotheses.

39. Final cheat sheet

Kavram	Hatırlanacak fikir
Clustering	Unsupervised grouping
Distance	Benzerliğin matematiksel temeli
Scaling	Distance tabanlı yöntemlerde kritik
K-Means	Centroid + inertia
Elbow	Inertia düşüş kırılması
Silhouette	Cohesion + separation
Hierarchical	Dendrogram ve linkage
DBSCAN	Density + noise
PCA	Boyut/noise azaltma
Stability	Seed/sample altında tutarlılık
Profiling	Business anlamı çıkar
ARI	Assignment agreement
MiniBatchKMeans	Büyük veri için ölçeklenebilir
Point-in-time	Future leakage engelle
Business action	Cluster değerini deneyle doğrula

Bu modülden sonra
Dimensionality Reduction bölümünde PCA, t-SNE ve UMAP'i clustering ve görselleştirme ile birlikte daha bilinçli kullanabileceksin.