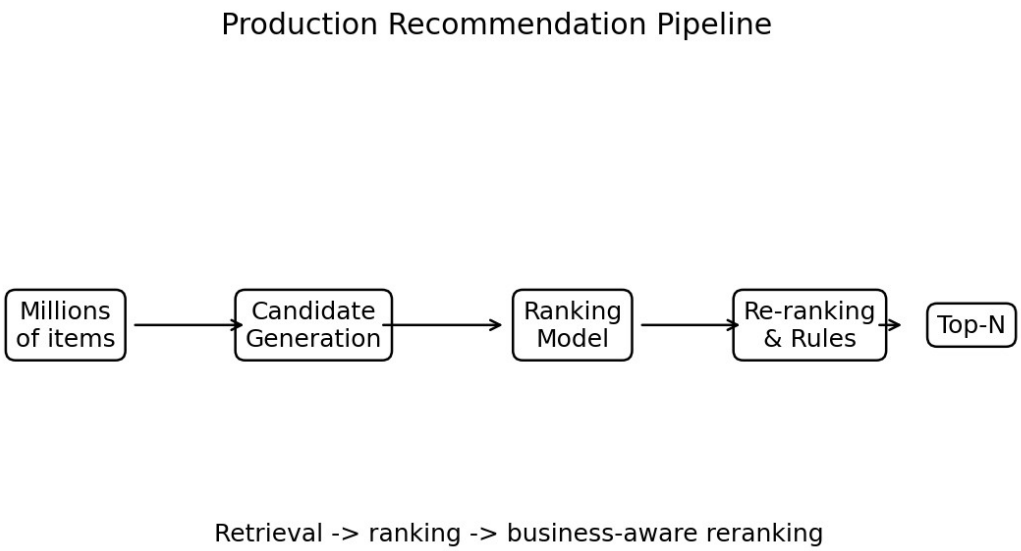
33. RECOMMENDATION SYSTEMS

Collaborative Filtering • Content-Based • Matrix Factorization • Ranking



Bu modülün amacı
Recommendation sistemlerinin sadece “benzer ürün gösterme” olmadığını; candidate generation, personalization, ranking, evaluation, cold-start ve production trade-off’larıyla uçtan uca bir karar sistemi olduğunu öğrenmek.

Kazanım	Modül sonunda
Problem framing	User-item-event yapısını ve implicit/explicit feedback farkını kurabilirsin.
Collaborative filtering	User-user, item-item ve latent-factor yaklaşımlarını açıklayabilirsin.
Content-based	Item/user özelliklerinden kişiselleştirilmiş benzerlik üretebilirsin.
Ranking	Candidate generation ile ranking aşamasını ayırabilirsin.
Evaluation	Precision@k, Recall@k, MAP/NDCG ve offline-online farkını kullanabilirsin.
Production	Cold start, diversity, novelty, popularity bias ve feedback loop risklerini yönetebilirsin.

1. Recommendation system nedir?

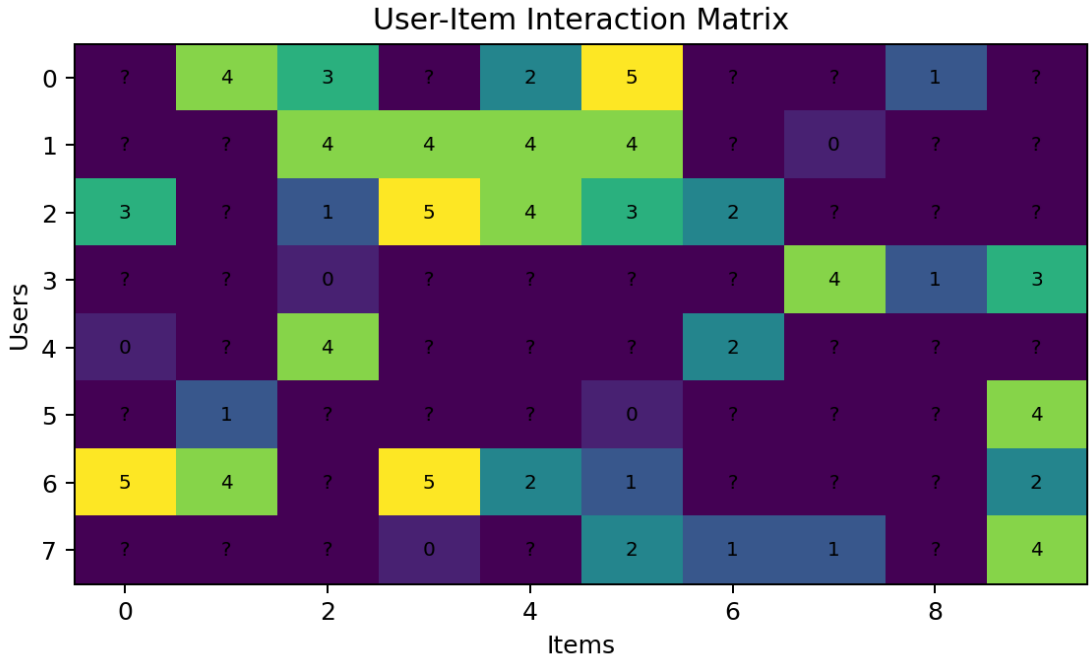
Kullanıcıya çok büyük bir seçenek uzayından en alakalı ürün, içerik, video, ilan, müzik veya aksiyonu sıralayıp sunan sistemdir. Çoğu gerçek sistem iki hedefi dengeler: kullanıcı faydası ve iş hedefi.

Önemli
Recommendation bir classification problemi olmak zorunda değildir. Çoğu zaman asıl çıktı, kullanıcı için sıralanmış top-N listedir.

2. Kullanım alanları

Alan	Öneri
E-commerce	Ürün, bundle, next-best-offer
Streaming	Film/dizi/video
Music	Şarkı/playlist
News	Makale feed
Ads	Ad/creative ranking
Jobs	İlan önerisi
Social	Post/account suggestion
B2B	Next-best-action / lead ranking

3. User-Item-Interaction yapısı



Recommendation verisinin temel grain'i çoğu zaman user-item interaction'dır: görüntüleme, tıklama, sepete ekleme, satın alma, rating, watch time vb.

Sütun	Örnek
user_id	u_204
item_id	p_918
event	purchase
timestamp	2026-10-01 20:10
value	1 veya rating/watch time
context	device, page, campaign

4. Explicit vs implicit feedback

Feedback	Örnek	Özellik
Explicit	1-5 rating, like/dislike	Kullanıcı açık tercih bildirir
Implicit	click, view, watch, purchase	Davranıştan tercih çıkarılır

Implicit feedback zorluğu
Bir ürüne tıklamamak “sevmiyor” anlamına gelmez; kullanıcı ürünü hiç görmemiş olabilir. Exposure bilgisi kritik olabilir.

5. Positive, negative ve unobserved

- Positive: click/purchase/long watch gibi gerçekleşen ilgi.
- Negative: explicit dislike veya skip gibi daha güvenilir olumsuz sinyal.
- Unobserved: kullanıcı-item çifti hiç gözlenmedi; gerçek negative değildir.

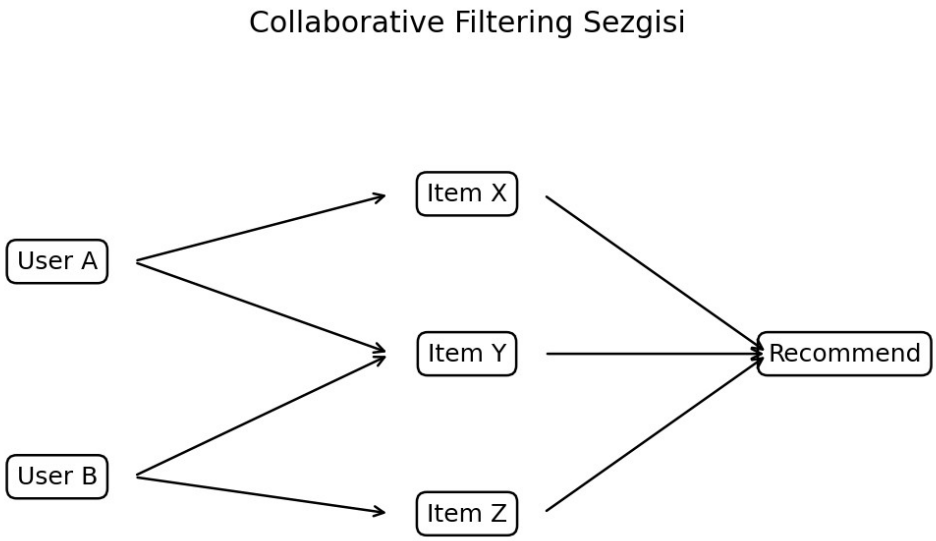
Negative sampling
Implicit recommender’larda milyonlarca unobserved çifti kullanmak yerine kontrollü negative sampling yaygındır.

6. Baseline önericiler

Baseline	Mantık
Global popularity	En popüler item’ları herkese göster
Recent popular	Son dönemin popülerleri
Category popular	Kullanıcının ilgilendiği kategoride popüler
Most recent	Yeni item’ları öne çıkar
Rule-based	Stok/fiyat/uygunluk kuralları

Baseline şart
Complex recommender’ın gerçekten değer kattığını ancak güçlü popularity/context baseline’a karşı ölçebilirsin.

7. Collaborative Filtering



Benzer kullanıcıların benzer item'ları tercih edeceği veya birlikte tüketilen item'ların birbirine benzeyeceği varsayımına dayanır.

8. User-User Collaborative Filtering

```
# fikirsel akış
1. user-user similarity hesapla
2. en yakın kullanıcıları bul
3. onların sevdiği ama hedef kullanıcının görmediği item'ları skorla
4. top-N öner
```

Sorun
Çok kullanıcı ve sparse interaction olduğunda user-user similarity pahalı ve unstable olabilir.

9. Item-Item Collaborative Filtering

Aynı kullanıcılar tarafından birlikte tüketilen item'lar benzer kabul edilir. E-commerce ve içerik önerilerinde güçlü ve explainable baseline'dır.

```
# bir item için benzer item'lar
score(item_a, item_b) = cosine(interactions_a, interactions_b)
```

Avantaj
Item katalogu çoğu sistemde user sayısından daha stabil olduğu için item-item benzerlik cache edilebilir.

10. Cosine / Jaccard benzerliği

Metric	Ne zaman?
Cosine	Weighted/rating/vector interactions
Jaccard	Binary set overlap
Pearson	Rating centering gereken explicit feedback
Dot product	Latent embeddings/ranking

11. Sparse matrix problemi

Gerçek kataloglarda interaction matrix'in çok büyük kısmı boştur. 1 milyon user x 100 bin item matrisini dense tutmak pratik değildir.

- Sparse matrix formatları kullanılır.
- Approximate retrieval gerekir.
- Matrix factorization latent representation üretir.

12. Matrix Factorization

User-item interaction matrix'i düşük boyutlu iki latent matrix ile yaklaşıklar: user embedding U ve item embedding V.

```
R ≈ U @ V.T
predicted_score(u, i) = dot(user_embedding[u], item_embedding[i])
```

Sezgi
Model "aksiyon", "romantik", "ucuz", "premium" gibi isim vermediğimiz latent preference eksenleri öğrenebilir.

13. SVD bağlantısı

Explicit rating problemlerinde düşük-rank approximation SVD sezgisiyle ilişkilidir. Ancak missing değerlerin "0" olmadığı recommender ortamında doğrudan klasik SVD her zaman uygun değildir.

14. Bias terimleri

```
rating_hat = global_mean
           + user_bias[u]
           + item_bias[i]
           + dot(U[u], V[i])
```

Neden?
Bazı kullanıcılar sürekli yüksek rating verir; bazı item'lar genel olarak daha popülerdir. Bias terimleri latent preference ile popularity'yi ayırmaya yardımcı olur.

15. Explicit feedback objective

Observed rating'lerde prediction error minimize edilir; regularization overfitting'i sınırlar.

```
loss = Σ_observed (r_ui - rhat_ui)^2
     + λ(||U||² + ||V||²)
```

16. Implicit feedback matrix factorization

Implicit sistemlerde interaction var/yok veya weighted confidence modellenir. ALS benzeri yaklaşımlar unobserved pair'leri düşük confidence negative olarak ele alabilir.

Confidence
Purchase, add-to-cart, long watch gibi sinyallere view'dan daha fazla ağırlık verilebilir.

17. Content-Based Recommendation

Item feature'larından representation üretip kullanıcının geçmişte sevdiği item'lara benzeyen içerikleri önerir.

Item feature	Örnek
Text	title, description, tags
Categorical	category, brand, genre
Numeric	price, duration, year
Multimodal	image/audio embedding
Metadata	creator, language, region

18. User profile oluşturma

```
user_profile = weighted_mean(
   embeddings_of_consumed_items
)

score = cosine(user_profile, item_embedding)
```

Weighting
Recent purchase > old view gibi event type ve recency weight eklenebilir.

19. TF-IDF tabanlı content recommender

```
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.metrics.pairwise import cosine_similarity

tfidf = TfidfVectorizer(ngram_range=(1, 2), min_df=3)
X = tfidf.fit_transform(items["text"])

sim = cosine_similarity(X[item_idx], X).ravel()
top_idx = sim.argsort()[::-1][1:11]
```

20. Embedding tabanlı content recommender

Modern sistemlerde title/description/image gibi içerikler embedding model ile dense vector'a çevrilip vector search ile candidate retrieval yapılabilir.

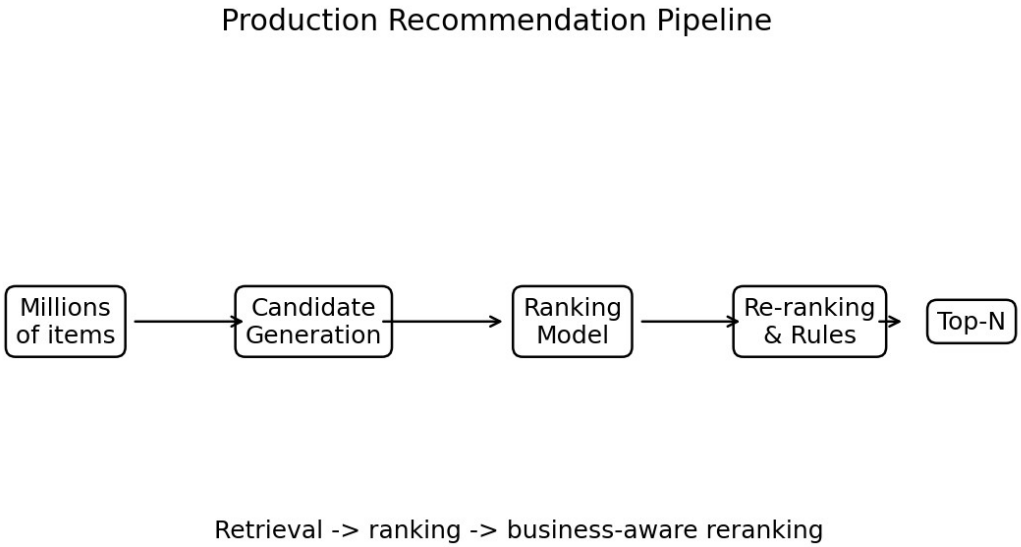
32. modül bağlantısı
Vector database bilgisi burada doğrudan recommendation candidate generation için kullanılabilir.

21. Hybrid recommender

Collaborative ve content sinyallerini birleştirerek her iki yaklaşımın zayıflıklarını azaltır.

Bileşen	Katkı
Collaborative	Crowd behavior
Content	Item semantics / cold item
Popularity	Robust fallback
Context	Time/device/page intent
Business rules	Stock, compliance, margin

22. Candidate generation vs Ranking



İki aşamalı mimari
Candidate generation milyonlarca item'dan yüzlerce aday getirir; ranking model bu adayları daha zengin feature'larla sıralar.

23. Candidate generation yöntemleri

Kaynak	Örnek
Collaborative	ALS / item-item
Content	Vector nearest neighbors
Popular	Trending / category popular
Recent history	Similar-to-last-item
Business	Sponsored / contractual candidates

24. Ranking feature’ları

Feature ailesi	Örnek
User	tenure, segment, activity
Item	price, popularity, freshness
User-item	similarity, affinity, prior views
Context	hour, device, surface
Cross	user_category_affinity x item_category
Business	margin, stock, delivery time

25. Pointwise ranking

Her user-item candidate için click/purchase probability tahmin edilir. Logistic regression, gradient boosting ve neural networks kullanılabilir.

```
P(click=1 | user, item, context)

rank_score = model.predict_proba(features)
```

26. Pairwise ranking

Amaç, pozitif item'ın negatif item'dan daha yüksek skor almasıdır.

```
score(u, positive_item) > score(u, negative_item)
```

BPR
Bayesian Personalized Ranking implicit feedback için klasik pairwise yöntemlerden biridir.

27. Listwise ranking

Tek tek veya çiftler yerine tüm ranked list'in kalitesini doğrudan optimize etmeye çalışır. Learning-to-rank ailesinin daha gelişmiş yaklaşımıdır.

28. Deep recommendation

- Two-tower networks: user encoder + item encoder.
- Wide & Deep: memorization + generalization.
- DeepFM / factorization-machine ailesi.
- Sequence recommenders: recent behavior sequence.
- Transformer tabanlı recommender'lar.

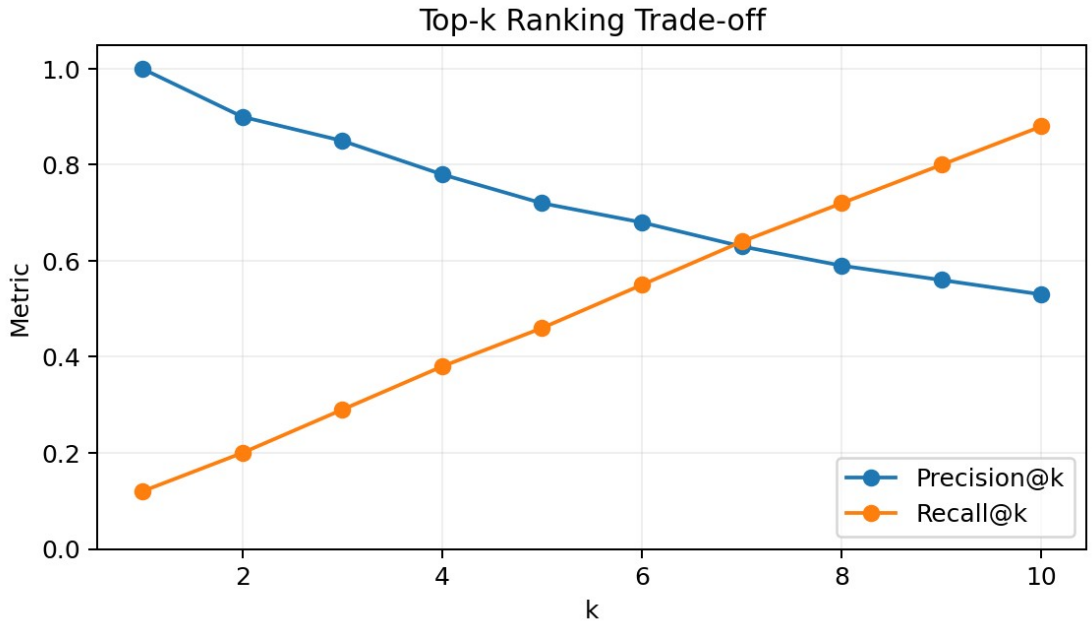
Two-tower
Candidate retrieval için user ve item embedding'lerini ayrı üretip ANN search yapmak production'da çok yaygındır.

29. Offline evaluation mantığı

Train geçmiş interaction'lardan öğrenir; validation/test gelecekte gerçekleşen interaction'ları temsil etmelidir. Random split çoğu recommender'da temporal leakage yaratabilir.

Temporal split
Kullanıcının gelecekteki davranışını geçmişe sızdırmamak için timestamp tabanlı evaluation sıklıkla tercih edilir.

30. Precision@k ve Recall@k




```
Precision@k = relevant_in_top_k / k
Recall@k    = relevant_in_top_k / all_relevant
```

31. Hit Rate@k

Kullanıcının gerçek ilgili item'larından en az biri top-k içinde mi? Özellikle leave-one-out evaluation'da yaygındır.

32. MAP / MRR / NDCG

Metric	Odak
MAP@k	Birden fazla relevant item için precision sırası
MRR	İlk relevant item'ın rank'i
NDCG@k	Relevant item'ların üst sıralarda olmasını ödüllendirir

Ranking metric
Recommendation'da yalnız "doğru item geldi mi?" değil, "ne kadar üstte geldi?" de önemlidir.

33. Coverage

Model katalogun ne kadarını gerçekten öneriyor? Sadece en popüler %1'i dönmek yüksek accuracy ama düşük coverage üretebilir.

34. Diversity

Top-N listesindeki item'ların birbirinden ne kadar farklı olduğunu ölçer. Kullanıcı deneyimini tekdüzelikten korur.

35. Novelty ve Serendipity

Kavram	Anlam
Novelty	Kullanıcının muhtemelen bilmediği item
Serendipity	Beklenmedik ama alakalı item

Trade-off
Sadece en benzer item'ı önermek relevance'i artırırken keşfi azaltabilir.

36. Offline vs Online metrics

Offline	Online
Recall@k	CTR
NDCG@k	Conversion rate
Coverage	Revenue per session
Diversity	Watch time / dwell time
Calibration	Retention / repeat usage

Altın kural
Offline metric iyileşmesi business KPI artışı garantisi değildir. Final doğrulama A/B test ile yapılır.

37. A/B testing recommender

- Primary KPI: CTR / conversion / watch time / revenue per session.
- Guardrail: latency, bounce, refund, complaint.
- Segment: new vs existing user, device, region.
- Novelty/long-term effects için experiment horizon yeterli olmalı.

38. User cold start

Yeni kullanıcı için interaction geçmişi yoktur.

Çözüm	Örnek
Onboarding	Kategori/genre seçimi
Context	Region/device/referrer
Popularity	Global/segment popular
Exploration	Çeşitli item gösterip hızlı sinyal toplama

39. Item cold start

Yeni item henüz interaction toplamadığı için collaborative yöntem görünmez hale getirebilir.

- Content embedding
- Metadata features
- Exploration budget
- Freshness boost

40. Popularity bias

Popüler item daha çok gösterilir -> daha çok interaction alır -> daha popüler hale gelir. Bu feedback loop uzun-tail item'ları baskılar.

Çözüm
Re-ranking, exploration, popularity normalization ve catalog coverage hedefleri kullanılabilir.

41. Feedback loops

Model yalnız önerdiği item'lardan feedback görür. "Görülmeyen" item'ın gerçek preference'i bilinmez. Bu selection bias ve exposure bias yaratır.

Counterfactual problem
Observed click verisi kullanıcı tercihi + ne gösterildi mekanizmasının birleşimidir.

42. Re-ranking

Ranking çıktısına business ve UX constraint'leri uygulayan final aşamadır.

Kural	Örnek
Diversity	Aynı markadan max 2 ürün
Freshness	Yeni item boost
Stock	Out-of-stock çıkar
Safety	Uygunsuz içerik çıkar
Business	Sponsored item limitli ekle
Fairness	Creator exposure kısıtları

43. MMR

Maximal Marginal Relevance, relevance ile çeşitliliği birlikte optimize eden klasik re-ranking fikridir.

```
MMR = λ * relevance
    - (1-λ) * similarity_to_selected
```

44. Calibration

Öneri listesinin kullanıcı geçmiş preference dağılımına benzemesi. Örneğin kullanıcı %70 drama, %30 comedy tüketiyorsa listenin tamamının drama olması aşırı concentration olabilir.

45. Business-aware objective

Click probability tek hedef olmak zorunda değildir. Revenue, margin, long-term retention ve complaint risk birlikte düşünülür.

```
score = p_click * expected_value
      - complaint_risk
      + exploration_bonus
```

Multi-objective
Gerçek recommender çoğu zaman tek metric değil çoklu hedef optimizasyonudur.

46. Session-based recommendation

Login/user history olmasa bile aynı session içindeki son tıklamalar intent sinyali verir.

- Last-click similarity
- Session co-visitation
- RNN/Transformer sequence encoder
- Short-term intent + long-term profile birleşimi

47. Sequential recommendation

Interaction sırasını kullanır. “Ne seviyor?” yanında “şu anda neye yöneliyor?” sorusunu da modellemeye çalışır.

Transformer bağlantısı
Sequence recommender’larda causal attention ile geçmiş item sequence’ından next-item prediction yapılabilir.

48. Context-aware recommendation

Context	Örnek
Time	weekday/hour/season
Device	mobile/TV/web
Location	region/store
Surface	home/search/cart
Campaign	organic/paid
Inventory	availability/delivery ETA

49. Negative sampling stratejileri

Negative	Özellik
Random	Kolay ve hızlı
Popular negatives	Daha zor
In-batch negatives	Deep models için efficient
Hard negatives	Modelin karıştırdığı item’lar
Exposure-aware	Gösterilip tıklanmayan item’lar

Hard-negative riski
Gerçekte relevant ama unobserved item’ı negative seçmek label noise yaratabilir.

50. Production architecture

Katman	Görev
Event pipeline	Click/view/purchase log
Feature store	User/item/context features
Candidate services	CF/content/popular
Ranking service	ML scoring
Re-ranker	Business rules/diversity
Serving cache	Low latency
Experimentation	A/B assignment
Monitoring	Quality/latency/drift

51. Batch vs real-time

Batch	Real-time
Nightly user embeddings	Session intent
Daily item similarity	Inventory
Long-term preference	Recent clicks
Cheap scalable	Fresh but more complex

Hybrid serving
Uzun dönem user profile batch hesaplanıp son session sinyali online eklenebilir.

52. Latency

Feed/search/ads benzeri ürünlerde recommendation bütçesi onlarca milisaniye olabilir. Candidate retrieval ve ranking bu latency sınırında çalışmalıdır.

- Precompute embeddings
- ANN index
- Feature cache
- Batch prediction / vectorized scoring
- Model compression

53. Monitoring

Kategori	Metric
System	p50/p95 latency, error rate
Data	event volume, missing rate
Model	score drift, embedding norm
Product	CTR, conversion, watch time
Catalog	coverage, long-tail exposure
Fairness	creator/category exposure

54. E-commerce vaka

Aşama	Çözüm
Candidate	item-item co-purchase + content ANN
Ranker	LightGBM user-item-context features
Re-rank	stock + diversity + margin
Offline	Recall@50, NDCG@10
Online	CTR, CVR, revenue/session
Cold start	category popular + content embedding

55. Streaming vaka

Sinyal	Örnek
Positive	long watch, completion
Negative	quick skip
User embedding	watch history sequence
Candidate	two-tower ANN
Rank	watch-time prediction
Re-rank	genre/creator diversity

56. News/feed vaka

Freshness çok hızlı bozulur. User preference yanında content age, topic trend ve exploration kritik olur.

Short half-life
Dün popüler olan haber bugün değersiz olabilir; time-decay feature ve online candidate refresh gerekir.

57. Basit implicit item-item Python

```
import pandas as pd
from scipy.sparse import csr_matrix
from sklearn.metrics.pairwise import cosine_similarity

mat = interactions.pivot_table(
    index="user_id",
    columns="item_id",
    values="event_weight",
    fill_value=0
)

item_sim = cosine_similarity(
    csr_matrix(mat.values).T
)
```

Portföy notu
Gerçek büyük dataset'te pivot_table dense memory yaratabilir; sparse construction ve ANN yaklaşımı tercih edilir.

58. Top-k evaluation kod mantığı

```
def precision_at_k(recommended, relevant, k):
    topk = recommended[:k]
    hits = len(set(topk) & set(relevant))
    return hits / k

def recall_at_k(recommended, relevant, k):
    topk = recommended[:k]
    hits = len(set(topk) & set(relevant))
    return hits / max(1, len(relevant))
```

59. Leakage ve split

Yanlış	Doğru
Future interaction user feature'a girmiş	Feature yalnız cutoff öncesi
Random split ile same session dağılmış	Temporal/session-aware split
Test item popularity training sonrası hesaplanmış	Training-window popularity
Negative sample future exposure'dan	Cutoff-aware sampling

60. Sık yapılan hatalar

- Popularity baseline kurmadan complex model geliştirmek.
- Random train-test split ile future leakage yaratmak.
- Unobserved interaction'ı kesin negative kabul etmek.
- Sadece RMSE ile ranking kalitesini ölçmek.
- Candidate recall ölçmeden ranker'ı suçlamak.
- Cold start planı yapmamak.
- Catalog coverage ve diversity'yi izlememek.
- Offline gain'i online gain sanmak.
- Exposure bias ve feedback loop'u yok saymak.
- Latency/serving maliyetini model tasarımından ayrı düşünmek.

61. Mülakat soruları

Soru	Kısa cevap
Collaborative filtering nedir?	Kullanıcı-item interaction örüntülerinden öneri üretir.
Content-based nedir?	Item/user feature similarity kullanır.
Explicit vs implicit?	Açık rating vs davranış sinyali.
Matrix factorization?	User/item latent embedding dot-product yaklaşımı.
ALS ne için?	Large sparse implicit/explicit factorization.
Cold start?	Yeni user/item history yokluğu.
Candidate vs ranking?	İlk aşama daraltır, ikinci aşama hassas sıralar.
Precision@k?	Top-k içindeki relevant oranı.
Recall@k?	Tüm relevant item'ların top-k içinde yakalanan oranı.
NDCG?	Relevant item'ın üst rank'te olmasını ödüllendirir.
Popularity bias?	Popüler item'ın sürekli daha çok exposure alması.
Negative sampling?	Unobserved pair'lerden training negatives seçme.
Two-tower?	User/item encoder'larını ayrı öğrenip ANN retrieval yapma.
Re-ranking?	Diversity/business/safety constraint uygulama.
Offline-online farkı?	Ranking metric gain A/B business KPI gain'i garanti etmez.

62. Uygulama alıştırmaları

1. Popularity ve category-popularity baseline kur.
2. Item-item cosine recommender geliştir.
3. User profile + TF-IDF content recommender yap.
4. Temporal leave-last-one-out evaluation kur.
5. Precision@k, Recall@k, HitRate@k ve NDCG@k fonksiyonlarını yaz.
6. Cold-start user için fallback stratejisi tasarla.
7. Popularity bias ve coverage raporu çıkar.
8. Collaborative + content hybrid score oluştur.
9. MMR ile diversity-aware re-ranking uygula.
10. Candidate recall ve ranker NDCG'yi ayrı ölç.

63. Mini portföy projesi

Proje: End-to-End E-Commerce Recommendation System

Dosya	İçerik
01_eda.ipynb	Interaction sparsity, popularity, repeat behavior
02_baselines.ipynb	Popular/category popular
03_cf.ipynb	Item-item collaborative filtering
04_content.ipynb	Text/embedding content recommender
05_hybrid.ipynb	Hybrid candidates + rank score
06_eval.ipynb	Temporal Recall/NDCG/Coverage
src/retrieve.py	Candidate generation
src/rank.py	Ranking/re-ranking
api.py	Top-N recommendation endpoint
README.md	Architecture, metrics, trade-offs

CV cümlesi

Built a hybrid e-commerce recommendation system combining collaborative and content-based candidate generation with temporal top-k evaluation, diversity-aware re-ranking and cold-start fallbacks.

64. Final cheat sheet

Kavram	Hatırlanacak fikir
Implicit feedback	Davranış sinyali
Collaborative filtering	Crowd pattern
Item-item	Birlikte tüketim benzerliği
Matrix factorization	Latent user/item vectors
Content-based	Metadata/embedding similarity
Hybrid	CF + content + context
Candidate generation	Milyonlardan yüzlere
Ranking	Candidate'ları hassas sırala
Precision@k	Top-k temizliği
Recall@k	Relevant coverage
NDCG@k	Rank position quality
Cold start	History yokluğu
Popularity bias	Feedback loop
Negative sampling	Unobserved subset
Re-ranking	Diversity/business constraints
Two-tower	ANN retrieval architecture
A/B test	Gerçek product KPI doğrulaması

Bu modülden sonra

34. Data Engineering Temelleri bölümünde recommendation ve ML sistemlerinin beslendiği ETL/ELT, batch/streaming ve warehouse/lake altyapısına geçeceksin.