36. CLOUD

AWS • Azure • GCP • Storage • Compute • Database • IAM • ML Services

Veri bilimi için tipik cloud mimarisi



IAM • Network • Secrets • Monitoring • Cost

Bu modülün amacı
Bir veri bilimcinin cloud ortamında veri depolama, compute, database, networking, IAM, secrets, deployment, managed ML ve maliyet kararlarını anlayabilmesini sağlamak. Hedef tek bir sağlayıcının ürün isimlerini ezberlemek değil; AWS, Azure ve GCP servislerini ortak mimari kavramlar üzerinden okuyabilmektir.

Kazanım	Modül sonunda
Cloud mental model	IaaS/PaaS/SaaS ve shared responsibility modelini açıklayabilirsin.
Storage & compute	Object storage, VM, container ve serverless seçeneklerini ayırabilirsin.
Data platform	Warehouse, managed Spark ve managed database seçeneklerini konumlandırabilirsin.
Security	IAM, network segmentation, secrets ve encryption temelini anlayabilirsin.
ML	Managed training, model registry, batch/online inference mimarilerini tasarlayabilirsin.
Cost	Compute/storage/network maliyetlerini ölçme ve optimize etme mantığını kurabilirsin.

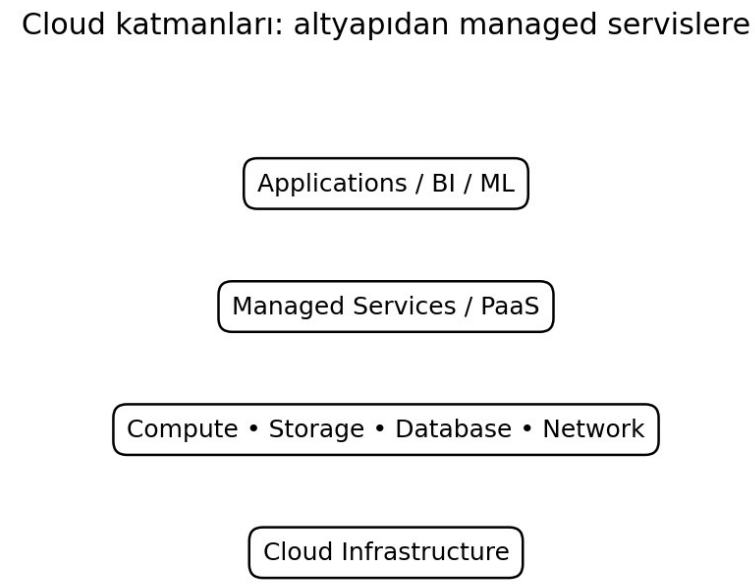
1. Cloud nedir?

Cloud computing; compute, storage, database, networking ve managed platform servislerinin talep üzerine, programatik ve ölçülebilir şekilde kullanılmasını sağlar.

On-premise	Cloud
Sunucu satın al	Kaynağı dakikalar içinde oluştur
Kapasiteyi yıllık planla	İhtiyaca göre ölçekle
Donanımı kendin yönet	Managed servis kullan
CapEx ağırlıklı	Usage-based OpEx

Cloud = sihir değil
Aynı temel bilgisayar bilimleri geçerlidir; fark kaynakların API ile programatik ve elastik yönetilebilmesidir.

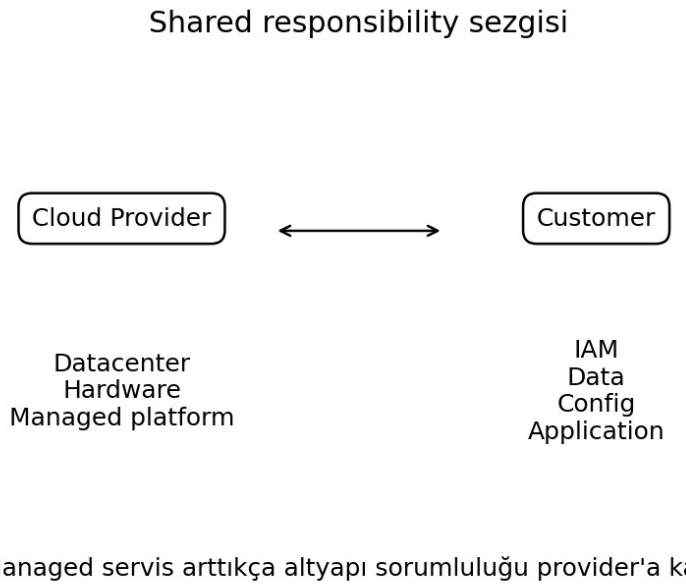
2. IaaS, PaaS, SaaS



Model	Sen yönetirsin	Provider yönetir
IaaS	OS, app, runtime	Hardware, datacenter
PaaS	App/data/config	Runtime + infrastructure
SaaS	Kullanım/konfigürasyon	Uygulamanın çoğu

Veri bilimci için
Managed servis arttıkça operational yük azalır; bunun karşılığında daha az low-level kontrol ve bazen daha yüksek birim maliyet olabilir.

3. Shared responsibility



- Provider fiziksel altyapı güvenliğinden sorumludur.
- Kullanıcı IAM, data access, application config ve secrets'tan sorumludur.
- Managed servis türüne göre sınır değişir.

En sık hata
Cloud'a taşımak güvenliği otomatik çözmez; yanlış IAM veya public bucket hâlâ kullanıcı hatasıdır.

4. Region ve Availability Zone

Kavram	Anlam
Region	Coğrafi cloud bölgesi
Availability Zone	Region içindeki izole failure domain
Edge	Kullanıcıya yakın dağıtım noktaları

Neden önemli?
Latency, data residency, disaster recovery ve servis availability'si region/AZ seçimine bağlıdır.

5. AWS - Azure - GCP ortak mental model

İhtiyaç	AWS sınıfı	Azure sınıfı	GCP sınıfı
Object storage	S3	Blob Storage	Cloud Storage
VM	EC2	Virtual Machines	Compute Engine
Managed containers	ECS/EKS	Container Apps/AKS	Cloud Run/GKE
Warehouse	Redshift	Synapse/Fabric	BigQuery
Managed Spark	EMR/Glue	Databricks/Synapse Spark	Dataproc
Managed ML	SageMaker	Azure ML	Vertex AI

Ezberleme yöntemi
Önce kategori öğren: object storage, VM, container, warehouse, Spark, ML platform. Ürün ismi sonradan gelir.

6. Object storage

Cloud data platformlarının temel storage katmanıdır. Dosya/object bazlı, çok ölçeklenebilir ve genellikle ucuzdur.

- Parquet/CSV/JSON
- Model artifacts
- Images/audio
- Backups
- Raw data lake

Veri bilimci açısından
Training datası ve model artifact'ları çoğu modern mimaride object storage üzerinde tutulur.

7. Bucket / container yapısı

```
s3://company-data/
  raw/orders/date=2026-10-10/
  silver/orders/date=2026-10-10/
  gold/customer_features/date=2026-10-10/
  models/churn/v12/
```

Path = API değildir
Bucket path naming convention veri keşfi, lifecycle ve partition pruning davranışını etkileyebilir.

8. Storage class ve lifecycle

Katman	Kullanım
Hot	Sık erişim
Cool / infrequent	Daha az erişim
Archive	Uzun süre saklama

Lifecycle rule
90 günlük eski raw dosyaları daha ucuz storage class'a otomatik taşımak maliyet optimizasyonudur.

9. Compute: Virtual Machine

VM, CPU/RAM/GPU gibi kaynakların sanal makine olarak tahsis edilmesidir.

Artı	Eksi
Tam kontrol	OS patch/ops yükü

Her yazılımı çalıştır	Idle iken de maliyet
GPU instance seçenekleri	Scaling'i yönetmek gerekir

Ne zaman?
Özel runtime, uzun-running service, custom GPU environment veya low-level kontrol gerektiğinde.

10. Autoscaling

Traffic veya workload'a göre instance/container sayısının otomatik artıp azalmasıdır.

- CPU
- Queue depth
- Request count
- Custom metric

ML serving
Online inference API p95 latency ve request rate'e göre autoscale edilebilir.

11. Spot / preemptible compute

Daha ucuz ama provider tarafından kesilebilen compute capacity.

İyi kullanım
Fault-tolerant batch training, hyperparameter search ve distributed ETL. Kesilmeye dayanıklı checkpoint tasarımı gerekir.

12. Containers

Application + dependencies'i portable image olarak paketler.

VM	Container
Tam OS abstraction	Host kernel paylaşır
Daha ağır	Daha hafif
Boot yavaş	Startup daha hızlı
Ops kontrolü yüksek	Deployment portability yüksek

40. modül bağlantısı
Docker bölümünde container image ve Dockerfile ayrıntılı işlenecek; cloud bu image'ın nerede çalışacağını belirler.

13. Managed container platformları

- Kubernetes
- Serverless containers

- Managed container services

Seçim
Kubernetes yüksek esneklik ve operasyonel karmaşıklık; serverless container daha düşük operasyon ve daha az kontrol.

14. Serverless

Sunucu/cluster yönetmeden fonksiyon veya container tabanlı compute çalıştırma yaklaşımı.

Avantaj	Risk
Scale-to-zero	Cold start
Usage-based cost	Execution/runtime limitleri
Ops düşük	Platform bağımlılığı
Event-driven kolay	Debugging dağıtık olabilir

Batch inference
Kısa süreli event-triggered preprocessing veya küçük API'lerde serverless güçlü olabilir.

15. Database türleri

Tür	Use case
Relational OLTP	Transactions, app state
Analytical warehouse	BI/large scans
Key-value	Low-latency lookup
Document	Flexible JSON
Time-series	Metrics/events
Vector DB	Embedding retrieval

16. Managed relational database

Provider backup, patching, failover ve maintenance'in önemli kısmını yönetir.

Production avantajı
Self-managed database'e göre operational yük ciddi azalır; yine schema, indexes ve query design kullanıcı sorumluluğundadır.

17. Data Warehouse

Cloud warehouse büyük analitik query ve aggregation için optimize edilir.

- Columnar storage
- Massively parallel processing
- Compute-storage separation
- SQL

BI ve DS
Feature extraction, experiment analysis ve KPI mart'ları warehouse üzerinde sık çalışır.

18. BigQuery / Snowflake / Redshift sınıfı düşünce

Ürün isimlerinden bağımsız temel soru: compute nasıl ölçekleniyor, storage ayrı mı, concurrency nasıl, query başına maliyet ne?

Veri bilimci için
SELECT * alışkanlığı cloud warehouse'da doğrudan maliyete dönüşebilir.

19. Managed Spark

Spark cluster oluşturma, autoscaling, runtime ve integration'ların provider tarafından kısmen yönetildiği hizmetler.

Yaklaşım	Artı
Managed Spark	Cluster ops azalır
Serverless Spark	Cluster yönetimi daha da azalır
Databricks tipi platform	Notebook + jobs + lakehouse + ML entegrasyonu

35. modül bağlantısı
Spark syntax aynı kalır; cloud katmanı compute provisioning, storage ve IAM entegrasyonunu değiştirir.

20. Networking temelleri

Kavram	Anlam
VPC/VNet	İzole virtual network
Subnet	Network segment
Route	Traffic yönlendirme
Security group/firewall	Inbound/outbound rules
Private endpoint	Public internet olmadan managed service erişimi
Load balancer	Traffic dağıtımı

ML security
Model API'yi public açmak zorunda değilsin; internal VPC/private endpoint içinde çalışabilir.

21. Public vs Private subnet

Internet'e doğrudan route'u olan network segmentleri public; yalnız internal erişim kullanan segmentler private tasarlanabilir.

Default yaklaşım
Database, feature store ve internal model servisleri mümkün olduğunca private network içinde tutulur.

22. DNS ve load balancing

Domain adını doğru service endpoint'e çözer; load balancer request'leri sağlıklı instance'lara dağıtır.

- Health checks
- TLS termination
- Path-based routing
- Blue/green deployment

Online ML
Yeni model versiyonunu %5 traffic ile canary test etmek load balancer/service mesh katmanıyla uygulanabilir.

23. IAM

Identity and Access Management, kimin hangi kaynağa hangi aksiyonu yapabileceğini belirler.

Parça	Örnek
Identity	User/service account/role
Resource	Bucket/database/model endpoint
Action	Read/write/invoke
Policy	Allow/deny kuralları

Least privilege
Training job sadece ihtiyaç duyduğu bucket'ı okumalı; tüm hesaba admin yetkisi verilmemeli.

24. Service accounts / roles

Application'ların insan kullanıcı parolası yerine machine identity ile cloud kaynaklarına erişmesini sağlar.

Ana kural
Access key'i kod içine gömmek yerine workload identity/role kullan.

25. Secrets management

- Database password
- API key
- Signing secret
- Third-party token

Yapma
.env dosyasını GitHub'a commit etmek veya secret'ı container image içine yazmak güvenlik açığıdır.

26. Encryption

Durum	Koruma
At rest	Disk/object/database encryption
In transit	TLS
Key management	Managed KMS/HSM

Encryption yetmez
Yanlış IAM ile yetkili kullanıcı encrypted data'yı yine okuyabilir. Access control ayrı katmandır.

27. Logging ve audit

Kim hangi cloud kaynağında hangi işlemi yaptı sorusunun cevabı audit logs'tadır.

- IAM change
- Bucket access
- Model endpoint update
- Network config

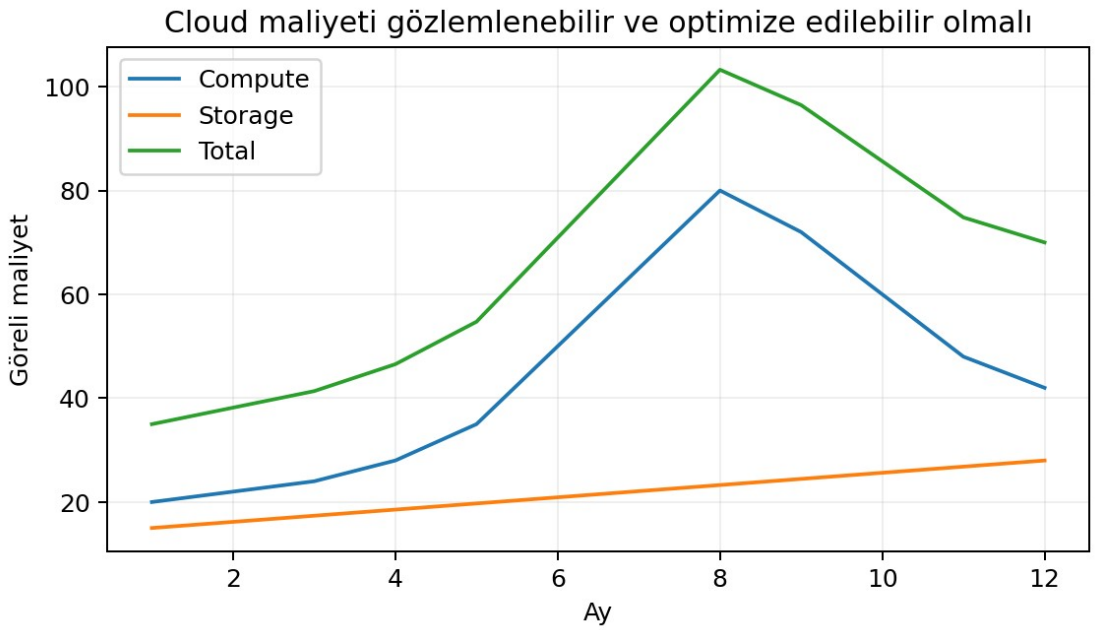
Incident response
Audit log olmadan güvenlik olayının kök nedenini bulmak zordur.

28. Monitoring ve observability

Sinyal	Örnek
Metrics	CPU, GPU, memory, latency
Logs	Application errors
Traces	Distributed request path
Alerts	p95 latency > SLA
Dashboards	Service health

MLOps bağlantısı
Model accuracy yanında service health ve infrastructure metricleri de izlenir.

29. Cost model



Maliyet	Örnek
Compute	CPU/GPU runtime
Storage	GB-month
Database	Capacity/queries
Network egress	Region dışına trafik
Requests	Serverless/API calls

FinOps
Cloud maliyeti mimari kararların teknik metriğidir; sonradan muhasebe işi olarak düşünülmemelidir.

30. Cost optimization

- Idle compute kapat.
- Autoscaling kullan.
- Spot/preemptible batch workload.
- Lifecycle policies.
- Column pruning / partition pruning.
- Right-size instance.
- GPU utilization ölç.

En ucuz servis
Kullanılmayan kaynaktır. Otomatik shutdown dev/test ortamlarında büyük kazanç sağlar.

31. Tags / labels

Cloud resource'lara team, environment, project, owner gibi metadata eklemek maliyet ve governance takibini kolaylaştırır.

Cost attribution
ML ekibinin GPU maliyetini hangi projelerin oluşturduğunu tags/labels ile takip edebilirsin.

32. Infrastructure as Code

Cloud kaynaklarını elle console'dan değil deklaratif kodla tanımlama yaklaşımıdır.

```
# pseudo Terraform
resource "object_storage_bucket" "ml_data" {
  name = "company-ml-data"
  versioning = true
}
```

Neden?
Review edilebilir, tekrar üretilebilir ve environment'lar arasında tutarlı altyapı.

33. Terraform mental model

- Desired state
- Plan
- Apply
- State

Veri bilimci ne kadar bilmeli?
Tam DevOps uzmanlığı gerekmez; resource, variable, output ve plan/apply akışını okuyabilmek güçlü avantajdır.

34. Cloud CLI ve SDK

Console dışında CLI veya Python SDK ile kaynakları otomatik yönetebilirsin.

```
# pseudo Python SDK pattern
client = cloud.storage.Client()
bucket = client.bucket("ml-data")
bucket.upload("model.pkl")
```

Automation
Pipeline'lar GUI click'leriyle değil API/SDK/IaC ile reproducible olur.

35. Managed ML platformları

Yetkinlik	Managed platform
Notebook/workbench	Managed dev environment
Training jobs	CPU/GPU distributed training
HPO	Managed tuning
Model registry	Versioned model artifacts
Endpoints	Online serving
Pipelines	Orchestration

SageMaker/Azure ML/Vertex AI
Üçü de benzer problem kategorilerini çözer; detaylı ürün menüleri değişebilir.

36. Managed training job

Training script + container + data location + compute spec gönderilir; platform ephemeral compute üzerinde işi çalıştırır.

- Logs
- Metrics
- Artifacts
- Spot training
- Distributed training

Avantaj
Notebook instance'ın açık kalmasına gerek yok; job reproducible config ile başlatılır.

37. GPU seçimi

Kriter	Soru
VRAM	Model/batch sığıyor mu?
Throughput	Training ne kadar sürüyor?
Precision	FP16/BF16 destekli mi?
Cost	Saatlik fiyat vs toplam süre
Availability	Region quota var mı?

En pahalı GPU = en ucuz training değil
Daha hızlı GPU toplam training süresini ciddi kısaltıyorsa toplam maliyet daha düşük olabilir.

38. Hyperparameter tuning in cloud

Her trial bağımsız compute job olarak paralel çalıştırılabilir.

Spot fırsatı
Fault-tolerant HPO workload spot/preemptible compute için ideal adaydır.

39. Model Registry

Model artifact, metrics, dataset lineage, stage ve approval bilgisini versioned olarak tutar.

Metadata	Örnek
Version	churn:v17
Metric	PR-AUC 0.42
Data	snapshot_2026_10_01
Status	staging/approved/prod
Artifact	model.tar.gz

40. Batch inference

Büyük dataset periyodik olarak modelden geçirilir ve sonuç tablo/object storage'a yazılır.

Use case
Her gece 10 milyon müşteri için churn score üretmek.

41. Online inference

Request geldiğinde düşük latency ile prediction döndüren persistent endpoint.

Metric	Online serving
Latency	p50/p95/p99
Throughput	RPS
Availability	Uptime
Cost	Per request/hour
Scaling	Replica count

42. Serverless inference

Düşük/seyrek traffic için scale-to-zero veya request-driven model serving yaklaşımı.

Trade-off
Cold start veya model load süresi büyük modellerde problem olabilir.

43. Async inference

Request hemen cevaplanmak zorunda değilse queue/object-based asenkron scoring kullanılabilir.

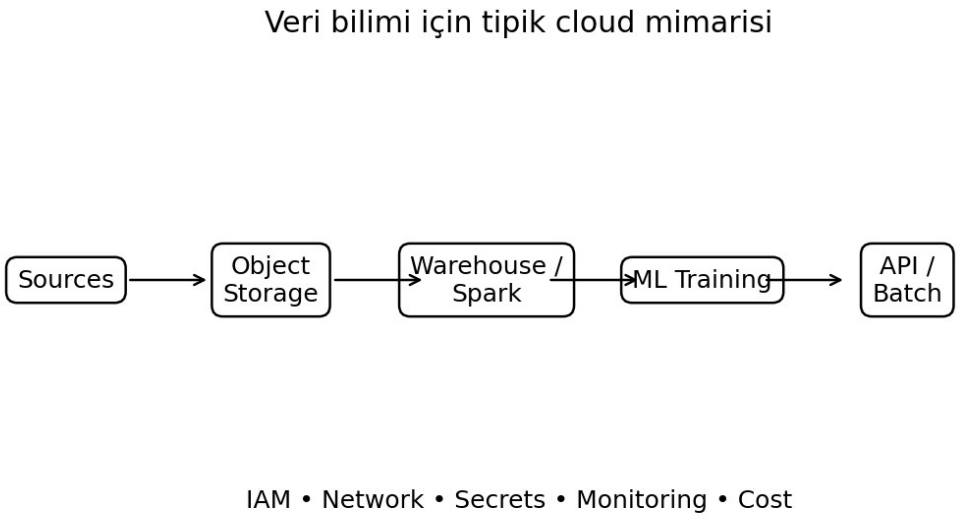
Use case
Video/image/document inference gibi saniyeler-dakikalar süren işler.

44. Feature storage in cloud

İhtiyaç	Cloud karşılığı
Offline features	Warehouse/lake
Online features	Low-latency KV/feature store
Registry	Managed metadata
Materialization	Batch/stream pipelines

Point-in-time correctness
Cloud platform değişse de training-serving consistency ve historical correctness kuralları değişmez.

45. End-to-end ML architecture



Katman	Bileşen
Ingest	Batch/stream data
Storage	Object storage / warehouse
Transform	SQL/Spark
Train	Managed CPU/GPU job
Registry	Versioned model
Serve	Batch/online endpoint
Monitor	Infra + model metrics

46. Real-time fraud architecture

- Transaction event stream
- Streaming feature computation
- Online feature store
- Low-latency model endpoint -> alert/action service

Cloud kritik noktası
Network hop sayısı, feature lookup ve endpoint latency toplam karar süresini belirler.

47. E-commerce churn architecture

Aşama	Cloud pattern
Raw data	Object storage
Customer mart	Warehouse/Spark
Training	Scheduled managed job
Registry	Best model
Scoring	Daily batch
Activation	CRM table/API

48. NLP / LLM cloud architecture

- Documents -> object storage
- Chunk/embedding jobs
- Vector database
- LLM endpoint / API
- RAG service
- Evaluation + logs

Cost driver
LLM inference token cost + vector retrieval + hosting + egress birlikte değerlendirilir.

49. Multi-cloud ve vendor lock-in

Aynı workload'u birden fazla cloud'da çalıştırmak bazı kurumlarda stratejik olabilir; ancak operational complexity yükselir.

Artı	Eksi
Risk dağıtımı	İki platform öğrenme
Regulatory seçenek	Data movement complexity
Vendor negotiation	Duplicate tooling

Pratik
Erken aşamada sırf teorik taşınabilirlik için multi-cloud çoğu takımda gereksiz karmaşıklık yaratır.

50. Disaster Recovery

- Backup
- Cross-region replication
- RPO / RTO

RPO vs RTO
RPO ne kadar veri kaybı kabul edilebilir; RTO hizmet ne kadar sürede ayağa kalkmalı?

51. Data residency

Bazı verilerin belirli ülke/region sınırları içinde tutulması gerekebilir.

Mimariye etkisi
Region seçimi sadece latency değil hukuki/governance gereksinimidir.

52. Cloud security checklist

- Public bucket var mı?
- Admin yetkisi gereksiz verilmiş mi?
- Secrets kod/repo içinde mi?
- Encryption at rest/in transit açık mı?
- Database public internet'e açık mı?
- Audit logs aktif mi?
- Unused access keys var mı?
- Backup/restore test edildi mi?

53. Cloud cost checklist

- Idle VM/GPU var mı?
- Dev kaynakları gece kapanıyor mu?
- Storage lifecycle policy var mı?
- Cross-region egress gerekiyor mu?
- Warehouse query'leri partition pruning kullanıyor mu?
- Oversized instance var mı?
- Autoscaling doğru metric'e bağlı mı?
- Spot workload kullanılabilir mi?
- Tag/label ile owner ve project belli mi?

54. Sık yapılan hatalar

- Console üzerinden elle kaynak oluşturup kaydetmemek.
- Admin rolünü tüm servis hesaplarına vermek.
- Public endpoint'i default kabul etmek.
- GPU'yu idle bırakmak.
- Region/egress maliyetini görmezden gelmek.
- Managed servisleri sırf popüler diye kullanmak.
- Monitoring ve budget alert kurmamak.

- Model artifact ve data version'ını kaydetmemek.
- Production ve dev environment'ı ayırmamak.
- Provider ürün adlarını bilip temel mimariyi anlamamak.

55. Mülakat soruları

Soru	Kısa cevap
IaaS vs PaaS?	IaaS altyapı kontrolü yüksek; PaaS runtime/ops'un daha fazlasını provider yönetir.
Object storage ne için?	Data lake, artifacts ve büyük dosya storage.
VM vs serverless?	Kontrol ve long-running workload vs event-driven low-ops compute.
Region/AZ farkı?	Coğrafi bölge vs region içi izole failure domain.
IAM nedir?	Identity-resource-action permission sistemi.
Least privilege?	Yalnız gereken minimum yetki.
Private endpoint?	Managed servise public internet olmadan erişim.
Warehouse vs OLTP DB?	Analytics scan/aggregate vs transactional workload.
Managed Spark?	Cluster/runtime/ops'un provider tarafından yönetildiği Spark.
Spot compute?	Ucuz ama kesilebilir kapasite.
Model registry?	Versioned model artifact + metadata + stage.
Batch vs online inference?	Periyodik toplu scoring vs request-time prediction.
RPO/RTO?	Kabul edilen veri kaybı / recovery süresi.
IaC?	Cloud resources'ı kodla tanımlama.
Cloud cost ana kalemleri?	Compute, storage, database, network, requests.

56. Uygulama alıştırmaları

- AWS/Azure/GCP için object storage, VM, warehouse ve ML servislerini eşleştir.
- Bir churn batch-scoring cloud mimarisi çiz.
- Public ve private subnet kullanan model API tasarımı yap.
- Least-privilege IAM policy senaryosu yaz.
- Dev GPU'nun gece otomatik kapanması için workflow tasarla.
- Raw/silver/gold object storage path standardı oluştur.
- Batch vs serverless inference maliyetini örnek sayılarla kıyasla.
- Terraform ile bucket + IAM role için pseudo config yaz.
- Managed training job metadata checklist'i oluştur.
- Cloud security review checklist'i bir projeye uygula.

57. Mini portföy projesi

Proje: Cloud-Native Churn Scoring Platform

Bileşen	İçerik
storage/	Raw + feature + model artifact paths
infra/	IaC: network, bucket, IAM, compute
training/	Managed training job
registry/	Model version + metrics
batch/	Daily scoring job
monitoring/	Latency/cost/job success dashboards
security.md	IAM/network/secrets design

cost.md	Monthly estimate + optimization ideas
README.md	Architecture + deployment flow

CV cümlesi
Designed a cloud-native ML scoring architecture using object storage, managed training, model registry, least-privilege IAM, private networking, scheduled batch inference, monitoring and cost controls.

58. Final cheat sheet

Kavram	Hatırlanacak fikir
Region	Geographic cloud location
AZ	Isolated failure domain
Object storage	Cheap scalable files/objects
VM	Full compute control
Container	Portable application package
Serverless	No server management / scale-to-zero
Warehouse	Analytics SQL
Managed Spark	Distributed compute with lower ops
VPC/VNet	Private cloud network
IAM	Who can do what
Secrets	Credentials outside code
KMS	Managed encryption keys
IaC	Infrastructure as code
Spot	Cheap interruptible compute
Registry	Versioned model lifecycle
Batch inference	Periodic bulk scoring
Online inference	Request-time prediction
RPO	Acceptable data loss
RTO	Acceptable recovery time
FinOps	Cost as engineering metric

Bu modülden sonra
37. Git & GitHub bölümünde cloud ve ML projelerinin kod, branch, pull request, issue ve repository yapısını profesyonel biçimde yönetmeye geçeceksin.