43. MONITORING

Service Health • Data Quality • Drift • Model Performance • Alerts • Retraining

Production ML monitoring katmanları



Monitoring = service + data + model + business sinyallerini birlikte okumak

Bu modülün amacı
Production ML sisteminde sadece API ayakta mı sorusunu değil, veri doğru mu, dağılım değişti mi, model hâlâ iyi mi, iş KPI etkileniyor mu ve ne zaman müdahale edilmeli sorularını sistematik biçimde yanıtlamak.

Kazanım	Modül sonunda
Service monitoring	Latency, throughput, error rate, saturation ve availability metriklerini kurabilirsin.
Data monitoring	Schema, freshness, null, volume ve distribution kontrolleri tasarlayabilirsin.
Drift	Data drift, prediction drift ve concept drift farklarını ayırabilirsin.
Model quality	Delayed labels ile performans ve calibration izleyebilirsin.
Alerting	Threshold, anomaly, severity, runbook ve escalation tasarlayabilirsin.
Retraining	Drift/performance/business sinyallerinden retraining policy üretebilirsin.

1. Monitoring nedir?

Monitoring, production sisteminin beklenen şekilde çalışıp çalışmadığını sürekli ölçme ve sapmalara aksiyon verme sürecidir.

2. ML monitoring neden farklı?

Klasik yazılımda doğru cevap çoğu zaman deterministic iken ML sisteminde servis sağlıklı olsa bile tahmin kalitesi sessizce bozulabilir.

3. Monitoring katmanları

Service, data, prediction/model ve business katmanları birlikte izlenmelidir.

Katman	Ana soru
Service	Sistem ayakta ve hızlı mı?
Data	Input doğru ve güncel mi?
Prediction	Output dağılımı normal mi?
Model	Gerçek performans korunuyor mu?
Business	Ürün KPI hedefi korunuyor mu?

Altın kural
Tek bir dashboard veya tek bir metrik production ML sağlığını anlatmaz.

4. Golden signals

Signal	ML service örneği
Latency	p50/p95/p99 inference süresi
Traffic	RPS/QPS
Errors	5xx, timeout, validation fail
Saturation	CPU/GPU/memory/queue

SRE bağlantısı
Golden signals klasik servis sağlığının temelidir; ML-specific monitoring bunun üzerine eklenir.

5. Latency

```
latency_ms = response_time - request_start

track:
  p50
  p95
  p99
```

Ortalama yeterli değil
Az sayıdaki çok yavaş request kullanıcı deneyimini bozabilir; tail latency önemlidir.

6. Throughput

Bir sistemin birim zamanda işlediği request, event veya prediction sayısıdır.

- RPS / QPS
- Batch rows/minute
- Tokens/second

Capacity
Throughput, autoscaling ve capacity planning için doğrudan kullanılır.

7. Error rate

Hata tipi	Örnek
Client	4xx validation/auth
Server	5xx exception
Dependency	DB/vector store timeout
Model	NaN output / inference exception

Sınıflandır
4xx artışı client contract problemi; 5xx artışı server incident olabilir. Aynı alarm değildir.

8. Availability

Servisin hedef dönemde başarılı request sunabildiği oran.

```
availability = successful_requests / total_requests
```

SLO
Örneğin aylık %99.9 availability hedefi error budget ile yönetilebilir.

9. Saturation

- CPU
- GPU utilization / memory
- RAM
- Queue depth
- Connection pool

Sinyal
Latency yükselmeden önce saturation artabilir; leading indicator olabilir.

10. Health checks

Check	Anlam
Liveness	Process çalışıyor mu?
Readiness	Traffic almaya hazır mı?
Dependency health	Kritik servis erişilebilir mi?

Doğru readiness
Model yüklenmemişse veya zorunlu feature store erişilemiyorsa ready dönme.

11. Logging

```
logger.info(
    "prediction_completed",
    extra={
        "request_id": request_id,
        "model_version": model_version,
        "latency_ms": latency_ms
    }
)
```

PII uyarısı
Raw kişisel veya hassas inputları loglama; yalnız gerekli teknik metadata tutulmalı.

12. Metrics vs logs vs traces

Sinyal	Soru
Metrics	Ne kadar?
Logs	Ne oldu?
Traces	Nerede gecikti/bozuldu?

13. Distributed tracing

```
request_id
  -> gateway
  -> feature service
  -> model service
  -> downstream action
```

RAG örneği
Retriever, reranker ve LLM sürelerini ayrı span olarak izlemek end-to-end latency kök nedenini gösterir.

14. Data quality monitoring

Boyut	Örnek
Schema	Kolon/type değişti mi?
Completeness	Null rate arttı mı?
Freshness	Data gecikti mi?
Volume	Satır sayısı düştü mü?
Validity	Range/category doğru mu?
Uniqueness	ID duplicate mi?

Sessiz hata
Pipeline success olabilir ama 0 satır veya %40 null üretmiş olabilir.

15. Schema monitoring

```
expected = {
  "age": "float",
  "income": "float",
  "segment": "string"
}
```

Contract
Feature type değişikliği modelin crash etmesine veya daha tehlikelisi sessizce yanlış davranmasına yol açabilir.

16. Freshness

Bir dataset veya feature setinin en yeni event ile arasındaki gecikme.

```
freshness_lag = now - max(event_time)
```

Online feature
Fraud modelinde 10 dakikalık stale feature kabul edilemezken churn batch modelinde günlük freshness yeterli olabilir.

17. Volume monitoring

Row/event/request sayısındaki beklenmeyen değişiklikleri izleme.

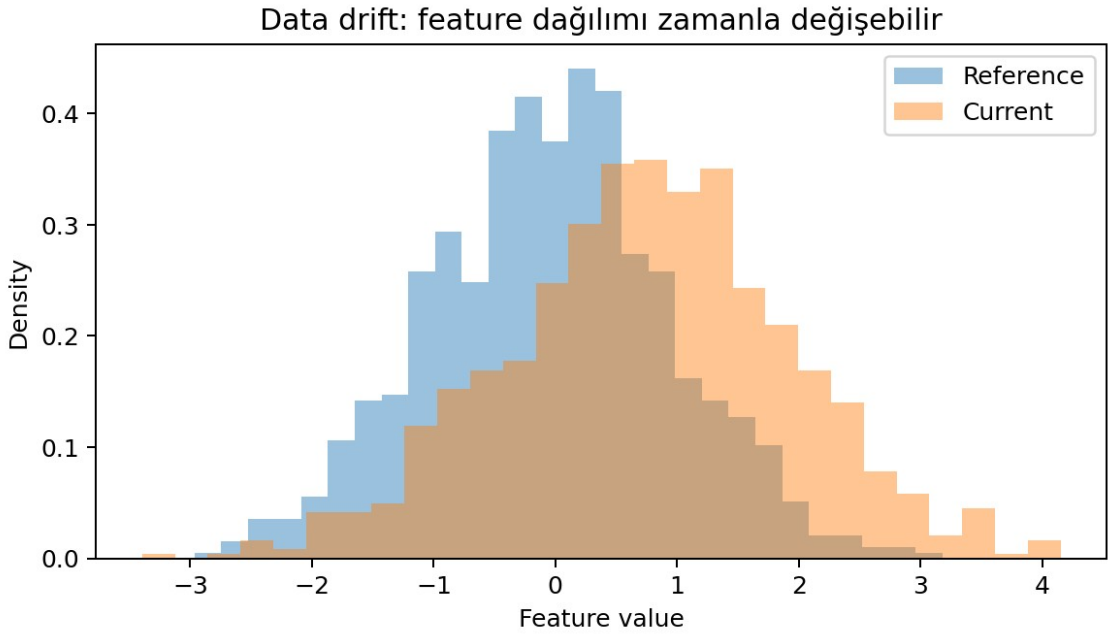
Örnek
Normalde 5M satır gelen daily partition 80k satır geldiyse pipeline teknik olarak başarılı olsa bile alarm gerekir.

18. Null / missingness monitoring

Feature	Reference null	Current null
income	1.2%	1.4%
device_type	0.4%	18.7%
tenure	0.0%	0.0%

Model etkisi
Default fill nedeniyle servis crash etmeyebilir fakat predictive signal kaybolabilir.

19. Data drift nedir?



Production feature dağılımı P(X), training/reference dönemine göre değişir.

Önemli
Drift model bozuldu demek değildir; performans riski sinyalidir.

20. Drift reference window

Reference	Ne zaman?
Training data	Baseline davranış
Recent stable window	Seasonal sistemler
Same season last year	Seasonality güçlü ise

Yanlış referans
Black Friday haftasını normal haftayla kıyaslamak sahte alarm üretebilir.

21. PSI

```
PSI = sum((current_i - reference_i)
      * ln(current_i / reference_i))
```

Sezgi
Feature bin dağılımlarındaki farkı tek sayıya özetler; threshold evrensel gerçek değil, use case ve sample size ile yorumlanmalıdır.

22. KS testi

İki continuous distribution arasındaki maksimum CDF farkını ölçer.

p-value tuzağı
Çok büyük sample size küçük pratik farkları bile anlamlı gösterebilir. Effect size/visualization ile birlikte bak.

23. Jensen-Shannon divergence

İki probability distribution arasındaki simetrik ve bounded divergence ölçüsüdür.

Categorical ve histogram
Probability bins üzerinde kullanışlı olabilir.

24. Categorical drift

Kategori	Ref	Current
mobile	55%	74%
desktop	40%	22%
tablet	5%	4%

New category
Training'de olmayan yeni kategori oranı ayrıca izlenmelidir.

25. Multivariate drift

Tek feature ayrı ayrı stabil görünürken feature ilişkileri değişebilir.

- Classifier-based drift detection
- Embedding distribution
- Correlation/covariance change

Maliyet
Multivariate yöntemler güçlü ama yorumlanması ve operasyonu daha zordur.

26. Prediction drift

Model output dağılımındaki değişim.

- Positive rate
- Probability histogram
- Mean/quantiles

Hızlı sinyal
Label henüz gelmeden anormal score dağılımı model/data pipeline sorunu gösterebilir.

27. Concept drift

P(Y|X) ilişkisinin değişmesidir. Aynı feature pattern artık farklı outcome üretir.

Örnek
Ekonomik kriz sonrası geçmiş gelir/ödeme davranışının default riskiyle ilişkisi değişebilir.

28. Data drift vs concept drift

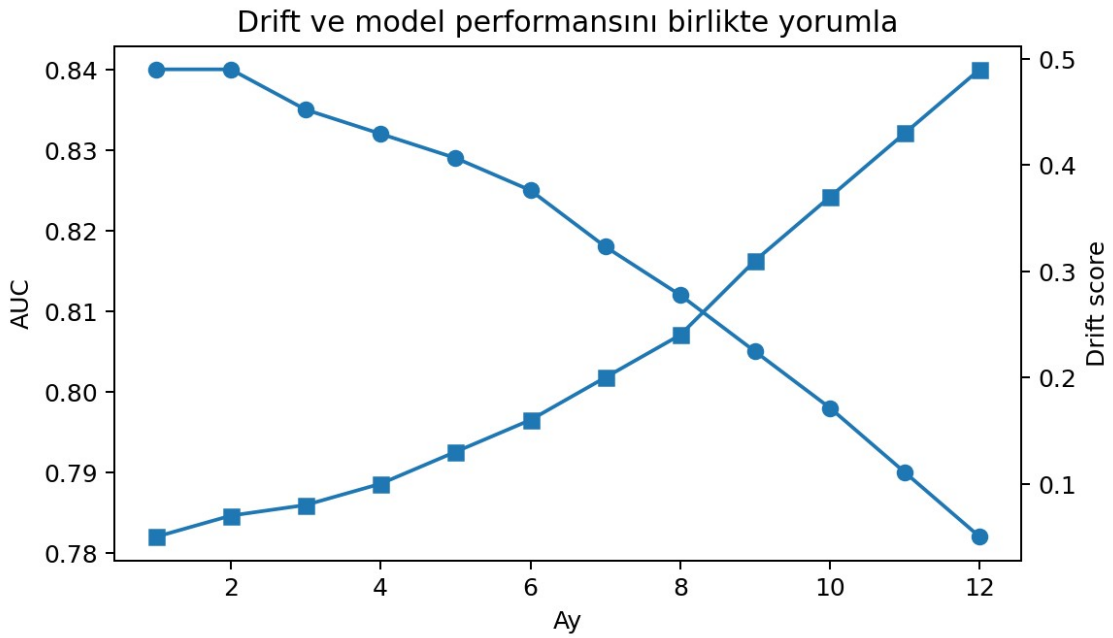
Drift	Ne değişir?	Label gerekir mi?
Data drift	P(X)	Hayır
Prediction drift	P(ŷ)	Hayır
Concept drift	P(Y|X)	Genellikle evet

29. Delayed labels

Churn, fraud veya credit default labelı günler/haftalar sonra netleşebilir.

Sonuç
Model performance monitoring doğal olarak gecikmeli olabilir; proxy/leading signals gerekir.

30. Model performance monitoring



- AUC / PR-AUC
- Precision / Recall / F1
- MAE / RMSE
- Calibration
- Cost-weighted business metric

Segment
Global metric iyi olsa da kritik müşteri segmentinde bozulma olabilir.

31. Calibration monitoring

Tahmin probabilityleri gerçek outcome frekanslarıyla uyumlu mu?

predicted ~0.8 olan grupta
actual positive rate ≈ 0.8 olmalı

Risk sistemleri
Probability karar maliyetine dönüştürülüyorsa calibration kritik olabilir.

32. Threshold monitoring

Decision threshold sabit olsa bile score distribution değişince positive rate ve operasyon yükü değişebilir.

Fraud
Recall artarken manual review queue patlayabilir. Threshold business capacity ile birlikte izlenir.

33. Segment performance

Segment	Metric örneği
New users	Recall
Region	Calibration
Device	AUC
Premium users	False positive rate

Fairness bağlantısı
Segment monitoring performans heterojenliğini gösterir; fairness değerlendirmesi daha geniş normatif bir çerçevedir.

34. Business KPI monitoring

- Revenue
- Conversion
- Retention
- Fraud loss
- Manual review workload

Offline metric ≠ value
Model metrikleri sağlıklı olsa bile business KPI düşebilir.

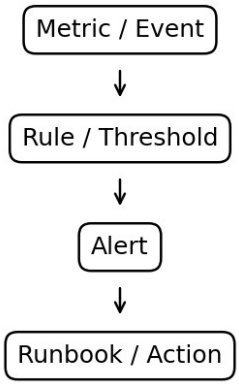
35. Model health dashboard

Panel	Örnek
Service	p95, RPS, 5xx
Data	freshness, null, volume
Drift	top drifting features
Prediction	score histogram
Performance	AUC/recall/calibration
Business	revenue/cost

Version annotation
Dashboard üzerinde deployment/model version değişim zamanlarını işaretle.

36. Alerting

İyi alert, aksiyona bağlanan alerttir



Alert = action
Bir alarm geldiğinde kimin ne yapacağı belli değilse yalnız gürültü üretir.

37. Static threshold

```
if p95_latency_ms > 150:
    alert("latency_slo_breach")
```

İyi taraf
Basit ve anlaşılır. Kötü taraf: seasonality ve baseline değişimini yakalayamayabilir.

38. Dynamic threshold

Rolling baseline, z-score, quantile veya anomaly detection ile beklenen davranışa göre threshold üretme.

Risk
Aşırı akıllı alert sistemi açıklanamazsa operasyon ekibi güvenmeyebilir.

39. Severity

Seviye	Örnek
Info	Minor drift
Warning	Freshness yaklaşan SLA
Critical	Model endpoint down / severe output anomaly

Escalation
Her sinyal pager gerektirmez. Kritik alarm ile dashboard bilgi sinyalini ayır.

40. Alert fatigue

- Çok hassas threshold
- Duplicate alerts
- Aksiyon gerektirmeyen alarm
- Kapanmayan chronic issue

Hedef
High signal-to-noise ratio.

41. Runbook

Alarm	İlk aksiyon
Freshness breach	Upstream job / latest partition kontrol
Score shift	Data schema + model version kontrol
Latency spike	Saturation + downstream traces
Recall drop	Label/data drift + segment analysis

Runbook
Alert mesajı doğrudan ilgili runbook linkini/ID sini taşımalıdır.

42. Root-cause analysis

```
symptom
  -> service?
  -> dependency?
  -> data?
  -> feature logic?
  -> model version?
  -> business environment?
```

Sıra
Önce en basit ve en hızlı doğrulanabilir failure mode'lardan başla.

43. Deployment annotation

Metric time-series üzerinde deployment, data pipeline release, config ve threshold değişimlerini işaretle.

Kök neden
AUC düşüşü model release ile aynı anda başladıysa investigation daralır.

44. Model version telemetry

```
prediction_event = {
  "model_version": "v17",
  "feature_version": "fv8",
  "request_id": "..."
}
```

Rollback
Hangi prediction hangi version tarafından üretildi bilinmelidir.

45. Data lineage telemetry

Batch score tablosu input data snapshot, code SHA, model version ve run ID içermelidir.

Audit
Bir skor yeniden üretilebilir hale gelir.

46. Monitoring storage

Data	Retention
Infra metrics	Günler-aylar
Prediction aggregates	Aylar
Raw prediction logs	Privacy/volume policy
Labels	Uzun dönem model eval

Her şeyi saklama
Cost ve privacy nedeniyle aggregate/retention politikası gerekir.

47. Privacy-aware monitoring

- PII minimize et
- Hashed/anonymous IDs
- Access control
- Retention policy
- Sensitive feature aggregation

Monitoring exemption değildir
Observability ihtiyacı privacy kurallarını ortadan kaldırmaz.

48. High-cardinality metrics

Her customer_id gibi milyonlarca label değeri metric sistemlerini pahalı ve yavaş hale getirir.

Kural
User ID log olabilir; metric label olarak genellikle olmamalı.

49. Monitoring sampling

Çok yüksek traffic'te raw feature/prediction telemetry örneklenebilir, ancak aggregate counters eksiksiz tutulabilir.

Bias
Sampling özellikle rare-event/fraud segmentlerini kaçırmamalı.

50. Batch monitoring

Sinyal	Örnek
Completion	04:00 öncesi bitti mi?
Rows	Expected count
Freshness	Correct snapshot
Scores	Distribution
Publish	Downstream table ready

Batch success
Exit code 0 tek başına yeterli değildir.

51. Online monitoring

- Latency
- Availability
- RPS
- Feature lookup error
- Prediction distribution
- Business action outcome

Near-real-time
Online servis alarmı dakikalar içinde aksiyon gerektirebilir.

52. Streaming monitoring

Sinyal	Örnek
Consumer lag	Kafka lag
Watermark	Late event horizon

State size	Window state
Throughput	Events/sec
Dropped events	Invalid/late

Model input
Streaming feature pipeline bozulursa model endpoint teknik olarak sağlıklı kalabilir ama yanlış veri alır.

53. RAG monitoring

Katman	Metric
Retriever	Recall@k / hit rate
Reranker	nDCG/MRR
Generator	Answer quality
Serving	TTFT / tokens/sec
Safety	Refusal/violation rate
Cost	Tokens/request

End-to-end
Answer kalitesi düşerse retrieval ve generation ayrı incelenmeli.

54. Recommendation monitoring

- CTR
- Conversion
- Coverage
- Diversity
- Popularity concentration
- Latency

Feedback loop
Sistemin önerdiği item daha çok exposure aldığı için observed data endogenous olur.

55. Fraud monitoring

Metric	Neden
Recall	Kaç fraud yakalandı?
False positive rate	Customer friction
Review queue	Operational load
Fraud loss	Business cost
Latency	Realtime karar

Delayed labels
Chargeback sonucu haftalar sonra gelebilir.

56. Churn monitoring

- Score distribution
- Top-decile lift
- Calibration
- Retention campaign response

Intervention effect
Modelin hedeflediği kullanıcıya kampanya uygulanması label distribution'ını değiştirebilir.

57. Forecast monitoring

Metric	Use
MAE/WAPE	Error
Bias	Over/under forecast
Coverage	Prediction interval
Horizon error	1d vs 30d
Segment	Store/product

Temporal
Forecast performansı horizon ve season'a göre ayrıca izlenmeli.

58. Calibration drift

Model ranking gücü aynı kalırken probability calibration zamanla bozulabilir.

Risk
Threshold ve expected value hesapları calibration'a bağlıysa tekrar calibration gerekebilir.

59. Retraining trigger

Trigger	Artı / risk
Schedule	Basit / gereksiz retrain
Data volume	Yeni bilgiye bağlı
Drift	Hızlı sinyal / false positive
Performance	En doğrudan / label gecikmesi
Business KPI	Değer odaklı / confounding

En iyi policy
Çoğu sistem hibrit trigger kullanır; retrain sonrası yine evaluation gate gerekir.

60. Drift varsa otomatik retrain mi?

Hayır. Önce drift'in kaynağı, model etkisi ve data quality doğrulanmalıdır.

Tehlike
Pipeline bug yüzünden drift varsa retraining bug'lı veriyi modele öğretir.

61. Retrain decision tree

```
drift detected?
  -> data quality ok?
     -> no: fix pipeline
     -> yes: labels available?
        -> performance degraded?
           -> yes: retrain/evaluate
           -> no: watch
```

62. Baseline model monitoring

Production modelin basit baseline'a karşı avantajı zamanla korunuyor mu?

Guardrail
Complex model artık baseline'dan iyi değilse operational maliyetini hak etmiyor olabilir.

63. Champion/challenger

Champion production model; challenger yeni aday model. Aynı monitoring framework altında kıyaslanır.

Shadow
Challenger production data üzerinde kararı etkilemeden izlenebilir.

64. Monitoring testleri

- Metric calculation unit test
- Alert rule test
- Dashboard query test
- Synthetic incident drill

Monitoring de code
Alarm kuralı ve metric pipeline'ı da regress olabilir.

65. Synthetic monitoring

Belirli aralıklarla bilinen test request gönderip end-to-end path'i doğrulama.

Fayda
Gerçek trafik düşse bile servis bozulmasını yakalayabilir.

66. Incident drill

Önceden kontrollü failure simüle ederek alert, runbook, rollback ve ownership akışını test etmek.

Amaç
Gerçek incident'ta ilk kez runbook okumamak.

67. Dashboard tasarım prensipleri

- Önce health özeti.
- Version/deploy annotation ekle.
- Global + segment görünümü.
- Threshold line göster.
- Trend + baseline birlikte.
- Aksiyon gerektirmeyen grafiği azalt.

68. Monitoring anti-patterns

- Sadece CPU ve RAM izlemek.
- Drift gördüğünde otomatik retrain etmek.
- Her feature için aynı threshold kullanmak.
- Seasonality dikkate almamak.
- Model version bilgisini prediction loguna yazmamak.
- Alert oluşturup runbook tanımlamamak.
- Raw PII telemetry saklamak.
- Sadece global metric izlemek.
- Label gecikmesini yok saymak.
- Business KPI ile model metricini ilişkilendirmemek.

69. Monitoring checklist

1. Service SLO tanımlı.
2. Data freshness metriği var.
3. Schema/null/volume checks var.
4. Prediction distribution izleniyor.
5. Drift reference window tanımlı.
6. Label geldiğinde model metric hesaplanıyor.
7. Segment metricleri var.
8. Business KPI bağlantısı var.
9. Alert severity ve owner belli.
10. Runbook ve rollback yolu var.

70. Mülakat soruları

Soru	Kısa cevap
Data drift nedir?	Production P(X) dağılımının reference dağılımından değişmesi.
Concept drift?	P(Y|X) ilişkisinin değişmesi.
Prediction drift?	Model output dağılımının değişmesi.
Drift model bozuldu demek mi?	Hayır; risk sinyali, performans ile doğrulanmalı.
Delayed labels ne yaratır?	Performance monitoring gecikir.
p95 neden önemli?	Tail latency kullanıcı deneyimini gösterir.
Freshness nedir?	En yeni data ile now arasındaki gecikme.
Alert fatigue?	Çok/gereksiz alarm nedeniyle kritik alarmların kaçması.
Runbook?	Alarm sonrası adım adım müdahale rehberi.
PSI ne ölçer?	Binned distribution farkını.
Training-serving skew?	Offline ve online feature/preprocessing farkı.
Calibration monitoring?	Probability ile gerçek frekans uyumu.
Retrain trigger?	Schedule, drift, performance, volume veya business sinyali.
Rollback sinyali?	Error/latency/model/business regression.
Monitoring layers?	Service + data + model + business.

71. Uygulama alıştırmaları

1. Bir churn API için 15 monitoring metriği seç.
2. Feature freshness alarmı tasarla.
3. Reference ve current dağılım için PSI hesapla.
4. Prediction histogram drift dashboardı tasarla.
5. Delayed label senaryosunda proxy metric belirle.
6. p95 latency alert + runbook yaz.
7. Segment bazlı recall dashboardı tasarla.
8. Bir deployment annotation standardı oluştur.
9. Retraining decision tree yaz.
10. Synthetic incident drill senaryosu hazırla.

72. Mini portföy projesi

Proje: Production ML Monitoring & Drift Detection System

Dosya / katman	İçerik
monitoring/service_metrics.py	Latency, RPS, error rate
monitoring/data_quality.py	Schema, null, freshness, volume
monitoring/drift.py	PSI/KS/category drift
monitoring/model_metrics.py	AUC/recall/calibration
monitoring/alerts.yaml	Threshold + severity + owner
dashboards/	Service + model + business panels
runbooks/	Incident response procedures
tests/	Metric/alert unit tests
README.md	Architecture + retraining policy

CV cümlesi
Built an end-to-end ML monitoring system covering service health, data quality, feature and prediction drift, delayed-label performance, calibration, alerting, runbooks, deployment annotations and evidence-based retraining triggers.

73. Final cheat sheet

Kavram	Hatırlanacak fikir
Latency	p50/p95/p99
Throughput	RPS/QPS
Availability	Successful service time
Freshness	How current is data?
Completeness	Null/missingness
Data drift	P(X) change
Prediction drift	P(ŷ) change
Concept drift	P(Y|X) change
Calibration	Probability realism
Delayed labels	Performance lag
PSI	Binned drift score
Alert severity	Info/warn/critical
Runbook	Action after alert
Retrain trigger	Evidence-based update
Deployment annotation	Link change to metric
Business KPI	Ultimate value signal

Bu modülden sonra
44. Data Ethics & Governance bölümünde monitoring ile birlikte bias, fairness, privacy, leakage, explainability ve security sorumluluklarını yöneteceksin.