44. DATA ETHICS & GOVERNANCE

Fairness • Privacy • Bias • Governance • Security • Auditability • Responsible AI

Responsible AI yönetişim katmanları



Bu modülün amacı
Veri ve ML sistemlerinin yalnız doğru çalışmasını değil, insanlara ve kuruma karşı sorumlu biçimde tasarlanmasını öğrenmek. Fairness, privacy, explainability, security, leakage, documentation, accountability ve model governance pratik veri bilimi örnekleriyle ele alınacak.

Kazanım	Modül sonunda
Ethics	Teknik doğruluk ile etik uygunluk arasındaki farkı açıklayabilirsin.
Fairness	Grup bazlı performans farklarını ölçüp yorumlayabilirsin.
Privacy	Data minimization, consent, retention ve erişim kontrolünü tasarlayabilirsin.
Governance	Model owner, approval, registry, documentation ve audit trail yapısını kurabilirsin.
Security	Data/model/API tehditlerini temel düzeyde değerlendirebilirsin.
Risk	Use case'i impact ve likelihood açısından sınıflandırıp kontrol önerebilirsin.

1. Data ethics nedir?

Data ethics, verinin ve algoritmaların yalnız yasal olup olmadığını değil; adil, orantılı, açıklanabilir ve insanlara zarar vermeyecek biçimde kullanılıp kullanılmadığını sorgular.

Teknik soru	Etik soru
Model AUC kaç?	Hangi gruplar daha çok hata alıyor?
Daha çok veri ekleyelim mi?	Bu veriyi toplamaya gerçekten ihtiyacımız var mı?
Prediction doğru mu?	Bu prediction hangi kararı etkiliyor?
Deploy edebilir miyiz?	Deploy etmemiz uygun mu?

Ethics ≠ compliance
Bir uygulama hukuken mümkün olsa bile etik açıdan zayıf olabilir. Tersine etik prensipler compliance tasarımını güçlendirebilir.

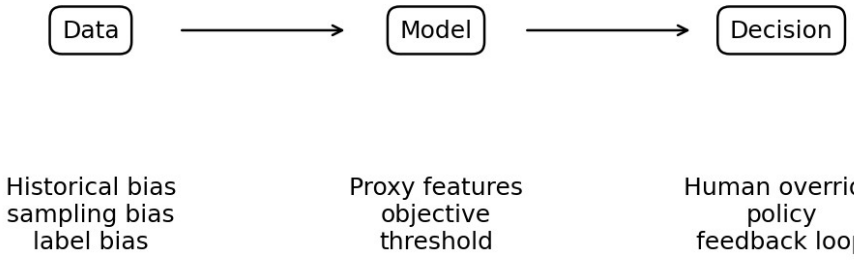
2. Responsible AI ilkeleri

- Fairness
- Privacy
- Transparency
- Accountability
- Safety
- Security
- Human oversight

Trade-off
Bu ilkeler bazen birbiriyle çatışır; örneğin tam explainability ile privacy arasında denge gerekebilir.

3. Bias nerede oluşur?

Bias yalnız modelde oluşmaz; tüm karar zincirinde oluşabilir



Önemli
Bias yalnız model algoritmasının özelliği değildir; data collection, labels, objective, threshold ve kullanım politikasında da oluşabilir.

4. Historical bias

Geçmiş kararlar sistematik eşitsizlik içeriyorsa model geçmişi öğrenerek bunu yeniden üretebilir.

Örnek
Geçmiş kredi onayları belirli grupları sistematik dışladıysa onay geçmişini target olarak kullanmak mevcut politikayı öğrenir.

5. Sampling bias

Training örneklemi hedef population'ı temsil etmiyorsa model bazı gruplarda zayıf performans gösterebilir.

- Region under-representation
- Age imbalance
- Device bias

Çözüm
Population coverage ve subgroup sample size raporlanmalı.

6. Label bias

Target gerçek olguyu değil, proxy veya insan kararını ölçüyorsa etik ve teknik hata oluşabilir.

Örnek
'Riskli müşteri' etiketi yalnız daha önce incelemeye seçilen müşterilerden üretilmişse selection bias vardır.

7. Measurement bias

Aynı kavram farklı gruplarda farklı kaliteyle ölçülüyorsa model input'u eşit değildir.

Örnek
Gelir verisi bir grupta resmi payroll, başka grupta eksik self-report olabilir.

8. Proxy variables

Sensitive attribute kullanılmasa bile postcode, school, language gibi kolonlar onu dolaylı temsil edebilir.

Fairness through unawareness yanılgısı
Sensitive feature'ı silmek tek başına fairness sağlamaz.

9. Protected / sensitive attributes

Mevzuata ve bağlama göre özel koruma gerektiren kişisel nitelikler olabilir.

- Age
- Disability
- Race/ethnicity
- Religion
- Sex/gender
- Health data

Bağlama bağlı
Hangi kategorilerin protected olduğu ülke, sektör ve kullanım amacına göre değişebilir.

10. Fairness ne demek?

Tek bir evrensel fairness metriği yoktur. Hangi hatanın kim için ne maliyet yarattığı use case'e göre değerlendirilir.

Kavram	Sezgi
Demographic parity	Positive decision oranları benzer olsun
Equal opportunity	Gerçek positive'larda TPR benzer olsun
Equalized odds	TPR ve FPR gruplar arasında benzer olsun
Calibration	Aynı score aynı risk anlamına gelsin

Birlikte mümkün olmayabilir
Bazı fairness tanımları veri dağılımına göre aynı anda sağlanamaz; business/ethics seçimi gerekir.

11. Confusion matrix'i grup bazında ölç

Group	TPR	FPR	Precision
A	0.82	0.10	0.76
B	0.64	0.18	0.60

Global metric tuzağı
Toplam F1 yüksek olsa bile belirli grupta recall ciddi düşük olabilir.

12. Equal opportunity

```
TPR_group_A = TP_A / (TP_A + FN_A)
TPR_group_B = TP_B / (TP_B + FN_B)

gap = abs(
  TPR_group_A - TPR_group_B
)
```

Yorum
Gap ne kadar kabul edilebilir sorusunun cevabı teknik değil, risk/policy kararıdır.

13. Demographic parity

```
selection_rate_A = positive_A / total_A
selection_rate_B = positive_B / total_B
```

Dikkat
Base rate'ler gerçekten farklıysa demographic parity her use case için doğru hedef olmayabilir.

14. Calibration fairness

Score 0.8 olan bireylerin outcome rate'i gruplar arasında benzer mi?

Risk scoring
Kredi/fraud/medical risk skorlarında calibration kritik olabilir.

15. Threshold fairness

Tek threshold tüm gruplarda farklı hata dengesi yaratabilir.

Group-specific threshold
Bazı alanlarda etik veya hukuki açıdan sorunlu olabilir; kullanmadan önce policy/legal review gerekir.

16. Fairness mitigation

Aşama	Yaklaşım
Pre-processing	Sampling/reweighting/data improvement
In-processing	Fairness-aware objective/constraints
Post-processing	Threshold/decision adjustment

En iyi çözüm çoğu zaman data/process
Sadece model sonrasında threshold oynamak kök neden olan kötü data'yı düzeltmez.

17. Intersectionality

Tek tek gruplar iyi görünürken kesişimsel gruplarda ciddi performans problemi olabilir.

- age x gender
- region x income
- device x language

Sample size
Intersectional analysis hızla küçük sample sorununa girer; belirsizlik raporlanmalıdır.

18. Fairness ve uncertainty

Küçük subgroup metric farklarını kesin gerçek gibi yorumlama; confidence interval veya bootstrap kullan.

19. Privacy-by-design

Privacy-by-design yaşam döngüsü



Privacy lifecycle = amaç sınırlama + veri minimizasyonu + erişim kontrolü + retention

- Purpose limitation
- Data minimization
- Access control
- Retention
- Deletion
- Audit

Başlangıç sorusu
Bu kolonu gerçekten toplamak zorunda mıyız?

20. Data minimization

Amaç için gerekli olmayan veriyi toplamamak, saklamamak ve modele vermemek.

Kötü	Daha iyi
Tüm customer profile	Sadece gerekli features
Raw text sonsuza kadar	Derived signal + retention
Tüm event history	Amaç için gerekli zaman penceresi

21. Purpose limitation

Bir amaç için toplanan veriyi bağlam dışı başka karar için otomatik kullanmamak.

Örnek
Fraud önleme için toplanan davranış verisini habersiz pazarlama segmentasyonunda kullanmak farklı purpose olabilir.

22. Consent ve lawful basis

Kişisel veri işleme zemini hukuk ve bağlama göre değişir; consent her durumda tek veya gerekli dayanak değildir.

Data scientist görevi
Legal interpretation yapmak değil; kullanım amacını, veri kaynağını ve retention'ı dokümante edip review sürecine taşımak.

23. Pseudonymization vs anonymization

Pseudonymization	Anonymization
Kimlik ayrı anahtarla geri bağlanabilir	Pratikte bireye geri bağlanamaz olmalı
Hâlâ kişisel veri olabilir	Gerçek anonimlik standardı daha yüksek
Tokenized customer_id	Aggregation / irreversible transform

Hash = anonimlik değildir
Sabit identifier hash'i dictionary/linkage saldırılarıyla yeniden ilişkilendirilebilir.

24. Re-identification riski

İsim kaldırılmış veri, yaş + postcode + timestamp gibi quasi-identifier kombinasyonlarıyla bireye bağlanabilir.

Risk review
Public/share edilen dataset'lerde uniqueness ve linkage riski analiz edilmelidir.

25. Retention

Veri	Örnek retention
Raw event logs	90 gün
Aggregated features	1 yıl
Model audit artifacts	Policy'e göre daha uzun

Sonsuza kadar saklama default olmamalı
Retention business/legal gereksinimle tanımlanmalı.

26. Right to delete / deletion propagation

Bir kaydın silinmesi raw data, derived tables, caches ve bazı downstream artifacts'a nasıl yansıyacak?

Pratik zorluk
Modelden tek bireyin etkisini geri çıkarmak her zaman trivial değildir; governance policy önceden belirlenmelidir.

27. Access control

- Least privilege
- Role-based access
- Row/column-level security
- Service accounts
- Audit logs

Need-to-know
Data scientist tüm production PII tablolarına admin erişimi gerektirmez.

28. Encryption

Durum	Koruma
At rest	Disk/object/database encryption
In transit	TLS
Keys	Managed KMS/HSM

Encryption tek başına privacy değildir
Yetkili ama gereksiz erişim hâlâ privacy problemidir.

29. Secrets

API key, DB password ve token'lar notebook/repo/model artifact içinde bulunmamalı.

ML artifact scanning
Pickle/model package içine yanlışlıkla credential gömülmediğini kontrol etmek yararlıdır.

30. Data leakage ve ethics

Leakage yalnız metric'i şişirmez; yanlış güven duygusuyla gerçek kullanıcıları etkileyen kötü kararlara neden olabilir.

- Target leakage
- Future leakage
- Train-test contamination

Governance
Leakage check model approval gate'i olmalıdır.

31. Explainability

Model kararını farklı paydaşlara anlaşılır biçimde açıklama yeteneği.

Paydaş	İhtiyaç
Data scientist	Debug / feature behavior
Reviewer	Risk/limitations
Business	Decision rationale
Affected user	Meaningful explanation

SHAP = governance'ın tamamı değil
Explainability output'larının doğru yorumlanması ve causal claim yapılmaması gerekir.

32. Global vs local explanation

Global	Local
Model genel olarak ne öğreniyor?	Bu prediction neden böyle çıktı?
Feature importance/PDP	SHAP/local explanation

33. Explanation riskleri

- Correlation'ı causality gibi sunmak
- Sensitive proxy'yi gizlemek
- Unstable explanations
- Technical jargon

Human-readable
Açıklama hedef kitleye uygun olmalı; feature attribution grafiği her kullanıcı için anlamlı değildir.

34. Human oversight

High-impact kararların tümü otomatik olmak zorunda değildir.

- Human review
- Appeal/escalation
- Override reason
- Feedback logging

Automation bias
İnsan reviewer model skorunu gereğinden fazla doğru kabul edebilir; interface tasarımı bunu etkiler.

35. Accountability

Soru	Governance cevabı
Model owner kim?	Named accountable owner

Kim approve etti?	Approval log
Kim deploy etti?	CI/CD audit trail
Hangi version?	Registry
Hangi data?	Lineage

Sahipsiz model yok
Production model için teknik ve business owner açık olmalıdır.

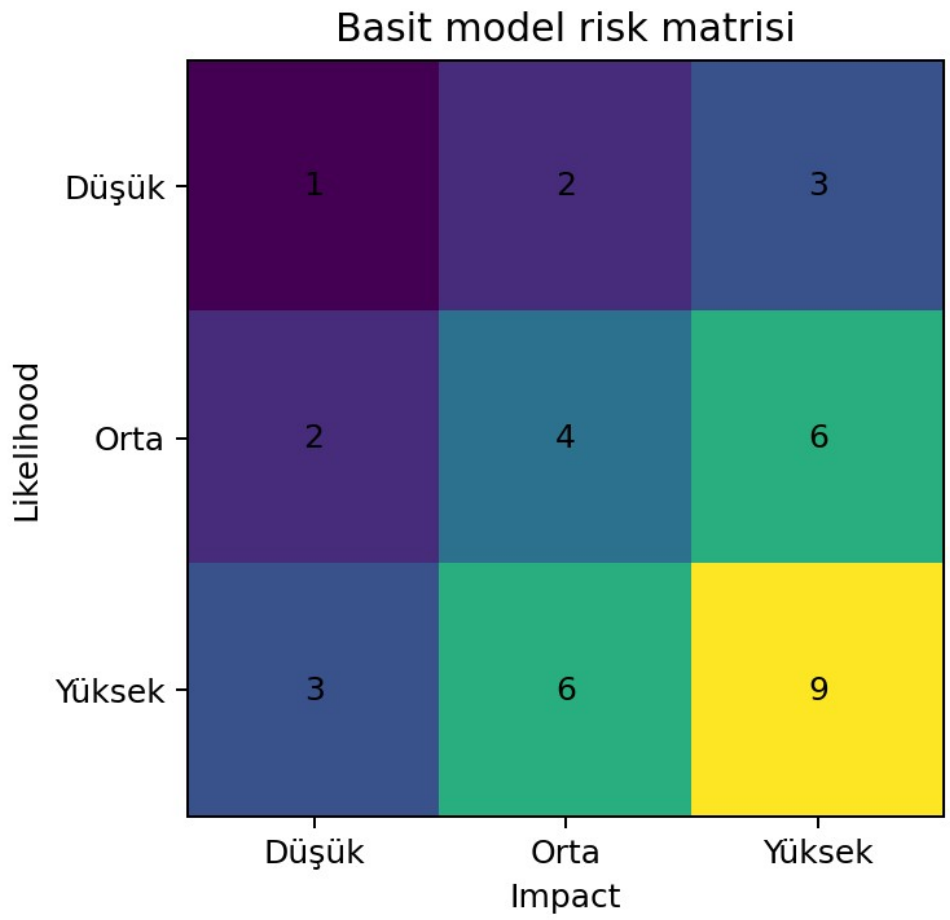
36. Model governance



- Inventory
- Risk tier
- Validation
- Approval
- Monitoring
- Retirement

Model inventory
Kurum production'da hangi modellerin çalıştığını bilmelidir.

37. Model risk tiering



Risk	Örnek
Low	Internal content tagging
Medium	Marketing prioritization
High	Credit/fraud/health/employment decision support

Yüksek risk = daha fazla kontrol
Validation, human oversight, documentation ve monitoring derinliği artırılmalı.

38. Model validation

- Data quality
- Leakage
- Performance
- Calibration
- Robustness
- Fairness
- Security

Independent review
High-risk modellerde geliştirici dışı validation güçlü governance pratiğidir.

39. Documentation

Doküman	İçerik
Model card	Use, metrics, limits, owners
Data sheet	Source, coverage, labels, risks
Risk assessment	Impact/likelihood/controls
Runbook	Incident/rollback
Decision log	Trade-offs/approvals

40. Model card alanları

- Intended use
- Out-of-scope use
- Training data
- Evaluation data
- Metrics by segment
- Limitations
- Ethical considerations
- Owner/version

Out-of-scope
Modelin hangi kullanım için uygun olmadığını yazmak en önemli alanlardan biridir.

41. Dataset documentation

- Source
- Collection process
- Population
- Missingness
- Label process
- Licensing/consent
- Known biases

42. Audit trail

```
decision_id = "D123"
model_version = "credit_v17"
data_version = "snapshot_2026_10_01"
policy_version = "P4"
request_id = "R789"
timestamp = "..."
```

Amaç
Sonradan hangi model/policy/data kombinasyonunun kararı etkilediğini gösterebilmek.

43. Security threat model

Varlık	Tehdit
Training data	Poisoning / tampering
Model artifact	Unauthorized replacement
API	Abuse / extraction
Features	Injection / malformed input
LLM/RAG	Prompt injection / data exfiltration

44. Data poisoning

Training datasına kasıtlı veya yanlış verinin girerek model davranışını bozması.

Kontrol
Source authentication, anomaly checks, lineage ve restricted write access.

45. Model extraction / stealing

Aşırı query ile model davranışını kopyalamaya çalışma.

- Rate limiting
- Authentication
- Output minimization
- Monitoring

46. Adversarial inputs

Modeli hataya sürüklemek için özel hazırlanmış input'lar.

Risk bağlama bağlı
Image, spam/fraud, security sınıflandırıcılarında daha kritik olabilir.

47. LLM / RAG ethics & governance

Risk	Kontrol
Hallucination	Grounding/evaluation
Prompt injection	Input isolation/tool permissions
Sensitive retrieval	ACL-aware retrieval
Data leakage	Redaction/access controls
Bias/toxicity	Safety evaluation
Untraceable answer	Citations/logging

RAG'da erişim kontrolü
Vector search sonuçları kullanıcının yetkisini aşmamalıdır.

48. Copyright / licensing

Training/evaluation datasetleri ve third-party içeriklerin kullanım koşulları kontrol edilmelidir.

Pratik
Dataset provenance ve license metadata'sı data catalog/model documentation'a bağlanabilir.

49. Human feedback

Human labels/feedback süreçlerinde annotator bias, worker welfare ve instruction consistency önemlidir.

- Clear guideline
- Inter-rater agreement
- Escalation
- Sensitive content support

50. Feedback loops

Model kararı gelecekteki training datasını değiştirerek kendi varsayımlarını güçlendirebilir.

Örnek
Sadece modelin seçtiği adayları incelemek, diğer adayların outcome label'larını hiç toplamamak.

51. Selective labels

Outcome yalnız karar verilen örneklerde gözleniyorsa ground truth eksiktir.

Kredi/fraud
Reject edilen veya incelemeye alınmayan örneklerin gerçek sonucu bilinmeyebilir.

52. Business objective riskleri

Optimize edilen	Olası yan etki
CTR	Clickbait
Watch time	Addictive content
Approval rate	Risk increase
Fraud recall	False positives/customer friction

Metric design etik karardır
Model davranışı objective function'ın optimize ettiği şeyi takip eder.

53. KPI guardrails

- Primary metric
- Fairness metric
- Safety metric
- User harm metric
- Cost/latency

Örnek
Conversion artarken complaint rate veya unfair rejection rate bozuluyorsa release başarısız olabilir.

54. Privacy-preserving approaches

Yaklaşım	Sezgi
Aggregation	Individual yerine grup
Pseudonymization	Direct identifier ayır
Differential privacy	Aggregate sonuçlara kontrollü noise
Federated learning	Raw data merkezi taşınmadan eğitim

Trade-off
Privacy teknikleri utility, complexity ve maliyet etkisi yaratabilir.

55. Differential privacy sezgisi

Tek bir bireyin dataset'e dahil olup olmamasının aggregate output üzerinde sınırlı etkisi olmasını hedefler.

Parametreler
Epsilon/delta gibi kavramlar privacy budget'ı temsil eder; doğru kullanım uzmanlık gerektirir.

56. Synthetic data

Gerçek verinin istatistiksel özelliklerini taklit eden yapay kayıtlar.

Anonimlik garantisi değil
Synthetic generator training data'yı memorize edebilir; privacy evaluation gerekir.

57. Data governance

- Data owner
- Data steward

- Catalog
- Lineage
- Quality
- Access policy
- Retention

44 + 34 bağlantısı
Data engineering pipeline'ı governance metadata taşımadığında kurumsal güven azalır.

58. Data classification

Sınıf	Örnek
Public	Açık katalog
Internal	Operasyon metrikleri
Confidential	Customer contracts
Restricted	Sensitive PII/health/payment

Kontrol seviyesi
Storage, access, logging ve sharing policy data classification'a göre değişir.

59. Lineage governance

Feature ve modelin hangi data kaynaklarından türediği izlenebilir olmalı.

Incident
Yanlış upstream tablo keşfedilirse hangi modellerin etkilendiğini lineage ile bulursun.

60. Data quality ownership

Quality check fail olduğunda kimin aksiyon alacağı belli olmalı.

Issue	Owner örneği
Source schema	Producer team
Transformation bug	Data team
Feature semantics	ML team
Business definition	Business owner

61. Change management

- Schema change review
- Feature change
- Model change
- Policy change

Breaking change
Riskli model için sadece code PR değil, governance approval da gerekebilir.

62. Monitoring for governance

- Fairness metrics over time
- Sensitive feature access
- Override rate
- Appeal rate
- Data retention violations
- Model drift

Governance canlı süreç
Approval'dan sonra bitmez; production davranışı da izlenir.

63. Fairness drift

Modelin grup bazlı performans farkı zaman içinde değişebilir.

Neden
Population mix, behavior, policy ve upstream feature değişiklikleri.

64. Complaint / appeal data

Kullanıcı şikayetleri ve itirazlar model risk sinyali olarak değerlendirilmelidir.

Qualitative data
Her governance metriği sayısal model metric değildir.

65. Incident response

Adım	Ethics/Governance sorusu
Detect	Kim etkileniyor?
Contain	Modeli durdurmalı mıyız?
Investigate	Data/model/policy kök neden?
Remediate	Etkilenen kararlar düzeltilecek mi?
Prevent	Yeni gate/control ne?

66. Retirement / decommission

Model kullanılmıyorsa endpoint kapatmak kadar data/artifact/access temizliği de gerekir.

- Remove traffic

- Archive audit artifacts
- Revoke credentials
- Delete temporary data
- Update inventory

Zombie model
Owner'sız ama hâlâ çalışan model governance riskidir.

67. High-impact use case review

1. Karar insan hayatını/erişimini etkiliyor mu?

2. Protected groups etkileniyor mu?

3. Hataların maliyeti kimde?

4. Human appeal var mı?

5. Sensitive data kullanılıyor mu?

6. Explainability ihtiyacı yüksek mi?

7. Monitoring ve rollback mümkün mü?

68. Risk treatment seçenekleri

Seçenek	Anlam
Avoid	Use case/modeli kullanma
Reduce	Kontroller ekle
Transfer	Insurance/contract/provider
Accept	Dokümante edilmiş residual risk

Risk acceptance
Kim tarafından ve hangi gerekçeyle kabul edildiği kaydedilmeli.

69. Gerçek vaka: kredi riski

Risk	Kontrol
Historical discrimination	Fairness evaluation
Proxy variables	Feature review
Reject bias	Selective-label analysis
Opaque decision	Reason codes/human review
Drift	Segment monitoring

70. Gerçek vaka: işe alım modeli

- Historical labels current policy'yi encode ediyor mu?
- CV text sensitive proxies içeriyor mu?
- Subgroup recall farklı mı?
- Human override/appeal var mı?

Yüksek etki
Employment decision support genellikle yüksek governance gerektirir.

71. Gerçek vaka: fraud

Trade-off	Risk
Recall ↑	False positive ↑
Strict threshold	Customer friction
Manual review	Operational cost

Fairness
False-positive rate belirli gruplarda sistematik yüksek mi kontrol edilmelidir.

72. Gerçek vaka: recommendation

- Popularity bias
- Filter bubbles
- Sensitive content exposure
- Creator fairness
- Feedback loops

Çok amaçlı ranking
CTR yanında diversity, satisfaction ve safety guardrail'leri izlenebilir.

73. Gerçek vaka: sağlık modeli

Training population ile deployment population farklıysa klinik risk oluşabilir.

Sınır
Bu tür modellerde uzman clinical validation, regulatory review ve insan denetimi teknik model eval'den daha ileri gereksinimler doğurabilir.

74. Governance checklist

1. Use case amacı açık.

2. Data provenance kayıtlı.

3. Sensitive attributes/proxies incelendi.

4. Fairness metrics segment bazında raporlandı.

5. Privacy minimization uygulandı.

6. Explainability ihtiyacı tanımlandı.

7. Human oversight/appeal tasarlandı.

8. Model card ve data sheet hazır.

9. Owner/approver belli.

10. Monitoring ve retirement planı var.

75. Sık yapılan hatalar

- Fairness'i sensitive column silmek sanmak.
- Tek global metric raporlamak.
- Etik review'ü deployment sonunda yapmak.
- Consent var diye her kullanımı uygun kabul etmek.
- Hash edilmiş veriyi anonim sanmak.
- Model explanation'ını causal explanation gibi sunmak.
- Human reviewer var diye automation bias riskini yok saymak.
- Model inventory tutmamak.
- Access log ve retention policy tanımlamamak.
- Monitoring'i yalnız accuracy ile sınırlamak.

76. Mülakat soruları

Soru	Kısa cevap
Bias nerede oluşur?	Data collection, labels, model, threshold ve policy zincirinin her yerinde.
Fairness through unawareness?	Sensitive feature silmek fairness garanti etmez; proxy olabilir.
Equal opportunity?	True positive rate'lerin gruplar arasında benzer olması.
Calibration?	Aynı score'un gruplar arasında benzer outcome riski temsil etmesi.
Data minimization?	Amaç için gerekli en az veriyi toplamak.
Pseudonymization vs anonymization?	Geri bağlanabilir tokenization vs pratikte geri bağlanamama.
Model card?	Use, metrics, limits, risk ve ownership dokümanı.
Lineage?	Data-code-model-decision bağlantı zinciri.
Human oversight?	Yüksek etkili kararlarda insan review/appeal/override mekanizması.
Risk tiering?	Use case'i impact/likelihood'a göre governance seviyesine ayırmak.
Selective labels?	Outcome yalnız seçilen örneklerde gözlenir.
Feedback loop?	Model kararı gelecekteki training datasını etkiler.
Privacy by design?	Minimization, purpose, access, retention ilkelerini baştan tasarlamak.
Audit trail?	Kararda kullanılan model/data/policy/version kayıtları.
Model retirement?	Traffic kapatma + access/artifact/inventory cleanup.

77. Uygulama alıştırmaları

1. Bir churn modeli için fairness risk haritası çıkar.

2. İki subgroup için TPR/FPR gap hesapla.

3. Sensitive proxy olabilecek 10 feature örneği yaz.

4. Bir dataset için data minimization review yap.

5. Model card şablonu doldur.

6. Bir use case'i low/medium/high risk tier olarak sınıflandır.

7. Audit trail için gerekli metadata'yı belirle.

8. Recommendation sistemi için guardrail KPI'ları tanımla.

9. RAG uygulamasında privacy/access threat model çıkar.

10. Model retirement checklist'i yaz.

78. Mini portföy projesi

Proje: Responsible AI Review for a Credit-Risk Model

Dosya / çıktı	İçerik
risk_assessment.md	Impact + likelihood + controls
data_sheet.md	Dataset provenance / coverage / bias
fairness.ipynb	Group metrics + uncertainty
model_card.md	Use / metrics / limitations
privacy_review.md	Minimization / retention / access
threat_model.md	Data/model/API security risks
governance_flow.md	Approval + owner + monitoring
README.md	Executive responsible-AI summary

CV cümlesi
Performed a responsible-AI governance review for a credit-risk model covering subgroup fairness, privacy minimization, model/data documentation, risk tiering, security threat modeling, approval gates and ongoing governance monitoring.

79. Final cheat sheet

Kavram	Hatırlanacak fikir
Ethics	Should we, not only can we?
Fairness	Hataların gruplara dağılımı
Proxy	Sensitive attribute'u dolaylı temsil
Equal opportunity	TPR parity

Calibration	Same score, similar risk
Minimization	Only necessary data
Purpose limitation	Use data for defined purpose
Pseudonymization	Identity separated but linkable
Anonymization	Practically non-identifiable
Retention	Keep only as long as needed
Explainability	Meaningful decision rationale
Human oversight	Review / appeal / override
Model card	Use + limits + metrics
Data sheet	Dataset provenance + risks
Lineage	Source-to-decision trace
Risk tier	Governance depth by impact
Audit trail	Who/what/when/version
Security	Protect data/model/service
Guardrail	Metric preventing harmful optimization
Retirement	Controlled decommission

Bu modülden sonra

45. Data Storytelling bölümünde teknik analiz ve model sonuçlarını yönetim, ürün ve diğer paydaşlara açık, karar odaklı ve sorumlu biçimde anlatmaya geçeceksin.